社団法人　電子情報通信学会
THE INSTITUTE OF ELECTRONICS,
INFORMATION AND COMMUNICATION ENGINEERS

信学技報
TECHNICAL REPORT OF IEICE.
NLC94-4 (1994-05)

ヒューリスティクスを用いた照応解析手法

佐藤 嘉高† 荒木 健治‡ 宮永 喜一† 栃内 香次†

†北海道大学 工学部 ‡北海学園大学 工学部

札幌市北区北１３条西８丁目 札幌市中央区南２６条西１１丁目

あらまし　文章や対話の構造を計算機上にモデル化することは，自然言語理解における重要な課題の一つである．この計算機モデルを無矛盾に構築するためには，照応語の指示先を正しく同定することが必要である．一般にはその処理のためにあらかじめシステムに背景知識を与えておくが，その知識の形式や分量についての絶対的な基準を設定することは困難である．我々はこれに対してルールや知識を必要に応じて蓄積し，段階的にシステムを構築する，というアプローチをとる．そのために本研究では，まず英文の代名詞を対象にして単純なアルゴリズムに基づく照応解析の実験を行なう．次に，その結果を調査することにより照応処理のためにはどのようなルールが必要かを考察する．

和文キーワード　照応，ヒューリスティクス，文章構造解析，語彙的結束性

An Anaphoric Resolution Method using Heuristic Rules

Yoshitaka SATO† Kenji ARAKI‡ Yoshikazu MIYANAGA† Koji TOCHINAI†

†Fac. of Eng, Hokkaido Univ. ‡Fac. of Eng, Hokkai-Gakuen Univ.

N13-W8, Kita-ku, Sapporo, 060, JAPAN

S26-W11, Chuo-ku, Sapporo, 064, JAPAN

Abstract　It is important for natural language understanding to construct a computational models for text structure. On constructing these models with no contradictions, the references of anaphoric words must be decided correctly. In general study, background knowledges are given to system for the decision. But it may be difficult to know in advance that what form and how many rules should satisfy for the resolutions. In this paper, we describe to our experiment, which based on some simple algorithms, for anaphora resolution on pronouns in English texts. And then we obserb how rules will be need for anaphora resolution by checking its results.

英文 key words　anaphora, heuristics, text structure, lexical cohesion

1 はじめに

文章や対話の構造を解析し計算機上にモデル化することは，自然言語理解における重要な課題の一つである．その解析やモデル化の際に問題となる要因の一つに自然言語の持つ曖昧性があり，文章に内在する曖昧性はその表層において種々の言語現象となって現れる．我々はその言語現象の一つである照応を解析することの重要性に着目し，特に英語の文章において代名詞の指示対象を正しく同定するためにはどのようなルールに基づいて処理を行なえばよいのかについての研究を行なっている．本稿では，まず2章で本研究の概要について述べ，3章でシステム化に先立ち行なったヒューリスティクス抽出の調査結果とルールの分類について述べ，次に4章でそのルールを取り入れて再び行なった調査とその結果について述べる．

2 本研究の目的と概要

文章の主題は表層ではキーワードを中心として表現されるが，文章を書く立場から見れば同じ単語を繰り返すことを避け，代名詞を使用して言い換えを行なう．したがって代名詞が文中のどの単語を指示するのかを正しく判断することは，文章の主題を把握する上で極めて重要な課題である．照応の解析のためにはあらかじめ背景知識をシステムに与えておくというアプローチが一般的である [1]．しかし，そのために知識をどのような形式で，またどの程度の分量を用意すれば必要かつ十分なのかを決定的に判断することは難しい．我々はこれに対して文章の実例を調査することによってルールや知識を蓄積し，段階的にシステムを構築する，という方法が妥当であると考える．そのために本研究では，まず，単純なアルゴリズムによる照応解析の調査実験を行なう．次に，その結果に基づき照応処理のためにはどのようなルールが必要かを考察する．さらに，そのルールを取り入れることによって照応解析の結果がどの程度改善されるかを再度調査する．

3 照応関係解析のための調査

我々は既に照応の対象を正しく判断するために，どのようなルールや処理が必要となるかを考察するため，簡単なアルゴリズムによるプログラムを用いた調査を行なった [2]．その結果を以下に示す．

3.1 調査の仮定

- 照応元の単語は，指示代名詞と人称代名詞のみとする．代名詞の他，定冠詞なども照応元の単語と見なすことができる [3, 4] が，本研究ではさしあたって代名詞のみを対象とする．ここで，代名詞を文献 [3] を参考にし，以下の表に示す6種に分類する．

細分類	実例
人称代名詞	I, your, him
指示代名詞	this, that, these, those のみ
関係代名詞	who, whose, whom, which, that
疑問代名詞	who, whose, whom, which, what
不定代名詞	all, every, any, other
再帰代名詞	himself, herself, itself

そのうち出現数が多く，かつ照応先の同定が比較的容易に行なえると考えられる指示代名詞と人称代名詞に対象を限定する．

- 照応先の単語は，照応元の単語を含む文の直前の文の主題語とする．この主題語をどのように決定するかについては後述する．照応現象は話題の中心になる単語に多く出現すると考えられ，また文章を構成するそれぞれの文が語彙的結束性などにより何らかの関係を持っていることを考慮すると，文の主題を表現する単語が空間位置上でも近くにあり，かつ重要な単語が照応先になる頻度が高いと仮定する．

- その文中で最初に出現する名詞を文の主題語とする．構文上の主語，すなわち ＳＶ，ＳＶＯ などの文形におけるＳが，必ずその文の意味的な主題であるとは断言できないが，ここでは文の主語をその文の主題を表現する語であると仮定する．また，英語においては日本語のように主語が省略されることが少なく，さらに単文の構造の基本は Ｓ→ＮＰ，ＶＰ であることを考慮し，文中で最初の名詞を文の主題語と仮定する．

これらの仮定の内容自体は言語学的な根拠によるものであるが，調査に先立ちどのような仮定を立てるかは筆者らの知見に基づいている．したがって，調査を繰り返していく過程においてこれらの仮定を見直す必要性が生じる可能性があると考えられる．以上の仮定に基づくヒューリスティクス抽出のためのアルゴリズムを以下に示す．

1. 文を1文読み込み，その主題語を決定，表示する．

2. 文中に指示代名詞または人称代名詞があった場合，その照応先，すなわち前文の主題語を表示する．

その結果に対して人手により代名詞の照応先が正しいかどうかを判断し，誤っているものに対してその原因を考察した．調査の対象とした文は英文和訳の問題集 [5] である．この調査対象文の分量を表1に示す．この分量をどの程度にするかの判断は，新しく抽出したルールの量の上昇度を参考にする．このグラフを図1に示す．この調査の結果を表2に，また調査のために作成したプログラムの出力例を付録に示す．

表 1: 調査対象文の分量

パラグラフ数	文数	単語数
50	496	8030

表 2: 1回目の調査結果

照応回数	正照応数	正照応率 (%)
815	186	22.8

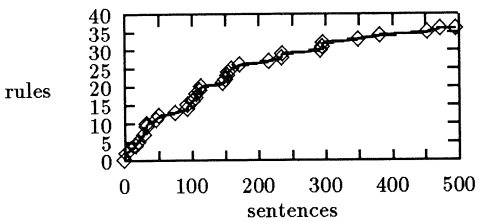


図1 :抽出したルールの上昇度

3.2 調査結果に関する考察

調査を行なった結果，照応解析に必要なルールには，すべての照応語に共通なものと各照応語固有のものの2つに分類できることが判明した．また，調査はその考察結果をふまえた上で繰り返し行なう必要があることを確認した．以下では，第一回目の調査結果について考察する．

3.2.1 すべての照応語に共通なもの

1. 被照応語の検索範囲

   調査では，文を1つずつ読み込んだ時点で，文単位で処理プログラムを起動していた．このプログラムが照応の対象として扱えるのは前文以前の文中の単語のみである．したがって，例えば

   When *Bill* saw *Linda*, *he* greeted *her* with a smile.[3]

   のように，照応元の単語と同じ文中に照応先の対象がある場合に，照応先を正しくとらえることができない．したがって，これを単語を1つずつ読み込みそれが照応語であった場合に，その単語より前に出現した全ての名詞を照応先の候補として扱えるように変更する．

2. 被照応の範囲について

   ある単語が照応する対象として，単語のみしか考慮していなかったが，調査実験の結果を見ると句や文などが照応対象となる文が存在した．以下のものは分析やシステム化がかなり困難なことが予想される．

   - it が会話文 (直接話法) の内容を指す
   - “the two people” や “professional, amateur” を they で受ける
   - 名詞並列句中の名詞句を単数の代名詞で受ける

3. 後方参照

   実験では，照応の対象を前方に検索していた．したがって，例えば

   After *he* left *his* office, *Joe* went to the bookstore.

   のように，代名詞があとに出る語 (句) を指す後方参照 [3] については，照応の対象を発見することが不可能である．

3.2.2 各照応語固有のもの

各照応語それぞれについて考察する必要があると考えられるものについて以下に列挙する．

1. 多品詞語の品詞選択

   ある多品詞語が，照応する品詞としない品詞の両方を持つ場合，字面のみからは照応するかしないかを判断することができない．抽出した中での具体例は以下の二つである．

   - that : 指示代名詞 (照応する) ／関係代名詞 (照応しない)

- one：指示代名詞 (照応する) ／形容詞 (数詞)(照応しない)

これらについては，構文構造を参照することにより解決することが可能であるが，構文木における曖昧性の問題については本研究では対象外とする．

2. 単語に対し細分類を付与する

例えば，名詞の複数形を単数の代名詞で照応すると解釈するなど比較的簡単に改良が可能と考えられるものが多数あった．照応先の候補の幅をできるだけ簡略な手法でかつ少ないデータ量で狭めるために前述の単語の品詞分類をさらに詳細化する．詳細分類としては既存の辞書等で一般的に用いられている分類が望ましく，以下を採用することを考えている．

- 性 (男性／女性／中性)
- 数 (単数／複数)
- 人称 (一人称／二人称／三人称)

3. it に関するもの

it の指示代名詞以外の用法が多かった．以下に示す．

(a) 形式主語：あとに来る名詞，to 不定詞，動名詞，名詞節を代表する

(b) 強調構文： It is ～ that/who ～

4. 代名詞の指示形容詞的用法

指示代名詞が形容詞的に使用される場合，後続の名詞を照応先同定の参考にすることが可能である．例えば
We propose a method(1).
This method(2) is .....
のように同じ単語が繰り返し使用される場合などには，表層の一致すなわち文字列のパターンマッチングで照応先の同定が可能と考えられる．

5. その他

以下のものは解析やシステム化が困難である．

- 擬人法 (ex. dog を he で受ける)
- 会話文中で人称が変化する代名詞の照応

4 ヒューリスティクスに基づく実験

4.1 目的と概要

前述の考察結果に基づき，ヒューリスティクスを用いた調査のための実験を行なった．この調査の目的を以下に示す．

1. 1回目の調査の仮定と，それより得たヒューリスティクスとを比較する．
2. 1回目の調査で得たヒューリスティクスの，代名詞それぞれに対する有効性を調べる．
3. 複数のヒューリスティクスを組み合わせると，それらを個別に用いた場合に対して結果がどのように変化するのかを調べる．

実験はまず問題集 [5] 中の “he” と “she” を対象にして行なった．これらの照応先の単語を，

- (A) 直前の文のなかで最初に出現した名詞
- (B) 前方にさかのぼり最初に出現した名詞
- (C) B＋単語属性チェック (単語の属性が一致するまでBを繰り返す)

のそれぞれについて，人手により正しく照応先が同定されているかの調査を行なった．このうち (A) は1回目の調査の仮定であり，2回目の調査と比較するためのものである．例えば，

文n: 名詞1 … 名詞2 (単数) … .

文n+1: 名詞3 (複数) … 代名詞 (単数) … .

という場合，代名詞の照応先は，
(A)→名詞1
(B)→名詞3
(C)→名詞2
となる．

he,she に対する調査の結果を表3に示す．

さらに，(A) と (B) について，“this” に対しても調査した．(C) について調査を行なわなかった理由は後述する．この結果を表4に示す．

表 3: 2回目の調査結果 (he,she)

代名詞	(A)	(B)	(C)	総数
he	81	35	152	176
she	12	4	23	28

表 4: 2回目の調査結果 (this)

代名詞	(A)	(B)	総数
this	1	1	58

4.2 ヒューリスティクスに基づく調査結果の考察

まず he,she に関する調査では，照応語の検索の方法を変えたり単語の属性の一致を調べることで比較的結果が改善されることを確認した．ところが，同じヒューリスティクスを用いて “this” に対して調査を行なったところ，正解するものがほとんどなかった．これは this の用法 が he,she に比べて多いためである．また he,she が単数の名詞一語を指すのに対して，this は文章の中の文や文脈を指す場合もある．

したがって，this の照応解析のためにはさらに別のヒューリスティクスが必要と考えられる．

5 おわりに

5.1 まとめ

照応解析に必要なヒューリスティクスを得るための実験を行なった．この実験の結果から，代名詞の照応先の同定にはどのようなルールに基づき解析を行えばよいのかを調査した．

5.2 今後の課題

5.2.1 ヒューリスティクスの組み合わせについて

調査により抽出した個々のヒューリスティクスは，それをいくつか組み合わせた形で使用される．ヒューリスティクスには文や文章の表層構造に基づくものや意味的なものなど，種々の解析のレベルに対応するものがある．したがって，ヒューリスティクスをどのような形で組み合わせるかは異なったレベルの処理をどのように融合させるかという問題につながる．

この問題についてはヒューリスティクスがどの解析のレベルに対応するかを判断し，その適用順序を考察する [6] などの方策が考えられる．

5.2.2 調査方法について

調査の対象とする文章は，ヒューリスティクスの抽出時とそれに基づく調査実験時とで同じものを使用しているが，いわばオープンデータに対して抽出したヒューリスティクスの有効性を確認するのが望ましい．しかし現在のところ照応先の同定が正しいかどうかの判断は人手により行なっている．したがって調査の対象とするデータの分量を増加する必要がある場合には調査をより効率良くかつ正確に行なえるように何らかの工夫が必要と考えられる．

また，代名詞の照応の対象は，表層では，単語，句，節，文，文脈の5種類の異なった大きさをもつと考えられる．しかし，本来照応は意味的な現象なので，表層での大きさの範囲と真の照応先が一致するとは限らない [7]．この点に関しても検討する必要がある．

参考文献

[1] Zadrozny, W. and Jensen, K.
Semantics of Paragraphs, *Computational Linguistics,* vol.17, No.2, pp.171-209 (1991)

[2] 佐藤嘉高，荒木健治，宮永喜一，栃内香次
“英語文章における照応解析のためのヒューリスティクスに関する考察”
情報処理北海道シンポジウム ’94(1994)

[3] 安藤貞雄，樋口昌幸（共編）
英文法小事典，北星堂書店 (1991).

[4] 安藤貞雄，樋口昌幸，鈴木誠一（共編）
言語学・英語学小事典，北星堂書店 (1990).

[5] 伊藤和夫
英文和訳演習（入門編，基礎編，中級編），駿台文庫 (1989).

[6] 山村 毅，大西 昇，杉江 昇
日本語文の照応問題解決システム
電子情報通信学会論文誌，Vol.J73-D-II,NO.6, pp.887-896 (1990).

[7] Halliday, M.A.K. and Hasan,R.
Cohesion in English, Longman, London and New York (1976).

TEXT No. 1==========

◎ Tom is an engineer.
[[tom]] [engineer]

◎ He works in a factory which makes bicycles.
[[he]] [↑:tom] [factory] [bicycles]

◎ He has been at this factory for a year : before he came to the factory, he was studying to be an engineer at the University of London.
[[he]] [↑:he] [this] [↑:he] [factory] [year] [he] [↑:he] [factory] [he] [↑:he] [engineer] [university] [london]

◎ He does his work very well, and some day he is going to be the manager of a big factory – at least, he hopes so, and his girl friend, Susan, hopes so too.
[[he]] [↑:he] [his] [↑:he] [work] [day] [he] [↑:he] [manager] [factory] [he] [↑:he] [his] [↑:he] [girl] [friend] [susan]

◎ The factory is a long, low building between the road and the railway about five miles from Bishopton.
[[factory]] [building] [road] [railway] [miles] [bishopton]

◎ It was built about ten years ago.
[[it]] [↑:factory] [years]

◎ There are a lot of people working in the factory, and many of them live in the near towns and villages and travel to the factory every day.
[[people]] [factory] [them] [↑:it] [towns] [villages] [factory] [day]

◎ Some of them are brought to the factory each morning to buses, and are taken home again in the evening.
[[them]] [↑:people] [factory] [morning] [buses] [home] [evening]

◎ It is always very noisy in the factory, but the workers soon get used to the noise.
[[it]] [↑:them] [factory] [workers] [noise]

[[単語]] … 主題語,　　[単語] … 名詞または代名詞

[単語 1][↑: 単語 2] … 単語 1 が前出の単語 2 を指す

付録:調査実験の出力例