社団法人　電子情報通信学会
THE INSTITUTE OF ELECTRONICS,
INFORMATION AND COMMUNICATION ENGINEERS

信学技報
TECHNICAL REPORT OF IEICE.
NLC94-5 (1994-05)

誤りを含む文字列からの復元手法における接続情報の利用

神野大輔 † 荒木健治 †† 宮永喜一 † 栃内香次 †
† 北海道大学工学部 札幌市北区北１３条西８丁目
†† 北海学園大学工学部 札幌市中央区南２６条西１１丁目

あらまし
連続音声認識の結果には、付加、脱落、置換などの誤りが存在すると考えられる。このような誤りを含む文字列に対して語を決定する際、確実性の高さにより語を階層化し多段階に決定する手法が有効である。また、語と語の接続情報を利用することによりその決定の確実性を高めることができる。本稿では、確実性の高さに応じて複数の語との接続情報を用いることにより、従来確実性の低かった語に対しても精度良く決定する手法を提案する。また、本手法の評価実験を行いその有効性を確認した結果について述べる。

和文キーワード　連続音声認識，語の階層化，確実性，接続情報

Use of Word Connections for Error Recovery in Character Strings

Daisuke JINNO † Kenji ARAKI †† Yoshikazu MIYANAGA † Koji TOCHINAI †
† Hokkaido University N13-W8,Kita-ku,Sapporo 060,Japan
†† Hokkai-Gakuen University S26-W11,Chuo-ku,Sapporo 064,Japan

Abstract
In the result of continuous speech recognition, there exists errors of addition, deletion, permutation. When we decide words in the character strings including such errors, a method for deciding words on multistage by classifying words using certainty is effective. And, we can raise certainty of decision using word connections. In this paper, we propose a method for decideing the words more certainly which have low certainty using several word connections according to the height of certainty. We have done the experiment on this method, and the result shows the effectiveness.

英文Key words　continuous speech recognition, classifying words, certainty, word connections

1 はじめに

現在，計算機に日本語文書を入力する方法として，最も一般的なのはキーボードからの入力である．一方，音声の利用という別のインターフェースも考えられ，盛んに研究が行われている．しかし，音声による入力において現在の技術レベルでは，音響的な情報のみで完全な認識結果を得ることは困難である．このため，音響処理部の出力には誤りが含まれる．そこで，この誤りを含む文字列に対して，語彙情報，構文情報，意味情報などの言語情報を利用して，原文を復元する必要がある [1].

我々は，入力者が単音節単位で発声した音声を単音節音声認識装置により認識を行い，その出力結果である誤りを含む文字列から原文を復元する手法として多段階分割復元法を提案し，実験によりその有効性を確認している [2]. 現在は，より実用的でかつ自然な方法として連続音声に対応できるように研究を行っている．

多段階分割復元法においては，語彙情報を主体にして統計的に確実性の高い語から段階的に復元処理を行っている．そのために，復元された文章が日本語として意味を持たない場合や文章としての整合性を持たない場合が存在する．そこで，より上位レベルの情報として語と語の接続関係に着目しそれを利用して復元の信頼性を向上させる手法を提案し，実験によりその有効性を示した [3].

本稿では，より確実性の低い語に対して，複数の語との接続情報を用いることにより高い確実性を持って復元を行う手法，それにより語を階層化する手法の提案，並びに本手法を評価するために行った実験結果について報告する．

2 概要

人間は誤りを含む文字列を見た時，最初に手がかりとなる部分を見出して誤りの訂正を試み，前後のつながりに矛盾を生じないようであれば同様の操作を進めていき，原文を正しく読みとっていくものと考えることができる．多段階分割復元法ではこのような考え方を利用して，誤りを含む文字列の複数の単語候補の中から統計頻度に基づいた確実性の高いものから順次段階的に単語を決定し，原文を復元している（図１）．本手法は，上位の段階において語を決定することにより，その後の段階での単語候補が急激に減少するため，誤りを含む文字列を対象とした音声入力テキストプロセッシングにおける単語分割に有効である．

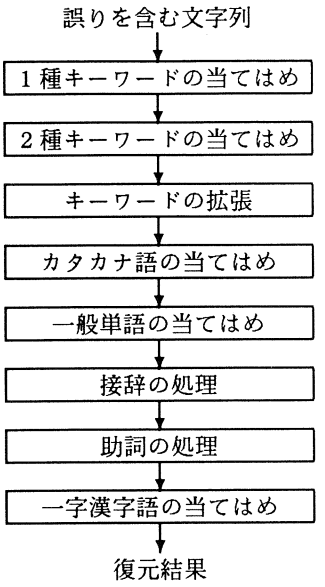


図 1: 多段階分割復元法の処理手順

ところで，ある限定された分野の文書においては，語はそれぞれ異なった固有の確実性を持つと考えられる．前述の多段階分割復元法においても確実性の比較的高い語に対しては，単語候補からの語の選択が比較的容易であり，またその精度も高い．しかしながら，下位の段階においては候補となる語の確実性が著しく低くなる．付加，脱落誤りを含む連続音声認識結果に対して，これらの語の中から正しい語を一意に決定するのは非常に困難である．

ここで，ある単語とその前後に隣接して現れる語をその単語の接続情報として語の連続を考える時，それらの語の確実性は１語のみを扱う時に比べて向上すると考えられる．確実性の低い語に関しては，この接続情報を用いることにより語の確実性が高まり，全体的な精度を高めることができると考えられる．

2.1 予備実験

語の決定の際に，語の接続情報を用いることにより当てはめの確実性がどの程度向上するかを調べるために以下の予備実験を行った．

2.1.1 実験方法

誤りを含む文字列に対して以下の手法により単語の決定を行った.

A）単語1語のみの候補の中から，連接情報の高い順に決定する

B）3，5，7語連続で接続可能な語の候補の中から，連接情報の高い順にその中心の1語を決定する

C）2～7語連続で接続可能な語の中から，連接情報の高い順にそれらの語全部を決定する

ここで，連接情報とは単語とその前後に存在する音節の組の情報である．また，語とは自立語，付属語全てを意味する．なお，以下の説明において手法B），C）のn語連続をそれぞれBn），Cn）と表す．

なお，実験に用いた資料は表3に示す情報処理に関する論文のNo. 1～4（総文字数 49,606 文字）である．これらの資料を音素表記で表し，連続音声認識のシミュレーションにより誤りを含む入力文字列を作成している．シミュレーションは，参考文献[4]に示されたコンフュージョンマトリクスに従い音素を誤らせている．また，出現単語とその接続情報は実験に用いた資料からあらかじめ抽出した．

2.1.2 実験結果

語の当てはめ結果に対して，当てはめられた総単語数を当てはめ語数，正しく当てはめられた総単語数を正当てはめ語数とする．なお，当てはめ精度，正当てはめ率は次の式で定義される．結果を表1に示す．

$$(\text{当てはめ精度}) = \frac{(\text{正当てはめ語数}) \times 100}{\text{当てはめ語数}} (\%)$$

$$(\text{正当てはめ率}) = \frac{(\text{正当てはめ語数}) \times 100}{\text{総単語数}} (\%)$$

2.1.3 考察

実験結果より，単語を決定する際に1語のみではなく何語かの連続したものを用いることにより当てはめ精度が大幅に向上している．このことから，接続情報を用いることにより語の確実性が向上するといえる．

B 3）とC 3）で当てはめ精度に差があるのは，3語の連続を考えるとき中心の1語は前後の2語に支持されているが，前後の語は中心の1語のみにしか支持されておらず中心の1語と両端の2語とでは中心の1語の方が確実性が高くなるためである．よって，C 3），C 5），C 7）の精度がB 3），B 5），B 7）よりも低くなる．

表 1: 予備実験の結果

処理手法	当てはめ精度	正当てはめ率
A）	44.1	50.3
B 3）	90.4	34.9
B 5）	98.6	15.4
B 7）	99.7	6.44
C 2）	66.0	47.4
C 3）	86.3	45.6
C 4）	92.9	36.4
C 5）	95.1	28.2
C 6）	96.5	22.0
C 7）	97.8	15.5

単語の連続する数が多くなるほど精度は向上するが，逆に正当てはめ率は悪くなる．つまり，当てはめ精度と正当てはめ率はトレードオフの関係にある．多段階分割復元法において，最も確実性の高い語である1種キーワードの精度が95％であることから，最大でも5語の連続を考えれば良いと考えられる．

3 接続情報を用いた復元手法

実際の語の決定をおこなうとき，全ての語（辞書登録されている）を当てはめ候補とすることは，候補の組合せ的爆発の危険性があり，またその際の語を一意に決定するのも困難になり非効率的である．よって，確実性が高くかつ効率の良くなる順序で多段階に単語の決定を行うことが重要である．

この問題に対し，語の決定に接続情報を用いることにより本来確実性の低い語に対しても高い確実性で決定することができる．また，高い確実性を得るために必要な接続情報量は語によって異なると考えられる．このため，本手法においては学習処理を行うことによりその語に最適な接続情報の量を得ることにする．

3.1 システムの概要

図2に本手法に基づくシステムの処理手順を示す．

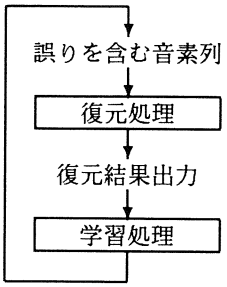


図 2: システムの処理過程

本システムは音声認識結果として得られる誤りを含む文字列を入力とする．その入力に対して，既知の単語，接続情報を用いて復元処理を行う．この結果得られる復元結果は，単語に分割された仮名漢字混じり文となる．次に，復元結果に対して正しい文になるように校正処理をユーザが行い，その結果と復元結果から学習処理を行う．ここで，単語や接続情報の新規登録並びに，確実性の評価を行う．以上の処理の結果，辞書を更新して新しい入力に対する復元処理を行う．

以下に，復元処理，学習処理について述べる．

3.2 復元処理

図3に復元処理の手順を示す．手順は，多段階分割復元法に準じたものになっている．今回新たに接続情報を用いて復元処理を行うのは，後述するキーワード接続単語，n語支持語の当てはめの部分である．

以下に各処理段階について述べる．

3.2.1 キーワード

誤りを含む文字列中において最初に手がかりとなる語がキーワードである．すなわち，出現頻度が高く，その単語と同じ文字列が存在したときその語と決定しても誤りにならない語である．このキーワードは一定の分野の文章の中にはその存在が確認されている [2]．キーワードは，その確実性の高さに応じてさらに2つに分類される．

3.2.2 1種キーワード

キーワードの中で最も確実性の高い語である．2種キーワードの中で頻度が高く，かつ当てはめ精度が９５％以上の語を登録する．最高で１００語の1種キーワードが1種キーワード辞書に登録できる．

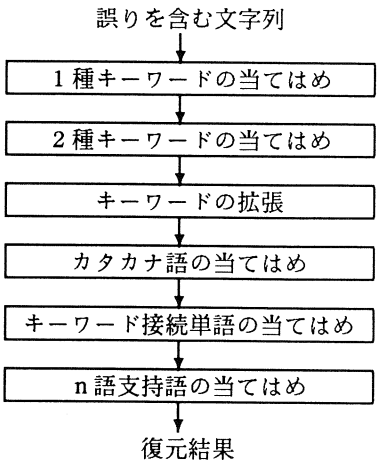


図 3: 接続情報を用いた復元処理の手順

3.2.3 2種キーワード

1回の処理において，誤って当てはまることがなくかつ他のキーワードと重複しない語を2種キーワードとして登録する．最高で３５０語の2種キーワードが2種キーワード辞書にできる．決定に際しては，同時期に2種キーワードに抽出された語が2語以上存在する場合にのみ当てはめを決定する．

3.2.4 キーワードの拡張

既に当てはめが決定されたキーワードに対して，それを前後に拡張した文字列が単語として単語辞書に存在する時，キーワードの拡張としてキーワードに変えて当てはめる．

3.2.5 カタカナ語

外来語などに用いられるカタカナ語は綴りに特徴のあるものが多く確実性が高い．このため，2種キーワード辞書から溢れた語のうちのカタカナ語をカタカナ語辞書に登録する．最大で１００語のカタカナ語をカタカナ語辞書に登録できる．

3.2.6 キーワード接続単語

キーワードに隣接した文字列中にキーワードと接続可能な5音素以上の語が存在する時，キーワード接続単語として当てはめを決定する．

キーワードは限定された分野の文書において確実性の高い語であり，同時にその前後にキーワードと

何らかの関係を持った語を伴うことが多いと考えられる．これらの語は，キーワードほどの確実性はないがキーワードとの関連で考えた場合確実性が高いと考えられる．

なお，このキーワード接続単語はキーワード1語によりその決定を支持されていると考える．

3.2.7 n語支持語

キーワードやその前後の単語の決定が終ると残りの単語は比較的確実性の低い語になる．また，残りの語の数は非常に多く候補の数も多くなり一意に決定するのが困難になる．これらの語に対しては，接続情報を用いて確実性を高めた上で当てはめを決定する．

この段階では非常に多くの確実性の低い語を扱うが，これらの中にも相対的に確実性の高い語から非常に確実性の低い語まで様々な語が存在していると考えられる．この相対的な確実性により，語を5つのrankに分類する．このrankは学習処理を行うことによりその語に最適なものを与える．そして，rankに従って与える接続情報を変化させることにより段階的に語の決定を行う．すなわち，ある語を決定する際，その決定を支持する語の数をその語のrankにより変化させる．また，このときn語に支持されている語をn語支持語と呼ぶ．以下に各rankの説明を行う．

1. rank0 ... 最も確実性の高い語であり，決定に際してはその語1語のみで決定できる語である
2. rank1 ... 1語のみでは確実性が低い語であり，隣接する1語に支持されるとき当てはめを決定できる語である
3. rank2 ... 1語に支持されただけでは確実性の低い語であり，前後に隣接する2語に支持されるとき当てはめを決定できる語である
4. rank3 ... 2語支持でもなお確実性の低い語であり，前後に隣接する計3語に支持されるとき当てはめを決定できる語である
5. rank4 ... 最も確実性の低い語であり，その語の前後2語づつ計4語に支持されるとき当てはめを決定できる語である

また，キーワード接続単語，n語支持語の各rankにおける接続情報の利用を図4に示す．図において，W_nは決定の対象となる語であり，nは何語に支持されているかを示す．また，w_f，w_bはそれを支持する語である．下線は接続情報を示す．例えばrank4において，W_4はw_f1，w_f2，w_b1，w_b2の4語に支持されており，(w_f1，w_f2，W_4)，(w_f2，W_4，w_b1)，(w_f2，W_b1，w_b2)の3つの接続情報を利用している．ここで，接続情報は自立語，付属語を問わずに語とその前後に隣接する語の組の情報である．

n語支持語を決定する際には，rank0からrank4の順に行う．この順に決定を行うことにより，処理が進むにつれて決定済みの単語が増加するため，支持される語が増加して語の決定が容易になると考えられる．

KW 接続単語	kw W W kw
rank.0	W_0
rank.1	$w_f\ W_1$ $W_1\ w_f$
rank.2	$w_f\ W_2\ w_b$
rank.3	$w_{f1}\ w_{f2}\ W_3\ w_b$ $w_f\ W_3\ w_{b1}\ w_{b2}$
rank.4	$w_{f1}\ w_{f2}\ W_4\ w_{b1}\ w_{b2}$

図 4: 接続情報によるn語支持

3.3 学習処理

図5に学習処理の手順を示す．ここで，復元結果は当てはめられた語により分割されており，校正結果ユーザにより校正された正しい文書が単語単位に分割されている．以下に各処理について述べる．

3.3.1 単語辞書の更新

復元結果と校正結果との比較により当てはめられた語とその正誤を調べる．その結果，ある語が復元に使用されたときその使用頻度（H）を1増やし，履歴（R）を0にする．また，使用されなかった語のRを1増やし，誤って使用された語のエラー頻度（E）を1増やす．その結果，その単語の評価値をR＋α

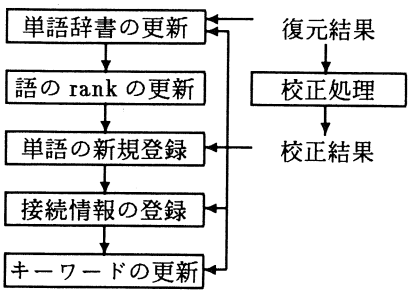


図 5: 学習処理の手順

E $-\beta$ H で表す．現在，実験により最適であった $\alpha=10$，$\beta=1$ を用いている．

3.3.2 語の rank の更新

単語辞書の更新の結果，単語の rank を決定する．現在 rank は E／H の値により 1／5 以下を rank0，1／4 以下を rank1，1／3 以下を rank2，1／2 以下を rank3，それ以上を rank0 としている．

3.3.3 単語の新規登録

校正結果中に現れ，かつ単語辞書に存在しない語を単語辞書に新規登録する．なお，現在は新規登録された語の rank は音素数 5 以上のものは rank0，音素数 5 未満のものは rank2 としている．これは，経験的に音素数 5 以上の語はキーワードになりうること，音素数 5 未満の語は非常に確実性が低いことによる．

3.3.4 接続情報の登録

校正結果中の全単語に対し，その前後に隣接する語を接続情報として接続情報辞書に登録する．文頭，文末も接続情報として扱う．

3.3.5 キーワードの更新

2 種キーワード辞書中で条件を満たす語を 1 種キーワード辞書に登録する．1，2 種キーワード及びカタカナ語辞書中で条件を満たさない語を抹消する．また，1 種キーワード辞書から溢れた語を 2 種キーワード辞書に，2 種キーワード辞書から溢れたカタカナ語をカタカナ語辞書に登録する．

校正結果中に存在する語の中で，キーワードの条件を満たす語を 2 種キーワード辞書に登録する．

4 評価実験

実験システムを用いて，本手法の評価実験を行った．

4.1 実験方法

実験に用いた資料は表 3に示す情報処理に関する論文 10 編（総単語数 49,751 語，総文字数 123,387 文字，総音素数 209,989 音素）である．これらを，句読点などにより 4,426 に分割した．さらに，連続音声認識のシミュレーションを行い，誤りを含む文字列を作成した．

実験システムは図 2に示したものを用い，この処理を 4,426 回行った．ただし，実験の簡略化のため，校正処理は行わず単語に分割済みの正しい文書を教師データとして与えた．なお，今回は論文 1 編を処理する前にその 1 編を学習したクローズ実験を行っている．

4.2 実験結果

復元結果に対して 2.1.2節と同様にして当てはめ精度と正当てはめ率，さらに誤当てはめ率，未当てはめ率を示す．各処理過程ごとの結果を表 2，論文 1 編ごとの当てはめ精度，正当てはめ率，誤当てはめ率，未当てはめ率の推移を図 6に示す．

なお，誤当てはめ率，未当てはめ率は以下の式で定義される．

$$\text{誤当てはめ率} = \frac{(\text{当てはめ数}-\text{正当てはめ数})\times 100}{\text{総単語数}}(\%)$$

$$\text{未当てはめ率} = \frac{(\text{総単語数}-\text{正当てはめ数})\times 100}{\text{総単語数}}(\%)$$

表 2: 実験結果

処理段階	当てはめ精度	正当てはめ率
1 種キーワード	89.7	0.808
2 種キーワード	85.4	5.34
拡張キーワード	65.9	0.0583
カタカナ語	—	—
キーワード接続単語	88.2	2.52
n 語支持語	75.4	52.8
rank0	69.9	13.5
rank1	73.4	17.1
rank2	80.5	17.5
rank3	81.0	4.17
rank4	90.2	0.649
計	76.8	61.6

表 3: 実験に用いた資料

(1) 分野：情報処理　出典：情報処理学会論文誌

No	論文名	著者名	巻名	文字数
1	高集積マイクロコンピュータに適したマイクロプログラム制御方式	前島他	Vol.23 No.1	15,199
2	ＣＯＢＯＬマシンとその設計思想―ハードウェア構成について―	山本他	Vol.23 No.1	11,106
3	フーリエ変換を用いたテクスチュアの構造解析	松山他	Nol.23 No.2	11,421
4	日本語文入力用カタカナ語検出規則とオンライン国語辞典の一分析	木村	Vol.23 No.2	11,880
5	インテリジェント・コンソール―ＯＳの機能拡張の一方法―	有田	Vol.23 No.3	13,294
6	ポータブル画像処理ソフトウェア・パッケージＳＰＩＤＥＲの開発	田村他	Vol.23 No.3	13,438
7	グラフィック・ディスプレイ・ターミナルのための端末作画システム	高藤他	Vol.23 No.4	9,421
8	オペレーティング・システムのファームウェア化対象選定法	長岡他	Vol.23 No.4	11,074
9	プログラム階層構造の生成，処理，文書化能力を有するテキスト・エディタ	酒井他	Vol.23 No.4	11,338
10	パステストに本質的な分岐に着目した網羅率尺度の提案	中所他	Vol.23 No.5	15,216
	情報工学分野の文字数の合計			123,387

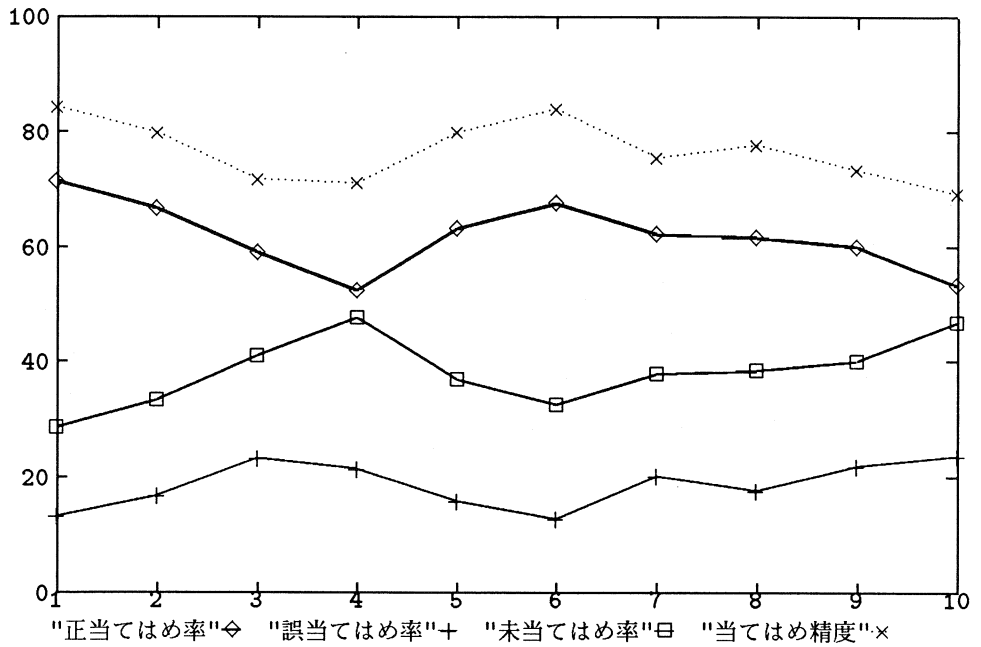


図 6: 実験結果

4.3 考察

実験結果から正当てはめ率は，全体で 61.6 %になっている．正しく決定できない部分は，誤った語が当てはめられた誤当てはめが 18.6 %，当てはめが行われなかった未当てはめが 38.4 %である．以下それぞれの結果について考察する．

まず正当てはめであるが，最も多くの語を決定したのは rank1，rank2 であるがこの部分の当てはめ精度が 80 %未満であり，精度に問題が残った．しかし，rank2 以下の部分では，確実性の低いと考えられる 1 文字語などが 80 %以上の精度で正しく決定されておりこれらの語に関しては接続情報の利用が有効であったと考えられる．また今回の実験では，正当てはめと見なす語は教師データ中の分割された単語の表記と同一であることを条件としている．同一の語であっても表記に揺れがある場合や教師データ

の単語分割に不統一な箇所があると実際正しく当てはめられた語でも誤りと見なされる場合があった．正当てはめ率がさほど高くない原因の一つであると考えられる．

次に，誤当てはめに関しては全体で9,270語存在した．そのうち4.91％が2種キーワード，31.2％がrank0，33.1％がrank1，22.7％がrank2であった．原因としては，現在のシステムでは1回で処理する文中に含まれる語の中で誤らずに当てはめられる語が2種キーワードになるので登録されるための条件が緩いということが上げられる．また，今回誤りの多かったrank0の語に関しても，5音素以上の語が新規登録されたときまずrank0にされるため，そこで誤りを起こすことが多い．rank0，rank1の両方に共通しているのは，rank2や3においては確実性の高い語もrank0や1になった時誤りを起こしやすいということである．rankを変更する条件について実験により最適な方法の検討が必要である．

最後に，未当てはめに関してであるが，現在の処理手順においてキーワード接続単語やn語支持語は接続情報が存在することが語の決定の必要条件である．そのため，上位段階で誤当てはめが行われると接続情報が適用できず，未当てはめを引き起こすことになる．現在のシステムにおいては，未決定の部分を最終的に何らかの語へ決定する処理を行っていない．この処理を行うことにより未当てはめ率を減少して正当てはめ率を向上できるものと考えられる．

5　おわりに

本稿では，音声認識結果など誤りを含む文字列の入力に対して，語と語の接続情報を利用して複数の語との接続関係により高い確実性を持って語の決定を行う手法，それにより語を階層化する手法について提案した．また，本手法を評価するための実験を行いその結果について考察した．その結果，クローズデータに対しては，従来確実性の低かった語に関しても高い精度で語の決定を行うことができ本手法の有効性が示された．

今後は，今回報告できなかったオープンデータへの対応，さらに考察で挙げた問題点を解決する手法の検討を行う予定である．

参考文献

[1] 古井：ディジタル音声処理，東海大学出版会，(1985).

[2] 荒木，宮永，栃内：多段階分割復元法による誤りの多い文字列からの原文の復元，情報処理学会論文誌，Vol30,No2,pp.169-178(1989).

[3] 神野，荒木，宮永，栃内：キーワードとの単語接続情報を用いた誤りを含む文字列からの原文の復元，1994 信学春季全大，D-113.

[4] 相川，杉山，鹿野：トップダウン処理による音韻認識，ＮＴＴ研究実用化報告第３２巻第１１号，pp2281-2292(1983)