社団法人　電子情報通信学会
THE INSTITUTE OF ELECTRONICS,
INFORMATION AND COMMUNICATION ENGINEERS

信学技報
TECHNICAL REPORT OF IEICE.
NLC94-42 (1994-12)

接続情報を利用した誤りを含む文字列からの原文復元法の性能評価

神野大輔 † 荒木健治†† 宮永喜一 † 栃内香次 †
† 北海道大学工学部
札幌市北区北１３条西８丁目
†† 北海学園大学工学部
札幌市中央区南２６条西１１丁目

あらまし　連続音声認識の結果には，一般に付加，脱落，置換の誤りが存在する．そこで，これらの誤りを含む文字列から原文を復元する必要がある．この問題に対して，確実性を用いて多段階に語を決定する手法が有効である．しかし，非常に確実性の低い語に対しては十分な精度を得ることが難しい．本研究では，語の接続情報を利用することによりこの確実性の低い語を精度良く決定する手法を提案する．本手法においては，接続情報により語をより長い語列として扱うことを考え，さらに語固有の確実性に着目することにより語を階層化している．また，本手法に基づく実験を行い，誤りを含む文字列の復元に本手法が有効であることを確認した．

和文キーワード　連続音声認識，復元，確実性，接続情報，語の階層化

The Performance Evaluation of Error Recovery Method in Character Strings Using Word Connections

Daisuke JINNO † Kenji ARAKI †† Yoshikazu MIYANAGA † Koji TOCHINAI †
† Hokkaido University
N13-W8,Kita-ku,Sapporo 060,Japan
†† Hokkai-Gakuen University
S26-W11,Chuo-ku,Sapporo 064,Japan

Abstract　In general there exist kinds of errors as addition, deletion, and permutation in continuous speech recognition. So, it is necessary to recover the errors in these recognized results. For this problem, we had found the effectiveness to use a method for deciding words using certainty. However, it is difficult to decide exactly words which have a low certainty. In this paper, we propose a method for deciding words of low certainty more exactly by using word connections. The method we used was to use a long string of words and to classify each of them by their own certainty. We took several experiments based on this method, and the results showed the effectiveness of recovering errors.

英文 key words　continuous speech recognition, recovery, certainty, word connections, classifying words

1 はじめに

近年，電子計算機の普及に伴い，日本語文書を計算機に入力する必要性が増大している．現在，その入力方法として主流であるのはキーボードによるものである．一方，OCR や音声認識によるものも研究が行われており，既に一部実用化もされている．しかし，現状の技術ではその認識結果に比較的多くの誤りを含むことが避けられない．このため，正しい日本語文を得るためには誤りを含む文字列に対して言語情報を利用して原文を復元することが必要となる [1].

これまでに，こうした誤りを復元する研究としては，漢字かな混じり文の誤りの復元に 1 重マルコフモデルを用いる手法 [2]，文字認識における誤り復元法 [3][4]，曖昧な音節列に対して 2 重マルコフ連鎖モデルを用いる手法 [5] などがある．しかし，扱っているのは漢字かな混じり文や文節であり，語の決定に際し，大きな曖昧性を持つ非常に曖昧な比較的長いべた書きの文字列を扱ったものについては，未だ有力な方法がないのが現状である．

我々は，単音節音声認識において統計的に確実性の高い語から多段階に語を決定することにより誤りを復元する手法として多段階分割復元法を提案し，実験によってその有効性を確認している [6]．しかし，連続音声認識など，より一般的な状況においては付加，脱落などの誤りが存在すると考えられ，これらの誤りに対処するためにはさらに強力な手法を用いる必要がある．そこで，上記の手法で用いていた単語レベルでの確実性に加えて，よりマクロな情報である単語どうしの接続情報を用いて復元の信頼性を向上させる手法を提案した [7]．本稿ではこの接続情報を用いた復元手法とその評価実験について述べる．

2 概要

人間は誤りを含む文字列を見たとき，最初に手がかりとなる部分を見出して誤りの訂正を試み，前後のつながりに矛盾を生じないようであれば同様の操作を進めていき，正しい原文を読みとっていくものと考えることができる．多段階分割復元法 [6] は，このような考え方を利用して，誤りを含む文字列の複数の単語候補の中から統計頻度に基づいた確実性の高いものから順次段階的に単語を決定し，原文を復元している（図 2）．例えば，図 1に示すように，誤りを含む文字列に対しては多くの単語が当てはめ候補となる．この例の場合，20 語の候補が存在する．この中で最も確実性の高い語として“命令”を当てはめると候補は 15 語に減少する．

syogisurNkokogiyorimakuromeireiteiSicigisuiyaku

処理すること より いる 命令 意識 制約
章 シングル におり マクロ れる 形式
しよう マイクロ 例
とりわけ RoMarray

図 1: 語の決定による候補減少効果

実際には，この例よりも多くの候補が存在し，上位の段階で語を決定することにより，その後の処理における単語候補が急激に減少する．このため，誤りを含む文字列を対象としたテキストプロセッシングにおける単語分割に有効である．

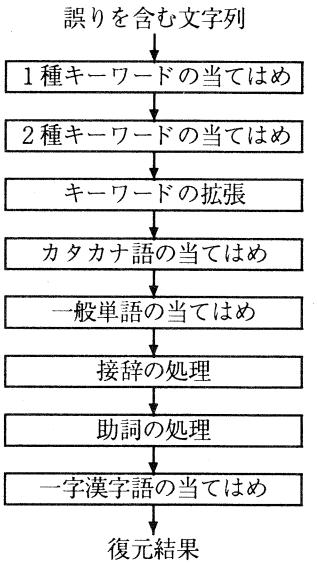


図 2: 多段階分割復元法の処理手順

ここで，最初に手がかりとなる部分を我々はキーワードと呼んでいる．キーワードは一定の分野において特徴的に現れる語であり，その存在と有効性が確認されている．このため，多様な文章を扱う場合にも，比較的少数のキーワードにより文章中の多くの単語を決定することができ，語彙が大規模になった場合のコスト増大の問題も回避できる．しかしながら，文章中の全ての語を処理しようとする場合，キーワードだけでは到底網羅することができない．このため，キーワードを決定した後，非常に多数の語を同時に扱う必要が生じる．多段階分割復元法ではこの部分を一般単語の当てはめとして扱っている．この部分では，語の決定に

おける曖昧性が極端に増大するために，正しい語を決定するのが困難になる．そこで，語の前後1文字を連接情報として利用することにより曖昧性を解消している．この手法は，少ない情報量で比較的正しく語を決定できることや未知の文章に関しても有効であるという利点を有するが，付加，脱落などを含む誤りには対処しにくいことやこの段階における語の決定の精度が上位の段階に比べて低下するという欠点がある．

我々は，この原因が文章中の全ての語を単語レベルの情報のみで処理しようとしていることにあると考え，曖昧性の高い部分に関してはより上位レベルの情報を用いることにした．ただし，キーワードを用いる多段階分割復元法による復元は，計算コストや分野におけるキーワードの適応性能など有効な部分が多いので，これらの利点をなるべく多く維持した上で新たな手法を加える方が有利であると考えている．また，こうした従来手法との整合性を考える上では，新たに加える手法としては比較的容易に得ることのできる情報であることが望ましい．多段階分割復元法は単語のみに着目して，統計的にその確実性を決定することにより復元処理を行っており，高度な文法処理や意味情報などは利用していない．このために，システムの構築が容易であり，入力文に文法的な制約を加える必要がなく，非文に対しても有効であるロバストな手法となっている．新たに加える手法もこういった性格を持つものとするため，文の表層から容易に得られる情報である語と語の接続関係を用いることにする．以後，この関係のことを接続情報と呼び，次章にその利用法について述べる．

3 接続情報の利用

3.1 目的

キーワードのように確実に決定できる語は，比較的長い語が多い．これは，最長一致法などからも明らかなヒューリスティクスの1つであると考えられ，統計的にもより長い語を優先させた方がより確実であると思われる．こうした考えに基づき，当てはめの候補として“語”ではなくより長い“語列”を扱うことが，復元の信頼性の向上に役立つと考えた．例えば図3において，それぞれの語候補の他に接続可能な語列“マクロ-命令-形式”という候補が存在する．このとき，この語列を選択するのは語を候補とするときに比べ，1）確実性が高い，2）より多くの単語候補が減少する，という2つの利点があると考えられる．

また，“する”，“こと”，“に”など短い語は曖昧性

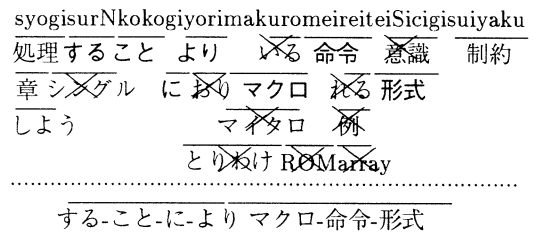


図 3: 接続情報を用いた語の決定による候補減少効果

が非常に高いために1語づつ決定していくのは困難である．ここで，“する-こと-に-より”という語列が当てはめ候補であるならば，この候補は非常に確実性が高いといえる．つまり，接続情報を用いることにより，1語で扱うにはあまり確実性の高くない語をキーワードと同様に確実性の高い状態にすることができるといえる．

この他に，かな漢字変換などでも問題になる同音異義語に対しても周辺の語を考慮することにより正しい語を選択できる [8] ことや，一定の分野を扱うときに多数現れる名詞の連続によって表される複合名詞，定型表現などが接続情報により語列を用いることによりその大半が網羅できることなどが期待される．接続情報により長い文字列（語列）を作ると出現頻度が低くなるという問題が生じるが，その要素となっている語は頻度の高いものが多く，それらによって構成される語列は比較的出現頻度の高いものになると期待される．以上が本手法における接続情報利用の目的である．

3.2 接続情報の抽出

接続情報を抽出する際に問題となるのは，どれだけの範囲を一度に抽出するかということである．例えば，1文を全て記憶させた場合，同様の文が現れた時には有効であるが，全ての文を記憶するのは容量や検索効率の点で得策ではない．従って，本手法では語の三つ組で接続情報を記述する．

これにより，ある文

$\mathrm{T}\ W_i\ \mathrm{B}\quad (1 \leqq \mathrm{i} \leqq \mathrm{n})$

において，

$(\mathrm{T}\ W_1\ W_2)$，…，$(W_{r-1}\ W_r\ W_{r+1})$，
…，$(W_{n-1}\ W_n\ \mathrm{B})\quad (2 \leqq \mathrm{r} \leqq \mathrm{n\text{-}1})$

の計n個の接続情報が得られる．なお，W_iは語，Tは文頭，Bは文末を表し，自立語と付属語の区別はしない．

さらにこの接続情報を組み合わせることにより，n語の連続した語列を作り出すことができる．このため，

未知の文の場合であっても語の三つ組が一致すれば文を処理できる可能性がある．

3.3 接続情報による語の階層化

接続情報を用いて語列を考えると，1語のみを扱う場合よりも確実性が高いと考えられる．しかし，接続情報によって生成された

$W_1\ W_2\ W_3 \cdots W_n$

のような語列において，例えばW_1とW_3とでは確実性が異なる．これはW_1には（$W_1\ W_2\ W_3$）という1個の接続情報のみしか使用されていないのに対し，W_3には，($W_1\ W_2\ W_3$)，($W_2\ W_3\ W_4$)，($W_3\ W_4\ W_5$）という3個の接続情報が使用されているからである．

また，語にはキーワードのように非常に確実性の高い語から1文字語のように非常に確実性の低い語まで様々なものが存在すると考えられる．このため，より多くの接続情報を用いた語列がより確実性が高くなるとは限らない．従って，実際に語を決定するにあたってはこれらの点を考慮する必要がある．このため，本手法では全ての語をその語固有の確実性により階層化してそれぞれの語に応じて必要かつ十分な接続情報の数を変化させることにする．以下にその分類方法について述べる．

まず階層についてであるが，語に応じてrank 0からrank 4まで5つのランクを設定した．rank nの語はn語との接続情報を持つとき，十分に確実性が高いことを意味する．rankを5段階にしたのは，5語の連続を考えれば十分に高い精度で語の決定ができるためである[7]．なお，n語との接続情報を持つ語をn支持語と呼び，図4にその様子を示す．なお，W_nはn支持語を表し，w_xはそれを支持する語，下線は使用された接続情報を示す．

0支持語	W_0
1支持語	$\underline{w_f\ W_1}$ $\underline{W_1\ w_f}$
2支持語	$\underline{w_f\ W_2\ w_b}$
3支持語	$\underline{w_{f1}\ \underline{w_{f2}\ W_3\ w_b}}$ $\underline{w_f\ \underline{W_3\ w_{b1}}\ w_{b2}}$
4支持語	$\underline{w_{f1}\ \underline{w_{f2}\ \underline{W_4}\ w_{b1}}\ w_{b2}}$

図4: 接続情報によるn支持の様子

語がどのランクに属するかは統計的に決定する．ある語（W）とその接続情報が既知であるとき，誤りを含む文字列にはWが候補として出現する．この候補となる頻度をS，実際に正しい文書に出現する頻度をAとする．このとき，Sには誤って候補になる可能性があるので，$S \geqq A$となる．ここで，候補となったWに対して接続情報を利用し，何語との接続情報を持つかを調べる．n支持であるWをlevel nとする．Sを各レベルごとに調べ，それぞれS_0〜S_4とする．Wがlevel nのときにはS_0からS_nまでを1増やす．こうして接続情報により制限を設けると，$S_n \leqq A$となるnが見つかる．こうなる最小のnをWのランクとして決定する．ランクはWがどれだけの接続情報を持つとき，十分確実性が高くなるかというWの性質を表すものであり，レベルは候補となったWがどれだけの接続情報を持っているかというWの状態を表すものである．

4 接続情報を利用した復元手法

本章では，前章までに説明した接続情報を用いた復元手法について具体的な語の決定アルゴリズムを説明する．

4.1 システムの構成

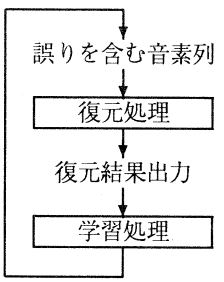


図5: システムの処理過程

図5に本手法に基づくシステムの処理手順を示す．本システムは音声認識結果として得られる誤りを含む文字列を入力とする．その入力に対して，既知の単語，接続情報を用いて復元処理を行う．この結果得られる復元結果は，単語単位に分割された仮名漢字混じり文となる．次に，復元結果に対して正しい文になるように校正処理をユーザが行い，その結果と復元結果の比較により学習処理を行う．ここで，単語や接続情報の新規登録および語のランクの検討を行う．以上の処理

の結果，辞書を更新して新たな入力に対して復元処理を行う．

4.2 復元処理

図6に復元処理の手順を示す．これは，多段階分割復元法（図2）に準じた構成になっている．決定すべき語の中で単語レベルで十分正確に決定できると考えられる1種キーワードからカタカナ語までを決定し，そこで残された非常に曖昧な部分に接続情報を用いた復元を行う．これは，キーワード接続語とn支持語の当てはめの部分である．なお，それでも決定できない部分は既知の語と接続情報を用いたヒューリスティクスにより最終的な処理を行っている．

以下に，各処理段階について述べる．

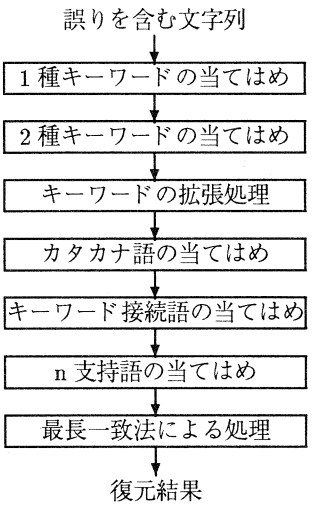


図 6: 接続情報を用いた復元処理の手順

4.2.1 1種キーワード

誤りを含む文字列中で語を決定する際に，多くの候補の中で最も確実であると考えられ，最初に手がかりとなる語がキーワードである．キーワードとなる語は出現頻度が高く，その語と同じ文字列が存在したとき，その文字列をその語であると決定しても誤りにならない語である．キーワードは一定の分野の文章の中にはその存在が確認されており，その確実性の高さに応じてさらに2種類に分類される．

1種キーワードはそのうち最も確実性の高い語である．2種キーワードの中で2種キーワード辞書に登録されてから30回以上使用され，かつ正しく使用される確率が95 %以上の語を登録する．最高で100語の1種キーワードが1種キーワード辞書に登録でき，溢れた場合は語の評価値をにより上位100語以外を2種キーワードに落す．文字列中に単独で存在した場合当てはめを決定する．

4.2.2 2種キーワード

1回の処理において，誤って当てはまることがなくかつ他のキーワードと重複しない語を2種キーワードとして登録する．キーワードとなる語は当初は全て2種キーワードとなる．最高で350語の2種キーワードが2種キーワード辞書にでき，溢れた場合は語の評価値により上位350語以外を2種キーワード辞書から除く．決定に際しては，同時期に2種キーワードに抽出された語が2語以上存在する場合にのみ当てはめを決定する．

4.2.3 キーワードの拡張

既に当てはめが決定されたキーワードに対して，それを前後に拡張した文字列が単語として単語辞書に存在する時，その文字列をキーワードの拡張としてキーワードに変えて当てはめる．

4.2.4 カタカナ語

外来語などに用いられるカタカナ語は綴りに特徴のあるものが多く確実性が高い．このため，2種キーワード辞書から溢れた語のうちのカタカナ語をカタカナ語辞書に登録する．最大で100語のカタカナ語をカタカナ語辞書に登録できる．文字列中に単独で存在した場合当てはめを決定する．

4.2.5 キーワード接続語

キーワードはある一定の分野の文書において確実性の高い語であり，同時にその前後にキーワードと何らかの関係を持った語を伴うことが多いと考えられる．これらの語は，キーワードほど確実性が高くはないがキーワードとの関連で考えた場合，確実性が高いと考えられる．そこで，既に決定されたキーワードとの接続情報を持つ語をキーワード接続語と呼び，他の語よりも優先して当てはめることにする．

既決定のキーワードに隣接した文字列中にキーワードとの接続情報を持つ5音素以上の語が存在するとき，キーワード接続語として当てはめを決定する．5音素以上の語としたのは，例えば，キーワード＋1文字語

といった接続情報により短い語が決定されるときこれが誤りである場合が多いためである．

なお，このキーワード接続語はキーワード1語に支持されているn支持語であるといえる．

4.2.6 n支持語

キーワードからキーワード接続語までの確実性の高い語の決定が終ると残りの単語は比較的確実性の低い語になる．また，残りの語の数は非常に多く候補の数も多くなり一意に決定するのが困難になる．これらの語に対しては，接続情報を用いたn支持語として確実性を高めた上で当てはめを決定する．

この段階では全ての語を当てはめの対象とするので，候補となった全ての語に対して接続情報を用い，その語のランクに応じて十分なレベルに達しているものを決定する．例えば，rank 2の語が候補である場合，少なくともlevel 2であれば十分に確実性が高いとして決定する．また，同時に異なる候補が存在した場合は1）より多くの語が接続可能な語，2）ランクの上位の語，3）評価値の高い語の順に決定する．

4.2.7 最長一致法による処理

ここまでの処理で語が決定できなかった部分に関しては，以下の手法に基づき語の決定を行う．

1. 既に決定済みの語に挟まれた部分全体に一致する語，または語列が存在するとき，これを当てはめる．
2. 一致しない場合は候補となる語，語列を1部分として2部分の最長一致を取る部分を左側から決定していく．

以上の手法で決定できない場合は，未処理のままとする．

4.3 学習処理

復元処理の結果に対し，ユーザが校正処理を行う．本手法ではこの校正結果と復元結果の比較により学習処理を行う．以下に処理の内容を述べる．

4.3.1 単語辞書の更新

復元に使用された語とその正誤を調べ，使用頻度（H），履歴（R），エラー頻度（E）を更新する．その結果，語の評価値 $C = R + \alpha E - \beta H$ を決定する．なお，この評価値と係数は実験により最適であったものを用いている．また，校正結果から辞書に未登録の語を新規登録する．

4.3.2 ランクの更新

辞書に登録されている語の出現頻度（A）と，入力された誤りを含む文字列において，当てはめ候補となる頻度（S）を各レベルごとに調べ3.3節に述べた方法で語のランクを決定する．

4.3.3 キーワードの更新

キーワード辞書をそれぞれの条件に従い更新する．さらに，校正結果中に存在する語の中でキーワードの条件を満たすものがあれば2種キーワード辞書に登録する．

5 評価実験

5.1 実験方法

本手法に基づく実験システムを作成し，本手法の性能評価のための実験を行った．用いたデータは情報処理と機械工学に関する論文それぞれ10編ずつ計20編（総単語数85,803，異なり単語数4,628，総文字数212,680）である．これを句読点などにより11,812に分割し，1処理単位（平均18文字）とした．これらを音素表記したものに連続音声認識シミュレーションを行い，誤りを含む文字列を作成した．このシミュレーションは文献[9]に従っている．

辞書は空の状態から始め，一処理単位ごとに図5の処理を行い，計11,812回行った．このため，復元処理は常に未知のデータに対して行うことになる．ただし，実験の簡略化のために校正処理は行わず単語に分割済みの正しい仮名漢字混じり文書を教師データとして与えた．

5.2 実験結果

復元結果に対して以下の式を用いて評価を行う．

$$\text{正当てはめ率} = \frac{\text{正当てはめ文字数}}{\text{総文字数}} \quad (1)$$

$$\text{誤当てはめ率} = \frac{\text{誤当てはめ文字数}}{\text{総文字数}} \quad (2)$$

$$\text{未当てはめ率} = \frac{\text{未当てはめ文字数}}{\text{総文字数}} \quad (3)$$

$$\text{占有率} = \frac{\text{当てはめ文字数}}{\text{総文字数}} \quad (4)$$

$$\text{精度} = \frac{\text{正当てはめ文字数}}{\text{当てはめ文字数}} \quad (5)$$

ここで，正当てはめ文字数とは正しく当てはめられた語に使用された文字数，誤当てはめ文字数とは誤って当てはめられた語に使用された文字数，未当てはめ文字数とは当てはめ対象とならなかった部分の文字数である．占有率は各処理段階において処理対象となった部分の全体に占める割合，精度はその中で正しかった割合を表す．

表1に実験を通しての各処理段階及び全体の結果，図7に結果の推移を示す．

表 1: 実験結果

処理段階	(1)	(2)	(3)	(4)	(5)
1種キーワード	-	-	-	5.80	96.3
2種キーワード	-	-	-	18.9	88.6
拡張キーワード	-	-	-	0.297	84.5
カタカナ語	-	-	-	0.572	68.2
キーワード接続語	-	-	-	3.40	90.9
n支持語	-	-	-	27.7	88.3
最長一致法	-	-	-	39.3	63.4
全体	75.4	20.5	4.08	95.9	78.6

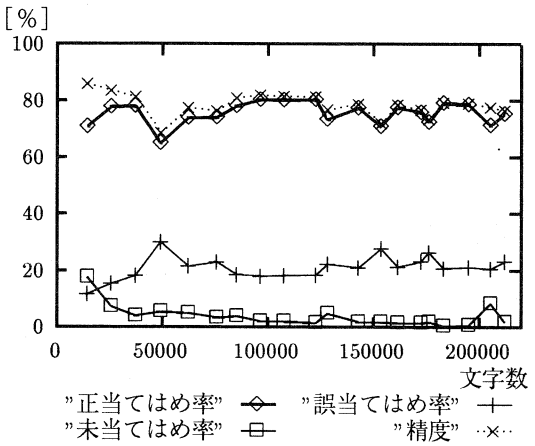


図 7: 当てはめ結果の推移

5.3 考察

表1に示すように，全体での正当てはめ率が75.4 %という結果になっている．この値は十分に満足できるとは言えないが，その原因としてはn支持語の当てはめを行った後の処理に問題があると言える．実際，最長一致法による処理における誤当てはめは全体の誤当てはめの7割を占める．逆にそこまでの当てはめ結果においては，占有率56.6 %，精度89.2 %となっておりキーワード並びに接続情報を用いた復元手法が有効に機能していると考えられる．今後全体の性能を向上させるためには，キーワードやn支持語などでより多くの語を扱えるように手法を改良すること，さらに新たなヒューリスティクスの導入をはかる必要などがある．また，誤りの原因として英単語，アルファベット，数字，記号などの扱いがある．今回は，これらを仮名に読み下してデータとしている．しかし，英語やアルファベットは読み方に揺れがあると考えられ，数字や記号には語の共起関係があまり存在しない．このためにこれらの部分がうまく処理できないことが多い．これらに関しては，今後の検討を要する．

本実験では辞書が空の状態から学習により徐々に語や接続情報を獲得していくが，正当てはめ率，精度はほぼ同じ値を維持している．結果が向上していかない原因として，接続情報が飽和しないことが挙げられる．今回用いた論文20編において，分野の同じ10編づつの中で語についてはほぼ飽和している．しかし，接続情報として存在し得る組合せは膨大なものとなり，飽和させるためにはさらに大量のデータを必要とする．このため，現実的には，対象とするデータに制限を加えて接続情報を飽和させることが重要である．例えば，かな漢字変換システムにおいて有効であるユーザへの適応 [10] が考えられる．使われる接続情報は1人のユーザに限定すればかなり限定されていることが予想されるからである．これについては今後の課題である．しかしながら，飽和していない状態においても接続情報を用いた語の当てはめは占有率31.1 %，精度88.6 %を示しており，学習に伴い占有率は徐々に上昇している．扱う語が増えるにつれて曖昧性が向上することを考えると十分有効であるといえる．次に未当てはめ率であるが，最初の段階で比較的多かった未当てはめ率は30,000文字程度の学習で5 %以下になる．語については飽和することが裏付けられる．

表2に復元結果の例を示す．この例は機械工学関連の論文の10編目の一部であり，正当てはめ率，精度共に約92 %である．誤りも何ヶ所かあるがほとんどが残りの部分の当てはめによるものである．この例では，キーワード接続語として“数値計算”が決定されている．これはキーワードと関連のある語による複合名詞であり，接続情報により扱うことを期待していたものである．また，n支持語により“明らかになった.”，“されることを示し,”などが決定されている．これも接続情報を用いる目的の一つであった短い語の連続を扱ったものである．キーワード接続語，n支持語の当てはめにはこのような語が多く用いられており．以上のことから，接続情報を利用することにより単語レベルでは扱いにくい，複合名詞，定型の表現などを扱えることが示された．

表 2: 復元結果の例

1.	正しい文書 (3) この方法を一つの対角線に関して対称な (凸形) 四辺形膜に適用して振動の固有値と振動形を数値計算した結果, 四辺形膜の偏平度の振動に与える影響が定量的に明らかになった. (4) 同じ形状を有する単純支持板と膜の振動が同一の方程式と境界条件に支配されることを示し,
2.	復元結果 / (//3/[)](この)[方法](を)(一つ)(の) (計)[縦線](に)(関し) (て)[対称](な)[(]#凸#(型)[ )][四辺形]/膜//に/[適用](して)[振動]/の/(と)(溶液)(を) [振動] (型)(を)[数値]#計算#/した/@結果@/, /[四辺形]/膜/(の)/偏平/ (゜)(の)[振動]/に//与え/(る)[影響]/が//定量//的//に/[明らか]/に//な//っ//た//. /[(]/4/[)] /を/(はじ)[形状]/を//有//す/(る)(単純)/支持/(板) (と)/膜// の/[振動]ha[同一](の)[方程式](を)/境界//条件/(に) (し) (ない) (され)(る)/こと//を//示//し//, /

@@：1 種 KW，[]：2 種 KW，##：KW 接続語，
//：n 支持語，()：残りの部分
※ 復元結果で下線部は誤当てはめを示す

6 おわりに

本稿では，誤りを含む文字列を復元する手法として，従来から利用していた語レベルの統計的な確実性のみでは十分精度良く決定できなかった部分に対処するために接続情報の利用を考え，接続情報を用いて語を階層化する手法，語の当てはめを行う手法を提案した．さらに，本手法に基づく実験システムを構築し，評価実験を行った．実験の結果，接続情報を用いた手法において約 90 %の精度が得られた．また，目的とした曖昧性の高い短い語に関しても定型的な表現の形で決定できることが分かり，本手法の誤りを含む文字列の復元における有効性が確認された．

今後は，接続情報のみではうまく決定が行えず，今回の実験でも多くの誤りを起こした部分に関して有効な接続情報の利用法の考察，さらには新たな情報の導入などを行う予定である．

参考文献

[1] 古井：“ディジタル音声処理”，東海大学出版会，(1985).

[2] 下村，並木，中川，高橋：“最小コストパス探索モデルの形態素解析に基づく日本語文誤り検出の一方式”，情処論，Vol33,No4,pp.457-464(1992).

[3] 伊東，丸山：“OCR 入力された日本語文の誤り検出と自動訂正”，情処論，Vol33,No5,pp.664-670(1992).

[4] 三部，大森：“信頼性の低い文字認識結果に対する言語情報を用いた誤認識文字の訂正”，情処論，Vol34,No10,pp.2117-2124(1993).

[5] 村上，荒木，池原：“日本語文音節入力に対して 2 重マルコフ連鎖モデルを用いた漢字かな混じり候補の抽出精度”，信学論，D-II,J75-DII,1,pp11-20(1992).

[6] 荒木，宮永，栃内：“多段階分割復元法による誤りの多い文字列からの原文の復元”，情処論，vol30,no2,pp.169-178(1989).

[7] 神野，荒木，宮永，栃内：“誤りを含む文字列からの復元手法における接続情報の利用”，信学技報，nlc94-5,pp.31-38(1994).

[8] 本間，山階，小橋:“連語解析を用いたべた書き文のかな漢字変換”，情処論，Vol.27, No.11,pp.1062-1068(1986).

[9] 相川，杉山，鹿野：“トップダウン処理による音韻認識”，NTT 研究実用化報告第 32 巻第 11 号，pp2281-2292(1983).

[10] 栃内，岡沢：“適応型変換辞書方式かな漢字変換システムの性能評価”，情処論，Vol.26, No.4, pp.733-739(1985).