1 英語文章における照応解析のための ヒューリスティクスに関する考察

†佐藤 嘉高 ‡荒木 健治 †宮永 喜一 †栃内 香次

†北海道大学 工学部 ‡北海学園大学 工学部

1 はじめに

文章や対話の構造を解析し計算機上にモデル化することは，自然言語理解における重要な課題の一つである．その解析やモデル化の際に問題となる要因の一つに自然言語の持つ曖昧性があり，文章に内在する曖昧性はその表層において種々の言語現象となって現れる．我々はその言語現象の一つである照応を解析することの重要性に着目し，特に代名詞の指示対象をどのように同定するかについて研究を行なっている．本稿では，まず2章で本研究の概要について述べ，3章でシステム化に先立ち行なったヒューリスティクス抽出のための実験結果について述べ，次に4章でそのルールの分類を行ない，5章で照応範囲決定のためのアルゴリズムについて考察する．

2 概要

照応の解析のためにはあらかじめ背景知識をシステムに与えておく必要がある[4]．我々はこれに対してルールや知識の量を極力少ないものにすることを目指している．そのために本研究では，まず単純なアルゴリズムによる照応解析の実験を行なう．次にその結果を調査することにより，照応処理のためにはどのようなルールが必要かを考察した．

3 照応関係の解析

照応の対象を正しく判断するために，どのようなルールや処理が必要となるかを調べるため，以下の仮定を立てた．

- 照応元の単語は，指示代名詞と人称代名詞のみ
- 照応先の単語は，照応元の単語を含む文の直前の文の主題とする．
- その文中で最初に出現する名詞を文の主題とする．

ヒューリスティクス抽出のためのアルゴリズムを以下に示す．

1. 文を1文読み込み，その主題を決定，表示する．
2. 文中に指示代名詞または人称代名詞があった場合，その照応先(前文の主題)を表示する

上述のアルゴリズムに基づくシステムを作成し，実験を行なった．その結果に対して人手により代名詞の照応先が正しいかどうかを判断し，誤っているものに対してその原因を考察した．実験の対象とした文は英文和訳の問題集[1]である．この結果を表1に示す．

4 考察

解析結果を，まず

1. 被照応の範囲と照応処理起動のタイミング
2. 語彙的情報について
3. 主題の抽出について

の3つに分類した．本稿ではこのうちの1と2についてのみ対象とする．以下に3章の条件の元で照応先の同定に失敗したものの原因について述べ，それらをどのように解決するかは，4章で考察する．

4.1 被照応の範囲と照応処理起動のタイミング

被照応の範囲と照応処理起動のタイミングに関するものについて以下に列挙する．

1. 被照応語の検索範囲が不適当

   実験では，文を1つずつ読み込んだ時点で，文単位で処理プログラムを起動していた．このプログラムが照応の対象として扱えるのは前文以前の文中の単語のみである．したがって，例えば
   When *Bill* saw *Linda*, *he* greeted *her* with a smile.[2]
   のように，照応元の単語と同じ文中に照応先の対象がある場合に，照応先を正しくとらえることができない．

2. 被照応の範囲について

   ある単語が照応する対象として，単語のみしか考慮していなかったが，予備実験の結果を見ると句や文などが照応対象となる文が存在した．

3. 後方参照

   実験では，照応の対象を前方に検索していた．したがって，例えば
   After *he* left *his* office, *Joe* went to the bookstore.
   のように，代名詞があとに出る語(句)を指す後方参照[2]については，照応の対象を発見することが不可能である．

4. その他

   以下のものは分析やシステム化がかなり困難なことが予想される．

   - it が会話文(直接話法)の内容を指す
   - "the two people" や "professional, amateur" を they で受ける
   - 名詞並列句中の名詞句を単数の代名詞で受ける

4.2 語彙情報に依存するもの

照応する単語に対してあらかじめ与えておくデータに関係する，または各単語に固有の問題と考えられるものについて以下に列挙する．

1. 多品詞語の品詞選択

パラグラフ数	文数	単語数	照応回数	正照応数	正照応率(%)
50	496	8030	815	186	22.8

表 1: 実験文のデータ

ある多品詞語が, 照応する品詞としない品詞の両方を持つ場合, 字面のみからは照応するかしないかを判断することができない. 抽出した中での具体例は以下の二つである.

- that : 指示代名詞 (照応する) /関係代名詞 (照応しない)
- one : 指示代名詞 (照応する) /形容詞 (数詞)(照応しない)

2. 照応する/しないカテゴリーの区分

代名詞をさらに 6 種類に細分類し [2, 3], 単語を辞書に登録する際に, 以下の分類に従い品詞情報を与えている.

照応するカテゴリー :指示代名詞, 人称代名詞

照応しないカテゴリー :再帰代名詞, 疑問代名詞, 不定代名詞, 関係代名詞

この分類の根拠が明確でなかったので, 本研究で扱う照応処理を詳細に定義し, 範囲を限定する必要がある.

3. 単語に対し細分類を付与する

例えば, 名詞の複数形を単数の代名詞で照応すると解釈するなど比較的簡単に改良が可能と考えられるものが多数あった.

4. it に関するもの

it の指示代名詞以外の用法が多かった. 以下に示す.

(a) 形式主語 : あとに来る名詞, to 不定詞, 動名詞, 名詞節を代表する

(b) 強調構文 : It is ～ that/who ～

5. 代名詞の指示形容詞的用法

指示代名詞が形容詞的に使用される場合, 照応元は代名詞と考えるよりも後続の名詞であるとするのが妥当である.
ex. We propose a method(*1).
This method(*2) is .....
this が method(*1) と照応するのではなく, method(*2) が method(*1) と照応する

6. その他

以下のものは解析やシステム化が困難であると考えられる.

- 擬人法 (ex. dog を he で受ける)
- 会話文中で人称が変化する代名詞の照応

5 得られたヒューリスティクス

5.1 照応検索範囲の変更

単語を 1 つずつ読み込みそれが『照応するカテゴリー』であった場合に, その単語より前に出現した全ての名詞を照応先の候補として扱えるように変更する.

5.2 単語に対し細分類を付与する

照応先の候補の幅をできるだけ簡略な手法でかつ少ないデータ量で狭めるために前述の単語の品詞分類をさらに詳細化する. 詳細分類としては既存の辞書等で一般的に用いられている分類が望ましく, 以下を採用することを考えている.

- 性 (男性, 女性, 中性)
- 数 (単数/複数)
- 人称 (1,2,3)
- 格 (主格, 所有格 など)

6 おわりに

6.1 まとめ

照応解析に必要なヒューリスティクスを得るための実験を行なった. この実験の結果から, 代名詞の照応先の同定にはどのようなルールに基づき解析を行えばよいのかを調査した.

6.2 今後の課題

照応するカテゴリーの再確認 現時点では, 6 種に細分類した代名詞のうち指示代名詞と人称代名詞のみを照応元として扱っている. これを『照応』の詳細定義と本研究で扱う範囲の限定に伴い再確認する必要がある.

被照応の範囲について 代名詞の照応の対象は, 表層では, 単語, 句, 節, 文, 文脈の 5 種類の異なった大きさをもつと考えられる. しかし, 本来照応は意味的な現象なので, 表層での大きさの範囲と真の照応先が一致するとは限らない [5]. この点に関しても検討する必要がある.

参考文献

[1] 伊藤和夫
英文和訳演習 (入門編, 基礎編, 中級編), 駿台文庫 (1989).

[2] 安藤貞雄, 樋口昌幸 (共編)
英文法小事典, 北星堂書店 (1991).

[3] 安藤貞雄, 樋口昌幸, 鈴木誠一 (共編)
言語学・英語学小事典, 北星堂書店 (1990).

[4] Zadrozny, W. and Jensen, K.
Semantics of Paragraphs, *Computational Linguistics*, vol.17, No.2, pp.171-209 (1991)

[5] Halliday, M.A.K. and Hasan,R.
Cohesion in English, Longman, London and New York (1976)

連絡先: 佐藤 嘉高
060 札幌市北区北 13 条西 8 丁目
北海道大学工学部 電子工学科 電子機器工学講座
Tel.011-706-6823 e-mail: sato@hudk.hokudai.ac.jp