2 後方隣接語を利用した英語テキストのタギング

Algorithm for Part-of-Speech Tagging

ファルディ. アクサヌル† 荒木 健治†† 宮永 喜一† 栃内 香次†
Aksanul Fardhi † Kenji Araki †† Yoshikazu Miyanaga † Koji Tochinai †
† 北海道大学工学部 †† 北海学園大学工学部
† Faculty of Engineering, Hokkaidō University †† Faculty of Engineering, Hokkai-Gakuen University

1 はじめに

ある単語のある文での品詞は、その単語のその文での役割を表す. 英語では、複数の品詞を持った単語が多く存在し、このような単語の意味の正しい理解はその単語の任意の文での品詞がどれだけ正しく決定できるかに依存する. ある単語の品詞を予測することをタギング(TAGGING)という.

タギングシステムは、大きく分けると、二つのタイプが今まで提案されてきた. 一番目のタイプは、全ての単語がタグ付(tagged, 品詞が決定済み)のコーパスから頻度データをとり、これに基づき実験データをタグするタイプのタギングシステムである. 二番目のタイプは、生(raw, 品詞が当てはめられていない)のコーパスから頻度データをとり、これに基づき実験データをタグするタイプのタギングシステムである[5].

我々の提案する手法は、品詞に対する単語の頻度データ[2]や品詞の組合せの頻度データ[4]を利用しているので一番目のタイプである.

2 本手法の概要

ある文の任意のi番目の単語w_iの品詞t_iを予測しようとする. このw_iの品詞としてもっとも頻度の高いいくつかの品詞を一番頻度の高い品詞から順に並べ、品詞集合にまとめ、その集合をt_{w_i}とする.

$$t_{w_i} = \{x_{i1}, x_{i2}, \ldots, x_{ir}\}$$

ただし、$C(x_{iq}, w_i)$を単語w_iがx_{iq}という品詞で現われる頻度とすると$C(x_{i1}, w_i) \geq C(x_{i2}, w_i) \geq \cdots \geq C(x_{ir}, w_i)$であり、頻度の等しい場合はアルファベット順に並べるとする. 尚、これらの頻度データは[2]に載っている.

次に、同じ文の$i-1$番目の単語w_{i-1}の品詞t_{i-1}は当然既にわかっている. このt_{i-1}の次に現われる可能性のある品詞の中からいくつか頻度の高い品詞から順に並べ、品詞集合にまとめ、その集合を$t_{t_{i-1}}$とする.

$$t_{t_{i-1}} = \{y_{i1}, y_{i2}, \ldots, y_{is}\}$$

ただし、$C(y_{ip}|t_{i-1})$を品詞y_{ip}が品詞t_{i-1}の後に現われる頻度とすると$C(y_{i1}|t_{i-1}) \geq C(y_{i2}|t_{i-1}) \geq \cdots \geq C(y_{is}|t_{i-1})$であり、頻度の等しい場合はアルファベット順に並べるとする. 尚、これらの頻度データは[4]に載っている.

更に、以下のアルゴリズムを紹介する.

1. if $i = 1$ then
   - x_{11}をそのまま当てはめる(Charniak,1992).
   - 6(終了)に移る.
2. t_{w_i}の中からもっとも頻度の高い品詞を選ぶ.
   それを$x_{in}(1 \leq n \leq r)$とする.
3. if $n = r$ then
   - 5に移る.
4. if $x_{in} \notin t_{t_{i-1}}$ then
   - x_{in}をt_{w_i}からはずす.
   - 2に戻る.
5. x_{in}をw_iの品詞t_iとして決定する.
6. 終了.

3 実験

本手法に基づく実験システムを作成し、実験を行なった. 入力文は、[6]の9ページからとったものであり、34文合計589単語が含まれている.

rパラメータは、特にある数字に固定されていない. 従って、任意の単語が持った品詞を全て考慮する.

sパラメータは、10にする. しかし、今回の実験では頻度データを取った資料が不十分だったため、次にくる品詞が限定されているものもある. 従って限定された数をmとすると$m < s$となる場合がある. このような品詞の場合のみsを$s = m$にする.

結果は、65.37%が正しく当てはめられた.

4 考察

本手法は、短い文の単語の品詞を予測するにはよい結果が得られたが、長い文になるとよい結果が得られない. 実験の結果を見ると、システムの失敗もほとんど長い文に起きた. 例えば、「They treat patients」という文でのtreatという単語の品詞は正しく動詞と予測することができた. しかし、「The people who care treat them」という文でのtreatの品詞は名詞と予測されてしまった.

5 おわりに

現在の我々の手法は、文の単語を1番目からn番目まで順番に決定していくものである. しかし、これは人間が行なっているタギングと異なる. 少なくとも我々の経験とは異なる. 我々の経験によると、i番目からn番目まで一つずつ決定していく前に、予めいくつかのキーワードを決めておいてから、そのキーワードのまわりの単語から決定するのが容易である. これを今後の課題にしたい.

参考文献

[1] *Charniak, E., Hendrickson C., Jacobson N. & Perkowitz M.* Equations for Part-of-Speech Tagging, Department of Computer Science, Brown University, 1992.

[2] *Francis, W. N. & Kučera, H.* Frequency Analysis of English Usage, Houghton Mifflin, Boston, 1982.

[3] *Johansson S. & Hofland K.* Frequency analysis of English vocabulary and grammar, Vol. 1: Tag frequencies and word frequencies, Clarendon Press, Oxford, 1989.

[4] *Johansson S. & Hofland K.* Frequency analysis of English vocabulary and grammar, Vol. 2: Tag combinations and word combinations, Clarendon Press, Oxford, 1989.

[5] *Kupiec, J.* Robust part-of-speech tagging using a hidden Markov model. Computer Speech and Language, Vol. 6., pp.225-242, 1992.

[6] *Rooney, A. A.* Word for word. Berkley Books, New York, 1987.

[連絡先:ファルディ. アクサヌル(Aksanul Fardhi)
〒060北海道札幌市北区北13条西8丁目
北海道大学工学部電子工学科電子機器工学講座
Tel.(011)706-6823, E-mail aksa@hudk.hokudai.ac.jp]