D-64

英文における照応解析のための単語分類手法

A Method of Classifying Words for Interpreting Anaphora in English Texts

佐藤 嘉高† 荒木 健治‡ 宮永 喜一† 栃内 香次†
Yoshitaka SATO† Kenji ARAKI‡ Yoshikazu MIYANAGA† Koji TOCHINAI†

†北海道大学 工学部
†Fac. of Eng, Hokkaido Univ.

‡北海学園大学 工学部
‡Fac. of Eng, Hokkai-Gakuen Univ.

1 はじめに

文章や対話の構造を解析し計算機上にモデル化することは，自然言語理解の分野における研究課題の一つである．その際，文章の主題は表層ではキーワードを中心として表現されるが，文章を書く立場から見れば同じ単語を繰り返すことを避け，代名詞を使用して言い換えを行なう．したがって，代名詞が文中のどの単語を指示するのかを正しく判断することは，文章の主題を把握する上で極めて重要な問題といえる．この照応の解析のためにはあらかじめ背景知識をシステムに与えておくというアプローチが一般的である [1]．しかし，そのために知識をどのような形式で，またどの程度の分量を用意すれば必要かつ十分なのかを決定的に判断することは難しい．我々は，これに対して，計算機上で照応解析のシステムを構築するためには，文章の実例を調査することによって種々の知識を蓄積し，段階的にシステムを構築する，という方法が妥当であると考え，特に英語の文章において代名詞の指示対象を正しく同定するためにはどのようなルールに基づいて処理を行なえばよいのかについての研究を行なっている [3]．

本稿では，3人称単数の人称代名詞の照応解析について，特に単語の属性及びそれらの検索方法について考察する．

2 本研究の目的と概要

人称代名詞に対しては，通常はテキスト中に性，人称，数，の一致する照応先が存在するはずである [2]．先に我々が行なった調査 [3] においても，名詞にあらかじめこれらの属性を付加することによってこれらの照応先の単語を，単語の属性が一致するまで前方にさかのぼり検索を繰り返すという単純なアルゴリズムで he, she それぞれ 86, 80 % の正照応率を得た．

本稿ではその he 及び she に対象を限定し，先の結果に対しさらに正照応率を上げることを目的とし，人称代名詞の照応解析のために必要な単語の属性及びその処理手法について考察する．

3 複数のルールに基づく照応解析の問題点

先に我々は英文和訳の問題集 [4] を対象にしていくつかのルールに基づいた実験を行なった [3]．

この実験では，その結果の一つとして，照応先同定のために複数のルールを同時に採用することが有効と考えられるが，それらのルールをどのように組み合わせるかは困難な課題である [5]，ということが判明した．

複数のルールを逐次的に採用して処理を行なう場合，例えば，照応先同定のためのルールとして A,B,C の 3 つを考え，A で失敗したら B, その次に C，というように処理することを考えた場合，最初のルール A で何らかの名詞を照応先と決定できた時に，その正誤の判断を自動的に行なうのは難しい．また仮に正誤の判断ができたとしても，ある一つの代名詞がその照応先を同定するための統一的な複数のルールの適用順序は一意に決定することはできない．例えば，he の照応先同定のためにはどのような場合においてもルール B,A,C の順で処理すればよい，というようには決定することができない．

そこで，この点に関し我々はルールに関しては単一のアルゴリズムに基づいた処理を行ない，単語に与える属性を工夫することを試みた．

4 単語の品詞とその分類

電子化された辞書などの資産の利用を将来的に考えた場合，辞書データとして単語にあらかじめ与えておく情報は，一般に用いられているものと同じものであることが望ましい．従って本研究においても単語に与えるデータとして品詞といくつかの属性値を用意している．このうち名詞に関しては一般名詞か固有名詞かという品詞分類 [6] をし辞書に登録している．前述の，照応解決をより精密なものにするために属性値を与えるということは，換言すれば照応される名詞を何らかの形で分類しておくことに相当する．しかし，そのための最適な分類はどのような形式になるかを照応解決処理に先立ち決定することは困難である．また，分類形式の複雑化に伴い辞書にあらかじめ必要なデータ量も増大することになり，望ましいとは言い難い．この問題に対し本研究では，対象を3人称単数の男性・女性の人称代名詞，すなわち he と she に限定した．照応先は表層では一般に名詞句の構造であるが，処理を簡便なものにするため構文構造が参照可能であることを想定し，本稿では照応先の対象を名詞一語にする．文を読み込んだ時点で，その中に含まれる名詞に対して，もし，その名詞が照応されるとしたら，he, she, it のどれにより参照されるのかを明示的に与えておく．単語によっては3つのうち1つに限定できないものもあるので，優先度を含む形で名詞をグループ化しておく．

実例を以下に示す [4]．

- But when Mickey Mouse appears on the screen, ...
- Yet like the cowboy, he moves and talks.

2文目の he は，本来は"Mickey Mouse" を照応するものだが，前述のルールを用いた解釈ではその直前の"cowboy" を照応先と判断してしまう．このような場合を正しく判断するために，照応処理の過程において，照応先の名詞の候補の中から絞りこむ際に

- 固有名詞と一般名詞との間にその優先度に差をつける．
- 文の主題となる名詞を優先的に選択する．

などの手法を用い，名詞の配列の中から照応先の名詞として1つを取り出すことを考えている．

5 おわりに

今後は，文献 [3] で行なった実験結果との比較のための実験を行ない，正照応率がどの程度上昇するか，また新しくデータを詳細化したことで誤りが増大することがないかを確かめる予定である．また，人称代名詞以外の代名詞に対する本手法の応用についても考察する予定である．

参考文献

[1] Zadrozny, W. and Jensen, K.: Semantics of Paragraphs, *Computational Linguistics*, vol.17, No.2, pp.171-209 (1991).

[2] Carter, D.: Interpreting Anaphors in Natural Language Texts, Ellis horwood limited (1987).

[3] 佐藤嘉高，荒木健治，宮永喜一，栃内香次: ヒューリスティクスを用いた照応解析手法，信学技報 NLC 94-32, pp. 25-30 (1994).

[4] 伊藤和夫: 英文和訳演習，駿台文庫 (1989).

[5] 山村 毅，大西 昇，杉江 昇: 日本語文の照応問題解決システム，信学論 Vol.J73-D-II,NO.6, pp.887-896 (1990).

[6] 安藤貞雄，樋口昌幸（共編）: 英文法小事典，北星堂書店 (1991).