154 実例からの帰納的学習による因果関係の推定

Presumption for Causal Relation Using Inductive Learning from Examples

－ 同音異義語の自動選択への応用 －

－ Application for Automatic Japanese Homonym Selection －

荒木 健治† 栃内 香次††
Kenji Araki† Koji Tochinai ††

† 北海学園大学工学部 †† 北海道大学工学部
† Fac. of Eng., Hokkai-Gakuen Univ. †† Fac. of Eng., Hokkaido Univ.

1 はじめに

日本語処理システムが広く用いられるようになってきたが，依然としていくつかの問題が残されている．特に，処理が高度化するにつれて必要とする情報量は膨大となっている．このような状況のもとでは，計算機の能力を最大限に生かすために必要最小限の情報を適宜蓄えて置くことは精度及びコストの両面から重要な問題である．我々は，この問題を解決するために従来より実例からの帰納的学習を自然言語処理に応用する試みを行なっている [1, 2]．本稿では，べた書き文のかな漢字変換における同音異義語の自動選択への帰納的学習の応用について述べる．

2 背景

我々は人間が持つ言語及び知識を獲得する生得的な能力を解明し，これを工学的に応用することを目的として研究を行なっている．これまでの研究で行なわれたことは，(1) 未知文字列からの語の獲得と認識 [1]，(2) 二つの対応関係を有する未知文字列からの対応関係の獲得 [2]，(3) 言語理解を行なうヒューリスティクスの解明 [3] である．生得的能力実現の目的から言えば，(1),(2) は幼児が言語を獲得していく過程に基づくボトムアップからのアプローチである．一方，(3) は成人の言語理解に用いられる知識を明らかにすることにより生得的能力を解明するもので，トップダウンのアプローチである．本稿で提案する手法は，前者のアプローチの第 3 段階で，実例から原因・結果の因果関係を獲得するメカニズムを解明し，これを工学的に応用することを目的としている．

ここで獲得すべき因果関係は工学的な立場からは，必ずしも人間が獲得するものと一致する必要はない．すなわち，システムが学習を初めて間もない段階では，少ない実例と乏しい知識しか持ち合わせてはおらず，この状態で人間が持つ膨大な知識から導き出される因果関係を常に正しく決定することは極めて困難である．したがって，実例から因果関係を獲得する場合には，それまで与えられた実例だけの閉じた世界の因果関係のみを満たすルールを獲得することを考える．学習機能を有するシステムでは，ルールは新たな実例が入力された段階でその世界を満足するように学習機能によって新たに生成され処理対象に適応する．したがって，このようなシステムは，少ない情報量で特定の個人あるいは分野に膨大な情報量と同程度の性能を示すことが可能なので，工学的に非常に有効なものとなり得る．また，幼児も知識が不十分な段階では，新たな情報に対してそれまでの知識に新たな情報が加わった世界を満たすルールを次々に生成しながら学習を繰り返し，一般的な正しいルールを獲得するという処理を行なっていると考えられるので，このような手法の開発は幼児の学習過程の解明という意味で科学的な立場からも有効であると考えられる．

本稿で提案する手法は，新たな入力に対して既存のルールで説明できない時，改めてルールを生成し直す．しかし，このような手法では，可能性が非常に多くなり，組合せの爆発を起こす．したがって，これを防ぐために可能性を制約する必要がある．これを行なうのはヒューリスティクスである．ここでは，このようなヒューリスティクスは与えられたものとし，ヒューリスティクスの獲得のメカニズムの解明は別のテーマとして研究を進める．上述した手法の一つの応用としてべた書き文のかな漢字変換における同音異義語の自動選択を考える．

3 共起関係の帰納的学習

同音異義語の自動選択については，頻度情報を利用するもの，前後 1 文字の情報を利用するもの [4]，共起する単語の情報を利用するもの [5] など種々の研究がある．中でも，共起する単語の情報を利用する手法は，頻度情報などの確率的手法に比べ，人間の同音異義語の選択過程に類似しているので，高い精度で同音異義語を決定できる有望な手法である．

しかし，これらの手法は，万人に共通の固定された情報を辞書に記録することによりすべての人が高い精度で使うことのできるシステムを作成することを目的として開発されたために，その手法が利用する情報量は膨大となるという問題がある．しかし，個人あるいは特定分野に限って言えば，必要とする情報量は比較的少なくて済み，しかも高い精度が得られることが確認されている [6]．

本稿で提案する手法は実例から帰納的に共起関係を学習することにより同音異義語の選択を行なうものである．したがって，本手法は動的に個人あるいは特定

分野に適応することができる．このことは，本手法が比較的少数の情報により多くのユーザあるいは種々の分野に適応でき，従来の静的な手法で膨大な情報を用いた場合と同程度の性能を得ることができる可能性を示している．

4 同音異義語の選択方法

$aBcd$ 及び $eFcd$ の二つの文のみ存在する世界を考える．ここで，a,B,c,d,e,Fは一語を表し，B,Fが同音異義語であるとする．このとき，この二つの文の同音異義語以外の差分を取ると (a,e) である．したがって，B,Fとなる原因は，(a,e) にあると推定され，以下のような因果関係が得られる．

- $a \Rightarrow B$
- $e \Rightarrow F$

また，$aBcd$ 及び $eFgd$ の二つの文の存在する世界を考える．この場合には，差分が (a,e)，(c,g) の二つ存在するので，以下のような因果関係が考えられる．

1. 因果関係が存在しない．
2. a,c,e,gのうち一つが原因
   (a) $a \Rightarrow B$
   (b) $e \Rightarrow F$
   (c) $c \Rightarrow B$
   (d) $g \Rightarrow F$
3. a,c,e,gのうち二つが原因
   (a) (a,e) が原因
   $a \Rightarrow B, e \Rightarrow F$
   (b) (c,g) が原因
   $c \Rightarrow B, g \Rightarrow F$
   (c) (a,g) が原因
   $a \Rightarrow B, g \Rightarrow F$
   (d) (c,e) が原因
   $c \Rightarrow B, e \Rightarrow F$
4. a,c,e,gのうち三つが原因
   (a) (a,c,e) が原因
   $a \Rightarrow B, c \Rightarrow B, e \Rightarrow F$
   (b) (a,c,g) が原因
   $a \Rightarrow B, c \Rightarrow B, g \Rightarrow F$
   (c) (c,e,g) が原因
   $c \Rightarrow B, e \Rightarrow F, g \Rightarrow F$
5. a,c,e,gのすべてが原因
   $a \Rightarrow B, c \Rightarrow B, e \Rightarrow F, g \Rightarrow F$

これらのうちのどれが正しいのかはこれだけの例からは決定できない．すなわち，この二つの実例だけの世界では，このような曖昧さが残る．そこで，まず a,c,e,gすべてが因果関係を有すると仮定する．すなわち，以下のような因果関係を仮定する．

- $a \Rightarrow B$
- $e \Rightarrow F$
- $c \Rightarrow B$
- $g \Rightarrow F$

このような世界に $eFcd$ のような文が加えられると $aBcd$ より c は B,Fを識別するための指標とはなり得ないことがわかる．その結果，上記の因果関係の曖昧さは以下のように減少する．

- $a \Rightarrow B$
- $e \Rightarrow F$
- $g \Rightarrow F$

また，この世界にさらに $hBcd$ のような文が加わると $eFgd$ より h も Bの原因となり得ることがわかる．したがって，この世界での因果関係の可能性は以下のようになる．

- $a \Rightarrow B$.
- $e \Rightarrow F$
- $h \Rightarrow B$
- $g \Rightarrow F$

このような操作を繰り返すことによりそれまでに与えられた実例の世界を対象とした同音異義語を決定するための共起関係を帰納的学習により獲得し，個人あるいは対象分野に動的に適応することができる．

5 おわりに

実例から帰納的学習により因果関係を推定する方法について，同音異義語の自動選択への応用を例として述べた．本手法の有効性は，学習が効率良く行なわれるような実例が実際の文章中にどれくらい頻繁に存在するかに依存する．したがって，今後は同音異義語が存在する文を収集することにより，本手法の可能性を評価し，その上で本手法に基づく実験システムを完成し，どの程度少ない情報量でどの程度の精度の同音異義語の選択が行なわれるのかを評価する予定である．

参考文献

[1] 荒木、栃内："帰納的学習による語の獲得および確実性を用いた語の認識"、信学論 $(D-II)$, **J75-D-II**,7,pp.1213-1221(1992-07).

[2] 荒木、高橋，桃内，栃内："帰納的学習によるべた書き文のかな漢字変換手法の適応能力の評価"、信学技法, **NLC94**,3,pp.17-24(1994).

[3] 荒木、桃内 : "ヒューリスティクスを用いた意味ネットワークの自動生成"、信学技法, **NLC94**,10,pp.23-30(1994).

[4] 栃内，伊藤，鈴木："前後連接文字を利用した同音語選択機能を有するかな漢字変換システム"、情処学論, **27**,3,pp.313-320(1986).

[5] 山本，久保田："共起グループを用いたかな漢字変換"、情報処理学会第 44 回全国大会講演論文集,3,pp189-190(1992).

[6] 栃内香次，岡沢好高 : "適応型変換辞書方式かな漢字変換システムの性能測定"，情処学論，**26**, 4, pp.733-739(1985).