156 英語テキストのタギングにおけるキーワードの利用

The Utilizing of Keyword To Shorten The Chain of Word in English Text Tagging

ファルディ・アクサヌル† 荒木 健治†† 宮永 喜一† 栃内 香次†
Aksanul Fardhi † Kenji Araki †† Yoshikazu Miyanaga † Koji Tochinai †
† 北大工 †† 北学園大工
† Faculty of Engineering, Hokkaidō University
†† Faculty of Engineering, Hokkai-Gakuen University

1 はじめに

ある単語のある文での品詞は、その単語のその文での役割を表す．英語では、複数の品詞を持った単語が多数存在し、このような単語の意味の正しい理解はその単語の任意の文での品詞がどれだけ正しく決定できるかに依存する．

ある単語の品詞を予測することをタギング (TAGGING) という．現在まで、大きく分けると、二つのタイプのタギングシステムが提案されてきた．一番目のタイプは、全ての単語がタグ付（tagged, 品詞が決定済み）のコーパスから頻度データをとり、これに基づき実験データをタグするものである．二番目のタイプは、生（raw, 品詞が当てはめられていない）のコーパスから頻度データをとり、これに基づき実験データをタグするものである ([3])．

本論文で我々の提案する手法は、品詞に対する単語の頻度データ ([1]) や品詞の組合せの頻度データ ([2]) を利用しているので一番目のタイプである．

2 本手法の概要

我々が今まで提案してきた後方隣接語手法 ([5]) は、文の単語を1番目から n 番目まで順次に決定していくものである．しかし、この方法だけではよい結果がなかなか得られないことがわかった．

その理由として挙げられるのは、単語列の長さである．すなわち単語列が長ければ長いほどそれが学習コーパスに存在しない可能性が高い．そのため、このような単語列は未知単語として処理されてしまう．

そこで、我々は予めその文のいくつかの単語をキーワードとして決めておき、残りの単語は従来の後方隣接語手法で品詞を予測するシステムの構築を試みた．ここで、キーワードの決定方法は以下の通りである．

ある単語 w_iに対し、もっとも頻度の高い品詞を t_1とし、その次に頻度の高い品詞を t_2とする．また、これらの品詞の頻度をそれぞれ f_1、f_2とすると、f_1と f_2が以下の関係を満たせば w_iはキーワードとして決定される．

$$f_1 > f_2 t$$

ただし、tはしきい値である．

3 実験

実験に用いた資料は、[4]の9～14ページからとったものであり、108文合計2002単語が含まれている．また、実験は、しきい値 tを0．00から1．00まで変えながら101回行なった．実験の結果，本手法を用いることにより101回のうち99回は80%以上の精度でタギングが行なわれることが確認された．

4 考察

キーワードを導入することにより長い単語列をいくつかの短い単語列に分割することができた．そして，短い単語列は学習コーパスと一致する可能性が高いのでタギングの精度を向上させることができた．このことは，本手法へのキーワードの導入が有効であることを示していると考えられる．

また、実験の結果しきい値は文毎のキーワード数と関係していることが確認された．しかし，しきい値があまり低いと決定されたキーワードが少なくなり、精度を向上させることができなかった．しきい値が高いときも同様のことが起きた．今回の実験では、タギングの精度の最高値の87．7%はしきい値が0．75～0．83のとき得られた．

5 おわりに

今回は後方隣接語手法にキーワードを導入により長い単語列を分割し、タギングの精度を向上させることに成功した．しかし、最適なしきい値は対象のデータにより変動するので，これを自動的に決定するなどの方法を導入する必要がある．これを今後の課題にしたい．

参考文献

[1] *Francis, W. N. & Kučera, H.* Frequency Analysis of English Usage, Houghton Mifflin, Boston, 1982.

[2] *Johansson S. & Hofland K.* Frequency analysis of English vocabulary and grammar, Vol. 2: Tag combinations and word combinations, Clarendon Press, Oxford, 1989.

[3] *Kupiec, J.* Robust part-of-speech tagging using a hidden Markov model. Computer Speech and Language, Vol. 6., pp.225-242, 1992.

[4] *Rooney, A. A.* Word for word. Berkley Books, New York, 1987.

[5] ファルディ、荒木、宮永、栃内：後方隣接語を利用した英語テキストのタギング、情報処理学会情報処理北海道シンポジウム'94講演論文集、pp.13 (1994)