D-678

後方隣接語出現確率に基づく英文のタギング

Next Word's Probability Based English Text Part of Speech Tagging

ファルディ・アクサヌル† 荒木 健治†† 宮永 喜一† 栃内 香次†
Aksanul Fardhi † Kenji Araki †† Yoshikazu Miyanaga † Koji Tochinai
† 北海道大学工学部 †† 北海学園大学工学部
† Faculty of Engineering, Hokkaido University †† Faculty of Engineering, Hokkai-Gakuen University

1 はじめに

ある単語のある文での品詞は、その単語のその文での役割を表す．英語では、複数の品詞を持った単語が多数存在し、このような単語の意味の正しい理解はその単語の任意の文での品詞がどれだけ正しく決定できるかに依存する．ある単語の品詞を予測することをタギング (TAGGING) という．

大きく分けると、二つのタイプのタギングシステムが提案されてきた．一番目のタイプは、ルールやアルゴリズムに基づくシステムである．二番目のタイプは、確率に基づくシステムである．

これまで、当研究室では、前者のタイプの手法の研究を進めてきたが、十分な性能が得られたとは言えなかった。そこで、我々は上に述べた後者のタイプである確率に基づくアプローチを試みた．これは、後方隣接語に基づくアルゴリズムとキーワードによる長い単語列の分割を用いるものである。本手法に基づく実験システムを作成し、２０００語程度の実験データを用いて実験を行なった。その結果、８０％以上の精度で品詞が推測できることが確認された [1]．しかし、２０００個程度の単語では本手法の有効性を確認するには不十分である。そこで１，１５７，２６０単語という大量のデータを用いて本手法の有効性を確認するための実験を行なった．本稿では、この実験結果について述べる．

2 本手法の概要

英語という言語における長さ n 単語の文の各単語の品詞を求めるには、次の式を満たす品詞列 $t_{1,n}$ を求めればよい [2]．

$$\mathcal{S}(w_{1,n}) = \arg\max_{t_{1,n}} P(t_{1,n} \mid w_{1,n}) \tag{1}$$

ここで、英語という言語が持つ品詞の数と単語の数をそれぞれ x と y とすると、

$$\begin{aligned} t_{i=1,n} \in T &= \{t^1, t^2, \ldots, t^x\} \\ w_{i=1,n} \in W &= \{w^1, w^2, \ldots, w^y\} \end{aligned} \tag{2}$$

である．

（１）式は、次のように展開することができる．

$$\begin{aligned} \mathcal{S}(w_{1,n}) &= \arg\max_{t_{1,n}} P(t_{1,n} \mid w_{1,n}) \\ &= \arg\max_{t_{1,n}} \frac{P(t_{1,n}, w_{1,n})}{P(w_{1,n})} \end{aligned} \tag{3}$$

（３）式の最大値は $t_{1,n}$ にしか依存しないので最大値は分子の最大値で決まる．

$$\mathcal{S}(w_{1,n}) = \arg\max_{t_{1,n}} P(t_{1,n}, w_{1,n}) \tag{4}$$

また（４）式での $P(t_{1,n}, w_{1,n})$ は、次のように展開できる．

$$P(t_{1,n}, w_{1,n}) = P(t_1 \mid w_1) \prod_{i=2}^{n} P(t_i \mid t_{i-1}, w_i) \tag{5}$$

この（５）式を（４）式に代入すると次のような式は得られ

$$\mathcal{S}(w_{1,n}) = \begin{cases} \arg\max_{t_i \in T} P(t_i \mid w_i), & \text{for } i = 1 \\ \arg\max_{t_i \in T} P(t_i \mid t_{i-1}, w_i), & \text{for } 2 \le i \le n \end{cases}$$

更に、未知の単語列の対策として、上の（６）式に重み α つけて次の式に変える．

$$\mathcal{S}(w_{1,n}) = \arg\max_{t_i \in T} \{\alpha P(t_i \mid t_{i-1}, w_i) + (1-\alpha) P(t_i \mid w_i$$

この（７）式を利用しシステムを構築した．

3 実験と結果

対象データとしては、ＬＯＢコーパスを用いた [3]．コーパを学習データ（４９０４１文１，０４０，４７５単語）と実験データ（５４４９文１１６，７８５単語）とに分けて、$\alpha = 0.8$ 定し、実験を行なった．実験の結果は、９５．９％の精度での推測ができることが確認された．

4 おわりに

本実験では、使われたデータがアルゴリズムに基づくシスの実験のときに使われたデータより大量であるにも関わらず結果が得られた．これは、この手法の有効性を示している．

今後の課題としては、学習データが大量に必要であること本実験では０．８に固定されている重み α の最適値をフィードク学習などで α 実験中に自動的に最適化する手法の開発などげられる．

参考文献

[1] ファルディ、荒木、宮永、栃内：英語テキストのタギにおけるキーワードの利用、電気関係学会北海道支部連会講演論文集、pp.176 (1994)

[2] *Charniak, E., Hendrickson C., Jacobson N. & Perk M.* Equations for Part-of-Speech Tagging, Departme Computer Science, Brown University, 1992.

[3] *Johansson S. & Hofland K.* Frequency analysis of En vocabulary and grammar, Vol. 1: Tag frequencies word frequencies, Clarendon Press, Oxford, 1989.