帰納的学習による機械翻訳手法への遺伝的アルゴリズムの適用

越前谷　博*・荒木健治*・桃内佳雄*

The Application of Genetic Algorithms to Machine Translation Method Using Inductive Learning

Hiroshi ECHIZEN-YA*, Kenji ARAKI* and Yoshio MOMOUCHI*

これまでに研究・開発されてきた多くの翻訳手法は，解析型の翻訳手法であり，その問題点については既に十分な研究が行われている。そこで明らかになった問題点を解決する手法として，近年，実例に基づく学習型の翻訳手法の研究が盛んになってきている。我々は従来からこの実例に基づく学習型の翻訳手法の利点と問題点を明らかにするための性能評価実験を行ってきた。本論文では，この実例に基づく学習型の翻訳手法に遺伝的アルゴリズムを適用し，より精度の高い翻訳システムを構築した結果及びその性能評価実験結果について述べる。

1．はじめに

文化・産業・経済・科学などの多方面に渡る国際化が進むにつれて，国際間における様々な情報の交流が増大し，それに伴い翻訳の需要も急増している。このような情勢下において品質の高い翻訳を遅滞なくかつ経済的に行うための手段の確立が強く望まれてきている。そうしたニーズに応えるべく多くの機械翻訳システムの研究が行われてきた[1)]。機械翻訳システムにおける研究・開発の多くは，原文を文法的に解析してから翻訳を行う解析型の翻訳手法である。しかし，解析型の翻訳手法では有限個の文法規則の設定という制限により例外的な言語現象に弱く，このことが辞書を巨大なものとせざるを得ない最大の原因にもなっている[2)]。このような問題を解決する手法として，翻訳する文とよく似た既知の文の翻訳例を模倣利用することによって翻訳を行う，すなわち，豊富な実例や翻訳例を参照することでより良い翻訳を得る，実

＊北海学園大学工学部電子情報工学科
＊Department of Electronics and Information Engineering, Hokkai-Gakuen University

例に基づく学習型の翻訳手法[3,4]が盛んに研究されてきている。我々は実例より翻訳ルールを学習し，その翻訳ルールを用いて翻訳を行う帰納的学習による機械翻訳手法[5]の提案とその性能評価実験[6]を行ってきた。その結果，熟語や慣用句に適応した翻訳を行えることが明らかになった。しかし，このような利点と同時に多様な翻訳ルールを得るには2つ以上の類似した実例を必要とするため，十分な翻訳ルールの抽出ができず翻訳が行えないという問題も生じた。本論文は，従来の帰納的学習による機械翻訳手法の利点を損なうことなく問題点を克服するために，遺伝的アルゴリズムを適用することでより精度の高い学習型機械翻訳システムの実現を目的としている。遺伝的アルゴリズム[7,8]はバラエティに富んだ個体を作り出しながら環境に適応するための世代交代を繰り返すことで高度なシステムへ向けて進化していくという生物の進化の過程を模倣したものであり，最適化問題や探索問題に対して最適解を速やかに得るための手法である。本論文では，翻訳ルールを個体として位置づけることにより翻訳ルールの交叉，翻訳ルールに対する適応度の決定とその適応度に基づく淘汰などの遺伝操作を行い，最適な翻訳を行うための多様化した良質な翻訳ルールの生成を図っている。このように学習型システムにおける知識獲得に遺伝的アルゴリズムの持つ環境に適応するための進化の過程を適用することで，システム全体が最適な翻訳を行うように成長し続け，精度の高い学習型機械翻訳システムを構築して行く。本論文では，そのシステムと実験による性能評価について述べる。

2．処理過程

本論文で提案する学習型機械翻訳システムの処理の流れを図1に示す。まず，原文である英文が入力されると，翻訳部においてそれまでに獲得された翻訳ルールを用い，翻訳結果である日本語訳文を生成する。次いで，フィードバック学習部において，翻訳結果と正しい日本語訳文との照合により翻訳に使用された翻訳ルールに対する適応度の決定とその適応度に基づく淘汰を行う。そして，学習部で入力文と正しい日本語訳文からなる翻訳例を用いた選択交配処理を行い，多様な翻訳ルールの抽出を行う。このような処理を繰り返すことで，多くの知識を獲得しながら精度の高いシステムへ向けて進化して行く。

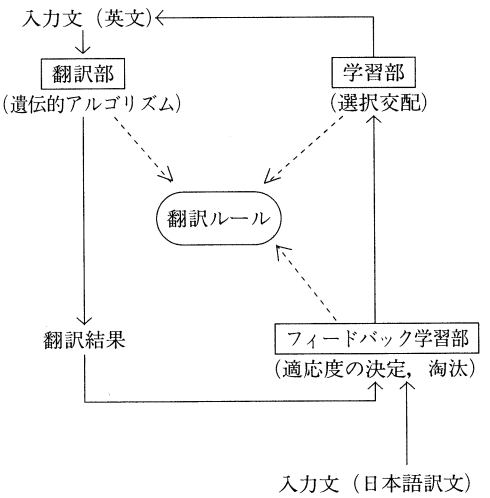


図1　処理過程

2.1 個体の染色体と遺伝子

次に遺伝的アルゴリズムを適用するにあたり本論文で個体の染色体と遺伝子をどのように位置づけているかについて述べる。図2に示すように個体には翻訳例，個体を構成する遺伝子には翻訳例を構成している単語を用いる。したがって，個々の個体は可変長の染色体を持つことになるが，これは進化の過程で高等生物になるにつれ，より長く複雑な染色体を持つということに対応している。また，翻訳例は翻訳ルールを抽出した後その翻訳例自体も翻訳ルールとして登録される。これを原文の翻訳ルールと呼ぶ。

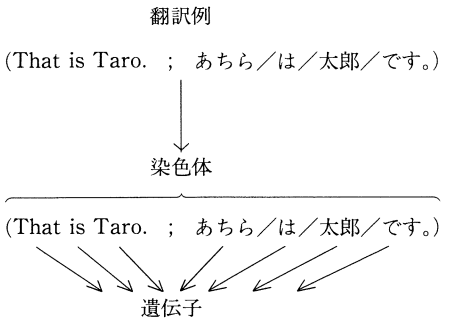


図2　染色体と遺伝子

2.2 フィードバック学習部

翻訳部で得られた翻訳結果と利用者が与えた日本語訳文との照合により得られた翻訳結果に対する正誤の判定を行う。そして，その結果より，使用された全ての翻訳ルールに対して適応度を決定する。適応度を決定する際の計算式を以下に示す。

$$\text{適応度}=\frac{\text{正翻訳使用回数}}{\text{全使用回数}}\times 100$$

適応度は，それまでに使用された回数と正しく使用された回数との比であり，翻訳ルールが正しい日本語訳文を導き出すうえで，どれだけ高い精度を持っているかを表している。そして，その適応度に基づき各個体に対する淘汰を行う。淘汰は5回以上使用された翻訳ルールに対して，適応度が25%以下のものに対して行う。

2.3 学習部

入力文と正しい日本語訳文との組からなる翻訳例に対して，遺伝的アルゴリズムの基本操作の一つである選択交配処理を行うことで多様な翻訳ルールの抽出を行う。選択交配処理を用いた多様な翻訳ルール抽出の処理過程を図3に示す。

翻訳ルール抽出の処理過程の具体例を以下に示す。まず，翻訳例において共通部分を持つものを2つのペアとして選択する。この例の場合，英文においては“is”，日本語訳文においては“は”と“です”が共通部分として抽出される。よって，英文においては“is”，日本語訳文においては“は”を交叉位置とする一点交叉を行う。また，“です”を交叉位置とする日本語訳文の交叉は，新たな翻訳例を生成しないので行わない。

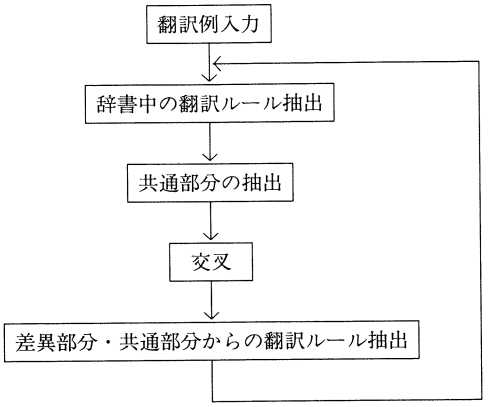


図3　翻訳ルール抽出の処理過程

（1）翻訳例

(This is Hanako.　　；　こちら／は／花子／です。)

(She is my friend.　　；　彼女／は／私の／友達／です。)

（2）英文の交叉

This is | Hanako.　　She is | my friend.

This is my friend.　　She is Hanako.

（3）日本語訳文の交叉

こちら／は | ／花子／です。　　彼女／は | ／私の／友達／です。

こちら／は／私の／友達／です。　　彼女／は／花子／です。

（4）新しく生成された翻訳例

(This is my friend.　　；　こちら／は／私の／友達／です。)

(She is Hanako.　　；　彼女／は／花子／です。)

次に，交叉により得られた翻訳例に対し，我々が先に提案した翻訳例の字面情報から差異部分と共通部分を多段階に抽出する手法[5]を適用することで，2つの翻訳例から多様な翻訳ルールの抽出が可能となる。翻訳ルール抽出の具体例を以下に示す。

（1）既存の翻訳例と交叉により生成された翻訳例

(This is Hanako.　　；　こちら／は／花子／です。)

(This is my friend.　　；　こちら／は／私の／友達／です。)

（2）差異部分の抽出

(Hanako　　；　花子)

（my friend　　；　私の／友達）

（3）共通部分の抽出

（This is @0.　；　こちら／は／@0／です。）

このような処理を繰り返すことにより，2つの翻訳例から抽出される最終的な翻訳ルールを以下に示す。ここで，変数を含まない具象化された翻訳ルールを具象的な翻訳ルール，変数を含む抽象化された翻訳ルールを抽象的な翻訳ルールと呼ぶ。

（1）変数を含まない翻訳ルール

①原文の翻訳ルール

（This is Hanako.　　；　こちら／は／花子／です。）

（She is my friend.　　；　彼女／は／私の／友達／です。）

（This is my friend.　　；　こちら／は／私の／友達／です。）

（She is Hanako.　　；　彼女／は／花子／です。）

②単語の翻訳ルール

（Hanako　；　花子），（my friend　；　私の／友達），（This　；こちら）

（She　；　彼女）

（2）変数1つの翻訳ルール

（This is @0.　　；　こちら／は／@0／です。）

（She is @0.　　；　彼女／は／@0／です。）

（@0 is Hanako.　　；　@0／は／花子／です。）

（@0 is my friend.　　；　@0／は／私の／友達／です。）

（3）変数2つの翻訳ルール

（@0 is @1.　　；　@0／は／@1／です。）

このような差異部分と共通部分を多段階に抽出することにより得られる翻訳ルールは，類似した翻訳例の組を必要とするため，その出現頻度の低さが従来の手法において大きな問題となっていた。本論文では，遺伝的アルゴリズムの基本操作の適用が多くの翻訳例を作り出し，この問題を解決する有効な手段となることを確認できた[9]。

2.4　翻訳部

学習部において抽出された翻訳ルールを用いて，最適な翻訳結果を導き出すことを目的としている。そのため，翻訳部のみで一つの完結した遺伝的アルゴリズムのシステムを構築することにより，高度な探索を可能にしている[10]。図4に翻訳部における処理の流れを示す。

以下に個々の処理の詳細について述べる。

（1）初期集団の発生

それまでに獲得された翻訳ルールを対象に入力文の基礎的な構造を表現している文の翻訳ルールを望ましい個体とし，その集まりを初期集団とする。よって，初期集団は，変数の数に依存しない文の翻訳ルールで構成される。

（2）各個体の適応度の決定

適応度の決定は，翻訳ルールに対してフィードバック学習部と同様の計算方法を用いて行う。

（3）個体に対する淘汰の実行

淘汰もフィードバック学習部と同様に，5回以上使用され，適応度が25%以下の翻訳ルールに対して行う。

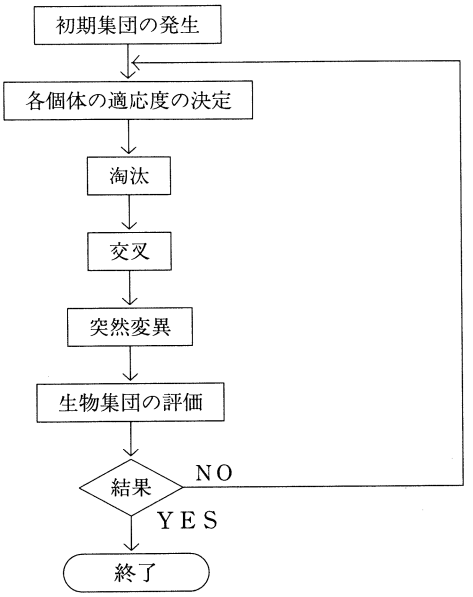


図4　翻訳部の処理過程

（4）交叉の実行

学習部で用いた手法と同様に，共通部分を持つものを選択し，その共通部分を交叉位置とする一点交叉を行う。

（5）突然変異の実行

突然変異率を2%とし，乱数を用いた文の翻訳ルールの単語に対するランダムな変更を行う。変更に使用する単語つまり遺伝子は，初期集団の発生時に収集した入力文の基礎的な構造を表現している単語の翻訳ルール又は変数とする。

（6）生物集団の評価

翻訳ルールの変数部分に具象的な翻訳ルールを代入することで，入力文と一致するものが存在するかどうかを調べる。一致するものが存在すれば入力文に対する日本語訳文が得られたとして翻訳部における処理を終了する。

以下に翻訳の例を示す。

（1）原文

She is a good friend.

（2）初期集団の発生

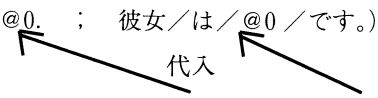
(@0 is a @1.　；　@0／は／@1／です。)

(She is @0.　；　彼女／は／@0／です。)

（3）交叉により得られた新たな翻訳ルール

(She is a @0.　；　彼女／は／@0／です。)

（4）生物集団の評価



具象的な翻訳ルール：(good friend　;　親友)

(5) 翻訳結果

彼女は親友です。

学習が進み，初期集団の発生時に多くの翻訳ルールが選択されるようになると，生物集団の評価において複数の翻訳結果が生成される場合がある。その場合には，適応度が75%以上の翻訳ルールを使用した翻訳結果を対象に，その中で抽象度の低い翻訳ルールを使用している翻訳結果を最終的な翻訳結果とする。

3．性能評価実験

3.1　実験結果

実験を行うにあたり有効な翻訳と無効な翻訳をどのように位置づけているかについて述べる。正翻訳は異表記の違いこそあるが翻訳結果と正翻訳文が一致しているものを指す。有効な翻訳の未登録は，未登録語が名詞又は形容詞句に限り，未登録語を与えることで容易に正翻訳が得られるものを指す。誤翻訳は未登録語を含まない誤った翻訳結果を指す。無効な翻訳の未登録は未登録語を含む誤った翻訳結果を指す。そして，翻訳不能は入力文の基礎的な構造を表現している文の翻訳ルールが一つも存在していない場合を指す。以下にそれぞれの具体例を示す。

・有効な翻訳

①正翻訳

入力文　：This is Makoto.

翻訳結果：こちらは真です。

正翻訳文：こちらは真です。

②未登録

入力文　：She is my classmate.

翻訳結果：彼女は私の@0です。

正翻訳文：彼女は私のクラスメイトです。

・無効な翻訳

①誤翻訳

入力文　：You are my classmate.

翻訳結果：あなたは僕の級友ではありません。

正翻訳文：あなたは僕の級友です。

②未登録

入力文　：I am not Makoto.

翻訳結果：私は@0です。

正翻訳文：私は真ではありません。

③翻訳不能

翻訳ルール無し

3.2 実験結果

本論文の実験は，翻訳ルールを全く持たない状態から中学１年用教科書ガイド・ワンワールド[11]に掲載されている英文より，翻訳ルールを学習し，その翻訳ルールを用いて翻訳を行った。表１に実験結果を示す。

表１　実験結果

Lesson	有効な翻訳		無効な翻訳			合計	正翻訳率
	正翻訳	未登録	誤翻訳	未登録	翻訳不能		
L 1	4	5	0	0	11	20	45.0%
L 2	23	8	1	6	8	46	67.3%
L 3	11	11	0	0	12	34	64.7%

3.3 考察

遺伝的アルゴリズムを適用することによる有効性として，第１に翻訳不能の減少が挙げられる。従来の手法では適用可能な翻訳ルールが一つも存在せずに翻訳不能となっていたものが，遺伝的アルゴリズムを適用することで多様な翻訳ルールの抽出を可能にし，適用可能な翻訳ルールが存在することにより翻訳不能が減少した。また，未登録語については，多くの翻訳例を作り出すことで１度出現した単語に対して早い段階で共通部分・差異部分としての抽出が可能となり，未登録語を含む翻訳結果が減少できる。そして，翻訳部においても遺伝的アルゴリズムを適用することで最適な翻訳結果を求めて，より高度な探索が可能となる。

しかし，多様な翻訳ルールの抽出が可能となったことによる利点が明らかとなった反面，その作り出された翻訳ルールに対して淘汰処理が追いつかないという，フィードバック学習部における淘汰処理の精度の低さが大きな問題点として挙げられる。特に，抽象度の低い翻訳ルールは，正しいものなのか誤ったものなのかわからないまま新たな翻訳ルールを作り出すためにのみ存在していることになり，処理時間を増大させる原因にもなっている。

4．おわりに

本論文では，帰納的学習による機械翻訳手法へ遺伝的アルゴリズムを適用することによる有効性と問題点を性能評価実験による結果に基づいて述べた。今後は，より多くの複雑な文章を用いた実験を行う。また，学習部で生成される翻訳ルールとそれらに対する淘汰処理のバランスを保つために，フィードバック学習部における淘汰の精度の向上を図る。そして，明らかに誤ったものと認識できる翻訳ルールの生成を防ぐヒューリスティックスを検討し導入することで，多くの翻訳ルールを作り出す際に必要となる膨大な処理時間の短縮を行い，より実用的な学習型機械翻訳システムの構築を図る予定である。

参 考 文 献

1) 長尾真：機械翻訳サミット，オーム社(1989)．
2) 長尾真：機械翻訳はどこまで可能か，岩波書店(1986)．
3) 佐藤理史：ＭＢＴ１：実例に基づく訳語選択，人工知能学会誌，Vol. 6，No. 4，pp 128－135(1991)．
4) 佐藤理史：ＭＢＴ２：実例に基づく翻訳における複数翻訳例の組合わせ利用，人工知能学会誌，Vol. 6，No. 6，pp 75－85(1991)．
5) 荒木健治，栃内香次：多段階共通パターン抽出法を用いた翻訳例からの帰納的学習による翻訳，情報処理北海道シンポジウム'91，pp. 47－49(1991)．
6) 内山智正，荒木健治，宮永喜一，栃内香次：帰納的学習による機械翻訳手法の評価実験，情報処理学会研究報告，NL 93-4，pp. 23－30(1993)．
7) 北野宏明：遺伝的アルゴリズム，産業図書(1993)．
8) 安居院猛，長尾智晴：ジェネティックアルゴリズム，昭晃堂(1993)．
9) 越前谷博，荒木健治，桃内佳雄：帰納的学習による機械翻訳手法への遺伝的アルゴリズムの適用，情報処理学会第４９回全国大会講演論文集，２K-1(1994)．
10) 越前谷博，荒木健治，桃内佳雄：遺伝的アルゴリズムを用いた帰納的学習による機械翻訳手法，平成６年度電気関係学会北海道支部連合大会講演論文集，No. 162．
11) 教科書ガイド教育出版版ワンワールド１，日本教材，東京(1991)．