社団法人 電子情報通信学会
THE INSTITUTE OF ELECTRONICS,
INFORMATION AND COMMUNICATION ENGINEERS

信学技報
TECHNICAL REPORT OF IEICE.
NLC95-42 (1995-10)

自然言語－意味構造対応ルールの獲得と適用

森 英悟† 荒木 健治†† 宮永 喜一† 栃内 香次†

†北海道大学工学部 ††北海学園大学工学部

札幌市北区北 13 条西 8 丁目

E-mail: eigo@hudk.hokudai.ac.jp

あらまし

計算機による自然言語処理の目標の一つに言語理解が挙げられる．”言語理解” の工学的な定義自体，完全に明確となっているわけではないが，現段階では言語表現に対応する意味表現を生成することを一つの目標としているといえよう．これまでの意味構造を作成するための手法としては，文をあらかじめ用意した規則によって解析（構文解析，意味解析）し，意味構造を出力する方法が多く取られてきた．これに対し，我々の研究の目標は言語表現と意味構造の間の変換規則を自動獲得し，このルールを用いて与えられた言語表現に対する意味構造を出力する手法を構築することである．本稿では意味構造の定義，規則の獲得，適用のアルゴリズムについて述べ，規則獲得と利用の実験について報告する．

キーワード 意味構造，概念定義，規則獲得

Acquition and use of rule between natural language and semantic structure

Eigo Mori† Kenji Araki†† Yoshikazu Miyanaga† Koji Tochinai†

†Faculty of Engineering. Hokkaido University. ††Faculty of Engineering. Hokkaigakuen University.

N13-W8-Kita-ku,Sappro, Japan

E-mail: eigo@hudk.hokudai.ac.jp

Abstract

Understanding of natural language is one of the main goals of Natural Language Processing. The definition of ”Language Understanding” is not so clear yet, but constructing semantic structures from language expressions is regarded as a concrete method. Almost of the former algorithms for constructing semantic structures are based on the analysis using prepared rules. On the other hand, the goal of our study is to construct a system which gets rules between language expression and semantic structure automatically, and produces semantic structures using the rules. In this paper, we propose the definition of semantic structure, rule acquisition and using algorithm. We also show the result of the experience using these methods.

key words semantic structure, concept definition, rule acquisition

1 はじめに

計算機による自然言語処理の目標の一つに言語理解が挙げられる．”言語理解”の工学的な定義自体，完全に明確となっているわけではないが，現段階では言語表現に対応する意味表現を生成することを一つの目標としているといえよう．これまでの意味構造を作成するための手法としては，文をあらかじめ用意した規則によって解析（構文解析，意味解析）し，意味構造を出力する方法が多く取られてきた．

これに対し，我々の研究の目標は言語表現と意味構造の間の変換規則を自動獲得し，このルールを用いて与えられた言語表現に対する意味構造を出力する手法を構築することにある．本稿ではまず本手法における意味構造の定義について述べ，特に問題となる意味構造中の概念定義の方法について，他言語の対訳を利用するモデルを提案する．

続いて，規則の獲得と適用のアルゴリズムについて，新たに採用した規則の一般化手法を説明し，規則獲得と利用の実験について報告する．

2 意味構造の定義

2.1 意味構造

言語表現に対応する意味表現として用いる意味構造は，階層化された素性－素性値ペアによるフレームによって表現される．fig-2.1 に意味構造の例を示す．

He has been loved by his mother.

[[SEM,LOVE_A],
[[AGT,[[SEM,mother_A],
[POSS,[[SEM,PRO],[PERS,3],[NUM,SG],[CASE,GEN]]]]],
[OBJ,[[SEM,PRO],[PERS,3],[NUM,SG],[CASE,ACC]]],
[MODAL,SIMPLE],[TENSE,PRESENT],
[ASPECT,PERFECT]]

fig-2.1 意味構造の例

素性には，時制，アスペクト，モダルなどを表すもの，概念名を表すものなどがある．我々の考える意味構造の素性は，言語非依存に定義することを目指している．また，概念名を指す素性 (SEM) の素性値となる概念名は各言語によって異なり，各言語別の概念辞書に定義される．素性は，その取り得る素性値によって大きく次の３つに分類される．

1.SEM
概念を値として持つ．各意味構造のヘッドに必ず存在する．

2. 下位範疇化素性
素性値として意味構造を持つ．SUBJ，OBJ など．

3. 一般素性
1,2 以外の素性．素性値として，各素性に限定された値のみを持つ．TENSE, ASPECT など．

table-2.1 に主な一般素性と素性値を示す．

table-2.1 一般素性と素性値

素性	素性の意味	素性値の例
NUM	数	SG
PERS	人称	2
GEN	性	FEMI
CASE	格	ACC
TENSE	時制	PAST
ASPECT	相	PROGRESSIVE
MODAL	態	POSSIBILITY

新しい素性を定義する基準は，その素性の素性値の違いによって言語表現上に違いが生じることによるものとする．(ただし下位範疇化素性については違った視点から素性が定義される) ある素性の素性値の違いが，一つの言語の言語表現上に違いを及ぼしても，他の言語上では及ぼさないことが起こる．これは使用可能な素性値の違いを他の言語では利用しなかったと考えることができる．したがって，ある言語で必要な素性が他の言語で必要でないという現象は，素性定義の言語非依存性を損なうものではないと考えることができる．

一般素性のうち時制，相，態などは，言語によって動詞で表現されるケース，助動詞で表現されるケース，語尾の活用形で表現されるケースなどさまざまであるが，素性や素性値は各言語間で共通して利用できるものとしている．

2.2 概念定義

そもそもの単語が持つ概念空間は，各言語の各単語に依存するものと考えられる．このことが機械翻訳における中間言語の定義を困難なものとしている大きな理由と言える．中間言語の語彙 (概念) を定義する方法としては，プリミティブを用いる方法や，各言語の単語の持つ概念をそのまま語彙としたもの[(1)]などがある．本手法でも，代名詞については人称，性などの素性を用いた定義を試みているがこれは将来的に省略補完，照応解決などへの本手法の応用を考慮してのことである．他の単語概念については，プリミティブを用いた定義は行なっていない．

本手法では意味構造の語彙は基本的には言語に依存するものと考えているが，これに関しては以下のような問題，要請が考えられる．

・一つの単語が持つ概念空間を一つに定義しこれをそのまま意味構造上に反映させることは可能であるが，これでは後述の類似度計算において単語の多義性を考慮した計算が不可能になる．

・異言語間話者のコミュニケーションが可能なことを考慮すると各言語の単語間の概念空間には重なりがあると考えることができる．本手法の機械翻訳などへの応用を考えると，意味構造の概念は異言語間の単語概念のなんらかの仲立ちをするものであることが望まれる．

ここで，概念の言語依存性を残したまま各単語の多義性を表現するモデルを提案する．fig-2.2 に概念定義のモデルを示す．本手法では単語に対する異言語の対訳を利用して意味構造の概念を定義しており，同時に，二言語間での単語概念の関係を表現することを目指している．

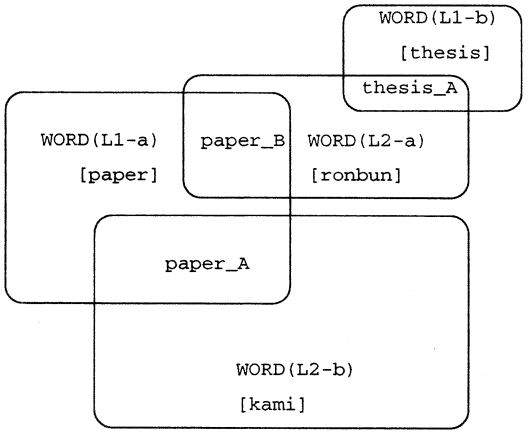


fig-2.2 概念定義のモデル

ある言語の一単語の概念空間に対して他の言語の単語が対訳として対応する時，その概念空間には重なりがあるものと考えることができる．そこでこの重なりを意味構造の概念として定義する．ここで重なりの面積の大きさは対訳語の概念空間の一致度に対応するものとする．現在は対訳対応の頻度を重なり部分の面積と対応させるものとしている．これによって，単語の持つ多義性をある程度分類し，二つの異言語間での意味概念のつながりを意味構造に反映させることができる．

ある単語に対して異言語の対訳が無いケースは稀であるが，対訳が単語でないケースは相当数ある．こうした場合の意味構造における概念は，その単語全体に対して意味構造上での一つの概念を割り当てる方法をとらざるをえない．相手言語では，句あるいは文の単位でこの概念に対応することになり，この対応メカニズムはルール獲得時に解決される．

同一言語の各単語が重なりあった概念空間を持つと考えた方が妥当なケースも多くある．この場合には意味構造の概念同士も重なりを持つ定義が生まれるがこれは特に大きな問題とは考えていない．また，三つ以上の言語に対してこのモデルをこのまま拡張すると，概念空間の重なりを二次元で表現することが困難になり，各単語概念との一致度も低下する．単語概念との一致度を考えると，現在のところ意味構造の概念は必要に応じて二言語間で定義することがもっとも有効であると考えている．

2.3 下位範疇化素性

下位範疇化素性は動詞や前置詞などによって支配されるサブカテゴリである．当初我々は概念ごとの必須サブカテゴリを辞書に明記し，これを解析の手がかりに使っていたが，実際の文に対する調査の結果，英語のように比較的構造的制約の厳しいと思われる言語においてさえも頻繁に省略が起こり，必須下位範疇を利用する試みは有効に機能しなかった．現在は，各概念による下位範疇の束縛の条件は設けていない．下位範疇化素性名は文献[2]などを参考に，言語非依存に定義することを目指している．table-2.2 に下位範疇化素性の例を示す．

table-2.2 下位範疇化素性

素性	素性の意味
AGT	動作主
SUBJ	主題
OBJ	対象
FTR	特徴
FRQ	頻度
CAS	原因
QNT	数量
MNR	様態
TIM	時間
SPC	場所
SRC	始点
GOL	終点
POSS	所有

下位範疇化素性が最終的にどれ位の量になるかは検討中であるが，これらの素性は他の素性と異なり，言語表現の相違をよりどころに定義するものではなく，意味的必然性から定義している．したがって，言語表現としての相似性が意味構造に反映されないケースも存在する．

```
He ate with a fork.
[[SEM,EAT_A],
[AGT,[[SEM,PRO],[PERS,3],[NUM,SG],
                        [GEN,MASC],[CASE,NOM]]],
[IMP,[[SEM,fork_A],[NUM,SG]]],
[MODAL,SIMPLE],[TENSE,PAST],[ASPECT,SIMPLE]]

He groaned with desire.
[[SEM,GROAN_A],
[AGT,[[SEM,PRO],[PERS,3],[NUM,SG],
                        [GEN,MASC],[CASE,NOM]]],
[CAS,[[SEM,desire_A],[NUM,UC]]],
[MODAL,SIMPLE],[TENSE,PAST],[ASPECT,SIMPLE]]
```

fig-2.3 意味構造の例

2.2 で述べた概念定義モデルで L1 を英語，L2 を日本語とした時，英語が他動詞で日本語対訳が使役動詞となるケースが頻繁に発生する．

embarass ↔ 困惑させる
confuse ↔ 混乱させる
excite ↔ 興奮させる

しかし，I was excited by the game. の対訳としては「私はその試合に興奮させられた。」よりも「私はその試合に興奮した。」と自動詞で翻訳する方が日本語として自然であると考えられる．こうしたケースの自動詞と使役動詞 (他動詞) の違いは支配するサブカテゴリの違いである．自動詞，他動詞といった分析に立てばこれらは，主語、目的語に対する支配関係によって区別される．しかし，本手法の下位

範疇化素性の分類に従えば，これらはいずれもAGT(動作主)，CAS(原因) を下位範疇とする動詞概念と考えることができる．したがって以下の日英文はいずれも同じ階層構造の意味構造に写像される．

I was excited by the game.
[[SEM,EXCITE_A],
[AGT,[[SEM,PRO],[PERS,1],[NUM,SG],[CASE,NOM]]],
[CAS,[[SEM,game_A],[NUM,SG]]],
[MODAL,SIMPLE],[TENSE,PAST],
[ASPECT,SIMPLE]]

私はその試合に興奮した。
[[SEM,EXCITE_A],
[AGT,[[SEM,PRO],[PERS,1],[NUM,SG]]],
[CAS,[[SEM,game_A],[NUM,SG]]],
[MODAL,SIMPLE],[TENSE,PAST],
[ASPECT,SIMPLE]]

fig-2.4 意味構造の例

2.4 複文表現

一文中に動詞構造が入れ子になっているケースは，英語では不定詞，動名詞，分詞，関係代名詞節などによるものが考えられる．こうした構造に対する意味構造の定義は模索中であるが、現段階での定義例を fig-2.5 に示す．

I decided to head upward.
[[SEM,DECIDE_A],
[AGT,[[SEM,PRO],[PERS,1],[NUM,SG],[CASE,NOM]]],
[OBJ,[[SEM,HEAD_A],
  [GOL,[[SEM,UPWARD_A]]]]],
[MODAL,SIMPLE],
[TENSE,PAST],
[ASPECT,SIMPLE]]

fig-2.5 意味構造の例

2.5 熟語，慣用表現

熟語や慣用表現の扱いは意味構造に変換する際に大きなポイントとなる．これらは構造をさらに細分化しても無意味で、そのもの全体が一つの決まった意味を持つ．本手法では熟語はそのままで，一つの概念に対応するものとして取り扱う．

Jeremy gave up.
[[SEM,GIVE-UP_A],
[AGT,[[SEM,Jeremy_A],[NUM,SG]]],
[MODAL,SIMPLE],[TENSE,PAST],[ASPECT,SIMPLE]]

fig-2.6 意味構造の例

3 規則の獲得

規則の獲得法についてのメカニズムは，文献(3)(4)を参照されたい．ここでは規則獲得のおおまかなあらましと，改良点について述べる．自然言語と意味構造の間の対応規則の獲得は自然言語－意味構造ペアデータからシステムが自動的に行なう．システムは自然言語と意味構造のペアを読み込むと意味構造の構造をキーに自然言語と意味構造の対応関係を推定する．この手続きは意味構造の最上位の素性を順時解析していくことによってトップダウン式に行なわれる．処理は素性値によって以下の三種に分類され，それぞれに応じた処理が行なわれる．

1. 意味概念名を素性値として持つもの．(SEM)
概念辞書を参照し，言語表現との対応が認められた時には，対応を示すマーカーに置き換える．認められない時には，そのままルールとする．

2. 意味構造を素性値として持つもの．(AGT, OBJ etc)
既知のルールを部分的に適用することによって，素性値と言語表現の一部の対応関係を探す．対応が認められた時にはその部分を対応を示すマーカーに置き換える．置き換えに失敗した時にはルール獲得に失敗．

3. それ以外の素性．(TENSE, NUM etc)
そのままルールにする．

マーカー置き換えが終った言語表現と意味構造のペアが既知のルールでなかった時には，これを新しいルールとして記憶する．また，置き換え可能素性に対する素性値を用例履歴として記憶する．

SS:
[[SEM,id0],[AGT,id1],[OBJ,id2],[SPC,id3],
[MODAL,SIMPLE],[TENSE,PRESENT],
[ASPECT,SIMPLE]]

NL:
[id1,id0,<*2>,id2,id3,.]

EX
[LIKE_A,[[SEM,PRO],[PERS,3],[NUM,SG],
[GEN,MASC],[CASE,NOM]],
[[SEM,book_A],[NUM,SG]],
[[SEM,ON_A],[OBJ,[[SEM,book_A],[NUM,SG]]]]]

fig-3.1 ルールの例

ルールの獲得における最大の課題はルールを可能な限り一般化し，かつルール適用時の精度を失わないことにあるといえる．以下に，現在採用してしているルールの一般化手法を示す．この一般化は下位範疇化素性を持つルールに作用し，NL ルールが同じで，SS ルールの異なるルール同士を一つにして，一般化ルールを導出するものである．この際に，もとのルールの持っていた下位範疇化素性名は用例履歴の中に押し込められる．一般化されたルールを使用するときには，用例との類似度から，用例に押し込められた下位範疇化素性名が選択される．fig-3.2 に一般化前と一般化後のルールを示す．

<一般化前>
Rule1
SS:
[[SEM,id0],[AGT,id1],[FRQ,id2],[MODAL,SIMPLE],
[TENSE,PRESENT],[ASPECT,SIMPLE]]
NL:
[id1,id0,<*2>,id2,.]
EX:
[HAPPEN_A,[[SEM,PRO],[NUM,SG],[CASE,NOM]],
[[SEM,OFTEN_A]]]

Rule2
SS:
[[SEM,id0],[AGT,id1],[DGR,id2],[MODAL,SIMPLE],
[TENSE,PRESENT],[ASPECT,SIMPLE]]
NL:
[id1,id0,<*2>,id2,.]
EX:
[HURT_A,[[SEM,PRO],[NUM,SG],[CASE,NOM]],
[[SEM,TERRIBLY_A]]]

<一般化後>
SS:
[[SEM,id0],[AGT,id1],id2,[MODAL,SIMPLE],
[TENSE,PRESENT],[ASPECT,SIMPLE]]
NL:
[id1,id0,<*2>,id2,.]
EX1:
[HAPPEN_A,[[SEM,PRO],[NUM,SG],[CASE,NOM]],
[FRQ,[[SEM,OFTEN_A]]]]
EX2:
[HURT_A,[[SEM,PRO],[NUM,SG],[CASE,NOM]],
[DGR,[[SEM,TERRIBLY_A]]]]

fig-3.2 ルールの一般化

4 規則の適用

規則の適用手法，類似度計算手法のメカニズムについても文献(3)(4)を参照されたい．規則適用時にはシステムはルールの可能な適用を全て試みる．この過程で大量の候補が作成されるがこれらは規則獲得時に保存された用例履歴との類似度計算によって優先度の高いものに絞り込まれる．類似度計算は，素性値の一致度を基準に計算されるが，概念名に関しては下位範疇化されたシソーラスを用いた類似度計算を行なう．類似度計算は単語間でなく概念間で行うため，多義性を持つ単語のそれぞれの意味に対応する類似度計算を別のものとして扱うことができる．

本研究の概念モデルに対するシソーラスを厳密に構築することは困難であるため，我々は近似的に L2 言語のシソーラスを用いる方法を採用している．すなわち fig-2.2 に示した概念定義モデルのように L1 を英語とし，L2 (日本語) における対訳によって概念定義する場合には，日本語シソーラスをベースに意味構造概念間の類似度計算を行うものである．

5 実験

本手法の有効性を確認するために規則獲得と適用の実験を行なっている．まず提案手法に基づいて，規則獲得および適用のシステムを構築した．次に概念の定義について，L1 を英語，L2 を日本語として複数の辞書を用いて概念辞書を作成した．両言語の概念間の重なりは対訳の頻度調査によって決定すべきであるが，十分な量の対訳コーパスが入手できていないため，現在は辞書における対訳順に応じて以下のように定義している．

English
english;NOUN;paper_A;paper
english;NOUN;paper_B;paper
english;NOUN;paper_C;paper
english;NOUN;paper_D;paper
english;NOUN;paper_E;paper

Japanese
japanese;NOUN;paper_A; 紙
japanese;NOUN;paper_B; 論文
japanese;NOUN;paper_C; 書類
japanese;NOUN;paper_D; 新聞
japanese;NOUN;paper_E; 答案

A～E の各添字は，頻度率に換算すると 50%, 25%, 13%, 6%, 3%の値に相当させている．類似度計算のためのシソーラスは大規模な日本語シソーラスが未入手のため，手作業で小規模なシソーラスを作成し用いている．現在，これを分類語彙表(5)で置き換えることを検討している．

自然言語文の解析の困難さの指標の一つとして文長が挙げられる．英語のテキスト，情報処理関係の論文，Internet News から物語，人工知能に関する投稿を文長にソートし，文長 2～6 について，各数十文ごとをランダムに抽出した．ただし，抽出文は重文以外の肯定文を条件とし，動詞によって構造が構成されていない呼びかけ，返答 (I was. などを含む)，見出しや，接続詞の接続関係が一文中で解決されないものは除いた．

抽出された各文に対し人手で対応する意味構造を作成し，意味構造と自然言語の各ペアについて，まず規則適用を行ない，続いて規則獲得を行なう方法で規則獲得と適用について同時に検証した．ルール適用の結果を以下のように分類し，このうち 5 の正しい意味構造が出力されたケースについての推移を fig-5.1 に示す．

1. 意味構造が全く出力されなかったケース．
2. 意味構造は出力されたが構造に致命的な誤りがあるケース．
3. 意味構造中の下位範疇素性名の選択に失敗したケース．
4. その他の素性の間違い．(NUM に対する SG，UC の選択の間違いなど)
5. 正しい意味構造が出力されたケース

実験結果の詳細は検討中であるが，規則適用における正変換率は現在のところ良好な結果が得られていない．語長が 4 未満では 4 および 3 のケースが多い．これは類似度計

算によるルール選択の失敗と考えられ，用例履歴の不足，シソーラスの未整備が原因に挙げられる．語長が 4 以上では 1 のケースが大きな比率を占める．これは，ルール獲得数の不足によるものと思われる．

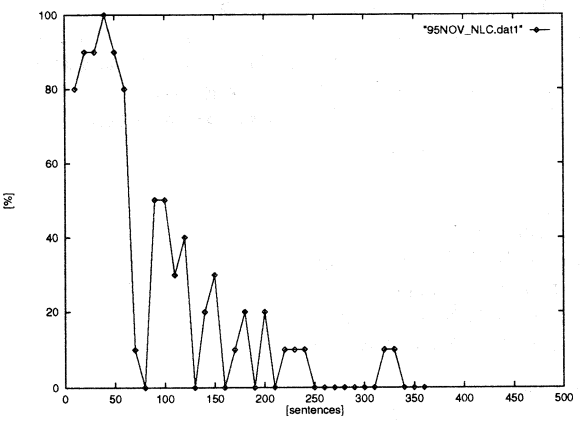


fig-5.1 ルール適用結果の推移

次にルール獲得数の推移を fig-5.2 に示す．

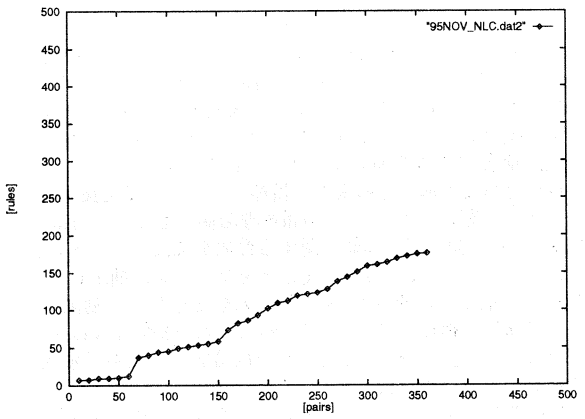


fig-5.2 ルール獲得数の推移

ルールの収束については語長 2～3 については収束性がみられるものの，それ以上については確認できなかった．規則獲得用データを増やした実験が必要であろう．

6 おわりに

自然言語を意味構造に変換する手法の一手法として，変換ルールを自動獲得する方法を提案した．意味構造の定義において，概念の定義を二言語間の対訳を用いて行なう方法を提案し，いくつかの言語表現に対する意味構造定義を示した．

提案手法にしたがってシステムを構築し，実際の文と対応する意味構造のペアデータからの規則の獲得，オープンデータに対する規則適用の実験を行なっている．実験の規模が小さいためルール数の収束性，正変換率の推移についての評価は今後のさらに大規模な実験による課題である．

また，さまざまな文に対応できる意味構造の定義，シソーラスの整備なども行なう必要がある．将来的には本手法を拡張して，省略の補完機能なども考えている．また，意味構造を仲介する機械翻訳システム[3][4][6][7]についても検討中である．

参考文献

[1] 崔, 小松, 安原:EDR 電子化辞書を用いた単語類似度計算法，情処研報,Vol93,No.1,1993

[2] 石崎:自然言語処理, 昭晃堂,1995

[3] 森, 荒木, 宮永, 栃内:素性構造を媒介とする実例学習型機械翻訳, 信学技報,NLC94-43,1994

[4] 森, 宮永, 栃内:素性構造を媒介する機械翻訳システムの構築, 信学会全国大会予稿集,(平 7 秋期)

[5] 国立国語研究所:分類語彙表, 秀英出版,1964

[6] 森, 宮永, 栃内:実例学習型機械翻訳への素性構造の応用, 信学会全国大会予稿集,(平 6 秋季)

[7] 森, 宮永, 栃内:実例学習型機械翻訳への素性構造の応用 II, 電気関係学会北海道支部連合大会予稿集,160,(平 6)