英文からの文法自動生成手法

笹岡久行　荒木健治　桃内佳雄　　栃内香次
北海学園大学工学部　　北海道大学工学部

1 はじめに

機械翻訳の手法として、実際の翻訳例を利用して翻訳を行う手法について研究がなされている [1, 2]。さらには、英文とその翻訳文から翻訳規則を学習して翻訳を行う手法が提案されている [3, 4]。しかし、このような学習型の機械翻訳システムには以下にあげる問題点がある [5]。

1. 処理時間の増大
   学習して得られた翻訳規則を組み合わせて利用する際に、組み合わせの爆発により処理時間の増大を招く。
2. 翻訳規則の学習の失敗
   字面情報を利用して翻訳規則を学習しているシステムの場合には、英文と翻訳文の間に対応する単語が存在しない場合には、誤った学習を行うことがある。

これらの問題点を解決するために、翻訳規則を学習する際に文法規則を利用する手法について現在研究中である。

また、文法規則を学習により獲得できれば、自然言語の多様性にも対応できる。文法の自動抽出手法としては、構文構造が付加されたコーパスからの文脈自由文法の自動抽出の手法が既に提案されている [6]。しかし、この手法ではあらかじめコーパスに対して構文構造を用意しておかなくてはならない。そこで本稿では、機械翻訳において利用するための文法を、英文のみから自動生成する手法を提案する。

2 文法規則自動生成の手法

文法規則の自動生成手法の手順を以下に示す、

1. 文中の単語と記号に非終端記号を与えていく。
2. 単語に対して共通部分と差異部分の抽出を行う。抽出されたものに対して新たな非終端記号を与えることにより文法規則の生成を行う。

ここで生成される文法は、機械翻訳において利用することを目的としている。そのために、非終端記号に対して<名詞>や<名詞句>などのような意味を含んだ名前は付与されない。

3 処理過程

以下の例文より文法を生成する方法について説明する。

This is my pen.
My bag is blue.

3.1 単語分割と記号の付与

英文を単語ごとに区切り、単語毎に非終端記号を付けていく。非終端記号は、**a1,a2,a3,....** のようにする。

すなわち、

This	is	my	pen	.
a1	a2	a3	a4	a5
My	bag	is	blue	.
a6	a7	a8	a9	a10

となる。

3.2 共通部分と差異部分の抽出

新しい非終端記号と丸括弧を用いて共通部分と差異部分をまとめる。丸括弧の中身は、共通部分あるいは差異部分として抽出されたものである。

共通部分である、*is*、*my*、. を記号**b1**、**b2**、**b3** でそれぞれまとめると、以下のようになる。

b1 → (a2,a8)
b2 → (a3,a6)
b3 → (a5,a10)

次に、差異部分の抽出をおこなう。差異部分を新しい非終端記号を用いてまとめる。

c1 → (a1,b2a7)
c2 → (b2a4,a9)

また、誤った文法規則の生成を防ぐために差異部分の抽出において、2つの文において対応する部分が無いものに関しては文法規則として取り出さない。

さらに抽出を行うと、

d1 → c1b1c2b3

となる。

文法規則として抽出されたものをまとめると以下のようになる。

1. 単語に関するもの

a1	→	This
(a2,a8)	→	is
(a3,a6)	→	my
(a5,a10)	→	.
a4	→	pen
a7	→	bag
a9	→	blue

2. 句に関するもの

b1 → (a2,a8)
b2 → (a3,a6)
b3 → (a5,a10)

c1 → (a1,b2a7)
c2 → (b2a4,a9)

3. 文に関するもの

d1 → c1b1c2b3

3.3 高次の抽出

生成された文法を、共通部分と差異部分の抽出によりさらにまとめ上げる。*my pen* と *my bag* について文法規則を抽出していく。非終端記号は3．2節と同じものを用いる。

差異部分の抽出により記号をまとめる。

e1 → (a4,a7)

ここから

e2 → b2e1

が得られる。

4 実験

中学1年生用教科書ガイド ニューホライズン [7] にある英文を取り出し、本手法で文法を生成した。生成された句と文についての文法規則のみを、以下に示す。

例1

Good morning , everyone .
a1 a2 a3 a4 a5

Good morning , Miss Sato .
a6 a7 a8 a9 a10 a11

共通部分と差異部分の抽出により、

b1 → (a1a2a3,a6a7a8)
b2 → (a2a3,a7a8)
b3 → (a3,a8)
b4 → (a5,a11)
c1 → (a4,a9a10)

更に抽出を行うと、

d1 → b1c1b4

例2

Good morning , everyone
a1 a2 a3 a4 a5

Good by .
a6 a7 a8

共通部分と差異部分の抽出により、

b1 → (a1,a6)
b2 → (a5,a8)

c1 → (a2a3a4,a7)

更に抽出を行うと、

d1 → b1c1b2

5 考察

4章の例1から抽出された文法規則を利用すれば、帰納的学習による機械翻訳手法 [3, 4] における翻訳規則を以下のように記号付きで得ることができる。

(Good morning,*c1* ; おはようございます、*c1*)

しかし、例2から抽出された文法規則だけでは正しい翻訳ができる翻訳規則の生成に失敗する。なぜなら、本手法では単語の字面情報により共通部分と差異部分の抽出を行っているので、英文中での単語の文法的な役割が違っても文法規則を生成してしまうからである。

6 おわりに

本手法により生成された文法は、機械翻訳の翻訳規則生成において利用するには十分ではない。解決する手段としては、別の文から生成された文法規則の集合との組み合わせに対して共通部分と差異部分の抽出を行って有効な文法規則を生成していくことが考えられる。このことを今後の課題とする。さらに、自動生成された文法規則を利用して学習型機械翻訳を行う手法についての研究を進めていく予定である。

参考文献

[1] 佐藤理史：MBT2：実例に基づく翻訳における複数翻訳例の組み合わせ利用、人工知能学会誌、Vol. 6、No. 6、pp. 23−30、(1991).

[2] 隅田英一郎、飯田仁、幸山秀雄：用例に基づいた翻訳、情報処理学会第40回全国大会講演論文集、pp. 411−412、(1990).

[3] 内山智正：帰納的学習による機械翻訳手法、北海道大学大学院工学研究科電子工学専攻、修士論文、(1994).

[4] 内山智正、荒木健治、宮永喜一、栃内香次：帰納的学習による機械翻訳手法の評価実験、情報処理学会研究報告、NL93−4、pp. 23−30、(1994).

[5] 西方弘樹、荒木健治、宮永喜一、栃内香次：解析型および学習型機械翻訳手法の評価、情報処理北海道シンポジウム'94、pp. 15−17、(1994).

[6] 白井清昭、徳永健伸、田中穂積：コーパスからの文法の自動抽出、情報処理学会研究報告、NL101−11、pp. 81−88、(1994).

[7] 教科書ガイド東京書籍版ニューホライズン1、あすとろ出版、東京(1991).

[連絡先：笹岡久行 北海学園大学工学部
札幌市中央区南26西11丁目 Tel.(011)841-1161(内線856)
E-mail sasa@eli.hokkai-s-u.ac.jp]