270 2次マルコフモデルを用いた接続情報のタギングにおける応用

Application of 2nd Order Markov Model on English Text Tagging

ファルディ・アクサヌル† 荒木 健治†† 宮永 喜一† 栃内 香次†
Aksanul FARDHI † Kenji ARAKI †† Yoshikazu MIYANAGA † Koji TOCHINAI †
† 北海道大学工学部 †† 北海学園大学工学部
† Faculty of Engineering, Hokkaido University †† Faculty of Engineering, Hokkai-Gakuen University

1 はじめに

ある単語のある文での品詞は、その単語のその文での役割を表す．英語では、複数の品詞を持った単語が多数存在し、このような単語の意味の正しい理解はその単語の任意の文での品詞がどれだけ正しく決定できるかに依存する．ある単語の品詞を予測することをタギング (TAGGING) という．

大きく分けると、二つのタイプのタギングシステムが提案されてきた．一番目のタイプは、ルールやアルゴリズムに基づくシステムである．二番目のタイプは、確率に基づくシステムである．

我々は上に述べた後者のタイプである確率に基づくアプローチを試みた．従来のほとんどの確率に基づくシステムは1次マルコフを用いたシステムである [1]．本稿では、2次マルコフモデルを用いたタギング手法を提案する．さらに、本手法を品詞付きコーパスを用いて学習させた上で、他のコーパスを用いてその有効性を評価し、良好な結果が得られた．また処理時間が非常に遅く、処理時間の短縮の必要があることが実験から明らかになった．そのためキーワードという概念を導入し、キーワードを用いて処理時間の短縮を行なった．このことについても報告する．

2 本手法の概要

英語という言語における長さ n 単語の文の各単語の品詞を求めるには、次の式を満たす品詞列 $t_{1,n}$ を求めればよい．

$$S(w_{1,n}) = \arg\max_{t_{1,n}} P(t_{1,n} \mid w_{1,n}) \tag{1}$$

ここで、英語という言語が持つ品詞の数と単語の数をそれぞれ x と y とすると、

$$\begin{aligned} t_{i=1,n} \in T &= \{t^1, t^2, \ldots, t^x\} \\ w_{i=1,n} \in W &= \{w^1, w^2, \ldots, w^y\} \end{aligned} \tag{2}$$

である．

（1）式は、次のように展開することができる．

$$\begin{aligned} S(w_{1,n}) &= \arg\max_{t_{1,n}} P(t_{1,n} \mid w_{1,n}) \\ &= \arg\max_{t_{1,n}} \frac{P(t_{1,n}, w_{1,n})}{P(w_{1,n})} \end{aligned} \tag{3}$$

（3）式の最大値は $t_{1,n}$ にしか依存しないので最大値は分子の最大値で決まる．

$$S(w_{1,n}) = \arg\max_{t_{1,n}} P(t_{1,n}, w_{1,n}) \tag{4}$$

また（4）式での $P(t_{1,n}, w_{1,n})$ は、次のように展開できる．

$$P(t_{1,n}, w_{1,n}) = P(t_1 \mid w_1) \prod_{i=2}^{n} P(t_i \mid w_{i-1}, w_i) \tag{5}$$

この（5）式を（4）式に代入すると次のような式は得られる．

$$S(w_{1,n}) = \begin{cases} \arg\max_{t_i \in T} P(t_i \mid w_i), & \text{for } i = 1 \\ \arg\max_{t_i \in T} P(t_i \mid w_{i-1}, w_i), & \text{for } 2 \le i \le n \end{cases} \tag{6}$$

更に、未知の単語列の対策として、上の（6）式に重み α をつけて次の式に変える．

$$S(w_{1,n}) = \arg\max_{t_i \in T} \{\alpha P(t_i \mid w_{i-1}, w_i) + (1-\alpha) P(t_i \mid w_i)\} \tag{7}$$

この（7）式を利用しシステムを構築した．

3 実験と結果

対象データとしては、LOBコーパスを用いた．コーパスを学習データ（49041文1,040,475単語）と実験データ（5449文116,785単語）とに分けて、α をいくつかの値にと設定し、実験を行なった．実験の結果は、最高97．33%の精度で品詞の推測ができることが確認された [2]．

現時点まで、このシステムの最も速い処理時間が40時間34分02秒だった．そこでキーワードを用いた処理時間の短縮を行なった．キーワードとなる単語は、単品詞の単語、つまり品詞を一つしか持っていない単語である．このような単語は2次マルコフモデルを使わなくても正しくタギングできるのでタギング精度を犠牲にせずに処理時間の短縮が可能となる．実験の結果、最大で35時間20分48秒となった．

4 おわりに

本実験では、2次マルコフモデルを用いることにより良好な結果が得られた．これは、本手法の有効性を示している．しかし、2次マルコフモデルを用いると辞書が大きくなり検出に要する時間が多くなりシステム全体の処理時間も増大することが挙げられる．そこで、キーワードを用いて処理時間を短縮した．

今後の課題としては、本システムの出力を用いて構文解析を行なうことや日本語の文を対象にすることが挙げられる．

参考文献

[1] *DeRose, S.J.*, Grammatical Category Disambiguation by Statistical Optimization, COLING Vol.14, No.1, 1988

[2] *Fardhi, A., Araki, K., Miyanaga, Y. & Tochinai, K.*, Prediction of Part of Speech Categories for Words in English Text Using Second Order Markov Model, IPSJ Reports on Human Interface Research No.61, pp.1-8, 1995