272　帰納的学習を用いた英単語からの単語片の抽出

Extraction of a Piece of Word from English Words Using Inductive Learning

笹岡久行†　荒木健治†　桃内佳雄†　栃内香次‡
Hisayuki Sasaoka†　Kenji Araki†　Yoshio momouchi†　Koji Tochinai‡
†北学園大工
† Fac. of Eng., Hokkai-Gakuen Univ.
‡北大工
‡ Fac. of Eng., Hokaido Univ.

1　はじめに

広大な自由度を持つ人間の学習能力を解明し、計算機上で実現させるために様々な研究がなされている。言語能力を対象にしたものとして、帰納的学習によって文字列より語を獲得する手法の研究 [1]、帰納的学習による機械翻訳手法の研究 [2], [3], [4] などがある。本稿では、帰納的学習による機械翻訳手法で利用できる知識を獲得する手法として、帰納的学習を用いて英単語から単語片を抽出する手法を提案する。

2　人間が利用している知識

例えば人間が、英単語 *happy* を見た後に *unhappy* を見ると、*"un..."*を *happy* に付け加えられたものと考える。本研究では、このような単語の中の文字列に関する知識を獲得する能力を実現することを試みる。

単語の中にある他の単語との共通部分を中心語片 (*a CenTer Piece of Word*) と呼び、ＰＷ＿ＣＴと表記する。また、ＰＷ＿ＣＴの前後の差異部分をそれぞれ前方語片 (*a FRont Piece of Word*)、後方語片 (*a REar Piece of Word*) と呼び、ＰＷ＿ＦＲ、ＰＷ＿ＲＥと表記する。さらに、ＰＷ＿ＦＲ、ＰＷ＿ＣＴ、ＰＷ＿ＲＥを総称して、単語片 (*a Piece of Word*) と呼び、ＰＷと表記する。

これまでに我々が行っている帰納的学習を利用した機械翻訳手法では単語を一つの単位とみなし、単語の内部に立ちいった学習は行われていない。PW の抽出により単語の中に存在する基本的な単位を獲得できると考えている。

3　帰納的学習を用いたＰＷ抽出手法

3.1　概 要

英文は単語が分かち書きされているのでそれを元に単語を取り出す。単語を意味的情報を持つ文字列とみなすと、ある単語は別の単語のＰＷ＿ＣＴとなりうる。ある２つの単語の間に共通部分（ＰＷ＿ＣＴ）が存在する時、その共通部分（ＰＷ＿ＣＴ）と差異部分（ＰＷ＿ＦＲ，ＰＷ＿ＲＥ）の抽出をおこなう。その抽出方法を、図 1に示す。

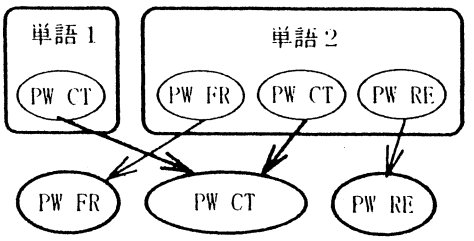


Fig. 1　英単語からのＰＷ抽出方法

3.2　ＰＷの抽出例

以下に、英単語から抽出されるＰＷの例を示す。また、"—" は空、つまり該当する文字列が無いことを表わしている。

例 1 接頭語あるいは接尾語となりうる文字列

単語 1:happy　　単語 2:unhappy
⇓
PW-FR:un　PW-CT:happy　PW-RE: —

例 2 名詞や動詞などの単語が変化した時の文字列

単語 1:mind　　単語 2:minds
⇓
PW-FR: —　PW-CT:mind　PW-RE:s

例 3 それ以外の情報を持った文字列

単語 1:no　　単語 2:nothing
⇓
PW-FR:—　PW-CT:no　PW-RE:thing

単語から単語を構成するプリミティブな単位を抽出という本研究の目的のために、例１や例２のような文字列だけではなく例３のような文字列も抽出する。

評価実験

実験方法

「The society of mind」[5]のChapter 1の英文（201文、1091単語）に対して上に述べた手法で、単語からPW__FR、PW__CT、PW__REを抽出した。

そして、その抽出結果を英和辞書[6]を用いて以下のように分類した。

1 抽出されたすべてのPWが単語として存在するもの。

例えば、単語「*a*」,「*foundation*」で、

(PW-FR:)*found*,**(PW-CT:)***a*,**(PW-RE:)***tion*

という抽出をした場合はこの項目に分類する。

また、PW__FR、PW__REのどちらか一方が空であり、かつもう一方が単語として存在する場合もこの項目に分類した。例えば、単語 *happy*, *unhappy* で、先に述べたような抽出をした場合はこの項目に分類する。

2 PW__FR、あるいはPW__REの一方が単語として存在するもの。

例えば、単語「*in*」,「*working*」で、

(PW-FR:)*work*, **(PW-CT:)***in*, **(PW-RE:)***g*

という抽出をした場合はこの項目に分類する。つまり、PW__FRの「*work*」は単語として存在しているが、もう一方のPW__RE の "*g*" は単語としては英和辞書に存在していない。

3 PW__FRとPW__REがともに、単語として存在しないもの。

例えば、単語「*to*」,「*skeleton*」で、

(PW-FR:)*skele*, **(PW-CT:)***to*, **(PW-RE:)***n*

という抽出をした場合はこの項目に分類する。

実験結果

1269個の抽出結果が得られ、264個のPW__CT 609個のPW__FRと638個のPW__REを獲得し、英和辞書と比較した結果を表１に示す。

考察

我々の研究の目的から、分類１と２を有効な結果とする。しかし、結果を見ると分類１と２は分類３の合より低い。その原因として、「ａ」等の文字数がない単語がPW__CTとなった時、出現する箇所毎に文字列の抽出が行われるために、単語として存在しないPWが多く抽出された。これを改善する手法として、抽出結果から学習を行うフィードバック学習を導入することにより、システム自身が自分の知識を改善する方法が考えられる。具体的には、各文字列に対してPW__FR、PW__CT、PW__REのそれぞれでの確実性に関する数値を導入することによりフィードバック学習を行うことが考えられる。また、抽出されたPWを用いて単語を分解することによりさらに本手法が有効になるものと考えられる。

Table 1 抽出実験の結果

分類	個数（個）	割合
分類１	４０８	３２．２％
分類２	１３０	１０．２％
分類３	７３１	５７．６％

5 おわりに

本稿では、英単語からそのプリミティブな単位である単語片を抽出する手法について述べた。

評価実験結果からわかるように、本手法だけでは実験に用いた全ての単語で有効と見なすことができるプリミティブな単位を獲得することはできなかった。しかし、実験で抽出されたPWの組の約40％は有効なPWの組として、単語から帰納的に獲得することが可能であると確認された。

また、評価実験の結果から各文字列に対する確実度に関する数値を持たせたフィードバック学習を導入すると、より有効に学習が進むと考えられる。今後それを元に本手法を改善する予定である。

参考文献

[1] 荒木健治、栃内香次：帰納的学習による語の学習および確実性を用いた語の認識、信学論 (D-II),J75-D-II,7,pp.1213-1221(1992-07).

[2] 赤間清：帰納的学習システムＬＳ／１による翻訳の学習, 人工知能学会誌,Vol.2,No.3,(1987).

[3] 佐藤理史：ＭＢＴ２実例に基づく翻訳における複数翻訳例の組み合わせ利用、人工知能学会誌,Vol.6,No.6,pp.75-85,(1991).

[4] 内山智正、荒木健治、宮永喜一、栃内香次：帰納的学習による機械翻訳手法の評価実験、情報処理学会研究報告, ＮＬ９３-４,pp.23-30,(1993).

[5] Marvin M.: The society of mind,A Touchstone Book,New York,(1986).

[6] 小稲 ほか：新英和大辞典、研究社, 東京 (1993).