273　遺伝的アルゴリズムを用いた帰納的学習による機械翻訳手法の性能評価（Ⅱ）

Performance Evaluation Experiment for Machine Translation Method Using Inductive Learning to Apply Genetic Algorithms （Ⅱ）

越前谷 博[†]　荒木 健治[†]　桃内 佳雄[†]　栃内 香次[††]
Hiroshi Echizen-ya,[†] Kenji Araki,[†] Yoshio Momouchi[†] and Koji Tochinai[††]
[†]北学園大工　[††]北大工
[†]Faculty of Engineering, Hokkai-Gakuen University
[††]Faculty of Engineering, Hokkaido University

1．はじめに

我々は、従来より帰納的学習による機械翻訳手法[1]へ遺伝的アルゴリズムを適用し、その有効性の確認を目的とした評価実験を行ってきた[2]。その結果、少量のデータからの多様な翻訳ルールの抽出とより良い翻訳結果の生成が可能となることを確認できた。本稿では、これまでの中学１年生レベルの翻訳から、さらに実用的な翻訳の実現に向けて行った評価実験より、本手法の有効性について述べる。

2．処理過程

本手法では、翻訳例を個体として、翻訳例を構成している単語を遺伝子として位置付けている。このような状況で、遺伝的アルゴリズムを適用することによりバラエティに富んだ翻訳ルールを生成し、それらを用いたより良い翻訳を行う学習型機械翻訳システムを実現する。図１に処理過程を示す。

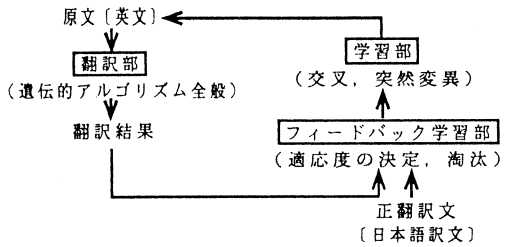


図１　処理過程

2．1　学習部

学習部では、入力された翻訳例に対し、交叉と突然変異を行うことにより、多様な翻訳ルールを抽出する。交叉の例を以下に示す。まず、共通部分を持つ２つの翻訳例を選択する。

(She was twelve last year.；彼女/は/去年/１２/歳/でした。)
(He was walking toward the station.
；彼/は/駅/の/方/に/歩いて/きてい/ました。)

次いで共通部分(was;は)を交叉位置とし、一点交叉を行う。

(She was walking toward the station.
；彼女/は/駅/の/方/に/歩いて/きてい/ました。)
(He was twelve last year.　；彼/は/去年/１２/歳/でした。)

このように新たに生成された翻訳例を加え、我々が先に提案した共通部分と差異部分を多段階に抽出する手法[3]を用い、多様な翻訳ルールを抽出する。また、突然変異は突然変異率を２％として翻訳例に対するランダムな変更を行う。

2．2　翻訳部

翻訳部では、生成された翻訳ルールを効率よく活用し、より最適な翻訳結果を作り出す。その生成過程を以下に示す。

（１）生成された翻訳ルールから適用可能な文の翻訳ルールを選択し、初期集団を発生させる。
（２）フィードバック学習部と同様の手法を用い、各翻訳ルールに対する適応度の決定と淘汰を行う。
（３）学習部と同様、翻訳ルールへ交叉と突然変異を行う。
（４）生物集団の評価を行う。存在している翻訳ルールを組み合わせることにより、翻訳結果を求める。
（５）最適な翻訳結果を求め（１）から（４）を繰り返す。

2．3　フィードバック学習部

フィードバック学習部では、翻訳結果へ正しい日本語訳文を与えることで、使用された翻訳ルールに対する適応度の決定と淘汰を行う。適応度は以下の計算式により求められる。

$$\text{適応度（％）} = \frac{\text{正翻訳度数}}{\text{全翻訳度数}} \times 100$$

また、淘汰は全翻訳度数が５以上、適応度が２５％以下の翻訳ルールを対象に行う。

3．評価実験

3．1　実験方法

実験は、中学１年生レベルの文章１，８１０組より学習した翻訳ルールを初期辞書とし、中学２年生用教科書ガイド・ワンワールド[4]に掲載されている文章２４０組（４８０文）に対して、１文ずつ翻訳と学習を行った。

3．2　実験結果

実験結果を表１に示す。有効な翻訳とは、未登録語を含まない正翻訳と未登録語を含む正翻訳である。ここで、未登録語を含む正翻訳は、未登録語に名詞句や形容詞などの単語のルールを与えることで容易に正翻訳が得られるものである。無効な翻訳とは、未登録語を含まない誤翻訳と未登録語を含む誤翻訳、及び全く翻訳が行えなかった翻訳不能である。

表１　実験結果

	割合（文数）
有効な翻訳	４１．７％（１００）
無効な翻訳	５８．３％（１３０）

3．3　考察

本実験のデータ中に初めて出現した、名詞句や形容詞といった未登録語ではない単語で、再度、データ中に出現していたものは、１９．１％であった。この中で、２度目の出現の際に、有効な翻訳となったものは６３．０％であった。中学１年生レベルの実験における同様の調査では、６０．０％であったことから、中学２年生レベルの文章においても学習能力の低下は見られず、本手法が有効であることを確認できた。

4．おわりに

本稿では、中学１年生レベルの文章と比べ、より実用レベルの文章における本手法の有効性について述べた。今後は、さらにより多くの実用レベルの文章を用いた実験を続け、より良い翻訳を実現するための研究を進める予定である。

参考文献

（１）内山智正，荒木健治，宮永喜一，栃内香次：帰納的学習による機械翻訳手法の評価実験，情報処理学会研究報告，NL 93-4，pp23-30(1993).
（２）越前谷博，荒木健治，桃内佳雄，栃内香次：実例からの帰納的学習による機械翻訳手法における遺伝的アルゴリズムの有効性について,情報処理学会研究報告，NL107-10，pp. 75-82（1995).
（３）荒木健治，栃内香次：多段階共通パターン抽出法を用いた翻訳例からの帰納的学習による翻訳，情報処理北海道シンポジウム’９１，pp.47-49(1991).
（４）教科書ガイド教育出版版ワンワールド２，日本教材，東京(1991).