274 ルール接続情報を用いた帰納的学習による機械翻訳手法の改良

西方 弘樹† 荒木 健治†† 宮永 喜一† 栃内 香次†
† 北海道大学工学部 †† 北海学園大学工学部

1. はじめに

我々は機械翻訳の一手法として，帰納的学習による学習型機械翻訳手法の提案及び，実験システムの構築を行なっている[1].

本手法は文例に基づく文の変換によるもの[2]で，入力文との距離が最小である既知の文例に適用される変換ルールを適用して翻訳するという考え方に基づいている．また，ルール適用をより一般化するために入力文から変数スロット付きルールを抽出し，辞書中のルールとの比較を繰り返すことによりルールの一般化を行う．

我々はこれまで本手法の利点・問題点を明らかにするために評価実験を行ない[3]，その結果から，誤ったルールの抽出を抑制するためにルール抽出時に分割点に制限を設けるという改良を行なってきた[4].

本稿では，変数スロットにおけるルールに関する接続情報を利用し，より適切なルールの適用を行なう改良手法について述べる．

2. 帰納的学習による機械翻訳手法

2.1. 処理の流れ

図1に帰納的学習による機械翻訳手法[1]の流れを示す．

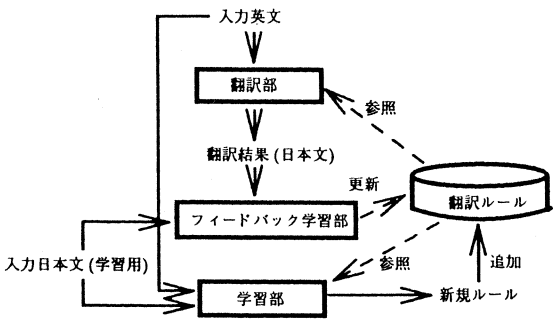


図1：処理の流れ

2.2. 学習処理

2つの翻訳例の共通部分と差異部分とを多段階に抽出することで翻訳ルールを獲得する．新規に入力された翻訳例を既知の翻訳ルールと全て比較して，差異部分が一意に対応づけられるとき，この差異部分と，差異部分を変数として付加した共通部分を翻訳ルールとして抽出する．抽出された翻訳ルールを既知の翻訳ルールと比較して，共通部分・差異部分が抽出されなくなるなるまで抽出を繰り返す．このとき，過剰な抽象化を防ぐために抽象化に閾値を設ける[1].

以下に基本的な例を示す．ここで，(1)(2)の2つの対訳が与えられた場合(3)(4)(5)が翻訳ルールとして抽出される．

Who is **that girl** ? ; あの 女の子 は 誰 ですか . (1)
Who is **your friend** ? ; あなたの 友達 は 誰 ですか . (2)

⇓

that girl ; あの 女の子 (3)
your friend ; あなたの 友達 (4)
Who is @0 ? ; @0 は 誰 ですか . (5)

学習部では以上の他に，差異部分だけの抽出，共通部分だけの抽出，異表記ルールの抽出，及びそれを用いた有効なルールの抽出，誤ったルールの削除を行なう[5].

2.3. 翻訳処理

翻訳部では学習部により抽出された翻訳ルールを用いて翻訳文を作成する．入力文に適用できる最も具象的なルールを始めに適用し，続いて，適用された翻訳ルールの変数部分に適用できる最も具象的なルールを適用していく．複数の翻訳結果が得られた場合，フィードバックデータを基にして優先順位を決定する．

なお，フィードバックデータについては翻訳結果の正誤により，フィードバック学習部において度数の更新処理を行なう．

3. ルール接続情報の利用

本システムの問題点の一つとして，変数スロットへのルールの適用の際に起こる誤りに起因する誤翻訳が挙げられる．

これは，本手法ではフィードバックデータとして「親ルール番号」「正翻訳度数」「誤翻訳度数」「使用した異表記ルール番号」のみを利用し，またルールの淘汰に対して正・誤翻訳度数のみを使用しており，変数スロット関して他のルールの接続の強さを考慮していないためと考えられる．以下に誤翻訳の例を示す．

some **@1** ; 数本の @1 (6)
trees ; 木 (7)
some **@2** ; いくらかの @2 (8)
milk ; 牛乳 (9)

⇓

some milk ; 数本の 牛乳 (10)

ルール(6)に(7)を適用，(8)に(9)を適用した場合はそれぞれ正翻訳となるが，(6)に(9)を適用した翻訳結果(10)は誤翻訳となる．

ここで，2つの翻訳対から一般化したルールの変数スロットに対し他のルールを適用する場合には，あるルールを適用することによって生成される単語列が親ルールとかけ離れたものになる時にはそのルールの適用を行なわない，と考えるのが普通である．この考えに基づき，本稿では以下に示すように変数スロットに対するルールの接続情報を利用することにより，改良を行なう．

学習部

- 変数スロット数が1以上のルールに対しては，親ルール番号，使用異表記ルール番号の他に以下のような接続データを抽出する．[スロット番号,接続ルール番号,正翻訳度数,誤翻訳度数]
- その接続ルールを親ルールとする子ルール全てについても，同様に接続データとして登録する．

翻訳部

- 変数スロットへのルール適用時には，接続データが存在するルールの適用を最優先する．

フィードバック学習部

- 翻訳結果が正翻訳となった場合には，接続データが既に登録済みものについてはその正翻訳度数を増加させ，接続データが登録されていないものについては新たにデータを登録する．
- 接続データが既に存在するものだけを使用して出来た翻訳結果が誤翻訳の場合には，その接続データの誤翻訳度数を増加する．

4. おわりに

本稿では，ルール接続情報を用いた帰納的学習による機械翻訳手法の改良について述べた．これにより，変数スロットへのルールの誤適用による誤翻訳が減少できる．

また，以上の改良により誤ったルールのフィードバック処理の改善も見込まれる．従来は，(10)式で示したようにルールそのものが間違っている訳ではなく，組合せだけが間違っている場合であっても使用ルールが誤翻訳としてフィードバック処理されていた．本稿での改良手法により，変数スロットに対するその他のルールとの接続情報についてフィードバック処理するため，上記のような問題は起こらないと考えられる．

今後は，上で述べたルール接続情報を組み込むことにより実際のシステムを改良し，その後評価実験を行なう予定である．

参考文献

[1] 内山，荒木，宮永，栃内：帰納的学習による機械翻訳手法の評価実験，情報処理学会研究報告,NL93-4,pp.23-30,(1993)
[2] 佐藤理史：MBT2 実例に基づく翻訳における複数翻訳例の組合せ利用，人工知能学会誌，Vol.6,No.6,pp.75-85,(1991)
[3] 西方，荒木，宮永，栃内：解析型および学習型機械翻訳手法の評価，情報処理北海道シンポジウム講演論文集，pp.15-17,(1994)
[4] 西方，荒木，宮永，栃内：帰納的学習による機械翻訳手法への解析的知識の導入，電気関係学会北海道支部連合大会講演論文集,p179,(1994)
[5] 内山，荒木，宮永，栃内：帰納的学習による機械翻訳手法の改良，電気関係学会北海道支部連合大会講演論文集,p397,(1993)