275 文章構造解析のための単語連鎖構造の生成

佐藤 嘉高† 荒木 健治‡ 宮永 喜一† 栃内 香次†
†北海道大学 工学部
‡北海学園大学 工学部

1 はじめに

計算機を使用した自然言語の解析において研究課題とされているものの一つに，文脈情報をどのように扱うか，ということがある．

我々の目的は文章の構造を解析し，文脈を理解する計算機システムを構築することである．一般に，文脈は文と文とのつながり具合と見なされている．したがってこの文脈を理解するためには文と文との間に見られる文法的・語彙的関係である結束関係を見つけることをまず行なわなければならない[1]．我々は特に文で述べていることの意味内容，主題がどのように移り変わっていくか，つながりがどう変わっていくかに着目することを考えている．すなわち，文章の構造の中で，どのように単語がつながっているか，もしくは，単語のつながりがどのように文章の構造に関わりがあるか，を実験的に考察することが本研究の目的である．

本論文では，英語の文章を対象とし，結束性の表現形式について考察し，実験を行ない検証した結果について述べる．

2 テキストの構造

2.1 結束性の表現形式

英語の文章の構造解析に関する研究には，例えば文献[2]がある．この研究では，単語の関係をRogetのシソーラスにおける分類を参照することにより求め，結束関係を単語の連鎖として表している．

この研究に関して，問題点や課題として以下のようなものを挙げることができる．

1. 単語連鎖は，それが張られているか否かしか表現されておらず，単語間の関係の強さについては考慮されていない．
2. シソーラスに固有名詞や専門的領域の用語が登録されていなかったり，単語間の関係の表現が不十分である．
3. 処理に計算機を使用しておらず，人間の直観的判断により実験を行なっている．

我々はこれらのうち，特に連鎖に強さを導入することが，第一に解決するべき本質的なものであると考える．

2.2 重み付き単語の連鎖

前節で述べたように，文章中における語と語の間の関係をより的確に表現するためには，そこに強さの概念を導入するべきであると考えている．ここでまず問題となるのは，その強さをどのように求めるか，ということである．我々は文献[2]においてとられている方法と同様に，単語の繰り返し，密度，距離から求めることとする．

次に，その強さの適応的変化の問題がある．強さは変化させる必要があると考える．その理由は，全体の意味は部分の意味の和として表されると考えられるので，文章の先頭から順に一文ずつ解析する場合には，それまでに解析した部分のlinkの強さが変化すると考えられるからである．

さらに，その強さをどのような基準で変化させるか，という問題がある．この点に関しては，検討中であるが，実験を行なった上で考察する必要がある．

なお，単語間の関係を得る知識ベースとしては，文献[2]と同様にシソーラスを用いる．

3 実験

テキストにおける単語の連鎖の生成は，以下のような手順にしたがって行なう．

1. テキストの先頭の文に対して，その中の名詞をすべて取り出し，リストに入れる．
2. テキストの2文目以降の文に対して以下の処理を行う．
   (a) 名詞について，表層上で同じ単語のくりかえしの出現を調べる．同じ単語の場合には，リンクを張る．
   (b) リンクの強さの更新をする．更新は以下の手順に基づいて行う．
      i. 同じ単語の繰り返しの場合は，強さを増加させる．
      ii. 異なる単語の場合には，重みの計算を行なう．

実験に先立ち，テキストに対して形態素解析が正確に行なわれることが前提となるが，本研究では，品詞情報が各単語に付加されたタグ付きコーパスを実験の対象データとする．

4 考察

単語の関係を解釈する元になるデータをどのようにして得るか，また，どのようなデータを用い，組み合わせるか，が重要であり，今後の研究の中心となると考えられる．

5 おわりに

文章の読みやすさ，わかりやすさはどのような要因によるものか，を客観的に判断し，文脈理解に役立てる目的で考察を行なった．

しかし，実験の手順や材料によって結果が大きく左右されると予想されるため，現段階ではこれらの客観的解釈は今だ難しい問題である．

今後は，実験を行ない，特に単語連鎖の重みをどのように変化させるのが適当か，に関して検討を行なう．

参考文献

[1] 山本和英，増山 繁，内藤昭三: 段落分けを用いた日本語文章における結束構造の検討，情報処理学会論文誌，Vol.35，No.10，pp.2029-2037 (1994).

[2] Morris, J. and Hirst, G.: Lexical Cohesion Computed by Thesaural Relations as an Indicator of the Structure of Text, *Computational Linguistics*, vol.17, No.1, pp.21-48 (1991).