277　誤りを含む翻訳文と校正済み翻訳文からの翻訳誤りの抽出

Extraction of Translation Errors from Erroneous Translation Sentences and Proofread Translation Sentences

荒木　健治
Kenji Araki
北学園大工
Faculty of Engineering
Hokkai-Gakuen University

栃内　香次
Koji Tochinai
北大工
Faculty of Engineering
Hokkaido University

１．はじめに

近年，高度情報化社会の高まりと国際化が急激に進み，機械翻訳の必要性は急激に増大している．しかし，現状では機械翻訳システムは広く使われてはいない．この原因は種々あるが，翻訳精度の低さ，翻訳品質の悪さ及び不愉快な機械的な翻訳誤りの発生が主たるものであると考えられる．すなわち，現状の機械翻訳システムは一応の翻訳はできるが人間が行うこなれた良質な翻訳とはほど遠く，しかも誤り方が人間とは異なるためにユーザに翻訳率の低さ以上の不快感を与えている．また，多くのユーザが機械翻訳システムに過大な期待を抱き，その想定した能力と現実のギャップのために失望するという事態が頻発している．この現状を打破するために，種々の機械翻訳手法[1][2]が提案されているが，上述した問題を抜本的に解決するに至っていない．

そこで，我々はこの問題に対して機械翻訳技術を早急に劇的に改善することが非常に困難であることを踏まえ，誤りを含む機械翻訳の結果と人間が校正を行った正しい翻訳結果より翻訳誤りを抽出し，その抽出された翻訳誤りを用いて誤りを含む機械翻訳結果を復元する手法の開発を試みている．直接，人間が校正した正しい翻訳結果を用いて学習を行うことにより，フィードバックが早くなり，従来の手法より良質な翻訳結果が得られるものと考えられる．

本稿では，その第一段階として行った誤りを含む翻訳文と校正済み翻訳文からの翻訳誤りの抽出手法について述べる．

２．翻訳誤り抽出手法

２．１　概　要

誤りを含む翻訳文と校正済みの翻訳文より翻訳誤りを抽出する際には，まず二文間の単語の対応関係を決定し，次にその対応関係より誤りを推測する必要がある．ところで，翻訳結果には比較的多くの誤りが含まれていることが多いので，構文解析，意味解析などの深い解析を行うのは現状では困難である．そこで，この対応関係を決定する際に用いる情報は，いくつかのヒューリスティクス，表層レベルの字面情報，形態素情報，英和辞典，シソーラス，かな漢字変換の辞書とする．また，対応関係を決定する際に用いるヒューリスティクスには，誤りが最少になるように対応関係を決定する，字面が同じ語は対応関係が存在する，位置的により近い語は遠い語より対応関係が存在する可能性が高い等である．

２．２　対応関係決定手法

次に，対応関係決定手法を以下に示す．なお，これらの処理の前に形態素解析を行うものとする．

（１）出現位置が同じで字面が一致する単語の対応関係を決定．
（２）出現位置が異なり字面が一致する単語の対応関係を決定．
（３）表記あるいは読みが一致する単語の対応関係を決定．
（４）同一の英単語の訳語として存在する単語の対応関係を決定．
（５）上位概念が一致する単語の対応関係を決定．
（６）決定済みの対応関係に挟まれている一語の対応関係を決定．
（７）品詞の一致する単語の対応関係を決定．
（８）より位置的に近い順に対応関係を決定．
（９）対応するものが無い語は付加あるいは脱落誤りである．

以上の各段階で条件を満たす語が複数存在する場合には，位置的に最も近いものを選択する．

２．３　翻訳誤りの抽出及び記録方法

次に，このようにして決定された対応関係を用いて翻訳誤りを抽出する．誤りの種類及びその記録方法を以下に示す．

（１）置換誤り

置換誤りは位置が同じで字面が異なる語である．なお，脱落誤り，付加誤りが存在する場合にはこれを補正して位置を決定する．翻訳結果と校正結果の表記を組で記録する．

（２）付加誤り

付加誤りは翻訳結果に存在し，校正結果に存在しない語である．この場合には，前後の語との三つ組みで記録する．

（３）脱落誤り

脱落誤りは復元結果に存在せず，校正結果に存在する語である．この場合にも，前後の語との三つ組みで記録する．

（４）語順誤り

語順誤りは位置が異なる語である．この場合にも，前後の語との三つ組みで記録する．

３．翻訳誤り抽出実験

３．１ 用いた資料

ＳｕｎＯＳ ４．１．３のオンラインマニュアルを資料として翻訳誤り抽出実験を行った．対象としたコマンドは”ｌｓ”で”ｍａｎ”コマンドで出力されるコマンドの説明文の英語版と日本語版を用いて実験を行った．対象とした文は，その中の１文である．以下にその１文を示す．なお，（２）（３）は形態素解析済みのもので，各語の前の数字は位置を表している．

（１）入力英文

The System V version of this command is available with the System V software installation option.

（２）翻訳結果

0(この)1(命令)2(の)3(System)4(V)5(バージョン)6(は)7(,)8(System)9(V)10(ソフトウェア)11(設置)12(選択)13(と)14(共)15(に)16(利用)17(できる)18(．)

（３）校正結果

0(System)1(V)2(バージョン)3(の)4(この)5(コマンド)6(は)7(、)8(System)9(V)10(ソフトウェア)11(・)12(イ ン ストレーション)13(・)14(オプション)15(と)16(とも)17(に)18(使用)19(できます)20(．)

なお，翻訳は市販の翻訳ソフトLogoVista EtoJ Personal(ロゴヴィスタ社）を用いて行い，形態素解析は，帰納的学習を用いた形態素解析手法[3]で行った．また，表記と読みは帰納的学習を用いたべた書き文のかな漢字変換[4]の辞書，英和辞典は新英和中辞典（研究社），シソーラスは分類語彙表（秀英出版）を用いた．

３．２ 実験結果

表１に対応関係の決定結果を示す．表１でＡは２．２項で述べた対応関係決定アルゴリズムのどの段階で決定されたかを示している．表２に抽出された翻訳誤りを示す．

表１ 対応関係決定結果

A	対応関係
1	6(は)→6(は),7(,)→7(、),8(System)→8(System),9(V)→9(V),10(ソフトウェア)→10(ソフトウェア)
2	0(この)→4(この)2(の)→3(の),3(System)→0(System),4(V)→1(V),5(バージョン)→2(バージョン),13(と)→15(と),15(に)→17(に),18(．)→20(．)
3	14(共)→16(とも)
4	12(選択)→14(オプション)
5	16(利用)→18(使用)
6	17(できる)→19(できます)
7	1(命令)→5(コマンド),11(設置)→12(イ ン ストレーション)
１０	10(脱落)→11(・),11(脱落)→13(・)

３．３ 考 察

１文のみの例であるが，本手法を用いて翻訳誤りが正しく抽出できることが確認された．これは，翻訳誤りの抽出において本手法が有効となりうる可能性を示しているものと考えられる．本手法では，対応関係を決定する際に種々の資源を使用するので，その資源を利用する際の処理時間の増大，未登録語が問題になるものと考えられる．また，本手法で用いた資料は比較的誤り方が良質であったために翻訳結果と校正結果に大幅な変更が見られない．しかし，実際の翻訳結果には正解にはほど遠いものがある．その場合には，翻訳結果と校正結果は全くかけ離れたものになる可能性がある．そのような翻訳結果と校正結果より翻訳誤りを抽出することは非常に困難である．どのレベルまでを対象として翻訳誤りを抽出するかも含めて今後検討する予定である．

表２ 翻訳誤り抽出結果

誤りの種類	翻訳誤り
置換誤り	1(命令)→5(コマンド),11(設置)→12(イ ン ストレーション),12(選択)→14(オプション),14(共)→16(とも),17(できる)→19(できます)
脱落誤り	10(ソフトウェ ア)**10(脱落)**11(設置)→10(ソフトウェア)**11(・)**12(イ ン ストレーション), 11(設置)**11(脱落)**12(選択)→12(イ ン ストレーション)**13(・)**14(オプション)
語順誤り	T**0(この)**1(命令)→3(の)**4(この)**5(コマンド) 0(この)**1(命令)**2(の)→4(この)**5(コマンド)**6(は) 1(命令)**2(の)**3(System)→2(バージョン)**3(の)**4(この) 2(の)**3(System)**4(V)→T**0(System)**1(V) 3(System)**4(V)**5(バージョン)→0(System)**1(V)**2(バージョン) 4(V)**5(バージョン)**6(は)→1(V)**2(バージョン)**3(の)

４．おわりに

本稿では，翻訳結果と校正結果より翻訳誤りを抽出する手法を提案し，さらに具体的な翻訳結果と校正結果より翻訳誤りを抽出した結果について述べた．この結果より本手法が翻訳誤り抽出に有効となる可能性が示された．

今後は，大量の翻訳結果を用いて翻訳誤り抽出実験を行い，本手法の有効性を確認する予定である．さらに，抽出された翻訳誤りより作成された復元ルールを用いて復元を行うシステムを作成する予定である．

参考文献

[1]長尾 真：機械翻訳サミット，オーム社(1989)．
[2]長尾 真：機械翻訳はどこまで可能か，岩波書店(1986)．
[3]荒木健治，栃内香次：帰納的学習による語の獲得および確実性を用いた語の認識，信学論，J75-D-II,7,pp.1213-1221(1992)．
[4]荒木健治，高橋祐治，桃内佳雄，栃内香次：帰納的学習をによるべた書き文のかな漢字変換手法の適応能力の評価，信学技報，NLC94-3,pp.17-24(1994)．