英単語からの帰納的学習を用いた単語片の抽出と単語の生成

笹岡久行*・荒木健治*・桃内佳雄*

Extraction of a Piece of Word and Production of Words Using Inductive Learning from English Words

Hisayuki SASAOKA*, Kenji ARAKI* and Yoshio MOMOUCHI*

計算機による自然言語処理は，これまで規則に基づく手法が主流であった。つまり，自然言語を処理するための規則をあらかじめ計算機に与え，それをもとにして処理を進める手法が多く用いられてきた。しかし，規則に基づく手法にはいくつかの問題点が指摘されている。そこで，最近，コーパス等の用例を利用した学習型の手法が提案されている。この手法は，自然言語を処理するために必要な知識を用例から獲得し，それを利用して処理を進める手法である。また，これまでの自然言語処理手法では単語を最小単位と考えて自然言語を処理する手法が大多数であった。しかし，我々は単語の中に綴りから獲得できるプリミティブな単位があると考えている。そこで，単語の中に存在するプリミティブな単位を抽出する方法およびそれらを用いて単語を生成する方法について研究を進めている。本論文において，単語の中のプリミティブな単位とは単語の中に存在する１文字以上の文字列であり，単語を構成する基本的な単位であると考えている。

本論文では，単語の中に存在するプリミティブな単位を単語片と定義し，英文から単語片を抽出する方法および単語片と単語片の接続を評価する単語片接続確率をもとにして単語を生成する方法を提案する。さらに，本手法をもとにした実験システムを作成し，評価実験を行なった。その実験結果および実験結果から考察される問題点とその改良方法について述べる。

1．はじめに

自然言語を大量にかつ迅速に処理したいという人間の欲求から計算機による自然言語処理手

＊北海学園大学大学院工学研究科電子情報工学専攻
＊Division of Electronics and Information Engineering, Graduate School of Engineering, Hokkai-Gakuen University

法についてさまざまな研究がなされてきた。具体的な応用例としてかな漢字変換や機械翻訳などがある。これまでの計算機による自然言語処理手法は，規則に基づく手法と呼ばれるものが主流であった。つまり，自然言語を処理するための規則をあらかじめ計算機に与えておき，それをもとにして処理を進める手法が用いられてきた。規則に基づく手法では自然言語を計算機で利用できる形にするまでにさまざまな解析処理を行なっている。例えば，日本語などの単語の間に区切りを入れない膠着語に対する形態素解析，構文解析，意味解析などが必要になる[1]。これまでの規則に基づく手法では解析に必要となる規則を予め人手により計算機に与えておくことが必要であり，その労力の大きさが問題となっている。また，規則に基づく手法には自然言語の多様性のために生じる例外に対する処理の問題あるいは人間の言語的な習慣に関する情報がシステムに反映されないなどの問題点が指摘されている[2]。

このような規則に基づく手法の抱える問題点を解決するために，コーパス等の大量の用例から必要な知識を獲得し，それらの知識をもとにして処理を進める用例に基づく手法が研究されている[2]，[3]。また，既に形態素解析[4]，機械翻訳[5][6]等の研究を行ないこのような手法の有効性を確認している。さらに，用例に基づく手法と言語情報に対する統計的な処理を組み合わせた手法が提案されている。例えば，日本語のかな漢字変換における膨大な派生語を扱う能力を大幅に拡張した研究[7]，仕事量という単位を利用して頻繁に使用されている定型表現をコーパスから抽出する研究[8]などがある。

ところで，英語は日本語と違い単語の間に区切りを入れて記述されている。そのために，これまで計算機により英語を処理する場合には単語を最小単位として扱ってきた。しかし，例えば，英単語のhappyとunhappyを見ると，unhappyの中に“**un**”と“**happy**”という文字列が存在している。つまり，英単語unhappyは“**un**”と“**happy**”という単位に分割して考えられている。また，“**un**”により英単語unconsciousやunsuitable等が構成されていることや“**happy**”からは英単語happyの派生語happinessやhappilyが存在することを連想する。このことから，単語の中に存在するプリミティブな単位に着目することによりこれまでの手法では見過ごされてきた情報を得ることができると考えられる。本論文において，単語の中のプリミティブな単位とは単語の中に存在する1文字以上の文字列であり，単語を構成する基本的な単位であると考えている。

我々は，単語の中に存在するプリミティブな単位を抽出し，それをもとにして自然言語処理を行なう研究を進めている。この単語の中に存在するプリミティブな単位を単語片(a Piece of Word)と定義する。本論文では，英文の中の単語から単語片を抽出し，単語片の接続を評価する数値である単語片接続確率を求める方法を提案する。次に，単語片とその単語片接続確率を利用して単語を生成する方法を提案する。さらに，本手法をもとにして作成した実験システムに対して行なった評価実験の結果およびそこから考察される問題点とその改良方法について述

べる。

2．処理過程

2.1　システムの概要

本手法をもとにして作成した実験システムの構成を図1に示す。

本研究においては，対象言語を英語とする。まず，入力された英文の単語の中に存在する単語片を抽出し，単語片の接続を評価する数値である単語片接続確率を求める単語片抽出部がある。そして，抽出された単語片とその単語片接続確率から単語候補を生成する単語候補生成部がある。さらに，生成された単語候補が単語であるかを判定する単語候補判定部がある。

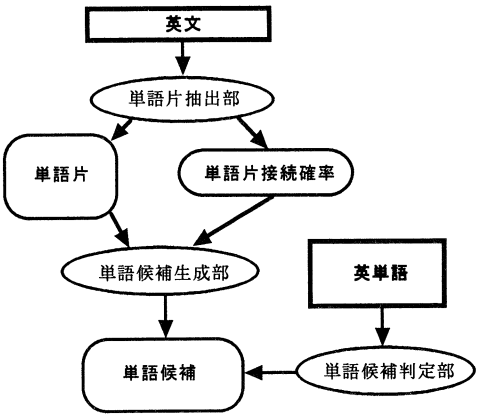


図1：システム構成図

2.2　単語片の抽出

本手法の単語片の抽出方法では，2つの単語の綴りの共通部分と差異部分の抽出を行ない単語片を獲得する。ここでは，仮に2つの単語を単語1と単語2とする。また，この単語1の方が単語2よりも文字列の長さは短いものとする。

1．共通部分の抽出
cat → 中心語片
2．差異部分の抽出
compli → 前方語片
ion → 後方語片
3．抽出結果
cat
中心語片
compli/cat/ion
前方語片／中心語片／後方語片

図2：単語片の抽出例

まず，単語2の中にある単語1と綴りが一致する部分を共通部分として抽出する。この共通部分を中心語片(a Center Piece of Word)と定義し，PW__CTと表記する。さらに，単語2の中で単語1と綴りが異なる部分を差異部分として抽出する。この差異部分のうち，中心語片より前方にあるものを前方語片(a FRont Piece of Word)，中心語片より後方にあるものを後方語片(a REar Piece of Word)と定義し，それぞれPW__FR，PW__REと表記する。共通部分は，2つの単語の綴りを左側から比較して最初に一致する部分を抽出する。
そして，共通部分の左側と右側のそれぞれを差異部分として抽出する。

図2に単語catとcomplicationから単語片を抽出する例を示す。

2.3 単語片接続確率

図3に示すように，単語片にはいくつかの単語片と接続する場合がある。その場合にこの単語片接続確率はある2つの単語片がどのような確率で接続するのかを示す。そして，単語候補の生成時に接続可能な単語片が複数存在する場合に選択の評価基準となる。

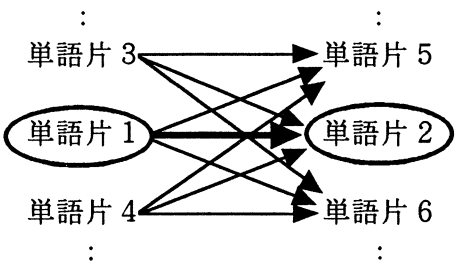


図3：単語片の接続

以下に，この接続確率を求める式を示す。

$$\frac{\text{単語片1と単語片2が接続した回数}}{\{(\text{単語片1の出現回数})+(\text{単語片2の出現回数})\}/2}$$

この式で，分子は英文の中の英単語で単語片1と2が実際に接続していた回数である。また，分母は両単語片の出現頻度の平均である。

2.4 単語候補の生成

本手法の単語候補の生成方法は，獲得された単語片と単語片の接続確率を利用して単語候補を生成するというものである。つまり，プリミティブな単位を統計的な数値を利用して組み合わせることにより単語生成をはかる。まず，既に獲得されている1つの単語片の左側あるいは右側に接続可能な単語片を選択する。複数の接続可能な単語片の候補が存在する場合にはその中で単語片接続確率が最高のものを選択する。左側に接続可能な単語片が存在した場合にはその単語片のさらに左側に接続可能な単語片の選択を行なう。このようにして接続可能な単語片の選択を繰り返す。同様に，右側に接続可能な単語片の選択を繰り返す。そして，このようにして選択された単語片を合わせたものが単語候補として生成される。

以下に，単語片 we から始められる単語候補の生成例を示す。

1．左に接続する単語片の選択

この例では，ans が選択された。この単語片のさらに左に接続する単語片の選択を試みたが，接続可能な単語片は存在しなかった。

左に接続する単語片：ans

2．右に接続する単語片の選択

この例では，rs が選択された。この単語片のさらに右に接続する単語片の選択を試みたが，接続可能な単語片は存在しなかった。

右に接続する単語片：rs

3．選択された単語片の合成

生成された単語候補：answers

2.5 単語候補の判定

生成された単語候補が単語であるかを判定する。単語候補が，以下に示す判定条件の中の単語のいづれかと一致する場合にその単語候補を単語と判定する。また，ここで利用するWordNetはPrinceton大学で作られたシソーラスである。このシソーラスに関する詳細は，文献[9]で述べられている。

判定条件：

1．単語片抽出の際に利用した英単語
2．WordNetの単語辞書にある英単語
3．WordNetの不規則変化する単語辞書にある英単語
4．規則変化する英単語
   (a) 語尾がs，esである名詞
   (b) 語尾がs，es，d，ed，ingである動詞
   (c) 語尾がer，estである形容詞，副詞

3．評価実験

3.1 実験の目的

本評価実験の目的は，我々が定義した単語片が単語のプリミティブな単位となっていることを確認することである。単語片とその単語片接続確率をもとにした単語候補の生成方法を用いて単語と判定される単語候補が生成されていることから，単語片が単語のプリミティブな単位となっていることを確認する。

さらに，単語片を抽出時に利用した英単語を単語候補生成の方法により再生できることを確認する。本論文における単語片の抽出方法では，英文の中の英単語から単語片の抽出を行なっている。システムの側から見ると，単語片の抽出時に利用した単語は1度学習していることになる。そこで，単語片とその単語片接続確率をもとにした単語候補の生成方法により1度学習した単語を生成する再生能力が実現されていることを確認する。

また，1度学習した単語以外の単語もこの単語候補の生成方法により生成できることを確認する。抽出された単語片を組み合わせることにより単語片の抽出時には学習していない単語を生成することが可能である。本手法により学習した以外の単語を生成する造語能力が実現されていることを確認する。

3.2 実験方法

本評価実験では，単語片を抽出する英文として文献[10] の Chapter 1(英文 200 文，単語数 895 個)を用いた。

実験の手順は，まず用意した英文の単語から単語片を抽出する。このときに単語片接続確率を求める。本実験において，英文の中の半角スペースおよび記号を単語の区切りとし，大文字と小文字の区別は行なわない。そして，抽出した単語片と単語片接続確率から単語候補を生成する。単語片接続確率へのしきい値による制限の有効性を調べるために，接続可能な単語片を選択する時に 1％から 80％までの間でしきい値を変化させ，そのしきい値以上の接続確率をもつ単語片のみを選択するという制限を加える。さらに生成された単語候補が単語となっているかどうかを判定する。

3.3 実験結果

用意した英文の単語から 1252 個の単語片が抽出された。

表 1 に，生成された単語候補が単語と判定されたものの数と割合を示す。表 2 に，単語と判定された単語候補のうち，学習した単語とそれ以外の単語のそれぞれの数と割合を示す。さら

表 1　単語と判定された数と割合

しきい値	単語候補数	正単語候補数	正単語候補率
1%	2716	826	30.4%
10%	1490	545	36.6%
13%	1376	519	37.7%
14%	1363	518	38.8%
15%	1360	515	37.9%
20%	1322	500	37.8%
30%	1276	476	37.3%
50%	1264	467	37.3%
80%	1252	456	36.9%

単語候補数　：生成した単語候補の総数
正単語候補数：単語と判定された単語候補の数
正単語候補率：生成した単語候補が単語と判定された割合を示し，以下の式で求められる数値

$$\frac{\text{正単語候補数}}{\text{単語候補数}}$$

表2　生成した単語の数と割合

しきい値	正単語候補数	再生能力値			造語能力値	
		正単語候補数	占有率	再生率	正単語候補数	占有率
1%	826	473	57.3%	52.8%	353	42.7%
10%	545	282	51.7%	31.5%	263	48.3%
13%	519	260	50.1%	29.1%	259	49.9%
14%	518	259	50.0%	28.9%	259	50.0%
15%	515	257	49.9%	28.7%	258	50.1%
20%	500	244	48.8%	27.3%	256	51.2%
30%	476	223	46.8%	24.9%	253	53.2%
50%	467	215	46.0%	24.0%	252	54.0%
80%	456	206	45.2%	23.0%	250	54.8%

正単語候補数：単語と判定された単語候補の数
再生能力値　：単語片の抽出時に利用した単語を生成する再生能力を評価する数値
造語能力値　：単語片の抽出時に利用した以外の単語を生成する造語能力を評価する数値
占有率：正単語候補数の中に占める再生された単語数と造り出された単語数の割合をそれぞれ示し，以下の式で求められる数値

$$\frac{\text{再生能力値（あるいは造語能力値）における正単語候補数}}{\text{単語候補数}}$$

再生率：単語片の抽出時に利用した単語を再生できた割合を示し，以下の式で求められる数値

$$\frac{\text{再生能力における正単語候補数}}{\text{単語片の抽出に利用した単語数}}$$

この実験において分母は定数で895

に，学習した単語候補を再生できた割合を示す。

3.4 考　察

表1からは，接続確率に対するしきい値が1%から14%未満迄では単語候補が単語と判定される割合がしきい値を増加させる程増加しているのがわかる。また，しきい値が14%となった時にその割合が最高になる。さらに，14%よりもしきい値を増加させても単語候補が単語と判定される割合は減少していることがわかる。このことから，単語片の接続確率に対するしきい値はある値まで増加させることにより単語候補が単語と判定される割合を上げることができることがわかった。しきい値が80%では1つの単語片が単語候補として生成されている。つまり，接続される単語片が選択されていないのである。したがって，単語片の接続確率に対するをしきい値を増加させすぎると接続可能なはずである単語片の選択が行なわれない現象が起こることがわる。表2からは，接続確率に対するしきい値が14%未満では学習した単語を再生する能力が強く，しきい値が14%では学習した単語を再生する能力とそれ以外の単語をつくり出す造語能力が同じ程度あり，しきい値を14%以上にすると造語能力が強くなっていることがわか

る。本手法では単語片接続確率を用いて単語候補を生成しているためにしきい値を増加させる程この実験システムにとって確実性の高い学習した単語を生成する数の方が多くなる，つまり単語の再生能力の方が強くなると考えられる。しかし，実際の実験結果はそうはなっていない。その理由として，この実験では学習量が十分ではなっかたと考えられる。図4に，この実験において生成された単語候補が単語と判定された正しい生成例を示す。また，図5に，この実験において生成された単語と判定されなかった誤った生成例を，その原因を分類して示す。

単語片	→	単語候補（単語）
e, motion	→	e/motion
interrel, at, ion	→	interrel/at/ion
be, wilder	→	be/wilder

図4：正しい生成例

このように実験結果を考察すると，単語片をもとにして生成した単語候補が単語と判定されている割合が35%程度あった。また，学習した単語を最高で52.8%，最低で23.0%再生した。このことから我々が定義した単語片が単語の中のプリミティブな単位の一部分であることが確認された。また，提案した単語候補生成の方法では生成した単語候補が単語と判定される割合が高いとは言えない。しかし，単語片と単語片接続確率を利用することにより学習した単語を

1．単語片の接続が足りない単語候補の例

単語片	→	単語候補
at, ion	→	at/ion
in, g	→	in/g

2．単語片の接続が多すぎた単語候補の例

単語片	→	単語候補
remem, be, cause	→	remem/be/cause
k, no, ther	→	k/no/ther

図5：誤った生成例

生成する再生能力と学習した以外の単語を生成する造語能力が実現できる可能性があると考えられる。

3.5　問題点とその改良方法

評価実験の結果に対する考察から本システムの手法に対する問題点が明らかになった。そこで，問題点とその改良方法を以下に述べる。

まず，単語片の抽出方法に関することである。現在の方法で抽出された単語片にはまだ分割の余地はあるが，そのまま存在しているものがある。また，生成した単語候補の中には現在の

方法では単語から抽出できていないが確かに新しい単語片となるものが存在した。このような抽出あるいは生成されたものを利用し，再帰的に単語片を獲得する方法を取り入れることにより単語片の抽出方法の改良を行う。

次に，単語候補の生成方法に関してである。本論文で提案する単語候補の生成方法では，接続可能な単語片の選択時に隣接する単語片の接続確率のみを評価基準としている。１つの単語候補の局所的な情報を用いた評価しかしていないので，１つの単語候補全体に対する評価基準を加えることが有効であると考えられる。また，それとは別に接続可能な単語片の選択の評価基準に出現頻度を導入することが必要であると考えられる。例えば，単語候補の生成時にある単語片と接続可能な単語片が２つあり，片方の単語片は100回出現していて他方は10回しか出現していない場合を考える。ある単語片と２つの単語片との接続確率がそれぞれ等しい時でも，人間が判断する場合には100回出現した単語片との接続の方がより確からしいと判断する。しかし，現在の方法のままでは両者は同じ程度の確かさを持つものと判断してしまう。この点を改良するために単語片の選択の評価基準に単語片の出現頻度を導入することが必要であると考えられる。

また，単語候補を判定した結果を次回の単語候補の生成時に利用することが必要である。生成した結果が正しい結果なのか失敗した結果なのかを判定し，その結果を次回の単語候補の生成時に利用することにより同じ失敗を
何度も繰り返すことを防ぐことができる。

4．おわりに

本論文では，計算機により単語の中に存在するプリミティブな単位を抽出する方法およびプリミティブな単位とその接続を評価する統計的な数値を利用して単語を生成する方法を述べた。そして，その手法をもとにして作成した実験システムに対して評価実験を行い，その結果から我々が定義した単語片が単語のプリミティブな単位の一部分となっていることを確認し，またそこから学習した単語を生成する再生能力と学習した単語以外の単語を生成する造語能力を実現できる可能性があることを示した。そして，本手法が有する問題点を明らかにし，その改良方法の幾つかを述べた。今後は，これらの点を改良し研究を進める予定である。

参考文献

[1] 田中穂積：自然言語解析の基礎，産業図書(1989).

[2] 工藤育男，井ノ上直巳：コーパスに基づく共起知識の獲得とその応用，人工知能学会誌，Vol. 10, No. 2，(1995).

[3] 宇都呂武仁，松本裕治：コーパスを用いた言語知識の獲得，人工知能学会誌，Vol. 10，No. 2，(1995)．
[4] 荒木健治，栃内香次：帰納的学習による語の学習および確実性を用いた語の認識，信学論(D－II)，J 75－D－II，7，pp. 1213－1221(1992)．
[5] 佐藤理史：ＭＢＴ２実例に基づく翻訳における複数翻訳例の組み合わせ利用，人工知能学会誌，Vol. 6，No. 6，pp. 75－85(1991)．
[6] 越前谷博，荒木健治，桃内佳雄：帰納的学習による機械翻訳手法への遺伝的アルゴリズムの適用，情報処理学会自然言語研究会資料，107－10，pp. 75－82(1995)．
[7] 市丸夏樹，中村貞吾，宮本義昭，日高達：シソーラスと確率文法による派生語解析，情報処理学会論文誌，Vol. 36，No. 4，pp. 849－858(1995)．
[8] 北研二，小倉健太郎，森元逞，矢野米雄：仕事量基準を用いたコーパスからの定型表現の自動抽出，情報処理学会論文誌，Vol. 34，No. 9，pp. 1937－1943(1993)．
[9] George, A.M., Richard, B., Christiane, F., Derek, G., and Katherine, M. : Introduction to WordNet, (1993).
[10] Marvin, M. : The society of mind, A Touchstone Book, New York(1986).