帰納的学習による機械翻訳手法における遺伝的アルゴリズムの有効性

越前谷博*・荒木健治*・桃内佳雄*・栃内香次**

Effectiveness of Genetic Algorithms for Machine Translation Method Using Inductive Learning

Hiroshi ECHIZEN-YA*, Kenji ARAKI*, Yoshio MOMOUCHI* and Koji TOCHINAI**

実用的な機械翻訳システムの実現に向け，これまで多くの機械翻訳手法の研究が行われてきた。その代表的なものは，解析型の機械翻訳手法である。この手法は，言語現象の多様性に対応しきれず，良質な翻訳を行うものとはなっていない。この問題点を解決する手法として，近年，実例や用例による学習型の機械翻訳手法の研究が行われている。我々は，学習型の機械翻訳手法の１つとして，従来より提案している帰納的学習による機械翻訳手法へ遺伝的アルゴリズムを適用し，より良い翻訳の実現に向けての研究を行っている。本論文では，本手法の有効性について，実験結果及びその考察結果に基づき述べる。

1．はじめに

近年，文化・経済・科学・技術などの各分野における社会の国際化が進み，他国間との情報交換を迅速に行うことの必要性が高まっている。その際に，大きな役割を担っているのが，言語に依存した情報である。国際社会において，異なる言語間での情報交換を円滑に行うための品質の高い翻訳システムの開発は不可欠となっている。そのために，これまで多くの機械翻訳システムの研究が行われてきた[1)]。その代表的なものは，原文を文法的に解析することで翻訳を

＊北海学園大学大学院工学研究科電子情報工学専攻
＊Division of Electronics and Information Engineering, Graduate School of Engineering, Hokkai-Gakuen University
＊＊北海道大学工学部電子情報工学専攻
＊＊Division of Electronics and Information Engineering, Hokkaido University

高い翻訳が可能となっている。しかし，問題点として，多様な言語現象を有限個の文法規則で記述することによる多分野に渡る良質な翻訳の困難さや辞書の構築・改良の困難さが指摘されている[2]。こうした問題点を解決する手法として，豊富な実例や用例を参照し，それらを利用することにより翻訳を行う，実例や用例に基づく学習型の機械翻訳手法[3)~6)]の研究が行われている。この手法においては，それまでに獲得した学習データに影響を及ぼすことなく，学習データを追加することが可能となるが，良質な翻訳を行うためには，あらかじめ十分な量の学習データを必要とする。我々は，従来より，学習型の機械翻訳手法の１つとして実例から翻訳ルールを帰納的に学習し，翻訳を行う帰納的学習による機械翻訳手法の提案[7)]とその性能評価実験[8)]を行ってきた。その結果，他の学習型の機械翻訳手法と同様に，良質な翻訳を行うためには大量の学習データを必要とすることが明らかとなった。そこで，我々は，この問題を解決する手法として，与えられたデータを最大限に活用した翻訳ルールの抽出とそれらを用いた効率的な翻訳結果の生成を目的に，帰納的学習による機械翻訳手法へ遺伝的アルゴリズム[9)~11)]を適用した。本手法では，英文とその日本語訳文の対からなる翻訳例を個体の染色体に，そして，英文とその日本語訳文を構成しているそれぞれの単語を遺伝子として位置付けている。このような状況のもとで，バラエティに富んだ個体を作り出しながら，環境に適合するための世代交代を繰り返し，最適解を速やかに得るという，遺伝的アルゴリズムの手法を適用する。その結果，システム自身が，与えられたデータから多様な翻訳ルールを作り出し，最適な翻訳結果を生成しながら，より良い学習型の機械翻訳システムへ向け進化を続ける[12)~16)]。本論文では，帰納的学習による機械翻訳手法における遺伝的アルゴリズムの有効性について，性能評価実験に基づき述べる。

2．処理過程

本論文で提案するシステムの処理過程を図１に示す。まず，原文として英文を入力し，その英文に対し，翻訳部においてそれまでに抽出された翻訳ルールを用いて最適な翻訳結果を生成する。次いで，フィードバック学習部において，翻訳部より求められた翻訳結果と利用者が与えた正しい日本語訳文との照合により使用された翻訳ルールに対する適応度の決定と淘汰を行う。そして，学習部において，英文とその日本語訳文からなる翻訳例に対し，交叉や突然変異

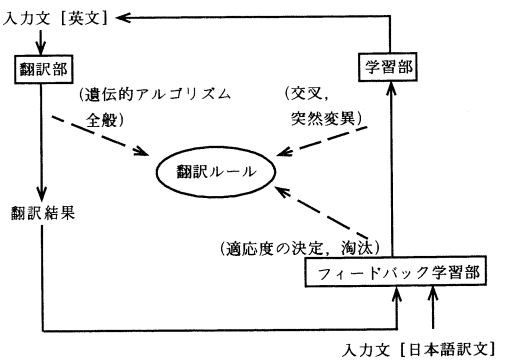


図１　処理過程

を行うことで，多くの翻訳ルールの生成を行う。このように，帰納的学習による機械翻訳手法へ遺伝的アルゴリズムを適用することで，バラエティに富んだ翻訳ルールを自動的に生成しながら，与えられた良質なデータに基づき，より良い学習型の機械翻訳システムへと進化する。

2.1　染色体と遺伝子

次に，本手法において染色体と遺伝子をどのように位置付けているのかについて述べる。図2に示すように染色体には英文とその日本語訳文からなる翻訳例を用いるが，英文とその日本語訳文がそれぞれ異なる遺伝子を持っている。よって，遺伝子にはそれぞれの単語を用い，英文とその日本語訳文が1つの組をなすことで意味を持つものとする。このような位置付けにおいては，個々の個体は可変長の染色体を持つことになるが，これは進化の過程で高等生物になるにつれ，より長く複雑な染色体を持つことを模倣している。また，翻訳例は翻訳ルールを抽出した後に，その翻訳例自身も翻訳ルールとして登録される。これを原文の翻訳ルールと呼ぶ。

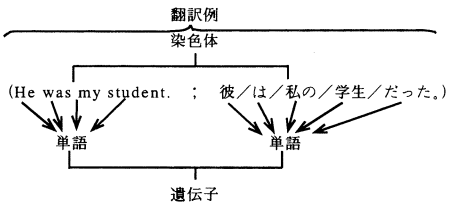


図2　染色体と遺伝子

2.2　フィードバック学習部

フィードバック学習部では，翻訳部で求められた翻訳結果と利用者が与えた正しい日本語訳文とが一致するかどうかにより，使用した全ての翻訳ルールに対する適応度の決定と淘汰を行う。まず，正しい日本語訳文と一致する翻訳結果に対し，翻訳結果の生成時に使用した翻訳ルールの正翻訳度数を1増加させる。また，一致しない翻訳結果に対しては，翻訳ルールの誤翻訳度数を1増加させる。次いで，その値より適応度を決定する。その計算式を以下に示す。

$$\text{適応度}\ (\%)=\frac{\text{正翻訳度数}}{\text{全使用回数}}\times 100$$

そして，この適応度を基に淘汰を行う。淘汰を行う際には，予備実験より，各翻訳ルールに対し，試用期間を必要とすることが明らかとなった[16]。これは，学習が十分に進んでいない段階では，日本語訳文において「私」と「君」や「～です」と「～だ」のような表現の違いを認識できずに，正しい翻訳結果を誤りと判断してしまうことで，使用した正しい翻訳ルールを淘汰する場合が生じるためである。そこで，試用期間を設け，学習を十分に行った上で各翻訳ルールを評価する。この試用期間中に，十分な学習を行うことで，誤った評価を受けた翻訳ルールは，適応度が徐々に増加し淘汰の対象から外れて行くと考えられる。よって，淘汰は適応度が25%以下，全使用回数が5以上の翻訳ルールに対し行う。

2.3 学習部

学習部では，与えられた翻訳例に対し，交叉や突然変異を行うことで，多様な翻訳ルールを生成する。交叉や突然変異を用いた翻訳ルールの抽出過程を図3に示す。交叉は，英文とその日本語訳文のそれぞれの共通部分を交叉位置とする一点交叉を行う。図4に交叉の具体例を示す。まず，既存の翻訳例を対象に，英文とその日本語訳文のそれぞれにおいて共通部分を持つ2つの翻訳例を選択する。図4に示す例では，英文においては「were」が，日本語訳文においては「は」と「でした」が共通部分となり選択された。次いで，その共通部分を交叉位置とし，英文とその日本語訳文のそれぞれにおいて一点交叉を行う。その結果，図4の（3）に示す新たな翻訳例が生成される。また，日本語訳文の「でした」を交叉位置とする交叉は，新たな翻訳例を作り出さないため，以後に使用しないものとする。このように，交叉では英文とその日本語訳文が，それぞれ独立して共通部分を基に一点交叉を行うことで，多くの翻訳例を生成する。

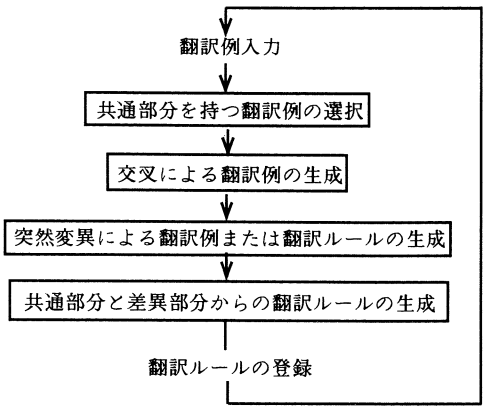


図3　翻訳ルール抽出の処理過程

突然変異は，乱数を用い，突然変異率を2％として翻訳例に対するランダムな変更を行う。図5にその具体例を示す。この例は，翻訳例の単語（summer；夏）が（winter；冬）に変更されたものである。このように変更の際に使用するものは，既存の単語の翻訳ルールもしくは変

（1）翻訳例の選択

(They were good students.　；　彼ら／は／よい／生徒／でした。)
(We were twelve years old.　；　私達／は／１２／歳／でした。)

（2）交叉の実行

They were ╲ good students.　→　They were twelve years old.
We were ╱ twelve years old.　　We were good students.

彼ら／は ╲ ／よい／生徒／でした。　→　彼ら／は／１２／歳／でした。
私達／は ╱ ／１２／歳／でした。　　私達／は／よい／生徒／でした。

（3）新たに生成された翻訳例

(They were twelve years old.　；　彼ら／は／１２／歳／でした。)
(We were good students.　；　私達／は／よい／生徒／でした。)

図4　交叉の例

数とする。また，突然変異は翻訳例に対するランダムな変更であるため，誤ったものを生成する場合がある。そのような誤った翻訳例もしくは翻訳ルールは，徐々に適応度を低下させ，淘汰することで対処している。

そして，新たに生成された翻訳例を加え，我々が先に提案した共通部分と差異部分を多段階に抽出する手法[7]を用いることで，多くの翻訳ルールの生成が可能になる。図4の(1)に示した2つの既存の翻訳例より抽出される最終的な翻訳ルールを図6に示す。このように，遺伝的アルゴリズムの基本操作を適用することで，システム自身が自動的に多くの翻訳例を生成し，良質な翻訳ルールの抽出が可能となる。その結果，従来の手法が抱えていた，複数の類似した翻訳例の不足により，良質かつ多様な翻訳ルールの抽出が困難であるという問題点を大幅に改善できることを確認できた[12)~16)]。

・成功例

(I like summer better.　；　私／は／夏／のほう／が／好き／です。)

↓ (winter；冬) による変更 ↓

(I like winter better.　；　私／は／冬／のほう／が／好き／です。)

・失敗例

(I like summer better.　；　私／は／夏／のほう／が／好き／です。)

↓ (winter；冬) による変更 ↓

(I like summer winter.　；　私／は／夏／冬／が／好き／です。)

図5　突然変異の例

①原文の翻訳ルール

(They were good students.　；　彼ら／は／よい／生徒／でした。)
(We were twelve years old.　；　私達／は／１２／歳／でした。)
(They were twelve years old.　；　彼ら／は／１２／歳／でした。)
(We were good students.　；　私達／は／よい／生徒／でした。)

②単語の翻訳ルール

(They　；　彼ら)，(We；　私達)，(good students　；　よい／生徒)
(twelve years old　；　１２／歳)

③文の翻訳ルール

(They were @0.　；　彼ら／は／@0／でした。)
(We were @0.　；　私達／は／@0／でした。)
(@0 were good students.　；　@0／は／よい／生徒／でした。)
(@0 were twelve years old.　；　@0／は／１２／歳／でした。)
(@0 were @1.　；　@0／は／@1／でした。)

図6　抽出された翻訳ルール

2.4 翻訳部

翻訳部では，学習部でそれまでに生成された翻訳ルールを用いて，最適な翻訳結果を生成することを目的としている。よって，翻訳部のみで，1つの完結した遺伝的アルゴリズムの流れを構築することにより，最適な翻訳結果の生成を行う。翻訳部における処理の流れを図7に示す。

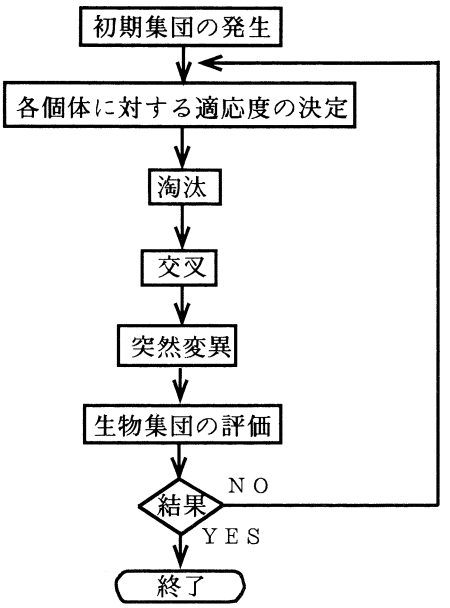


図7　翻訳部における処理の流れ

次に，図7における個々の処理部の詳細について述べる。

（1）初期集団の発生

それまでに抽出された翻訳ルールより，入力文の基礎的な構造を表現している文の翻訳ルールを選択し，初期集団を発生させる。入力文の基礎的な構造を表現している文の翻訳ルールとは，変数部分を除いた際の単語の構成が，入力文に完全に含まれているものである。

（2）各個体に対する適応度の決定

フィードバック学習部で用いた計算式に基づき，各翻訳ルールに対する適応度を決定する。

（3）淘汰

上記の（2）で決定された適応度より淘汰を行う。その際には，フィードバック学習部と同様に，全使用回数が5以上，適応度が25%以下の翻訳ルールを対象とする。

（4）交叉

学習部で用いた手法と同様に共通部分を基に，英文とその日本語訳文のそれぞれにおいて一点交叉を行う。

（5）突然変異

学習部と同様に，乱数を用い，突然変異率を2%として翻訳ルールに対するランダムな変更を行う。

（6）生物集団の評価

文の翻訳ルールの変数部分に単語の翻訳ルールを代入し，入力文と一致するものが得られるかどうかを調べる。一致するものが存在した場合，その英文に対する日本語訳文を翻訳結果とする。一致するものが存在しない場合，つまり，変数を含んだ翻訳結果が生成された際には，（2）から（6）を繰り返し，変数を除いた場合の英文が入力文と最も類似するものを検索す

る。そして，その英文に対する日本語訳文を最終的な翻訳結果として翻訳部における処理を終了する。図8に翻訳結果生成の具体例を示す。

翻訳結果が複数生成された場合，適応度の高い翻訳ルールを使用したものを最終的な翻訳結果とする。適応度より決定できない場合には，より具象的な翻訳ルールを使用しているもの，つまり，他の翻訳ルールとの組み合わせの必要性が最小限であった翻訳ルールを使用しているものを最適な翻訳結果とする。

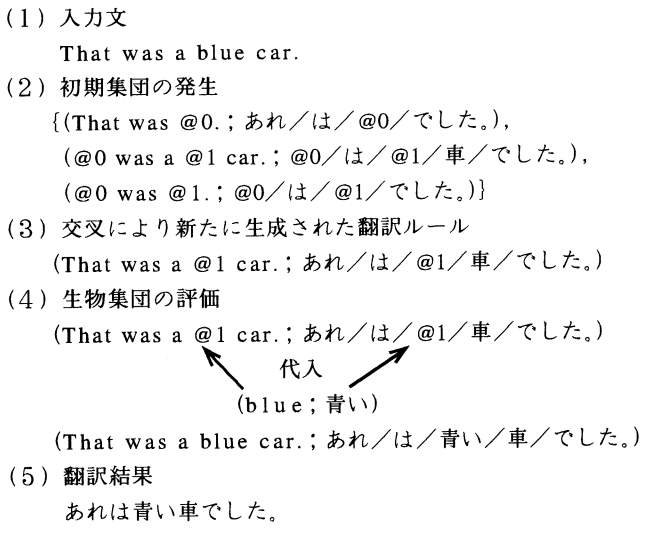


図8　翻訳結果の生成

3．性能評価実験

3.1　評価方法

本手法において生成された翻訳結果に対する評価方法について述べる。有効な翻訳は，未登録語を含まない正翻訳と未登録語を含む正翻訳である。未登録語を含む正翻訳とは，未登録語に名詞句や形容詞などの単語の翻訳ルールを与えることで，容易に未登録語を含まない正翻訳が得られるものである。また，無効な翻訳とは，未登録語を含まない誤翻訳と未登録語を含む誤翻訳，そして，適用可能な翻訳ルールが1つも存在せずに翻訳が全く行えなかった翻訳不能である。未登録語を含む誤翻訳とは，未登録語に名詞句や形容詞以外の単語の翻訳ルールを必要とするため，容易に有効な翻訳とならないもの，あるいは，未登録語は名詞句や形容詞などの単語の翻訳ルールを必要とするが，与えても未登録語以外に誤りがあるため有効な翻訳とならないものである。図9にその具体例を示す。

（1）有効な翻訳
①未登録語を含まない正翻訳（正翻訳）
入力文　：He is your teammate.
翻訳結果：彼はあなたのチームメイトです。
　　彼は君のチームメイトだ。
②未登録語を含む正翻訳（未登録）
入力文　：You play basketball.
翻訳結果：あなたは@0をします。
　　@0はバスケットボールをする。

（2）無効な翻訳
①未登録語を含まない誤翻訳（誤翻訳）
入力文　：That is my desk.
翻訳結果：あれは私の机ではない。
②未登録語を含む誤翻訳（未登録）
入力文　：I don't like fish.
翻訳結果：私は@0が好きです。
　　私は魚@0。
③翻訳不能（翻訳不能）
入力文　：He is older than I.
翻訳結果：翻訳不能

図9　翻訳結果の評価方法

3.2　実験方法

実験は，まず，辞書を空の状態にした後，中学1年生用教科書ガイド・ワンワールド[17]に掲載されている英文とその日本語訳文の1,010組（総文字数11,479文字）より学習した翻訳ルールを逐次，辞書に登録することにより初期辞書を作成した。次いで，中学1年生用教科書ガイド・ニューホライズン[18]に掲載されている英文800文を翻訳評価データとして翻訳を行った。また，翻訳結果が得られた後には，正しい日本語訳文を与え，1文ずつ学習を行った。

3.3　実験結果

本手法における有効な翻訳率は65.3%となった。表1に遺伝的アルゴリズムを適用しなかった場合の実験結果，表2に遺伝的アルゴリズムを適用した場合の実験結果を示す。また，図10に遺伝的アルゴリズムを適用しなかった場合と適用した場合の有効な翻訳率の推移を示す。破線で表したものが遺伝的アルゴリズムを適用しなかった場合，実線で表したものが遺伝的アルゴリズムを適用した場合の有効な翻訳率の推移である。

3.4　考察

実験結果より，有効な翻訳率は54.8%から65.3%に増加した。この増加は，中学1年生用教科書ガイド・ニューホライズン[18]に掲載されている英文800文における，無効な翻訳から有効な翻訳に移行した103文と有効な翻訳から無効な翻訳に移行した19文の差である84文に相当する。この遺伝的アルゴリズムの適用による翻訳率の増加は，多様かつ良質な翻訳ルールの生成が可能になったためである。以下にどのような良質な翻訳ルールが増加したのかを示す。

①入力文と完全に一致する翻訳ルール，つまり，変数を含まない原文の翻訳ルール

②変数を含んでいるが，名詞句や形容詞などの単語の翻訳ルールのみを必要とする良質な文

表1　遺伝的アルゴリズムを適用しなかった場合の実験結果

		翻訳率	合　計
有効な翻訳	正 翻 訳	41.7%	54.8%
	未 登 録	13.1%	
無効な翻訳	誤 翻 訳	7.5%	45.2%
	未 登 録	26.9%	
	翻訳不能	10.8%	

表2　遺伝的アルゴリズムを適用した場合の実験結果

		翻訳率	合　計
有効な翻訳	正 翻 訳	49.8%	65.3%
	未 登 録	15.5%	
無効な翻訳	誤 翻 訳	11.9%	34.7%
	未 登 録	16.5%	
	翻訳不能	6.3%	

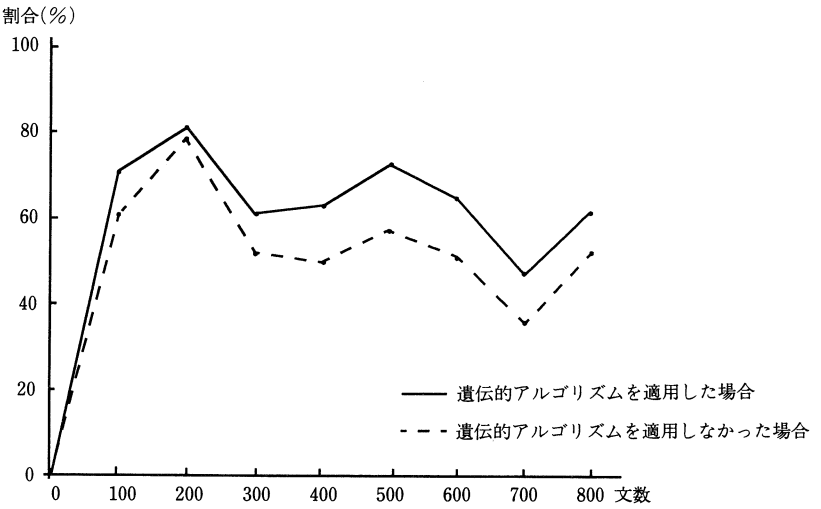


図10　有効な翻訳率の推移

の翻訳ルール

③正確に切り出された単語の翻訳ルール

このような翻訳ルールの生成は，遺伝的アルゴリズムの適用により，差異部分を明確に対応付けできる多くの翻訳例の出現数が増加したため可能となった。

次に，遺伝的アルゴリズムを適用することにより，無効な翻訳へ移行した19文について，その原因を以下に示す。

①交叉において英文とその日本語訳文の対応しない誤った翻訳例が作り出され，それらを使

用することで誤った翻訳ルールが生成された。

②学習が十分に進んでいない段階において，日本語訳文の表現の違いを認識できずに誤った翻訳ルールが生成された。

また，淘汰された翻訳ルールについては，その約97%を誤った翻訳ルールが占めていたことから，かなり高い精度で評価されていることが明らかとなった。

4．おわりに

本論文では，帰納的学習による機械翻訳手法における遺伝的アルゴリズムの有効性について，性能評価実験に基づき述べた。実験の結果，有効な翻訳率は54.8%から65.3%に増加し，遺伝的アルゴリズムの適用が，与えられたデータを効率良く活用した翻訳ルールの抽出とそれらを用いた翻訳結果の生成を可能にすることを確認できた。また，無効な翻訳において，その約47%がそれまでに与えられていない一般動詞や三人称単数により変化した形で与えられた一般動詞の出現によるものであったことから，学習を十分に行うことで翻訳率を向上させることが可能になると考えられる。

今後は，誤翻訳を防ぐことを目的とした，誤った翻訳ルールに対する生成防止と早期の淘汰の実現に向けての改良を行う。そして，より実用レベルの翻訳を可能にするための研究を進めて行く予定である。

参考文献

1）長尾真：機械翻訳サミット，オーム社(1989)．
2）野村浩郷（編）：言語処理と機械翻訳，講談社(1991)．
3）赤間清：帰納的学習システムＬＳ／１による翻訳の学習，人工知能学会誌，Vol.2，No.3，pp 341－349(1987)．
4）佐藤理史：ＭＢＴ２：実例に基づく翻訳における複数翻訳例の組合せ利用，人工知能学会誌，Vol.6，No.6，pp 861－871(1991)．
5）野美山浩：事例の一般化による機械翻訳，情報処理学会論文誌，Vol.34，No.5，pp 905－912(1993)．
6）古瀬蔵，隅田英一郎，飯田仁：経験的知識を活用する変換主導型機械翻訳，情報処理学会論文誌，Vol.35，No.3，pp 414－425(1994)．
7）荒木健治，栃内香次：多段階共通パターン抽出法を用いた翻訳例からの帰納的学習による翻訳，情報処理北海道シンポジウム'91，pp.47－49(1991)．
8）内山智正，荒木健治，宮永喜一，栃内香次：帰納的学習による機械翻訳手法の評価実験，情報処理学会研究報告，NL 93－4，pp. 23－30(1993)．
9）Goldberg, D.E. : Genetic Algorithms in Search, Optimization, and Machine Learning, Addison-Wesley (1989)．
10）北野宏明：遺伝的アルゴリズム，産業図書(1993)．

11) 安居院猛，長尾智晴：ジェネティックアルゴリズム，昭晃堂(1993)．
12) 越前谷博，荒木健治，桃内佳雄：帰納的学習による機械翻訳手法への遺伝的アルゴリズムの適用，北海学園大学工学部研究報告，22，pp. 275－283(1995)．
13) 越前谷博，荒木健治，桃内佳雄，栃内香次：遺伝的アルゴリズムを用いた帰納的学習による機械翻訳手法の性能評価，電子情報通信学会総合大会，D－112，pp. 118(1995)．
14) 越前谷博，荒木健治，桃内佳雄，栃内香次：帰納的学習による機械翻訳手法における遺伝的アルゴリズムの有効性の評価，情報処理北海道シンポジウム '95，pp. 22(1995)．
15) 越前谷博，荒木健治，桃内佳雄，栃内香次：実例からの帰納的学習による機械翻訳手法における遺伝的アルゴリズムの有効性について，情報処理学会研究報告，NL 107－10，pp. 75－82(1995)．
16) 越前谷博，荒木健治，桃内佳雄：遺伝的アルゴリズムを用いた帰納的学習による機械翻訳手法，平成6年度電気関係学会北海道支部連合大会講演論文集，No. 162.
17) 教科書ガイド教育出版版ワンワールド1，日本教材，東京(1991)．
18) 教科書ガイド東京書籍版ニューホライズン1，あすとろ出版，東京(1991)．