社団法人　電子情報通信学会
THE INSTITUTE OF ELECTRONICS,
INFORMATION AND COMMUNICATION ENGINEERS

信学技報
TECHNICAL REPORT OF IEICE.
NLC96-64 (1997-03)

# 語基および接辞の接続情報を用いた辞書未登録語の訳語推定手法

笹岡久行　荒木健治　桃内佳雄
北海学園大学工学部
〒064 札幌市中央区南２６条西１１丁目
E-mail: {sasa, araki, momouchi}@eli.hokkai-s-u.ac.jp

栃内香次
北海道大学工学部
〒060 札幌市北区北１３条西８丁目
tochinai@hudk.hokudai.ac.jp

あらまし　機械翻訳手法の研究における問題の一つに辞書未登録語の処理がある。これは、翻訳対象にシステムの辞書に未登録である単語が出現した場合に、その文の翻訳に失敗したりあるいはその翻訳が不可能になることである。我々は、この問題の解決を目指して帰納的学習を利用した辞書未登録語の訳語推定手法について研究を進めている。本稿では、単語とその訳語の字面から帰納的学習により得られる辞書未登録語の訳語推定に利用可能な単位の抽出手法およびその単位を利用した辞書未登録語の訳語推定手法を提案する。さらに、派生語と複合語を対象に、辞書未登録語の訳語推定手法を基にしたシステムの評価実験の結果およびその考察について述べる。

キーワード　帰納的学習、訳語、推定、辞書、未登録語

# Prediction Method of Word for Translation Using Connection Information of Base and Affix in Word

Hisayuki SASAOKA　Kenji ARAKI　Yoshio MOMOUCHI
Fac. of Enginneering,
Hokkai-Gakuen University
S26-W11,Chuo-ku,Sapporo 064,Japan
E-mail: {sasa, araki, momouchi}@eli.hokkai-s-u.ac.jp

Koji TOCHINAI
Fac. of Enginneering,
Hokkaido University
N13-W8,Kita-ku,Sapporo 060,Japan
tochinai@hudk.hokudai.ac.jp

Abstract

One of problems on the machine translation system is that it can not tranlate the word which is not registered in the dictionary. To resolve the problem, we do research on the prediction method of the unknown word for translation using inductive learning. In this paper, we propose the extraction method of units to use for the prediction of the unknown word for translation by inductive learning and the prediction method of the word for translation using these units. And we describe the experimental results of evalation for our method.

key words　Inductive Learning, Word for Translation, Prediction, Dictionary, Unknown Word

## 1 はじめに

我々は、膨大な量の情報が行き交う社会の中で生活しており、この情報の利用は必須の条件となりつつある。そして、パーソナルコンピュータの普及、通信網の発展等の理由により、各個人が扱う情報も多様化している。このために、多くの人にとって母国語以外の言語で記述された情報を扱う機会が増えている。そのような機会が増えるにつれてコンピュータに翻訳を行なわせる機械翻訳に対する需要が高まっており、機械翻訳手法の研究が盛んになっている [野村 88, 長尾 89, 隅田 90, 赤間 87, 佐藤 91, 長尾 96]。

機械翻訳システムを利用して実際に英文を翻訳するとシステムの辞書には登録されていない単語が出現している場合がある。このような単語を辞書未登録語と呼ぶ。この辞書未登録語の処理は機械翻訳の研究の抱える問題の一つである。多くの機械翻訳手法の研究では、システムの辞書の登録単語数を増やすことにより辞書未登録語の出現回数を減らすことを試みている [野村 88]。しかし、実際に存在する単語を全て辞書に登録することはその労力の大きさおよびハードウェア的な制約から考えて不可能である。また、自然言語には造語作用がある。辞書を作成した後に、この造語作用により新たな単語が生み出され、利用される。このためにそのような単語は、辞書未登録語となる。このような理由から、辞書の登録単語数を増やすことだけでは完全に辞書未登録語の処理の問題を解決できない。また、翻訳対象分野を限定することにより、出現する単語を限定しようとする機械翻訳手法の研究 [相沢 96] も存在する。確かに、翻訳分野を限定することにより、辞書未登録語の出現回数は減少すると考えられる。しかし、この手法では対象分野を変更するたびにシステムの辞書等を作り直さなければならず、その労力の大きさが問題となる。また、上述したように自然言語の造語作用による新出語の出現により辞書未登録語の処理の問題は完全には解決されていない。

大規模コーパスに出現した辞書未登録語の調査に基づき、辞書未登録語の処理の必要性を述べ、それらの性質を明らかにし、さらに未登録語を名詞に限定して意味概念の分類に有効となる知識を整理した研究 [山田 94] がある。この研究では、名詞の未登録語の意味概念の分類を推定する際に有効である知識は形態素レベルの知識であることを述べている。しかし、この研究では未登録語の意味概念の分類に有効となる知識の整理を行ったのみであり、機械翻訳手法の研究における未登録語の処理の問題の解決には至っていない。

そこで、我々は辞書未登録語の処理の問題の解決を目指し、帰納的学習を利用した辞書未登録語の訳語推定手法について研究 [笹岡 96a, 笹岡 96b] を進めている。本研究において帰納的学習とは、具体的な例から何らかの規則あるいは知識を発見し、獲得するアルゴリズムであると考えている。また、本手法では帰納的学習により英単語とその訳語の字面から訳語推定に利用する単位を抽出し、その抽出されたものを利用して辞書未登録語の訳語推定を行なう。英単語あるいはその訳語の字面の共通部分と差異部分の抽出結果から得られる文字の並びを単語片と呼び、二つの異なる英単語とその訳語の組みから抽出された単語片の組みを単語片対と呼んでいる。本稿では、帰納的学習を用いた英単語とその訳語からの単語片対の抽出手法および単語片対を利用した訳語推定手法を提案する。さらに、単語の語基とその訳語の組みあるいは接辞とその訳語の組みを単語片対として持っている初期状態での実験システムに対して行なった評価実験の結果およびその考察について述べる。また、本研究では英語の辞書未登録語から日本語の訳語を推定することを対象とする。

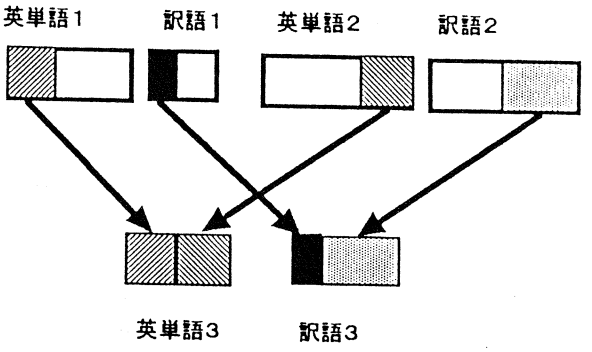



図1 訳語推定に用いる単位

## 2 単語片と単語片対

本研究では、辞書未登録語の訳語推定に利用する単位であり、単語の共通部分と差異部分の抽出結果から得られる文字の並びを単語片と呼ぶ。また、二つの異なる英単語とその訳語の組みから抽出される単語片の組みを単語片対と呼んでいる。英単語とその訳語の中に存在している単語片対を利用して辞書未登録語の訳語推定を行う。このような手法を取った理由は、我々が訳語推定に利用する単位が文脈の中に存在すると考えているからである。単語は、意味を表す文字列である。単語の文字の並びの中には、その単語に関連した意味を持つ文字の並びが存在する場合がある。人間はある単語を見た場合に、別の単語に存在したより小さな単位を利用してその単語の意味を考える場合がある。つまり、図1に示すように、単語3の訳語は単語1と単語2の英単語とその訳語の組みに存在する単語片対から推定可能な場合がある。

例えば、図2の英単語「system」と「systematic」におい

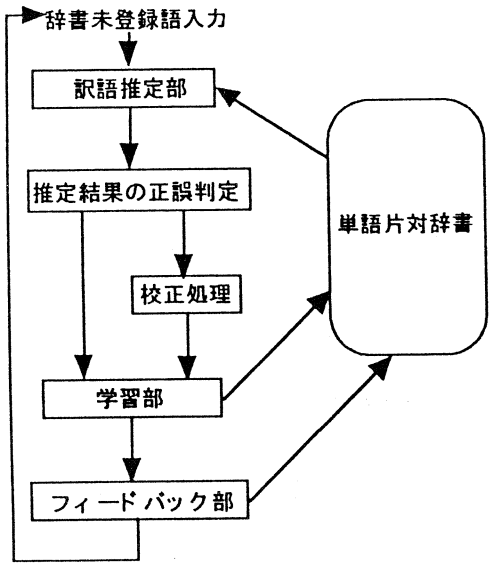



図6 システムの構成

単語片対とそれ以前に獲得されている単語片対の間からさらに新しい単語片対の学習を行なう。最後に、推定結果の正誤判定結果によって、訳語推定に利用した単語片対に対してフィードバック処理を施す。訳語推定に利用されたものに対してその推定結果の正誤に応じた処理を行なう。これは、正しい推定に利用された単語片対と誤った推定に利用された単語片対の間に差別化を行うための処理である。この処理により、正しい訳語推定に利用された単語片対の選択の優先順位を上げ、他の単語の訳語推定処理での単語片対の選択の際に選択されやすくし、同じ誤りを起こすことを防ぐ。そして、それ以降の訳語推定能力を改善する。

## 3.2 訳語推定処理

単語片対辞書に存在する単語片対を利用して、辞書未登録語の訳語推定を行なう。まず、対象となる辞書未登録語と単語片対の英語の単語片の字面において、左側からの最長一致によって利用可能な単語片対の検索を行なう。そして、検索された単語片対の日本語側の単語片対を組み合わせて訳語を生成する。そして、検索された英語の単語片を組み合わせ辞書未登録語の綴りが再現された場合、その訳語推定を完了する。

字面による検索の結果、複数の単語片対の組合せが存在した場合は、推定に利用している以下の数値を参照して推定結果の優先順位を決定する。

1. 訳語推定に利用している単語片対の個数
2. 訳語推定に利用した各単語片対の出現度数の平均
3. 訳語推定に利用した各単語片対の正推定度数の平均
4. 訳語推定に利用した各単語片対の誤推定度数の平均
5. 訳語推定に利用した日本語の単語片の接続の正接続度数の平均
6. 訳語推定に利用した日本語の単語片の接続の誤接続度数の平均

ここで、ある単語片対が正しい訳語推定に利用された回数をその単語片対の「正推定度数」、誤った訳語推定に利用された回数をその単語片対の「誤推定度数」と呼ぶ。また、日本語の単語片の接続において、正しい訳語推定に利用された回数をその単語片の接続の「正接続度数」、誤った訳語推定に利用された回数をその単語片の接続の「誤接続度数」と呼ぶことにする。

1の数値は小さいものを優先する。これは、単語の意味を構成する文字の並びにおいて、より大きな単位の組合せの方が正しいというヒューリスティクスに基づいている。また、2の数値は大きいものを優先する。2は、訳語推定において過去により多く利用したものの方が確からしいというヒューリスティクスに基づいている。3と5はの数値は大きいものを、4と6の数値は小さいものを優先する。これは、過去の推定において正しい推定に利用された回数の多いものほど確からしく、誤った推定に利用された回数が多いものほど確からしくないというヒューリスティクスに基づいたものである。

この優先順位の決定が有効な例として、推定対象単語が「testing」(正しい訳語「テストしている」)がある。単語片対辞書に「test@1、テスト@1」、「ing、している」、「in、の中に」、「@1g、@1グラム」が存在している場合、単語片対の組み合わせは「test ing、テスト している」、「test in g、テスト の中に グラム」の2通り存在する。しかし、上述した推定結果に対する優先順位決定の基準により、訳語推定に利用している単語片対の個数が少ない「test ing、テスト している」の推定結果をより優先順位の高い推定結果と決定することができる。また、この訳語推定結果は正しい訳語と一致している。

## 3.3 フィードバック処理

フィードバック処理では訳語推定に利用された単語片対および日本語の単語片の接続が持つ以下の数値を操作する。

1. 出現度数

英単語１：　「**system**」
英単語２：　「**systematic**」

⇓

共通部分：　「**system**」
差異部分：　「atic」

図 2 英語の単語片の例

日本語１：　「制御システム」
日本語２：　「オペレーティングシステム」

⇓

共通部分：　「システム」
差異部分１：　「制御」
差異部分２：　「オペレーティング」

図 3 日本語の単語片の例

英単語 1:　「**system**」　訳語 1:　「システム」
英単語 1:　「**systematic**」　訳語 1:　「システムの」

⇓

共通部分:　「**system**、システム」
差異部分:　「atic、の」

図 4 英単語とその訳語における単語片対の例

訳語推定対象単語：「systematize」

単語片対１：　「system @1、システム @1」
単語片対２：　「atize、化する」

⇓

推定結果：　「システム化する」

図 5 単語片対を利用した訳語推定の例

て、この二つの単語における共通な文字の並び「**system**」を見つけ出し、両単語の意味の関連性を発見する。そして、「**system**」の後ろに文字の並び「atic」が付くことにより「system」と「systematic」の意味の違いを作り出している。

また、「**system**」を基にしてその後ろに「atical」を付加して英単語「systematical」、同様に「atically」を付加して英単語「systematically」が生成可能である。このような例の中で、「system」、「atic」、「atical」、「atically」が我々の考えている単語片である。さらに、単語片として「control」あるいは「operating」を「system」の前に付加することにより「control system」、「operating system」等の複合語が生成されたと考えることができる。

また、図 3 の例のように、日本語の「制御システム」、「オペレーティングシステム」の間には、共通な文字の並び「システム」があるために、意味の関連性を見出すことが可能である。そして、二つの文字列「制御システム」、「オペレーティングシステム」の共通部分と差異部分の文字の並びである「システム」、「制御」、「オペレーティング」は日本語の単語片である。

また、図 4 にあるように、英単語とその訳語の組み「system、システム」と「systematic、システムの」から、英語と日本語において共通な文字の並び「system、システム」を見出す。さらに、「atic、の」が差異部分として見出される。「system、システム」、「atic、の」は単語片対である。

さらに、この単語片対の他に、単語片対として「atize、化する」が存在した場合、英単語「systematize」の訳語は、図 5 にあるように単語片対を組み合わせて「システム化する」と推定可能である。

ここで、単語片中の「@1」は変数であり、他の単語片が接続する位置を表す。また、変数は共通部分として抽出された単語片対に対してのみ付与される。これは、共通部分として抽出された単語片対は差異部分として抽出された単語片対よりもより確からしく、このような単語片対を基にして複数の単語を生成することが可能になるというヒューリスティクスに基づいている。

これらとは別の英語と日本語の文字の並びの組みである単語片対「control、制御」、「operating、オペレーティング」を利用すると複合語とその訳語の組み「control system、制御システム」「operating system、オペレーティングシステム」が生成可能である。本手法はこのような経験則に基づいて考えられている。

# 3　処理過程

## 3.1　概要

本手法を基にして作成したシステムの構成を図 6 に示す。

辞書未登録語が入力されると、最初に訳語推定部において訳語推定を行なう。ここでは、単語片対辞書に存在する単語片対を利用して訳語を推定する。次に、推定された訳語の正誤判定を行なう。ここでは、辞書未登録語に対応する訳語を人手により抽出し、それを正しい訳語として推定結果の正誤判定の基準にする。そして、推定結果が誤っていた場合には、この正しい訳語を辞書未登録語に与える。次に、この辞書未登録語と正しい訳語の組みを新たな単語片対として単語片対辞書に加える。この新しい

2. 正推定度数

3. 誤推定度数

4. 正接続度数

5. 誤接続度数

まず、訳語推定に利用した全単語片対の出現度数に1加算する。もし訳語推定結果が正しい結果であった場合、訳語推定に利用した単語片対の2の数値に1加算する。そして、訳語推定に複数の単語片を利用していた場合、その各接続の4の数値にも1加算する。もし訳語推定結果が誤った結果であった場合、訳語推定に利用した単語片対の3の数値に1加算する。そして、訳語推定に複数の単語片を利用していた場合、その各接続の5の数値にも1加算する。

これらの処理により、より確からしい単語片対および単語片の接続が訳語推定時に選択されやすくなる。このことにより、この処理以降の訳語推定処理の改善を図っている。

### 3.4 学習処理

本研究では、辞書未登録語の訳語推定に利用できるものは文脈に存在すると考えている。また、文脈を英単語およびその訳語と見なしている。帰納的学習により英単語とその訳語の字面に対する共通部分と差異部分の抽出を行ない、単語片対を獲得する。しかし、字面に対する共通部分と差異部分の抽出だけでは、英日の単語片の間の意味的な対応関係が誤っている単語片対を多く抽出してしまう。そこで、誤った対応関係を持つ単語片対の抽出を減らすために英語の単語片を抽出する際に以下のような条件を設けた。

条件 共通部分の文字数は2文字以上

英単語はアルファベットおよび記号という少数の字種により構成されているので、誤った対応関係を持つ共通部分が多く抽出されてしまう。そのために、このような条件を設けた。

また、単語片対を抽出する際には以下のような条件を設けた。

**条件1:** 抽出元の片方の組みに共通部分が1ヶ所だけあり、もう一方の組みに共通部分と差異部分が1ヶ所ずつ存在する場合

この条件1を満たす抽出例を、図7に示す。この例では、片方の組みには共通部分「print、印字」が1ヶ所だけ存在し、もう一方には共通部分「print、印字」と差異部分「ed、された」が1ヶ所ずつ存在している。このように、共通部分と差異部分として抽出された文字の並びの組みは単語片対となる。

英単語1： 「**print**」 訳語1： 「印字」
英単語2： 「**printed**」 訳語2： 「印字された」

⇓

共通部分： 「**print@1**、印字@1」
差異部分： 「ed、された」

図7 条件1を満たす単語片対の抽出例

英単語1: 「**printing**」 訳語1: 「印字している」
英単語2: 「**printed**」 訳語2: 「印字された」

⇓

共通部分: 「**print@1**、印字@1」
差異部分1: 「ing、している」
差異部分2: 「ed、された」

図8 条件2を満たす単語片対の抽出例

**条件2:** 抽出元のの双方の組みに、共通部分と差異部分が1ヶ所ずつ存在する場合

次に、条件2を満たす抽出例を、図8に示す。この例では、「printing、印字している」と「printed、印字された」の双方において英日の共通部分「print、印字」を1ヶ所だけ持ち、「printing、印字している」では、差異部分「ing、している」、もう一方の「printed、印字された」では差異部分「ed、された」を持っている。このように、共通部分と差異部分として抽出された文字列の組みも上述の条件1の場合と同様に単語片対となる。

また、本来は帰納的学習により英日の単語片の意味的な対応関係の付け方も学習されるべきであると思われる。しかし、現段階ではまだ実現できていない。そこで、今回は、対応関係を付けるための条件1と2は人手により与えた。

## 4 評価実験

### 4.1 辞書未登録語

本研究において、辞書未登録語は電子化された辞書 [久保 95] に見出し語として未登録である英単語とした。この辞書 [久保 95] には、見出し語として49,336語登録されており、辞書に登録されている単語は一般的な文章を読む際の利用を想定して選択されている。また、辞書

表 1 対象とする辞書未登録語の分類

| 種類 | 個数 (個) | 割合 (%) | 例 |
|---|---|---|---|
| 固有名詞 | 42 | 17.6 | Brian, Nelson 他 |
| 派生語 | 25 | 10.5 | internally, intelligently 他 |
| 複合語 | 28 | 11.8 | control-flow 他 |
| その他 | 143 | 60.1 | ANSI(略語), 1983(数値) 他 |

未登録語を抽出する対象は、文献 [Kernighan 88] に記載されている英単語とし、この文献 [Kernighan 88] の 1478 個の異なる英単語から辞書未登録語を抽出した。その結果、238 個の辞書未登録語が抽出された。この 238 個の辞書未登録語を分類すると表 1 のようになった。

「固有名詞」として分類された単語には、例に挙げた人名を表す単語の他に「DEC」のような企業名などが存在した。また、「その他」に分類された単語には例に挙げた単語の他に、文献 [Kernighan 88] がプログラミング言語に関する英文であることから「printf」や「n++」等のプログラミング言語あるいはコンピュータに関するものが多く存在した。この分類結果を基にして、抽出した辞書未登録語の中で派生語 25 個と複合語 28 個からなる 53 個の単語を、辞書未登録語の訳語推定を行なう対象とした。

## 4.2 初期状態でシステムの単語片対辞書に与える単語片対について

本実験では、辞書 [久保 95] に登録されている単語 49,336 語において、1 つの単語が複数の訳語を持つ場合それらの訳語と対応を付け、102,156 組みの英単語と訳語の組みを抽出した。本研究では、辞書に登録されている英単語とその訳語の組みを語基とその訳語とした。これは、単語は単独で意味を持ち、さらに別の単語を生成する基である語基になることも可能なためである。また、この英単語とその訳語の組みは、単語片対の定義を考慮すると、単語片対とも見なすことができる。そこで、この 102,156 組みを単語片対として実験システムの初期状態の単語片対辞書に与えた。

次に、文献 [前田 94] を参照し、同一の接辞 (接頭語および接尾語) を持つ単語とその訳語の組みから人手により接辞とその訳語の 351 組み (接頭辞とその訳語 69 組み、接尾辞とその訳語 282 組み) を抽出した。これらの組みは、英単語とその訳語の綴りから抽出された文字の並びの組みなので、単語片対と見なせる。

同一の接頭辞を持つ英単語とその訳語の組みから抽出された単語片対の例を図 9 に示す。この例では、「overanxious、心配しすぎる」と「overdrink、飲みすぎる」における英単語とその訳語の共通部分の文字の並びをそれぞれの抽出することにより接辞とその訳語「**over@1**、@1 すぎる」が得られた。

英単語 1 : 「**overanxious**」　訳語 1 : 「心配しすぎる」
英単語 2 : 「**overdrink**」　訳語 2 : 「飲みすぎる」

⇓

英語の単語片 : 「**over@1**」
日本語の単語片 : 「@1 すぎる」

図 9 同一の接頭辞を持つ英単語とその訳語から抽出される単語片対の例

英単語 1 : 「**careful**」　訳語 1 : 「注意深い」
英単語 2 : 「**thoughtful**」　訳語 2 : 「思慮深い」

⇓

英語の単語片 : 「**@1ful**」
日本語の単語片 : 「@1 深い」

図 10 同一の接尾辞を持つ英単語とその訳語から抽出される単語片対の例

また、同一の接尾辞を持つ英単語とその訳語から抽出できる単語片対の例を図 10 に示す。この例では、「careful, 注意深い」と「thoughtful、思慮深い」における英単語とその訳語の字面の共通部分の文字の並びを抽出することにより接辞とその訳語「**@1ful**、@1 深い」を得ることができる。

そこで、接辞とその訳語の組みも単語片対として実験の際にシステムの初期状態の単語片対辞書に加えた。

## 4.3 実験方法

本手法の有効性を確認するために、本手法を基に作成した実験システムに対して評価実験を行なった。訳語推定を行なう対象とした辞書未登録語は上述した文献 [Kernighan 88] における辞書未登録語である派生語と複合語 53 個とした。また、実験システムの初期の単語片対辞書に、上述した 102,507 個の単語片対を加えた状態から実験を開始した。そして、辞書未登録語の入力、辞書未登録語の訳語推定処理、推定結果に対する正誤判定および校正処理、単語片対を獲得する学習処理、さらに推定結果に対するフィードバック処理を繰り返し行った。そして、得られた辞書未登録語の訳語推定結果を評価した。

## 4.4 推定結果に対する評価方法

本評価実験において、以下に述べる基準を満たす推定結果を有効な推定結果とした。

推定対象単語「machine-dependent」
単語片対 1:　「machine、機械」
単語片対 2:　「independent、独立の」
単語片対 3:　「@1-@2、@1 @2」

⇓

推定結果：「機械独立の」
正しい訳語：「機械に依存しない」

図 11 有効な推定結果の例

1. 辞書未登録単語とその正しい訳語の綴りを、単語片対辞書の単語片対を利用して完全に再現可能な場合
2. 辞書未登録単語とその訳語の意味を表す主要部分を、単語片対辞書の単語片対を利用して再現可能な場合
3. 推定した訳語が、正しい訳語と同等であると判断できる場合
4. 推定した訳語が、英和辞書 [小稲 80] の見出し語の訳語と同等であると判断できる場合

## 4.5 実験結果

上述した基準における有効な推定結果は、対象となった 53 個中の 38 個であり、対象とした辞書未登録語の約 71.7%であった。また、無効な推定結果は 15 個あり、対象となった単語の約 28.3%を占めていた。

図 11 に有効な推定結果の例を示す。この例では、推定結果「機械独立の」と正しい訳語「機械に依存しない」の字面は一致していない。しかし、人間が判断して同一の意味を表していると判断できるので有効な推定結果とした。

図 12 に無効な推定結果の例を示す。この例では、推定結果「終りのファイル」と正しい訳語「ファイルの終り」の字面は一致していない。さらに、この推定結果と正しい訳語では意味しているものが異なるため、この推定結果は有効なものとはしなかった。

次に、帰納的学習により訳語推定に有効な単語片対が獲得され、訳語推定に利用された例を図 13 に示す。この例では、単語片対の学習により「machine-@0、機械に@0」が獲得された。さらに、辞書未登録語「machine-dependent」の訳語推定においてこの単語片対が利用された。単語片対「@1-@2、@1 @2」を利用した推定結果よりもこの単語片対を利用した推定結果の方が正しい訳語に近く、またより日本語として正しいと思われる推定結果を得た。このことから、帰納的学習により得られたこの単語片対が訳語推定において有効であったと言える。

推定対象単語「end-of-file」
単語片対 1:　「end、終り」
単語片対 2:　「of、の」
単語片対 3:　「file、ファイル」
単語片対 4:　「@1-@2-@3、@1 @2 @3」

⇓

推定結果：「終りのファイル」
正しい訳語：「ファイルの終り」

図 12 無効な推定結果の例

単語片対の学習

抽出元 1:　「machine-independent、機械に依存しない」
抽出元 2:　「machine-readable、機械に可読な」

⇓

共通部分:　「machine-@0、機械に@0」
差異部分 1:　「independent、依存しない」
差異部分 2:　「readable、可読な」

訳語推定での利用

推定対象単語「machine-dependent」
単語片対 1:　「machine、機械」
単語片対 2:　「dependent、独立していない」
単語片対 3:　「@1-@2、@1 @2」
単語片対 4:　「machine-@0、機械に@0」

⇓

推定結果 1:「機械に独立していない」
推定結果 2:「機械 独立していない」

正しい訳語:「機械に依存した」

図 13 有効な単語片対が獲得された例

### 4.6 考察

得られた推定結果における無効な推定に至った原因を考察すると、複合語に対する推定結果において語順が誤っているものがいくつか存在した。本手法では、上述の無効な実験結果の例で示したように、複合語の訳語推定では単語片対「@1-@2、@1 @2」や「@1-@2-@3、@1 @2 @3」が多くの場合で利用されている。これらの単語片対は、複合語の英語の語基の語順通りにその語基の訳語を並べている。しかし、複合語には英語の語基の語順と日本語の語基の語順に対応関係がないものが存在する。これを解決するための一つの方法としては、語基に関する語順規則を作成し、訳語推定の際に利用することが考えられる。

また、推定した結果の中から適切な訳語を選択するという問題が残っている。本手法による訳語推定では、一つの英語の単語片に対して複数の訳語が対応する場合、可能な全ての組合せを推定結果としている。推定結果に対してその優先順位を付けているが、その単語片対に対する学習が十分に進んでいない場合は確実な順位付けがなされずに推定結果を出してしまう。また、実際の機械翻訳システムにおいて本手法を適用する場合には、複数の訳語から適切な訳語を選択しなくてはならない。この問題はを解決する一つの手法として、文章中で利用されている訳語の頻度情報を利用することが考えられる。これは、1つの英語の単語片に対して複数の訳語が対応する場合、同一の文章中である一つの訳語を数多く利用されているならば、その訳語がそれ以降も利用され続けるというヒューリスティクスによるものである。

## 5 おわりに

本稿では、帰納的学習を利用した英単語とその日本語の訳語からの単語片対という単位の抽出手法、そして単語片対を利用した訳語推定手法を提案した。そして、派生語と複合語を対象とする訳語推定の評価実験の結果と考察を述べた。この実験結果において約71.7%の有効な推定結果を得たことから本手法の有効性を確認した。

しかし、本手法の抱える問題として、複合語における語順の問題、複数の推定結果に対する適切な訳語の選択の問題が明らかになった。これらについては、今後研究を進める予定である。また、本研究で対象とした派生語と複合語以外の種類の辞書未登録語に対応する手法についても今後検討する必要がある。

## 参考文献


[野村 88] 野村浩郷、田中穂積 (編) : 機械翻訳、共立出版 (1988).

[長尾 89] 長尾真 (編):機械翻訳サミット、オーム社、1989(東京).

[隅田 90] 隅田英一郎、飯田仁、幸山秀雄 : 用例に基づいた翻訳、情報処理学会第４０回全国大会講演論文集、pages 411 - 412、(1990).

[赤間 87] 赤間清 : 帰納的学習システム LS/１による翻訳の学習、人工知能学会誌、Vol.2、No.3、pages 341-349(1987).

[佐藤 91] 佐藤理史:ＭＢＴ２:実例に基づく翻訳における複数翻訳例の組み合せ利用、人工知能学会誌、Vol.6、No.6、pages 861-871(1991).

[長尾 96] 長尾真 (編) : 自然言語処理、岩波書店 (1996).

[相沢 96] 相沢輝昭、加藤直人、鎌田雅子:外電経済ニュースの英日機械翻訳、情報処理学会論文誌、Vol.37、No.6、pages 1041-1048(1996).

[山田 94] 山田一郎、山村毅、佐川雄二、大西昇、杉江昇 : 英文中に出現する未登録語の特徴分析とその意味推定のための知識の有効性に関する考察、情報処理学会論文誌、Vol.35、No.12、pages 2725-2733(1994).

[笹岡 96a] 笹岡久行、荒木健治、桃内佳雄 : 英文からの帰納的学習による単語片抽出を用いた未登録語の訳語推定、1996 年電子情報通信学会総合大会、D-53(1996).

[笹岡 96b] 笹岡久行、荒木健治、桃内佳雄 : 英文からの帰納的学習による訳語推定手法へのヒューリスティクスの適応、平成 8 年度電気関係学会北海道支部連合大会講演論文集、No.294.

[久保 95] 久保正治 : 英和・和英電索辞典 gene, 技術評論社、1995(東京).

[Kernighan 88] Brian,W.K. and Dennis,M.R.: THE C PROGRAMMING LANGUAGE, PRENTICE HALL, 1988,(New Jersey).

[前田 94] 前田健三:強くなる英単語、有精堂、1994(東京).

[小稲 80] 小稲義男 他 : 新英和大辞典、研究社、1980(東京).