D-53

英文からの帰納的学習による単語片抽出を用いた未登録語の訳語推定

Prediction of Unknown Words for Translation Using Extraction of a Piece of Word by Inductive Learning from English Sentences

笹岡久行　荒木健治　桃内佳雄
Hisayuki SASAOKA　Kenji ARAKI　Yoshio MOMOUCHI
北海学園大工学部
Faculty of Engineering, Hokkai-Gakuen University

1 はじめに

近年、機械翻訳の研究が盛んになってきている [1]。機械翻訳の研究において問題とされていることの1つに辞書の未登録語の処理がある。多くの機械翻訳手法では翻訳時の最小単位は単語である。しかし、我々は単語の中には訳語推定に利用可能な単位があると考え、それを単語片と呼ぶことにする。また、異なる言語間で対応がある単語片の組を単語片対と呼ぶことにする。本稿では単語の中に存在する単語片と単語片対を抽出し、単語片対を用いて辞書に未登録の単語の訳語推定を行なう手法を提案する。なお、本稿では英語の単語から日本語の訳語を推定することを対象とする。

2 単語片と単語片対

単語片は2つの単語の字面の共通部分と差異部分の抽出により自動的に獲得できる。具体例として、「自然言語処理」と「言語知識」からの抽出では「言語」、「自然〜処理」、「知識」が獲得される。また、単語片は他の言語の単語中にも存在する。例えば英語で 'language (言語)' と 'langue (知識言語)' からの抽出を行なうと 'lang'、'uage'、'ue' が獲得される。ここでの英日の単語片対は 'lang' と「言語」の組になる。

次に、単語片対により訳語推定が可能な例をあげる。最初に、'intelligence(知能)' と 'nonintelligence(知能ではないもの)' から単語片対 'intelligence(知能)' と 'non(ではないもの)' を学習する。更に単語片対 'mysterious(ミステリアス)' を学習した後、'nonmysterious' の訳語は「ミステリアスではないもの」と推定できる。

3 処理手法

3．1 概要

本手法をもとに作成した実験システムの概要を図1に示す。

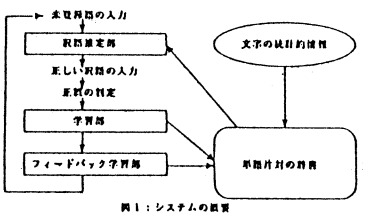


図1：システムの概要

3．2 訳語推定部

推定の対象単語と綴りが一致する単語片対の英語側の単語片の組み合わせを探す。そして、その日本語側の単語片を組み合わせて訳語を生成する。なお、単語片、単語片対そして単語片の接続の各々には出現頻度、正しい推定に利用された度数 (正推定度数) 更に誤った推定に利用された度数 (誤推定度数) がある。単語片対の選択は、推定の対象単語と英語側の単語片の一致する文字数、単語片の接続の割合、出現度数、さらに正推定度数と誤推定度数を参照する。

3．3 学習部

人間が与える未登録語と正しい訳語の組を新たな単語片対とみなし、これとこれまでに学習した単語片対の間で英日の単語片と単語片対を学習する。単語片は字面の共通部分と差異部分の抽出により帰納的に学習する。そして1個以上の共通な単語片と異なる単語片の組をそれぞれ単語片対として学習する。

また、字面のみの抽出では大量の誤った単語片対まで学習することが予備実験からわかっている。そこで英語の単語片の共通部分は2文字以上とする。さらに、n−gram (文字の共起関係) [2] を利用し統計的な情報から存在する頻度の高い文字列を取り出し、これらをもとに訳語推定に利用される確実性の高い単語片と低い単語片を区別する。確実性の高い単語片で構成される単語片対は訳語推定と学習に利用する。また、確実性の低い単語片で構成される単語片対は訳語推定のみに利用する。

3．4 フィードバック学習部

結果の正誤判定は人手により行なう。推定が正しい時は利用した単語片と単語片対および単語片の接続の各々の出現度数と正推定度数に1加算する。また誤った時は単語片と単語片対および単語片の接続の各々の出現度数と誤推定度数に1加算する。これらの処理により次回以降の訳語推定が改善される。

4 評価実験

4．1 実験方法

本手法の有効性を確認するために評価実験を行なった。統計的な情報 (n−gram) を取り出した文章は、オペレーティングシステムの 'Linux' のドキュメント (英語:268911 文字 日本語:281399 文字) であり、予備実験から5以上の出現頻度を持つものを存在する確率の高い文字列とした。また、訳語推定対象とした単語は、文献 [3] の第1章 (単語数:917 個) である。結果の正誤判定は、文献 [3] の訳本および英和辞書を利用して人手により行なった。また、初期状態では単語片対辞書は空の状態であり、全ての単語が未登録語である。

4．2 実験結果

推定結果は、翻訳対象となる全単語 917 個中で推定した単語数 31 個、正推定個数 23 個 (正推定率 74.2%)、誤推定度数 8 個 (誤推定率 25.8%) であった。

ただし、正推定率とは推定した単語数における推定に成功した単語の割合であり、誤推定率とは推定した単語数における推定に失敗した単語数の割合である。

4．3 考察

正推定率は約 74%であった。しかし、推定対象となった単語の個数 (917 個) に比べて推定できた単語の個数 (31 個) は少ない。これは学習した単語片対数が少ないことが原因であると考えられる。また、誤推定結果の中には英文中で名詞として使われている 'building'(建物) を (つくる) と推定したものがあった。この原因は字面の統計的な情報だけで訳語推定をするためであると考えられる。

5 おわりに

本稿では、英文からの単語片と単語片対の抽出手法と単語片対を用いた訳語推定手法を提案した。評価実験において正推定率が約 74%であることから本手法は英語の単語における日本語の訳語の推定に有効である事がわかった。今後は実験結果から考察された問題点を改良し、大量のデータを用いた実験を行う予定である。

参考文献

[1] 越前谷博 他：実例からの帰納的学習による機械翻訳手法における遺伝的アルゴリズムの有効性について、情報処理学会研究報告、NL107−10, pp.75−82(1995).

[2] 長尾真：自然言語処理、岩波書店、東京 (1996).

[3] Marvin,M.:The Society of mind A Touchstone Book, New York(1986).