294 英文からの帰納的学習による訳語推定手法へのヒューリスティクスの適用

笹岡久行 荒木健治 桃内佳雄
北学園大工

1 はじめに

我々はこれまで人間の有する言語獲得能力に注目し、この能力を工学的に実現するという目標に向けて、実例からの帰納的学習の仕組みを構成し、それをかな漢字変換や機械翻訳などに適用するいくつかの研究を行なってきた [1], [2]。

機械翻訳手法の研究における問題の1つに辞書の未登録語の処理がある。従来の機械翻訳ではあらかじめ用意された辞書を利用して翻訳を行なう必要があった。しかし、このような手法にはあらかじめ用意された辞書に登録されていない単語が出現した場合に翻訳ができないという問題が存在する。これまで、このような未登録語の問題に対して辞書に登録する単語数を増やすことにより問題の解決をはかろうとしていた。しかし、自然言語の持つ無限の造語能力によって常に単語が新しく作り出されているために、辞書の登録単語数を増やしても未登録語をなくすことは不可能である。本稿では既に我々が提案した単語片という単位を抽出する手法 [3] を利用した未登録語の訳語推定手法及び訳語推定実験とその結果から明らかになった問題点を解決するためのヒューリスティクスの適用について述べる。

2 単語片と単語片対

我々は単語を1つの記号列ととらえ、この記号列を生成するための規則を単語という実例から帰納的に学習することを目指している。単語を構成する基本的な単位を単語片と呼び、それは単語生成規則の基本要素となる。単語片は2つの文字列の字面の共通部分と差異部分を抽出することにより自動的にそして帰納的に学習することができる。ある単語とその訳語から共通部分として抽出された単語片の組みあるいは差異部分として抽出された単語片の組みを単語片対と呼ぶ。また、本稿での帰納的学習とは字面における共通部分と差異部分の抽出を行ないそれらを基にして単語生成規則を抽出することである。

抽出時の変数部分を@1と表す。例えば、英日の単語とその訳語の which :「どちら」と what :「どんな」において、英語側の共通部分の抽出から wh@1、差異部分の抽出から ich と at が単語片として得られる。また日本語側は、共通部分の抽出から「ど@1」、差異部分の抽出から「ちら」と「んな」が単語片として得られる。これらは単語生成規則の基本要素となりえるものである。そして、単語片対として共通部分の抽出から wh@1 :「ど@1」の組み、差異部分の抽出から ich :「ちら」と at :「んな」の組みが抽出される。

3 訳語推定手法

共通部分同士あるいは差異部分同士の組みである単語片対の英語側の単語片を組み合わせて訳語推定対象単語の綴りを生成し、同時に日本語側の単語片を組み合わせて訳語の推定を完成させる。

例えば、上述の単語片対 wh@1:「ど@1」の他に ere:「こへ」が既に学習されている状態で英単語 where の訳語を推定すると単語片対の組み合わせにより where:「どこへ」と推定できる。

また、単語片と単語片対には出現度数、そして正しい訳語推定に利用された度数 (正推定度数)、誤った訳語推定に利用された度数 (誤推定度数) が与えられる。訳語推定時に単語片対を組み合せる候補が複数存在する時は、以下のような優先順位でそれらの数値をもとに選択する。

1. 推定対象単語を構成する英語の単語片の数
2. 他の単語片対との接続の度合
3. 単語片対の出現度数
4. 単語片対の正推定度数と誤推定度数

4 処理手法

図1に、本手法を基に作成したシステムの概略を示す。まず訳語推定を行なう辞書に未登録な単語の入力を行ない、訳語推定部で訳語の推定を行なう。さらに学習部で単語片および単語片対を帰納的に学習する。最後にフィードバック学習部において訳語推定結果の正誤判定から以降の訳語推定の改善のために単語片及び単語片対に正推定度数あるいは誤推定度数を与える。

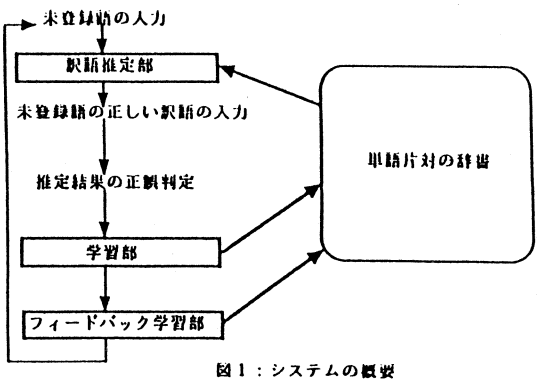


図1：システムの概要

5 訳語推定実験

5.1 実験方法

本手法を基にしたシステムを作成し、英語の単語の訳語推定実験を行なった。実験対象データには参考文献 [4] の第1章の始めから270語 (1482文字) を用いた。初期状態では単語片対辞書は空の状態にした。そして実験は、1単語ずつ訳語の推定、単語片と単語片対の学習そして訳語推定結果を基にしたフィードバック学習を行なった。

5.2 実験結果

実験対象データに対して訳語推定実験を行なった結果、実験対象データ２７０単語中の３４個の単語について訳語推定を行ない、そのうち3個の単語の訳語推定に成功した。全推定単語数に対する推定成功の割合である正推定率は、8.9%であった。

5.3 考察

学習している単語片対の数が不足していることが正推定率が低い原因のひとつと考えられる。また誤った訳語推定結果から以下のような推定失敗の原因の考察がなされた。

1. 過剰に分割された単語片対の組み合せによる失敗
   過剰な分割がなされた単語片対を選択し訳語の組み合わせを行なったために訳語推定を失敗した。
2. 単語片対の組み合せ位置の誤りによる失敗
   現在の単語片の抽出手法では、その単語片が単語の中のどの位置から抽出された単語片なのかを訳語推定時に知ることはできない。そのために誤った位置で単語片を組み合せてしまうことがある。small :「小さい」と smaller :「より小さい」からは単語の末端から単語片対@1er :「より@1」が抽出される。例えば、この単語片対は英単語 emerge のように単語の文字列中においてerが存在する単語の訳語推定に上述の単語片対@1er :「より@1」が利用されると訳語推定に失敗する。
3. 異言語間での対応のない単語片をもつ単語片対の誤った組み合わせによる失敗
   全ての単語片に単語片対を作れるような単語片が必ずしも存在するわけではない。例えば、英単語の book と books には同じ訳語「本」が与えられ、これらから単語片対を抽出しようとしても英語側の単語片@1s と単語片対を作る日本語側の単語片は存在しない。現在の単語片対の抽出手法ではこのような単語片対は抽出できない。その代わりに適切ではない単語片対を選択し訳語推定に失敗する。

6 ヒューリスティクスの適用

訳語推定実験の結果に対する考察から明らかになった問題点を解決するために以下のようなヒューリスティクスを適用する。

6.1 平均単語片文字数の導入

過剰な分割がなされた単語片対の選択を防ぐために1単語片の平均の文字数を示す平均単語片文字数を導入する。なお、平均単語片文字数は以下の式で求まる。

$$\text{平均単語片文字数} = \frac{\text{単語の文字数}}{\text{単語を構成する単語片の数}}$$

そして組み合せられた文字列の平均単語片文字数があらかじめ定めておいたしきい値以下にはならないようにする。これにより訳語推定時に過剰に分割された単語片の組み合せを防ぐ。

6.2 単語片抽出元の位置情報の付与

単語片対の誤った組み合せを少なくするために単語片の抽出元の位置を文字列の先頭、文字列の末端、それ以外に分けて単語片抽出時にこれらの中のどの位置から抽出されたのかの情報を付与する。これにより単語片の組み合せ時に抽出されたのと一致する位置に組み合わせることが可能になる。

6.3 変数のみの単語片をもつ単語片対の生成

対応する文字列を持たない英語の単語片があった場合はその単語片対の日本語側の単語片は変数のみにする。例えば、book : 本と books : 本から単語片対を抽出すると@1s :「@1」を得ることができる。

7 おわりに

本稿では帰納的学習による訳語推定手法を提案し、更に訳語推定実験とその結果から考察される問題点を解決するために有効であると思われるヒューリスティクスについて述べた。今後は本手法の有効性を確認するために大量データを用いた評価実験を行なう予定である。

参考文献

[1] 荒木健治，高橋祐治，桃内佳雄，栃内香次：帰納的学習を用いたべた書き文のかな漢字変換，電子情報通信学会論文誌，Vol.J79−D−II，No.3，pp.391−402(1996).

[2] 越前谷博，荒木健治，桃内佳雄，栃内香次：帰納的学習による機械翻訳手法における遺伝的アルゴリズムの適用，情報処理学会論文誌，Vol.37,No.8,pp.1565−1579(1996).

[3] 笹岡久行，荒木健治，桃内佳雄，栃内香次：帰納的学習を用いた英単語からの単語片の抽出，平成7年度電気関係学会北海道支部連合大会講演論文集，272，pp.296−297(1995).

[4] Marvin,M.:The Soiety of Mind, A Touchstone Book, New York(1986).