英単語と訳語からの帰納的学習による単語片を用いた訳語推定手法の改良

笹岡久行*・荒木健治*・桃内佳雄*

Improvement of Prediction Method of Unknown Word for English-Japanese Translation Using Pieces of Word Acquired by Inductive Learning

Hisayuki SASAOKA* · Kenji ARAKI* and Yoshio MOMOUCHI*

概　要

機械翻訳手法の研究における問題の一つに辞書未登録語処理の問題が存在する。これは，翻訳対象の文の中に翻訳のための辞書に未登録である単語が出現した場合にその時点で翻訳不能になる，あるいはその単語の翻訳を行わないでそのまま出力するという問題である。この問題を解決するためにこれまでは辞書の登録語数を増やすことや翻訳する対象を限定することで解決を図ろうとしてきた。しかし実際に存在する全単語を辞書に登録するのは困難である。また実際の自然言語では常に新しい単語が作り出され文の中で利用されている。従って登録単語が固定されている辞書を利用する手法を用いる限り未登録語は常に存在する。そこで我々は単語の中に存在する単語片および異なる2言語間の単語片の組みである単語片対を利用して辞書の未登録語の訳語推定手法について研究を行っている。

本報告では帰納的学習による英単語とその訳語からの単語片と単語片対の抽出手法，単語片対を用いた訳語推定手法とその改良方法の1つを提案する。さらに本手法を基に作成したシステムに対して行った評価実験の結果について述べる。

* 北海学園大学大学院工学研究科電子情報工学専攻
* Division of Electronics and Information Engineering, Graduate School of Engineering, Hokkai-Gakuen University

1. はじめに

我々の日常生活において自然言語処理技術の応用が様々な形で見られるようになってきている。ワードプロセッサのかな漢字変換や英日あるいは日英などの機械翻訳がその代表的なものである。パーソナルコンピュータの普及やインターネットの利用そしてCD－ROMなどの大容量メディアの利用により大量の自然言語が電子化されて利用されることが当然のこととなりつつある。そのために自然言語処理にはより良い処理精度と質の高い処理結果さらにより使いやすいインターフェイスなど多くの点での改良が期待されている。

そのような実情を踏まえて我々はこれまで自然言語処理手法の研究において人間の持つ言語獲得能力の計算機での実現及びその工学的応用を目指して研究を進めている[1)~3)]。これまで主に研究が行われてきた自然言語処理手法は規則及び知識をあらかじめ与えておきそれを利用して処理を進める手法である[4),5)]。従来の自然言語処理手法の抱える問題の１つとして未知の規則及び知識が必要となった場合にその処理が不能となるということがあげられる。また，実際の文を処理するためには大量の規則及び知識が必要となる。もし，それらを人手で用意する場合には必要とされる労力は膨大なものになる。さらに実際の自然言語では常に新しい単語が出現しその単語を利用した文が出現する。このような新出の単語や文を処理するためには用意された規則及び知識だけでは不十分である。そこで我々はシステムに対して学習能力を与え，その能力を利用して実例から規則あるいは知識を学習し，その学習されたものを基にして問題解決をはかる手法の実現とその工学的応用を目指し研究を続けている[1)~3)]。

特に機械翻訳手法の研究における問題の１つに辞書未登録語の問題がある。辞書に未登録語が存在する場合には，翻訳不能あるいはその単語の翻訳を行わずにそのまま出力しなければならない。この問題は従来から研究がなされてきた解析型の機械翻訳手法だけでなく我々が研究を続けている学習型の機械翻訳手法も含めた機械翻訳手法の研究全体にとって問題となっている。この辞書未登録語の問題に対してこれまでは単に辞書の登録単語数を増やすことあるいはユーザが自ら登録することで解決を図ろうとしてきた。しかし，実際の文に出現する全単語を登録するために必要とする大きな労力がユーザの負担を増す。さらに，膨大な辞書を持つことになってしまう。他方では翻訳する対象を限定することで辞書の未登録語を減らすことも考えられている。しかし，自然言語では常に新しい単語が出現しており，実際の文では，それらが利用されている。そのために登録されている単語が固定されている辞書を利用する手法を用いる限り辞書の未登録語の問題を完全には解決できないと考えられる。そこで，我々はシステムにとっての既知の英単語とその訳語を基にして辞書未登録語の訳語推定手法の研究を行っている[6)]。本手法では辞書未登録語が出現しても既知の訳語より訳語を推定することができる。さらに，必要となる規則あるいは知識はシステムが学習するので処理対象を限定したとしても他分

野へ動的に適応できる。このため予め学習データを用意すれば規則及び知識を用意する労力は不要になる。

我々は，既に単語片という単位の抽出手法を提案している[7]。本報告では単語片の組みである単語片対の抽出手法，そしてこの単語片対を利用した辞書未登録語の訳語推定手法とその改良方法の１つを提案する。さらに本手法を基に作成したシステムに対して行った評価実験結果について述べる。

2．単語片と単語片対

2.1　単語片

我々は，生得的な能力を「二つの事物が同じか異なるかを判断する能力」と仮定して，実例から帰納的学習により学習対象に関する規則あるいは知識を学習し，さらに学習したものを基にして未知の問題に対処する手法の有効性を日本語の形態素解析手法の研究[1]やかな漢字変換手法の研究[2]から確認している。

本研究の目的の一つは人間の持つ言語獲得能力の実現であるので，最初に人間による二つの異なる単語の認識について考える。単語は文字で構成されている。上述の人間の持つ生得的能力を仮定すると二つの異なる単語に同じ文字の並びが存在する場合は最初に二つの単語の共通な文字の並びに対応関係を発見し，それを一つの単位として認識する。そして，それ以外の文字の並びも一つの単位として認識する。つまり，人間は単語をより小さな単位を組み合わせたものとして認識している。これとは逆に，この認識している単位の組み合わせを基にして単語の生成を実現している。これはこれまでの研究における未知の文字列からの対応関係の抽出[1),2)]の対象を英単語とその訳語に想定したものと言える。

我々はこのような単語の認識と生成の単位に関するヒューリスティクスから単語を構成する単位でありかつ生成する単位が存在すると考え，それを単語片と呼んでいる。単語の綴りから抽出した共通部分と差異部分の文字の並びを単語片とし，単語片の組み合わせにより単語生成が可能である。

例えば，英単語「meaningless」と「meaningful」があった場合に，この２つの単語の字面の共通部分を抽出すると「meaning」，差異部分を抽出すると「less」と「ful」という文字の並びを得る。このようにして得られるものを単語片とする。また，この他に「count」や「care」のような単語片があった場合には「countless」，「careless」や「careful」などの単語を生成することができる。

また，単語片は英語の単語の中にだけ存在するわけではない。例えば，日本語の「意味のない」と「意味深長な」の間から，共通部分として「意味」，差異部分として「のない」，「深長な」

が抽出される。そして，英語の場合と同様に他の単語片「思慮」や「矛盾」があった場合には，「思慮のない」や「矛盾のない」などを生成することができる。

2．2　単語片対

意味的な対応関係がある異なる二つの言語の単語片の組みを単語片対と呼んでいる。未知文字列からの対応関係抽出の対象を英単語とその訳語の組みと想定して，抽出対象における文字の並びの共通部分と差異部分を近似的に単語片対とした。これは，共通な文字の並びで構成され類似した意味を持つ英単語の訳語には共通な文字の並びが存在しているというヒューリスティクスを利用している。さらに英単語の共通部分以外の文字の並びと訳語の共通部分以外の文字の並びの対応関係が付く場合にはこの差異部分同志の組みも意味的な対応関係が付く組みとなる。このようなヒューリスティクスに基づき単語片対の抽出に英単語と訳語の文字の並びの共通部分と差異部分を抽出した結果を利用した。このように本手法で利用されているヒューリスティクスは学習過程で獲得すべきものである。しかし，ここではヒューリスティクスの獲得の問題は別の問題と考え，本研究ではヒューリスティクスは与えられたものとする。

単語片が抽出できる例として，英単語とその訳語の組み「meaningless，意味のない」「meaningful，意味深長な」において，共通部分の抽出から「meaning，意味」，差異部分の抽出からそれぞれ「less，のない」「ful，深長な」が抽出される。これらは共通部分と差異部分がそれぞれ1対1に対応づけられるので単語片対と言える。

3．処理過程

3．1　システムの概要

本手法を基にして作成したシステムの構成を図1に示す。

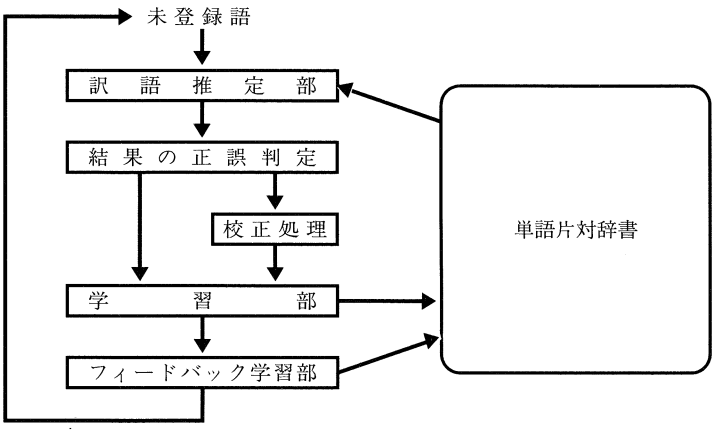


図1　システムの構成

本手法では前章で述べた単語片対を利用して訳語を推定する。この単語片対を利用した推定処理は訳語推定部で実行される。さらに推定結果の正誤判定を行い誤った推定結果には校正処理を人手により加える。単語片対の元になる英日の各単語片さらに単語片対を英単語とその訳語から学習部において抽出する。最後にフィードバック学習部において推定結果の正誤に応じて利用された単語片対に対する各数値の処理を施しそれ以降の推定処理の改善を図る。

以下でシステムの主要な処理の詳細を述べる。

3.2　学習部

3.2.1　抽出に対する制限

単語片は2個の英単語とその訳語の組みの字面の共通部分と差異部分から抽出されている。このとき英語の共通部分は2文字以上という制限を設けた。その理由としては，英単語を構成する文字の字種が少ないので過度の単語片の抽出を防ぐためである。

また対応関係の抽出を行う場合には差異部分の対応関係の取り方は出現順にとる場合と逆順にとる場合が考えられる[2)]。本研究における抽出対象は英単語とその訳語の単語片の組みである。差異部分の対応の取り方はその単語によって異なっているので，現段階では全ての組みに有効である差異部分の対応の取り方をヒューリスティクスから与えることはできない。そこで，本研究では単語片対を抽出するパターンとしては英単語とその訳語の共通部分と差異部分が英単語とその訳語の中にそれぞれ1カ所ずつ存在する場合，あるいは片方に共通部分が1カ所あり他方に共通部分と差異部分が1カ所存在する場合に制限した。この理由は，このパターン以外にも共通部分と差異部分のパターンは存在するがそれらでは英語と日本語の単語片の対応付けが困難なためである。

3.2.2　抽出例

共通部分と差異部分がともに1カ所ずつ存在して対応関係が取れる例として図2のような場合がある。英単語とその訳語「printed，印字した」と「printing，印字の」とから単語片として英語側から「print @1」「ing」「ed」日本語側から「印字 @1」「した」「の」が抽出される。ただし「@1」は変数部分であることを示す。この英語とその訳語には共通部分と差異部分がそれぞれ1カ所ずつ存在するので，単語片対として「print @1，印字 @1」「ed，した」「ing，の」を抽出する。

また，図3のように一方に共通部分が1カ所あり他方に共通部分と差異部分が1カ所存在する場合がある。英単語とその訳語の組み「vocal，声楽」「vocalist，声楽家」から共通部分と差異部分の抽出を行うと，「vocal，声楽」の方には共通部分が1カ所，「vocalist，声楽家」の方にはその共通部分と差異部分が1カ所ずつ存在する。このような場合は「vocal@1，声楽@1」「ist，家」を単語片対として抽出する。

英単語：printed　訳語：**印字**した
英単語：printing　訳語：**印字**の

↓

共通部分として抽出した単語片対：
「print @1, **印字** @1」
差異部分として抽出した単語片対：
「ed, した」,「ing, の」

図2　単語片抽出例1

英単語：vocal　訳語：**声楽**
英単語：vocalist　訳語：**声楽**家

↓

共通部分として抽出した単語片対：
「vocal @1, **声楽** @1」
差異部分として抽出した単語片対：
「ist, 家」

図3　単語片抽出例2

$$\text{平均単語片文字数}=\frac{\text{単語の文字数}}{\text{単語を構成する単語片数}} \quad (\text{式}1)$$

（式1）単語片平均文字数を求める式

3.3　訳語推定部

学習部で抽出された単語片対を組み合わせて訳語推定を行う。まず，単語片対の英語側を組み合わせて推定対象単語の文字列を生成する。それと同時に単語片対の日本語側を組み合わせて訳語を推定する。また，本手法では単語とその訳語の字面のみの情報を利用しているので推定処理の結果として複数の結果が得られる場合がある。その場合には，以下の数値からヒューリスティクスを利用して推定結果の優先順位を決定している。

1．推定に利用している単語片対の数
2．利用している他の単語片との接続の回数
3．利用した単語片対の出現度数
4．利用した単語片対の正推定度数と誤推定度数

1の数値と4の誤推定度数は低いものを優先し，他の数値は高いものを優先する。1で低い数値を優先させる理由は，単語を生成する際は長い単語片を優先させているというヒューリスティクスを利用している。また，2と3についても多く出現したものを優先するというヒューリスティクスを利用している。また，4の正推定度数とはその単語片対が正しい推定に利用された回数であり，同様に誤推定度数とはその単語片対が誤った推定に利用された回数のことである。これらは過去の推定において正しい推定に利用された回数が多いものを優先し，誤った推定に利用された回数の少ないものを優先するというヒューリスティクスを利用している。

例えば英単語「directly」の訳語を推定する場合で，単語片対「direct @1，直接 @1」「ly，に」「direct，間接」「@1 ly，@1に」などが学習されているとき，推定される訳語として「直接に」「間接に」が得られる。そこで上述した数値を参照して優先順位をつけてより確からしい推定結果を得る。この場合にもし「直接に」の優先度が高ければ「直接に」が1番目の推定結

果として得られる。

3.4　フィードバック学習部の処理

このフィードバック学習部では推定結果の正誤により利用された単語片対の以下の数値を操作する。

1．出現度数
2．正推定度数
3．誤推定度数
4．日本語側の単語片の他の単語片との接続の度数

推定に利用した全単語片対の出現度数と単語片の接続の出現度数にそれぞれ1加算する。さらに推定結果が正しい場合には正推定度数に1加算し，誤っていた場合には誤推定度数に1加算する。このフィードバック学習部の処理で，推定処理の優先順位決定に利用される数値を操作することでこれ以降の推定処理を改善する。

4．評価実験

4.1　実験方法

本手法の有効性を確認するために作成したシステムを用いて評価実験を行った。実験対象は英文が参考文献8)，日本文が参考文献9)である。この中の英単語とその訳語の600個の組みを利用した。ただし意訳などにより正確に1つの訳語が付与できない英単語は選択していない。

また初期状態ではシステムの英日の単語片及び単語片対は何も与えていない状態で実験を開始した。これは学習の仕組みだけを与え，その状態からの学習能力の有効性を確認するためである。

そして前章で述べたシステムの構成に従い，訳語推定，単語片および単語片対の抽出，さらに推定結果に対するフィードバック学習の各処理を順次繰り返す。

4.2　システムに対する改良

本手法に対する実験結果の考察から過剰に分割された単語片対の組み合わせによる訳語推定の失敗が多数存在した[6]。そこで訳語推定の際に単語片平均文字数を式（1）で計算し，推定に利用する単語片の単語片平均文字数があらかじめ定めたしきい値以下の場合にはその推定結果は利用しないことにした。これは人間が単語の訳語を推定する場合にはそれほど細かく分割して単語を見てはいないというヒューリスティクをに対応する。今回の実験では，改良を加える前の実験結果からしきい値を2とした。

4.3　実験結果

改良を加える前の実験結果と改良を加えた後の実験結果を表1に示す。

表1 評価実験の結果

	改良前	改良後
推定完了数	127個 (21.1%)	71個 (11.8%)
有効な推定数	54個 (9.0%)	53個 (8.8%)
正解数	1個	1個

ここで，推定完了とは英語側の単語片の組み合わせが完了して訳語を推定した結果を指す。また，有効な推定とは推定完了したもので訳語が正しい訳語と部分的に一致した結果を指す。正解である推定結果とは翻訳文中の訳語と完全に一致した結果を指す。

4.4 考察

この2つの実験結果において改良を加えることにより誤った推定が55個減少していることからこの導入の有効性を示すことができた。

しかし訳語推定の結果自体は正解が1個であり有効な推定結果の数も少ない。この原因は学習対象のデータ不足と考えられる。つまり英単語とその訳語の組みが600個と少量であったため訳語推定をするのに十分な単語片対が学習できていないからであると考えられる。

正しい結果に至ったのは，推定対象単語が「program」であり，推定した訳語が「プログラム」である。推定に利用した単語片対は「progra @1，プログラ@1」，「m，ム」であった。この結果では，推定に利用した単語片対は人間が判断して意味的に対応が付いている組みとは言えないが訳語推定結果としては正しい訳語が得られている。

有効な推定結果の例として，推定対象単語「declaring」，推定した訳語「宣言の」があり，正しい訳語は「宣言し」であった。この推定結果では「宣言」の部分までは正しい訳語と一致しているために有効な推定を行っている。推定に利用した単語片対は「declar，宣言」，「@1 ing，@1の」である。この推定結果では単語片対「declar，宣言」の方は人間が判断して意味的な対応が付くものと考えられる。また，もう一方の単語片対の「@1 ing，@1の」は別の単語とその訳語の組みでは正しく対応づけられた単語片対と言える。しかし，この「declaring」の推定では誤った単語片対となってしまった。この推定を行う時点で学習された単語片対の中に「@1 ing，@1し」が存在していなかったので「@1 ing，@1の」を選択したと考えられる。この原因として単語片対の学習量の不足が考えられる。この他にも推定の途中経過には有効な推定ではあるが単語片対の学習量が不足しているために正解とは至っていないものが多く見られた。

この考察から，今回の実験では有効な推定結果が得られているが正解となる推定結果の数が少ないことから有効な単語片対の学習が不足していたと言える。また，単語片対の学習が進めば正しい訳語推定結果を得られると考えられる。

5．おわりに

本報告では帰納的学習による単語片対という単位の抽出手法とその単語片対を利用した訳語推定手法とその改良方法の１つを提案した。そして本手法をもとに作成したシステムに対して行った評価実験について述べた。評価実験の結果から600個の英単語とその訳語では単語片対を十分に学習できないことが明らかになった。しかし，推定の途中経過には部分的に推定が成功しているものが存在した。このことから単語片対の学習が進めば本手法を利用して多くの単語の訳語推定が可能になると考えられる。また，単語片平均文字数を利用した改良の有効性を多くの誤った推定結果を減らすことができるという結果により示した。

今後は大量のデータを用いた実験を行い，その結果の考察をもとに本手法に対するさらなる改良を行いたいと考えている。

参考文献

1）荒木健治，栃内香次：帰納的学習による語の学習および確実性を用いた語の認識，電子通信学会論文誌，J75－D－II，No. 7，pp. 1213－1221（1992）.
2）荒木健治，高橋祐治，桃内佳雄，栃内香次：帰納的学習を用いたべた書き文のかな漢字変換，電子通信学会論文誌，J79－D－II，No. 3，pp. 391－402（1996）.
3）越前谷博，荒木健治，桃内佳雄，栃内香次：帰納的学習による機械翻訳手法における遺伝的アルゴリズムの適用，情報処理学会論文誌，Vol. 37，No. 8，pp. 1565－1579（1996）.
4）田中穂積：自然言語処理の基礎，産業図書，東京（1989）.
5）長尾真：自然言語処理，岩波書店，東京（1996）.
6）笹岡久行，荒木健治，桃内佳雄：英文からの帰納的学習による訳語推定手法へのヒューリスティクスの適用，平成８年度北海道電気関係学会北海道支部連合大会講演論文集，No. 294.
7）笹岡久行，荒木健治，桃内佳雄：英単語からの帰納的学習を用いた単語片の抽出と単語生成，北海学園大学研究報告，No. 23，pp. 221－230，（1996）.
8）B.W.Kernighhan, D.M.Ritchie : THE C PROGRAMMING LANGUAGE(Second Edition), PRENTICE HALL, New Jersey(1988).
9）B.W. カーニハン，D.M. リッチー：プログラミング言語C（第２版），共立出版，東京（1989）.