自然言語処理シンポジウム 資料

多段階交叉位置決定手法を用いたGA-ILMTの性能向上

工藤晃一 † 荒木健治† 桃内圭雄† 栃内香次††

† 北海学園大学工学部 †† 北海道大学大学院工学研究科

1 はじめに

コンピュータネットワークが急速に発達するにつれ、一般の人たちにも日本語以外の言語に触れる機会が大幅に増えてきた。そのため、翻訳を大量にかつ迅速に行うために機械翻訳システムが考案され、また、実用化されている。現在、実用化されている機械翻訳システムは、文法解析を用いた解析型の機械翻訳手法が中心であるが、文法解析の困難さや文法規則あるいは辞書の巨大化が問題となっている。そこで、この問題を解決するために実例や用例に基づく学習型の機械翻訳手法が研究されている。しかし、学習型では、良質な翻訳を行うためには大量の翻訳ルールを学習させなければならない。したがって、解析型と学習型の両方に実用的な問題が残されている。

現在、我々は、人間の言語と知識を計算機を用いて獲得する研究を行っている。そこで、我々は学習型の機械翻訳手法の実用化のために、与えられた翻訳例から自動的にかつ帰納的に翻訳ルールを獲得し、そこで学習された翻訳ルールを用いて、翻訳を行う機械翻訳手法を開発した。しかし、この機械翻訳手法においても大量の翻訳ルールを学習させる必要があった。この問題を解決するために、我々は遺伝的アルゴリズムを学習型機械翻訳手法に適用した。遺伝的アルゴリズムは、多様な個体を生成しながら、周囲の環境に適応することで進化していく生物の進化過程である。遺伝的アルゴリズムの適用により、少量の翻訳例をからバライティに富んだ新翻訳例をシステムが自動的に生成させることで、翻訳ルールの学習の問題を解決した。我々が開発したこの機械翻訳手法を遺伝的アルゴリズムを用いた実例からの帰納的機械翻訳手法 (GA-ILMT) と呼び、性能評価実験よりこの機械翻訳手法の有効性は確認されている [1]。

しかし、GA-ILMT の有効性は確認されてはいるが、依然として翻訳精度に問題があり、実用には至っていない。これは、与えられた翻訳例から遺伝的アルゴリズムの過程の一つである交叉によって生成される新翻訳例の精度の低さが原因である。遺伝的アルゴリズムの適用により多様な新翻訳例が生成可能となったが、知識などの制限を用いず共通な字面のみで交叉位置を決定し、ランダムに新翻訳例を生成しているため、誤った新翻訳例も大量に生成されてしまう。したがって、新翻訳例の精度が低下するのである。本来、誤った新翻訳例は、遺伝的アルゴリズムの過程の一つである淘汰によって消滅していくのだが、誤った新翻訳例を淘汰するには、大量の学習が必要になる。そのため、生成される誤った新翻訳例を減少させ、同時に生成される正しい新翻訳例を増加させて、生成される新翻訳例の精度を向上さることが必要である。そこで、我々は交叉位置の決定に知識を導入し、生成される新翻訳例の精度を向上させる多段階交叉位置決定手法を開発した。本手法は、様々な知識を用いて単語の対応関係を決定し、その結果から交叉位置を決定し新翻訳例を生成する手法である。遺伝的アルゴリズムに対する知識の導入により、その多様性に制限を加えることになるが、新翻訳例の精度を向上させることが可能であり、その有効性は確認されている [2]。しかし、交叉位置の決定による知識の導入は遺伝的アルゴリズムの特徴である多様性を制限するため、その長所を失う可能性がある。本手法は、GA-ILMT を実用化するときに生じる、遺伝的アルゴリズムの多様性と知識による制限の問題点を明らかにする点で大きな意義を持つものである。本稿では、多段階交叉位置決定手法を適用した GA-ILMT システムを使用した評価実験と考察結果に基づき、本手法による GA-ILMT の実用性の向上と有効性を確認する。

2 GA-ILMT の処理過程

GA-ILMT の基本的な処理過程を図 1 に示す。() 内は、各処理部の遺伝的アルゴリズムの適用過程を示している。また、本システムは、日英機械翻訳システムである。まず、原文として、英文を入力すると、翻訳

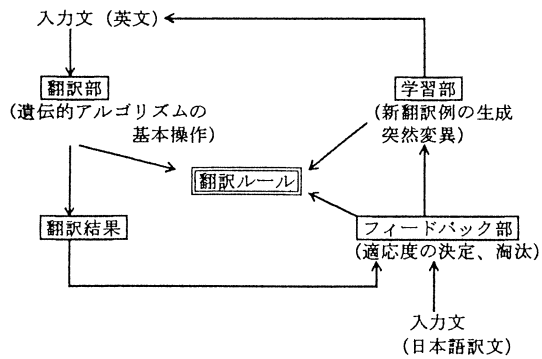


図 1: GA-ILMT の処理過程

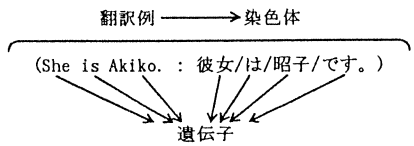


図 2: 染色体と遺伝子

部において、獲得されている翻訳ルールに対する遺伝的アルゴリズムの基本操作を用いて翻訳結果を生成する。次いで、フィードバック部において、ユーザーが与えた正しい日本語訳文を用い、翻訳部で用いられた翻訳ルールに対する適応度の決定と淘汰を行う。そして、学習部において、与えらた翻訳例（英文とその日本語訳文）に対して、交叉と突然変異を行い多様な新翻訳例を生成し、翻訳に活用する。今回、生成される新翻訳例の精度を向上させるために知識を導入するのは、学習部の新翻訳例の生成の部分である。

2.1 染色体と遺伝子

次に、翻訳例と遺伝的アルゴリズムにおける個体の染色体と遺伝子の対応を述べる。染色体には英文とその日本語訳文を組とした翻訳例を対応させる。そして、染色体を構成している遺伝子には翻訳例を構成している単語を対応させる。図 2 にその対応を示す。また、翻訳例は翻訳ルールを抽出後、その翻訳例自身も翻訳ルールとして辞書に登録される。

2.2 フィードバック部

この処理部では、ユーザーが与えた日本語訳文と翻訳結果との比較を行い翻訳結果の正誤判定を行う。生成された翻訳結果が与えられた正しい日本語訳文と一

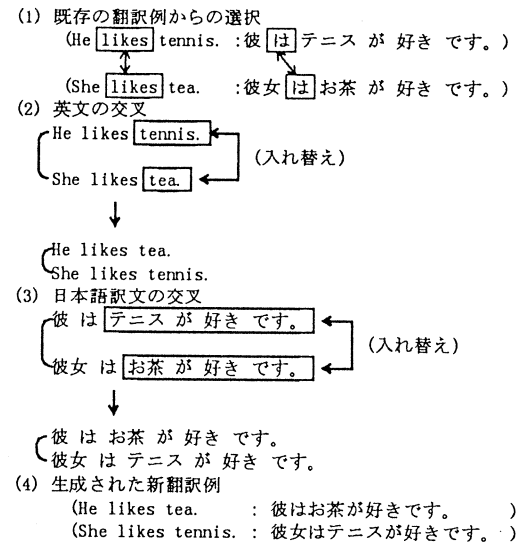


図 3: 従来の新翻訳例の生成例

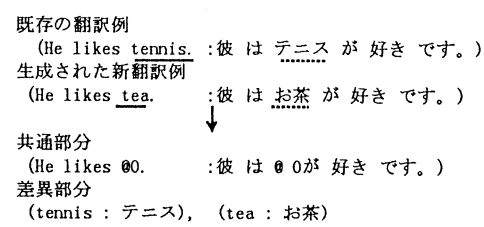


図 4: 共通部分と差異部分の抽出例

致する場合、使用された翻訳ルールの正翻訳度数を 1 増加させる。一致しない場合は、誤翻訳度数を 1 増加させる。ついで、その値により、翻訳部で使用された全ての翻訳ルールに対し適応度を決定する。適応度は以下の式 (1) により決定される。

$$\text{適応度 (\%)} = \frac{\text{正翻訳度数}}{\text{全翻訳度数}} \quad (1)$$

2.3 学習部

学習部では、交叉による新翻訳例の生成と突然変異、そして、翻訳ルールの抽出を行う。

従来の手法 (多段階交差位置決定手法を適用しない GA-ILMT) による新翻訳例の生成では、それまでに入力された翻訳例から英文と日本語訳文のそれぞれにおいて、字面が完全に一致する文字列を共通部分に持つ

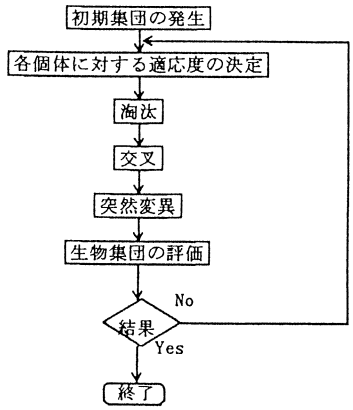


図 5: 翻訳部の処理過程

2つの翻訳例を選択し、共通部分を交叉位置として一点交叉を行う。図3に示す例では、英文において「likes」、日本語訳文においては、「は」と「が好きです」が共通部分として抽出される。したがって、英文においては「likes」、日本語訳文においては「は」が交叉位置として抽出される。また、「が好きです」を交叉位置とすると同じ日本語訳文が生成されるので翻訳ルールとしての登録は行わない。多段階交叉位置決定手法による新翻訳例の生成については、3章で述べる。突然変異は、翻訳例の単語に対するランダムな変更を行う。突然変異率は2%とする。突然変異を行うことにより、翻訳例の単語をそれまでに獲得されている単語の翻訳ルールや変数に置き換えることにより、新たな翻訳例や翻訳ルールを生成する。

次に翻訳ルールの抽出について述べる。その具体例を図4に示す。我々が先に提案した字面情報における共通部分と差異部分を多段階に抽出する手法[3]を用いることで多様な翻訳例の抽出を行う。

2.4 翻訳部

翻訳部では、それまで抽出された翻訳ルールを用いて入力文に対する最適な翻訳結果を導出する。そのため、翻訳部では1つの完結した遺伝的アルゴリズムのシステムを構築する。図5に翻訳の処理過程を示す。

(1) 初期集団の発生
それまでに獲得された翻訳ルールから、入力文の基礎的な構造を表現している文の翻訳ルールを選択し、その集団を初期集団とする。

(2) 各個体に対する適応度の決定
フィードバック部で使用した式(1)を用いて各翻訳ルールに対する適応度を決定する。

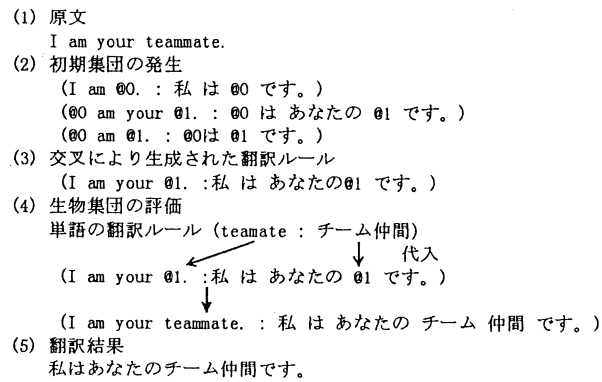


図 6: 翻訳部における翻訳結果の生成例

(3) 淘汰
フィードバック部と同様に、全翻訳度数が5以上、適応度が25%以下の翻訳ルールに対して淘汰処理を行う。

(4) 交叉
共通部分を持つ2つの翻訳ルールを選択し、その共通部分を交叉位置とする一点交叉を行う。

(5) 突然変異
学習部と同様に、突然変異率を2%として翻訳ルールに対するランダムな変更を行う。

(6) 生物集団の評価
文の翻訳ルールの変数部分に、既存の単語の翻訳ルールを代入し、入力文と一致するものが存在するかを調べる。一致するものが存在した場合、入力文に対する翻訳結果が得られたとして翻訳部における処理を終了する。また、入力文と完全に一致しない変数を含んだものが得られた場合、(2)から(6)を繰り返す。その結果、生成された英文に変化がなければ、その英文に対する日本語訳文を最適な翻訳結果として処理を終了する。

図6に処理過程の具体例を示す。

また、翻訳部では、1つの入力文に対し、複数の翻訳結果が生成される場合がある。その場合には、それらの翻訳結果に対し、次の3つの基準を用いて優先順位を決定する。

(1) 使用した翻訳ルールの適応度が最大のもの

(2) 使用した翻訳ルールの抽象度が最小のもの

(3) 使用した翻訳ルールの登録順位が最上位のもの

適応度はフィードバック部で使用した式(1)より求められたものと同様である。また、抽象度は翻訳結果を生成する際に、基本となった翻訳ルールの単語数における変数の個数の占める割合である。抽象度は、以下の式(2)より得られる。

$$\text{抽象度}(\%) = \frac{\text{翻訳ルール中の変数の個数}}{\text{翻訳ルール中の単語数}} \times 100 \quad (2)$$

3 多段階交叉位置決定手法

3.1 多段階交叉位置決定手法の概要

GA-ILMT の学習部に適用される本手法は、対象となる２つの文の単語の対応関係を確実性の高い順に決定し、その対応関係から交叉位置を決定する手法である。本手法で使用される情報は、確実性の高い対応関係を決定するために、字面、日本語の読み又は英単語の原形、訳語、上位概念、決定済みの対応関係の情報、品詞の順に各段階で用いられる。また、上位の段階で決定した対応関係は、下位の段階の処理対象からはずれる。したがって、上位で決定される対応関係ほど、確実性が高い。多段階交叉位置決定手法に基づいた新翻訳例の生成処理の過程を図７に示す。本手法に基づいた学習部における処理では、２つの既存の翻訳例の原文と訳文における全ての確実性の高い対応関係を決定するために、２つの翻訳例の原文同士及び訳文同士の単語の対応関係を決定する。次に原文と訳文における単語の対応関係を決定し、その後、対応関係の結果を用いて交叉位置を決定し、一点交叉を行い、２つの新翻訳例を生成する。

また、本手法では、英文と日本語訳文の両方で品詞情報を使用するため、入力文は、形態素解析を行っておく必要がある。原文は、Bril Tagger[4] を、訳文には、我々が開発した帰納的学習による形態素解析手法 [5] を用いる。 また、対応関係の決定に用いた辞書とツールを表１に示す。

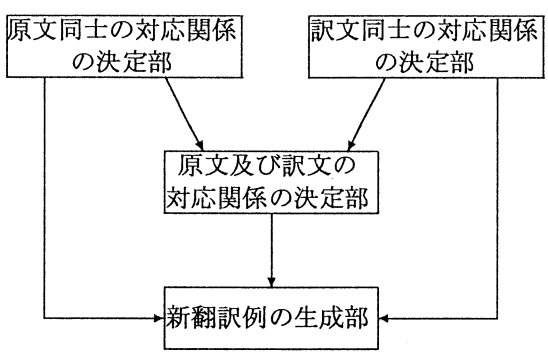


図 7: 本手法による新翻訳例の生成過程

3.2 原文同士の対応関係の決定部と訳文同士の対応関係の決定部

原文同士及び訳文同士の単語の対応関係の決定部では、以下の対応関係を決定する。

(1) 出現位置が同じで字面が一致する単語の対応関係を決定。

(2) 出現位置が異なり字面が一致する単語の対応関係を決定。

(3) 単語の表層的な形態が一致する単語の対応関係を決定。

- 原文では、原形が同じ単語の対応関係を決定。
- 訳文では、読み一致する単語の対応関係を決定。

(4) 同一の単語の訳語として存在する単語の対応関係を決定。

(5) 上位概念が一致する単語の対応関係を決定。

(6) 決定済みの対応関係に挟まれている一語の対応関係を決定。

(7) 品詞の一致する単語の対応関係を決定。

以上の７段階で対応関係が決定される。また、上位の段階で決定された対応関係は下位の段階では、処理対象としない。次に、この処理部で用いられた翻訳例の対応関係から決定される文同士の類似度の得点について述べる。この得点は、決定された対応関係の各段階における個数で計算される。この得点は式（３）で計算される。

$$alpha = \frac{100.0}{\text{２つの翻訳例の原文又は訳文の単語の合計}}$$

$$\text{得点} = alpha \times (2.0 \times N_1 + 1.8 \times N_2 + 1.6 \times N_3 + 1.0 \times N_4 + 0.8. \times N_5 + 0.4 \times N_6 + 0.2 \times N_7 - 0.5 \times N_8) \quad (3)$$

N_n:n 段階における対応関係の数
N_8:対応関係がなかった単語数

表 1: 対応関係に用いた辞書とツール

種別	名称	語数	作成者	使用段階	使用目的
シソーラス	WordNet	126,516	Princeton University	3. 原形の一致	不規則変化
				5. 上位概念の一致	英文の上位概念の検索
	分類語彙表	32,600	国立国語研究所	5. 上位概念の一致	日本語文の上位概念の検索
形態素辞書	Oxford Advanced Learner's Dictionary of Current English	70,646	University of London	3. 原形の一致	規則変化
英和辞書	英和・和英電索辞書	55,000	久保正治 (技術評論社)	4. 同一単語の訳語	訳語の取得
訳語リスト	ONE WORLD English Cource 1 NEW EDITION の単語リスト	389	長谷川潔 他	4. 同一単語の訳語	訳語の取得
訳語リスト	NEW HORIZON English Cource 1 の単語リスト	397	太田朗 他	4. 同一単語の訳語	訳語の取得
形態素解析ツール	Brill Tagger	1,429,865	Eric Brill	7. 品詞の一致	英文の品詞情報の取得
	帰納的学習による形態素解析手法	11,113	荒木健治 他	3. 表記と読みの一致	読みの取得
				7. 品詞の一致	日本語文の品詞情報の取得

3.3 原文・訳文の対応関係の決定部

原文の単語と訳文の単語における対応関係の決定には、英和辞書 [6] を使用する。この辞書から訳文の単語を検索し、対応する原文の単語を決定する。また、対応関係が重複したとき次のような処理を行う。

1. 重複した単語において、訳文における対応関係または、原文における対応関係がないものは、破棄する。
2. 1において対応関係が決まらないときは、次に処理を行う。
   - [1'] 訳文における単語の対応関係と原文における単語の対応関係の段階の合計が上位にあるものを選択。
   - [2'] 段階の合計が同値であるとき、重複した対応関係の単語において原文における単語の対応関係と訳文における単語の対応関係の段階が低い方を比較し、その段階が高い方を選択する。
3. 2でも決定できないときは、候補の位置が最も近いものを選択。

前の処理で決定された確実性の高い対応関係を優先して交叉位置とするためにこのような処理を行う。以

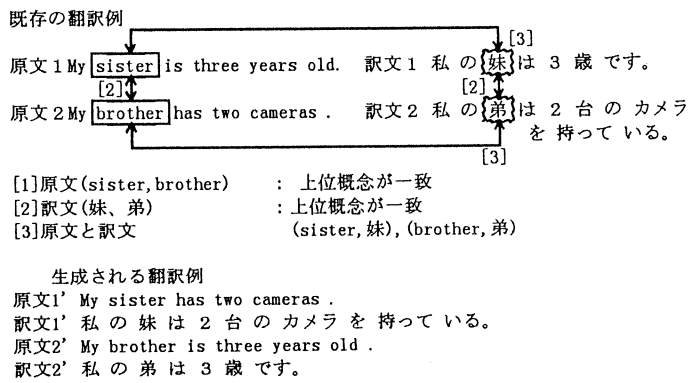


図 8: 本手法による新翻訳例の生成の例

上の処理より、原文の単語と訳文の単語の一対一の対応関係を決定する。

3.4 新翻訳例の生成部

新翻訳例の生成は、対応関係が決定された単語を交叉位置として翻訳例に対して一点交叉を適用して行う。交叉位置となる単語は、原文における対応関係または、訳文における対応関係が必ず存在し、かつ、原文と訳文における対応関係が存在する単語である。図 8 に、多

段階交叉位置決定手法による新翻訳例の生成の例を示す。最初に原文同士の対応関係の決定部では、原文１の"sister"と原文２の"brother"が上位概念の一致により対応関係が決定する。次に訳文同士の対応関係の決定部は、訳文１の"妹"と訳文２の"弟"もまた、上位概念の一致により対応関係が決定する。そして、原文と訳文同士の対応関係の決定部は、原文１の"sister"と訳文１の"妹"の対応関係を決定し、また、原文２の"brother"と訳文２の"弟"の対応関係を決定する。原文における対応関係が存在する単語と訳文における対応関係が存在する単語において、原文と訳文における対応関係が一致する場合、これらの単語を交叉位置として一点交叉を行う。図８では、原文では、原文１の"sister"と原文２の"brother"が、訳文では、訳文１の"妹"と訳文２の"弟"が、交叉位置となり一点交叉が行われ新翻訳例が生成される。

4 性能評価実験

4.1 実験結果

4.2 評価方法

本手法に基づいたシステムの翻訳結果に対する評価方法について述べる。翻訳結果は以下の２つ評価方法で分類する。

1 正翻訳

2 誤翻訳

正翻訳は、使用している利用者が正しい翻訳であると判断できる翻訳結果である。このとき未登録語を含んでいる翻訳結果において、未登録語に単語の翻訳ルールを与えることで容易に未登録語を含まない正翻訳を導き出せる翻訳結果も性翻訳に含む。誤翻訳は、利用者が正しい翻訳であると判断できない翻訳結果である。また、翻訳不能の場合も誤翻訳に含む。正翻訳率は以下の式 (4) で決定される。

$$\text{正翻訳率 (\%)} = \frac{\text{正翻訳数}}{\text{全翻訳数}} \times 100 \qquad (4)$$

また、生成された翻訳結果が複数存在する場合には、翻訳部で述べたように順位付けされた翻訳結果の上位１番から１０番までを評価対象とする。１０個の翻訳結果中に正翻訳に該当するものが存在していた場合、その翻訳結果を正翻訳とする。

4.3 実験方法

実験には、中学校１年生用教科書ガイド・ワンワールド [7] に掲載されている英文と訳文の 479 組を使用した。実験では１文ごとに翻訳を行い、翻訳終了時に正翻訳文を与え、学習も同時に行った。また、新翻訳例の生成の際、類似度が 25 点以上の翻訳例を交叉対象とした。これは、ある程度類似した翻訳例を交叉させ、新翻訳例の精度を向上させるためである。

実験結果より、多段階交叉位置決定手法を適用した GA-ILMT の正翻訳率は、53.4%となった。多段階交叉位置決定手法を適用しなかった従来の GA-ILMT の正翻訳率は、46.1%である。したがって、本手法を組み込むことにより正翻訳率は、7.3 ポイント増加した。

5 考察

5.1 本手法の有効性について

表 2 より、GA-ILMT に多段階交叉位置決定手法を適用することにより正翻訳例の精度は、7.3 ポイント向上した。本手法を適用した結果、誤翻訳から正翻訳へ移行したものが 60 文、正翻訳から誤翻訳に移行したものが 25 文である。結果として、正翻訳が 35 文増加したことに相当する。また、生成される新翻訳例の精度は、29.4%から 41.3%となり 11.9 ポイント向上した。正翻訳率の向上と新翻訳例の精度の向上から、本手法を適用した GA-ILMT の有効性を確認することができた。

5.2 翻訳結果について

本手法を組み込むことにより、正翻訳率の向上が確認された。これは、知識の導入による新翻訳例の精度の向上が大きな原因であると考えられる。新翻訳例の精度の向上に伴い、正しい新翻訳例から多くの良質な翻訳ルールが抽出可能となる。また、誤った新翻訳例の減少により、誤った翻訳ルールも減少していると考えられる。したがって、多くの良質な翻訳ルールを GA-ILMT の翻訳部で使用でき、また、誤った翻訳ルールの減少から、正翻訳率が向上したと考えられる。

図 9 は、正新翻訳例から良質な翻訳ルールを抽出し、この翻訳ルールを使用して翻訳を行い、正しい翻訳結果を得た例である。

5.3 新翻訳例について

本手法は、新翻訳例の生成において有効であることは既に確認済みである。表３より辞書中の新翻訳例で

表 2: 翻訳結果の総計

翻訳手法	正翻訳（文）	誤翻訳（文）	精度%
GA-ILMT	221	258	46.1
本手法を適用した GA-ILMT	256	223	53.4

(全翻訳文数 479 個)

表 3: 生成される新翻訳例の分類

翻訳手法	正新翻訳例（組）	誤新翻訳例（組）	精度%
GA-ILMT	973	2,338	29.4
本手法を適用した GA-ILMT	1,160	1.650	41.3

は、従来よりも精度が 11.9 ポイント増加している。しかし、正翻訳率は、7.3 ポイントの増加にとどまり、新翻訳例の精度の増加よりも下回っている。これは、新翻訳例から抽出される翻訳ルールの誤りが従来よりは減少したが依然多く、新翻訳例の精度の増加が完全に正翻訳率の増加に反映されていないためであると考えられる。今回は、新翻訳例の生成のみに知識を導入したが、今後は翻訳ルールの抽出に対しても知識を導入し、翻訳ルールの精度の向上を目指す必要がある。

5.4 多様性の制限について

本手法の組み込みにより、GA-ILMT の正翻訳率は向上した。しかし、本手法を組み込むことにより 25 文が翻訳不可能または、誤翻訳となった。この原因は、生成される新翻訳例に存在すると考えられる。本手法で生成される新翻訳例において、従来の GA-ILMT で生成不可能で本手法を適用した GA-ILMT で生成可能な正しい新翻訳例は、661 組存在する。しかし、逆に従来の GA-ILMT で生成可能で本手法を適用した GA-ILMT では生成不可能な正しい新翻訳例も組存在する。これは、従来の原文と訳文における共通な字面による共通部分の全ての組み合わせを交叉位置としたランダムな新翻訳例の生成が本手法ではできなくなった影響である。また、親の翻訳例の類似度の得点を制限して新翻訳例の生成を行ったため、交叉を行う対象からはずれる既存の翻訳例の組が存在することも考えられる。したがって、従来の方法で生成可能であった新翻訳例が生成不可能となることに伴い、そこから抽出されていた翻訳ルールも抽出不可能となり、この影響により 25 文が翻訳できなくなったと考えられる。これは、知識の導入による遺伝的アルゴリズムの多様性の制限によって翻訳ルールの多様性が失われた結果であると考えられる。しかし、実験結果から誤った新翻訳例の減少も確認することができるため、多様性を失うことで生成できなくなる正しい新翻訳例は存在するが誤った新翻訳例を減少させる利点もある。また、知識の導入により、本手法では生成不可能になった新翻訳例 424 組を上回る、従来の手法では生成できなかった 661 組の正しい新翻訳例の生成が確認されている。したがって、これ

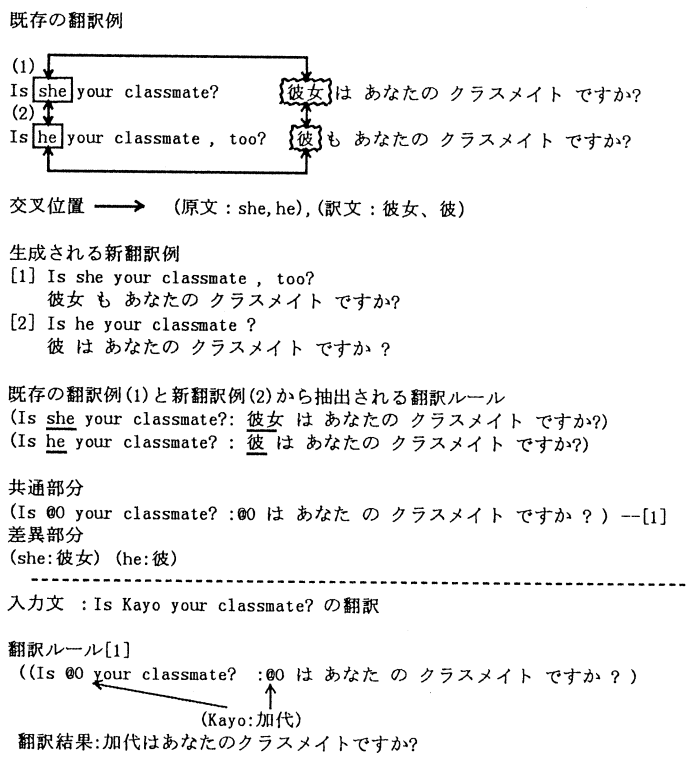


図 9: 本手法により翻訳可能となった翻訳の例

らの新翻訳例の存在によって、正しい新翻訳例の多様性の損失が補われ、かつ、多様性が向上していると考えられるので、知識の導入による多様性の制限は、誤った新翻訳例の多様性の制限に有効に働いていると考えられる。

6 おわりに

本稿では、多段階交叉位置決定手法を GA-ILMT に適用することの有効性を性能評価実験の結果より述べた。本手法の適用が生成される新翻訳例の精度を向上させ、正翻訳率の向上に効果があることが確認された。また、本手法の適用は遺伝的アルゴリズムの多様性に制限を付けることになり、その新翻訳例の多様性が失われることも確認されたが、多様性の損失の多くは誤った新翻訳例の多様性の損失であり、知識の導入よる今まで生成不可能であった正しい新翻訳例の生成から正しい新翻訳例の多様性の損失を補い、かつ、正しい新翻訳例の多様性を向上させることが可能であると考えられる。したがって、知識を導入により今まで問題であった新翻訳例の生成精度の低さによる正翻訳率の低下が解消される利点があり、GA-ILMT を実用的な機械翻訳システムにするためには、知識の導入が不可欠であることが確認された。

現段階では、依然として正翻訳率が不十分なので、多段階交叉位置決定手法の性能をさらに向上させ、実用的な学習型機械翻訳システムの実現に向けて研究を進める予定である。

参考文献

[1] 越前谷博, 荒木健治, 桃内佳雄, 栃内香次:遺伝的アルゴリズムを用いた実例からの帰納的学習による機械翻訳手法, 情報処理学会論文誌,Vol.2,No.8,pp.1565-1579,(1996).

[2] K,Kudo.,K,Araki.,Y,Mmouchi and K.Tochinai: Multi-Stage Decision Method for Production of New Translation Examples, Proceedings of the IASTED International Conference Arti fi-cial Intelligence and Soft Computing, pp.125-128 (1997).

[3] 荒木健治, 栃内香次:多段階共通パターン抽出法を用いた翻訳例からの帰納的学習による翻訳, 情報処理北海道シンポジウム'91,pp.47-49(1991).

[4] Eric Brill,A CORPUS-BASED APPROACH TO LANGUAGE LEARNING,(1993).

[5] 荒木健治, 栃内香次 : 帰納的学習による語の獲得および確実性を用いたごの認識, 電子情報通信学会論文誌,Vol.J75-D-II,No.7,pp.1213-1221,(1992).

[6] 久保正治 : 英和・和英電策辞典 gene, 技術評論社、東京,(1995).

[7] 教科書ガイド教育出版ワンワールド, 日本教材, 東京,(1991).