1 ＧＡ－ＩＬＭＴにおける新翻訳例生成手法の提案

工藤晃一* 荒木健治 桃内佳雄 栃内香次
(北海学園大学)† (北海道大学)‡

1 はじめに

近年、コンピューターネットワークの急速な発達により、日本語以外の言語にふれる機会が増加している。そのため、機械翻訳システムが考案され、実用化されている。しかし、現存する機械翻訳システムは、文法規則を用いる解析手法が主流であり、翻訳の精度及び品質が十分に実用的とは言えない。そこで、我々は解析型ではなく、学習型の機械翻訳システムの精度の向上を目指すために、遺伝的アルゴリズムを用いた実例からの帰納的学習による機械翻訳手法（ＧＡ－ＩＬＭＴ）の開発、研究を行なっている[1]。ＧＡ－ＩＬＭＴは、遺伝的アルゴリズムを適用して翻訳を行う学習型機械翻訳手法である。この手法の特徴は、与えられた翻訳例に対して遺伝的アルゴリズムを適用し、新翻訳例の生成を自動的に行なうことである。それゆえ、与えられた翻訳例より多くの翻訳例を学習させることが可能となる。

しかし、ＧＡ－ＩＬＭＴの有効性は既に確認されているが、学習部で生成される新翻訳例の個数と精度が十分ではないため、翻訳の精度と品質に問題が残されている。そこで、我々はＧＡ－ＩＬＭＴの翻訳の精度を向上するために種々の単語の属性を用いて単語の対応関係を推定して、新翻訳例を生成する手法を提案する。このような手法を多段階交叉位置決定手法と呼ぶ。本手法が新翻訳例の精度と生成個数の向上において有効であることは、すでに確認されている[2]。本稿では、本手法の概要とアルゴリズムについて述べる。

2 概要

本手法は、対象となる２つの文の単語の対応関係を確実性の高い順に用いて、交叉位置を決定する手法である。本手法で使用される情報は、確実性の高い対応関係を決定するために、字面、読み又は英単語の原形、訳語、シソーラス、品詞の順に各段階で用いられる。また、上位の段階で決定した対応関係は、処理対象からはずれる。本手法に基づいたシステムでは、２つの翻訳例の原文と訳文における全ての対応関係を決定するために、２つの翻訳例の原文同士及び訳文同士の単語の対応を決定し、次いで、これらの情報を用いて２つの翻訳例における原文と訳文の単語の対応関係を決定する。対応関係が決定した全ての単語が交叉位置となり、翻訳例に対して一点交叉が適用され、新翻訳例が生成される。したがって、本システムは、Fig. 1 に示されるように構成される。入力文は、原文が英文であり、訳文は日本語文である。また、英文は Brill Tagger[3] を、訳文は、帰納的学習による形態素解析手法 [4] を用いて形態素解析を行なう。

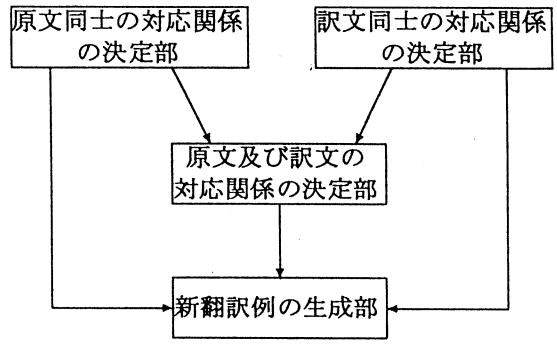


Fig. 1 システム構成

3 処理過程

3.1 原文同士の対応関係の決定部と訳文同士の対応関係の決定部

原文同士及び訳文同士の単語の対応関係の決定部では、次のように対応関係を決定する。

(1) 出現位置が同じで字面が一致する単語の対応関係を決定。
(2) 出現位置が異なり字面が一致する単語の対応関係を決定。
(3) • 原文では、原形が同じ単語の対応関係を決定。
• 訳文では、読みあるいは表記が一致する単語の対応関係を決定。
(4) 同一の単語の訳語として存在する単語の対応関係を決定。
(5) 上位概念が一致する単語の対応関係を決定。
(6) 決定済みの対応関係に挟まれている一語の対応関係を決定。
(7) 品詞の一致する単語の対応関係を決定。

以上の７段階で対応関係を決定する。対応関係の決定に使用した辞書とツールは Table 1 を参照。上位の段階で決定された対応関係は以下の段階では、処理対象としない。

3.2 原文・訳文の対応関係の決定部

原文の単語と訳文の単語の対応関係の決定には、英和辞書 [5] を使用する。この辞書から訳文の単語を検索し、対応する原文の単語を探す。ただし、対応関係が重複した単語は、原文同士または訳文同士の対応関係においての対応関係が上位にあるものを優先する。

3.3 新翻訳例生成部

新翻訳例の生成は、対応関係が決定された単語を交叉位置として翻訳例に対して一点交叉を適用して行う。交叉位置となる単語は、原文における対応関係または、

*kudou@ai.eli.hokkai-s-u.ac.jp
†札幌市中央区南２６条西１１丁目北海学園大学大学工学部
‡札幌市北区北１３条西８丁目北海道大学工学部

Table 1 対応関係に用いた辞書とツール

種別	名称	語数	作成者	使用段階	使用目的
シソーラス	WordNet	126,516	Princeton University	3. 原形の一致	不規則変化
				5. 上位概念の一致	英文の上位概念の検索
	分類語彙表	32,600	国立国語研究所	5. 上位概念の一致	日本語文の上位概念の検索
形態素辞書	Oxford Advanced Learner's Dictionary of Current English	70,646	University of London	3. 原形の一致	規則変化
英和辞書	英和・和英電策辞書	55,000	久保正治 (技術評論社)	4. 同一単語の訳語	訳語の取得
訳語リスト	ONE WORLD English Cource 1 NEW EDITION の単語リスト	389	長谷川潔 他	4. 同一単語の訳語	訳語の取得
訳語リスト	NEW HORIZON English Cource 1 の単語リスト	397	太田朗 他	4. 同一単語の訳語	訳語の取得
形態素解析ツール	Brill Tagger	1,429,865	Eric Brill	7. 品詞の一致	英文の品詞情報の取得
	帰納的学習による形態素解析手法	11,113	荒木健治 他	3. 表記と読みの一致	読みの取得
				7. 品詞の一致	日本語文の品詞情報の取得

訳文における対応関係が必ずある。そして、原文と訳文における対応関係が存在する。

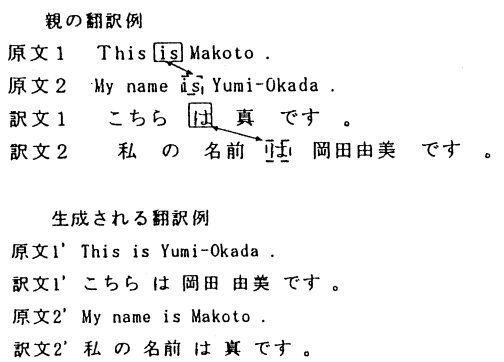


Fig. 2 翻訳例の対応関係の例

Fig. 2 では、原文同士、訳文同士の対応は、(2)の段階で決まる。また、原文と訳文の対応関係の決定において"is"と"は"の対応関係が決定する。原文において対応関係にある単語と訳文において対応関係がある単語が、各翻訳例において原文と訳文における対応関係が一致する場合、これらの単語を交叉位置として一点交叉を行う。例では、原文1と原文2では、"is"、訳文1と訳文2では、"は"が交叉位置として一点交叉が行われる。そして、Fig. 2のような新翻訳例が生成される。条件を満たす対応関係が存在する単語の対は、全て交叉位置とし、新翻訳例を生成する。

4 おわりに

本手法は、従来の手法よりも新翻訳例の精度及び生成個数において有効であることは既に確認されている。したがって、本手法をGA－ILMTの学習部に適用することにより正しい新翻訳例が増加し、誤った新翻訳例が減少することが考えられる。また、新翻訳例から抽出される翻訳ルールの誤りも減少すると考えられる。このため、GA－ILMTに本手法を適用することにより、翻訳の誤りを減少させることが可能である。今後は、本手法をGA－ILMTに組み込んで実験を行い、実際の翻訳における本手法の有効性について確認する予定である。また、本手法に対しても改良を加え、更なる新翻訳例の精度のと向上と正しい新翻訳例の生成個数の増加を目指す予定である。

参考文献

[1] 越前谷博, 荒木健治, 桃内佳雄, 栃内香次 : 遺伝的アルゴリズムを用いた実例からの帰納的学習による機械翻訳手法, 情報処理学会論文誌,Vol.2,No.8,pp.1565-1579,(1996).

[2] 工藤晃一, 荒木健治, 桃内佳雄, 栃内香次 : 多段階工佐一決定手法を用いた新翻訳例の生成, 言語処理学会弟3回次大会発表論文集,pp.589-592,(1997).

[3] Eric Brill,A CORPUS-BASED APPROACH TO LANGUAGE LEARNING,(1993).

[4] 荒木健治, 栃内香次 : 帰納的学習による語の獲得および確実性を用いたごの認識, 電子情報通信学会論文誌,Vol.J75-D-II,No.7,pp.1213-1221,(1992).

[5] 久保正治 : 英和・和英電策辞典 gene, 技術評論社、東京,(1995).