2 機械翻訳における事例を用いた多義語の訳語選択手法

水野秀紀* 荒木健治 宮永喜一 栃内香次
(北大工)† (北海学園大工) (北大工)

1 はじめに

近年、様々な機械翻訳システムが研究、開発されているが、文に内在する意味的な多義性の解消は、未だ解決されておらず、自然言語処理分野における困難かつ重要な問題となっている。

機械翻訳の手法としては、文法的な解析に基づく手法 [1] と事例データに基づく手法 [2]、[3]、[4]、[5] の2つに大別できる。文法的な解析に基づく手法は、入力文の形態素解析、構文解析を行なって入力文の構文木を生成し、それを目標言語の構文木に変換して翻訳を行なう手法である。この手法は、文法的に正しい翻訳結果が得られるが、膨大で複雑な文法情報と構文規則を辞書中に登録する必要があり、それらの制御が難しい。また、複雑で例外的な文には対応できないという問題点がある。一方、事例データに基づく手法は、入力文と事例データとの間で何らかの距離を計算して、最も距離の近い事例を用いて解の選択を行なう手法である。この手法では、事例データが解析された文の集合であるため、容易に事例の追加や削除ができ、複雑な文にも対応できる。

しかしながら、事例データに基づく手法は、大量の事例を必要とすることや距離の定義法に多くのバリエーションが考えられ、どれが最も適切であるか分かっていないという問題点が挙げられる。そこで、シソーラスによる事例の適用範囲拡大を試みた。また、距離に関しては、意味距離計算 [4] や優先度 [5] のようなシソーラスの概念階層における距離を基に作成した。

本稿では、英語から日本語への機械翻訳における、主に動詞の多義性の解消について、事例データに基づく手法を提案し、その有効性を確認するために行なった実験結果について述べる。

2 事例データ

事例データを用いる利点は、1章でも述べたように、容易に事例の追加や削除ができ、複雑な文にも対応できることである。また、一度多義性解消に失敗した文も修正して事例データに加えれば、二度と間違うことはない。

本研究では、事例データとしてC言語のマニュアル [6]、[7] を使用した。事例データには、それぞれの事例ごとに主語、動詞、直接目的語、間接目的語、補語、前置詞についてその概念番号と共に記してある。概念番号については、3章で述べる。また、受動態については能動態に変換してある。それから、代名詞に関しては、その代名詞が指す語句を記してある。扱う文は、あらかじめ構文解析されているものとする。

*mizuno@hudk.hokudai.ac.jp
†札幌市北区北 13 条西 8 丁目北海道大学工学部

3 シソーラス

全ての動詞の各語義に関して、十分な数の事例を用意することは当然できない。そこで、各語義の上位、下位、同義関係を用いて、事例の適用範囲を広げる必要がある。そのような関係を抽出するのにシソーラスを用いる。

本研究で用いたシソーラスは、Princeton 大学で開発された WordNet である。このシソーラスの特徴は、入力語に対する同義語、上位語、下位語がその意味ごとに木構造になっていて、それぞれの語の意味も英語で出力される。2章で述べた概念番号は、出力された意味の番号を指す。WordNet の語数は、名詞が 87,642 語、動詞が 14,727 語、形容詞が 19,101 語、副詞が 5,050 語であり、合計 126,520 語である。

4 距離の定義

距離については、1章でも述べたように、シソーラスの概念階層を基に次のように定義する。

- 任意の語とそれに隣接する上位語 (下位語) との間の距離は全て等しい。
- 任意の語とその同義語との間の距離は全て等しい。
- 任意の語とそれ以外の任意の語との距離は共通する上位語までのそれぞれの距離の和とする。

この定義に従って、次のような例を考えてみる。Fig.1 において、A、B、C、D、E、F、G、Hはそれぞれ同義語の集合とする。Bについて考えてみると、A は一つ上の上位語の集合であり、D、E、Fはそれぞれ一つ下の下位語の集合である。また、Cについて同様に考えてみると、A は一つ上の上位語の集合であり、G、Hはそれぞれ一つ下の下位語の集合である。A と Bとの間の距離を AB、Bと Dとの間の距離を BD、Bと Eとの間の距離を BE、Bと Fとの間の距離を BF、Bと Cとの間の距離を BC、Bと G との間の距離を BG とすると、

$$AB = BD = BE = BF \tag{1}$$

$$BC = 2AB \tag{2}$$

$$BG = 3AB \tag{3}$$

となる。

また、Bの中に p_1、p_2、p_3という語句が含まれていて、p_1と p_2との間の距離を p_1p_2、p_1と p_3との距離を p_1p_3、

p_2と p_3との距離を p_2p_3とすると、

$$p_1p_2 = p_1p_3 = p_2p_3 \tag{4}$$

となる。

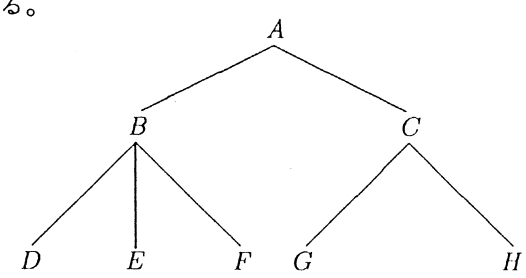


Fig. 1 距離

5 処理の概要

5.1 直接目的語のみで検索する手法

人間が英文における動詞の意味を決定する際に直接目的語に依存することが多い。このことから、入力文の直接目的語から事例データを検索していき、事例と入力文の距離が最も近い事例を用いて解の選択を行なうという手法を開発した。この手法は、検索対象が直接目的語のみなので検索に要する時間は少ないが、後の実験でも示しているように、直接目的語から事例データを検索することができない場合が多くあり、そのために非常に多くの事例が必要となってくる。

5.2 直接目的語以外でも検索する手法

5.1節で述べた問題点を解決するために、次のような手法を提案する。検索対象を直接目的語だけでなく、主語、間接目的語、補語、前置詞もその対象とし、それぞれの検索で求まった事例と入力文との距離を式(5)のように重みづけをした線形和をとり、その結果で解の選択を行なう。

$$Y = \alpha X_1 + \beta X_2 + \gamma X_3 + \delta X_4 + \varepsilon X_5 \tag{5}$$

X_1, X_2, X_3, X_4, X_5 は、それぞれ直接目的語、間接目的語、補語、主語、前置詞における事例と入力文との距離を表し、$\alpha, \beta, \gamma, \delta, \varepsilon$ は、それぞれの重み係数を表す。

この手法のアルゴリズムは次のようになる。

1. 動詞に関して、入力文と一致する事例を抽出する。
2. 直接目的語、間接目的語、補語、主語のそれぞれの各語義に関して、入力文と抽出した事例との間で次のような検索を行なう。
   (a) 入力文の語そのもので検索する。
   (b) シソーラスから入力文の語の同義語を取りだし、取りだした語で検索する。
   (c) シソーラスから入力文の語の全ての上位語、下位語を取りだし、取りだした語で検索する。
3. 前置詞に関して、入力文と抽出した事例を検索する。
4. 式(5)を用いて最適な解の選択を行なう。

6 実験

6.1 実験方法

実験は、直接目的語のみで検索する手法と直接目的語以外でも検索する手法の2通りで行なった。どちらの手法も250文からなる事例データを使用し、75文実験を行なった。実験に使う文は、事例データと同様に、C言語のマニュアル[6]、[7]の文を使用し、構文解析のみされていて、どの単語も多義性が解消されていないものとした。また、実験後解析した文を修正して、事例データに加えた。

6.1.1 直接目的語のみで検索する手法

5.1節で述べたように、検索対象は直接目的語のみとした。検索方法は、5.2節のアルゴリズムのように、まず直接目的語そのもので事例を検索し、その後同義語、上位語、下位語で検索を行なった。距離は、4章の定義に従って、入力文の語そのもので見つかった場合に0、同義語で見つかった場合に1、1つ上(下)の上位語(下位語)で見つかった場合に2という値を与え、その後1つ上(下)へいくごとに距離は1増えていくものとした。また、見つからなかった場合を20とした。この値に従って、最も距離の小さい事例を解として選択した。

6.1.2 直接目的語以外でも検索する手法

5.2節のアルゴリズムに従って行なった。距離は6.1.1項で述べた値に従った。また、式(5)における重み係数は、α に2.0、β に1.0、γ に1.4、δ に1.6、ε に0.5という値を与えた。この値の根拠は、直接目的語に関しては、5.1節で述べたように、人間が英文における動詞の意味を決定する際に直接目的語に依存することが多いので α を2.0と最も大きくし、前置詞に関しては、距離が0か20であり、表層構造のみの検索なので ε を0.5と最も小さくした。また、その他の語に関しては、人間が動詞の意味を決定する際に、どの語とのつながりを優先しているかを考慮に入れてこのような値を与えた。解は、式(5)が最小値を取るものを選んだ。

6.2 実験結果

6.2.1 直接目的語のみで検索する手法

直接目的語のみで検索する手法を用いたときの実験結果をTable 1に示す。Table 1において、異なる意味の事例数とは、検索対象としている動詞を含む事例のなかで動詞の意味が異なる事例数がいくつあるかを表している。また、検索不能とは、直接目的語の上位語、下位語、同義語のどれを検索しても見つからない場合のことであり、判定不能とは、距離の同じ事例が2つ以上あって判定できない場合であり、事例なしとは、入力文の動詞を含む事例が存在しない場合である。

Table 1 実験結果 (直接目的語のみで検索した場合)

	異なる意味の事例数	結果
正解	1	16 文
	2 以上	10 文
不正解	1	2 文
	2 以上	8 文
正解率	1 以上	72.2%
	2 以上	55.6%
検索不能		16 文
判定不能		3 文
事例なし		20 文

6.2.2 直接目的語以外でも検索する手法

直接目的語以外でも検索する手法を用いたときの実験結果を Table 2 に示す。閾値は、45 とした。

Table 2 実験結果 (直接目的語以外でも検索した場合)

	異なる意味の事例数	結果
正解	1	18 文
	2 以上	11 文
不正解	1	1 文
	2 以上	6 文
正解率	1 以上	80.6%
	2 以上	64.7%
閾値より大きい		19 文
事例なし		20 文

6.3 考察

6.3.1 失敗の原因

直接目的語のみで検索する手法で、解析に失敗した原因を Table 3 に示す。Table 3 より、事例不足が失敗の一番の原因となっている。また、直接目的語以外でも検索したほうが良いことが分かる。

一方、直接目的語以外でも検索する手法で、解析に失敗した原因を Table 4 に示す。Table 4 において、重み係数とは、重み係数を変えることで正解になるものである。このことは、全ての重み係数を 0.1 から 2.0 まで変えることで確かめることができた。また、直接目的語または主語が検索不能とは、重み係数の大きい直接目的語や主語の距離が 20 となってしまう場合であり、全体的に距離が大きいとは、直接目的語や主語では検索できているが全体で見ると値が大きい場合である。Table 4 より、やはり事例不足が失敗の一番の原因となっている。

Table 3 失敗の原因 (直接目的語のみで検索した場合)

出力	原因	文の数
不正解	動詞自体は事例にあるが入力文と同じ意味のものはない	8 文
	解となるべき事例の方が距離が大きい	2 文
検索不能	直接目的語のみで検索	16 文
判定不能	直接目的語のみで検索	3 文
事例なし	動詞自体が事例にない	20 文

Table 4 失敗の原因 (直接目的語以外でも検索した場合)

出力	原因	文の数
不正解	動詞自体は事例にあるが入力文と同じ意味のものはない	6 文
	重み係数	1 文
閾値より大きい	直接目的語または主語が検索不能	18 文
	全体的に距離が大きい	1 文
事例なし	動詞自体が事例にない	20 文

6.3.2 両手法の比較

両手法を比較すると、Table 1、Table 2 より正解率は直接目的語以外でも検索したほうが良い。また片方の手法が正解で、もう一方が正解以外となる文の数を Table 5 に示す。Table 5 からも直接目的語以外でも検索したほうが良い結果が得られることが分かる。

また、動詞以外の多義性解消について考えてみると、Table 6 のような結果が得られる。これは、解として選択された事例の検索対象の語が入力文の検索対象の語のどの意味で最も距離が小さいかを出力し、その出力されたものが正解である場合を示している。Table 6 より、直接目的語に関しては直接目的語以外でも検索したほうが良い結果が得られることが分かる。

Table 5 両手法の比較

直接目的語のみで検索	直接目的語以外でも検索	文の数
正解以外	正解	7 文
正解	正解以外	4 文

Table 6 動詞以外の多義性解消

手法	語	文の数
直接目的語のみで検索	直接目的語	11 文
直接目的語以外でも検索	直接目的語	15 文
	主語	9 文

7 おわりに

6.3.1項から分かるように、直接目的語のみで検索する手法も直接目的語以外で検索する手法も事例データに基づく手法の大きな課題となっている、非常に多くの事例を必要とするという問題点を解決するものではない。しかし、直接目的語以外でも検索する手法は、直接目的語のみで検索する手法と比べると、検索不能になる文がなくなるだけでなく、正解率も向上し有効な手法であることが分かった。

失敗の一番の原因となっている事例不足を解決するためには、今後事例を増やしていくことが必要である。また、今回用いた距離の値や重み係数の値が最適であるとは限らない。今後これらの最適な値を求めていく必要がある。また、直接目的語以外でも検索する手法で用いた判定式自体も検討しなければならない。それから、実験を行なった文が 75 文と少ないので、今後さらなる実験が必要である。

謝辞

本研究では、Cognitive Science Laboratory, Princeton University で開発されたフリーソフト WordNet を使用しました。ここに、Cognitive Science Laboratory, Princeton University に感謝致します。

参考文献

[1] 野村 浩郷編:"言語処理と機械翻訳", 講談社 (1991).

[2] 佐藤 理史:"MBT1:実例に基づく訳語選択", 人工知能学会誌 Vo.6, No.4, pp.592-600 (1991-7).

[3] 赤間 清:"帰納的学習システム LS/1 による翻訳の学習", 人工知能学会誌 Vol.2, No.3, pp.341-349 (1987-9).

[4] 古瀬 蔵, 隅田 英一郎, 飯田 仁:"経験的知識を活用する変換主導型機械翻訳", 情報処理学会論文誌 Vol.35, No.3. pp.414-425 (1994-3).

[5] 浦本 直彦:"制約と事例による優先度を組み合わせた英文の多義性の解消", 情報処理学会研究報告, 92-NL-90, pp.65-72 (1992-7).

[6] Brian W.Keringhan and Dennis M.Ritchie: "The C programming language. Second Edition", Prentice-Hall (1988).

[7] B.W. カーニハン, D.M. リッチー著, 石田 晴久訳: "プログラム言語C第2版", 共立出版 (1989).