332 機械翻訳における事例データを用いた動詞の多義性解消手法

水野秀紀† 荒木健治†† 宮永喜一† 栃内香次†
†北海道大学大学院工学研究科 ††北海学園大学工学部

1 はじめに

近年、様々な機械翻訳システムが研究、開発されている。しかしながら、文に内在する意味的な多義性の解消、特に動詞の多義性解消については、様々な研究が行なわれている[1][2]が、未だ解決されておらず、自然言語処理分野における困難かつ重要な問題となっている。本稿では、英日機械翻訳システムにおける、主に動詞の多義性解消について、事例データに基づく手法を提案し、その有効性を確認するために行なった実験結果について述べる。

2 システムの概要

本システムでは、英文が入力されると動詞が入力文と同じである事例を事例データから抽出する。そして、主語・直接目的語・間接目的語・補語・前置詞の各語に関して抽出した事例を検索し、入力文とそれぞれの事例との距離を算出する。その際、入力文の動詞以外の各語に関してはシソーラスから同義語、上位語、下位語を抽出して検索を行なう。そして、算出された距離を基に最適解(事例)の選択を行なう。

3 距離の定義

距離については、シソーラスの概念階層を基に次のように定義している。

- 任意の語とそれに隣接する上位語(下位語)との間の距離は全て等しい。
- 任意の語とその同義語との間の距離は全て等しい。
- 任意の語とそれ以外の任意の語との距離は共通する上位語までのそれぞれの距離の和とする。

4 最適解の選択

最適解は、各事例と入力文との距離を式(1)により算出し、この値が最小となる事例を選択する。

$$Y = \sum_{i=1}^{N} w_i X_i \qquad (1)$$

ここで、X_i はそれぞれの語における事例と入力文との距離を表し、w_i は重み係数を表す。また N は検索範囲の語数を表す。

5 実験

C言語のマニュアル[3][4]中の300文を使用して事例データの全くない状態から実験を行なったところ、直接目的語が検索範囲に含まれているものは正解率が70%以上であった。また、入力文と同じ動詞をもつ事例を抽出することができなかったものが117文あった。なお、今回の実験では、入力文は人間により構文解析がすでに行なわれているものを使用した。

6 考察

実験結果より、検索範囲の語数が3語以上でその中に直接目的語を含んでいる場合が良いと考えられる。また、本手法の問題点として、事例に入力文と同じ意味の同じ動詞が含まれている必要があるということが挙げられる。これを解決するためには、事例の追加だけでなく、新たなアルゴリズムの追加などが必要であると考えられる。

7 おわりに

本稿では、事例の全くない状態から実験を行なって300文という少量の事例で70%以上の正解率が得られ、本手法の有効性が示された。このことより、本手法は、大量の事例を必要とするという事例データに基づく手法の問題点を解決できる可能性をもっていると考えられる。今後、6章で述べた問題点の解決と正解率の向上のために改良を加えていく予定である。

謝辞

本研究では、シソーラスとしてCognitive Science Laboratory, Princeton Universityで開発されたWordNetを使用しました。ここに、Cognitive Science Laboratory, Princeton Universityに感謝致します。

参考文献

[1] 浦本直彦:"制約と事例による優先度を組み合わせた英文の多義性の解消", 情報処理学会研究報告, 92-NL-90, pp.65-72 (1992-7).

[2] 藤井敦, 乾健太郎, 徳永健伸, 田中穂積:"動詞多義性解消における格要素の貢献度について", 情報処理学会研究報告, 96-NL-111, pp.55-62 (1996-1).

[3] Brian W.Kernighan and Dennis M.Ritchie: "The C programming language. Second Edition", Prentice-Hall (1988).

[4] B.W.カーニハン, D.M.リッチー著, 石田晴久訳: "プログラム言語C第2版", 共立出版 (1989).