論　文

帰納的学習を用いた訳語推定手法の派生語および複合語における有効性の評価

笹岡　久行[†]　荒木　健治[†]　桃内　佳雄[†]　栃内　香次[††]

Evaluation of Prediction Method of Target Word Using Inductive Learning for Unknown Derivative Words and Compound Words

Hisayuki SASAOKA[†], Kenji ARAKI[†], Yoshio MOMOUCHI[†], and Koji TOCHINAI[††]

あらまし　機械翻訳手法において辞書未登録語の処理は大きな問題の一つである．これは，翻訳対象の中に辞書未登録語が出現した場合に，その翻訳に失敗したりあるいはその翻訳が不可能になるためである．我々は，この問題の解決を目指して研究を進めている．本論文では，辞書未登録語の訳語推定に利用する単位を，単語とその訳語の字面から帰納的学習を用いて抽出する手法を提案し，更に既存の辞書の見出し語とその訳語の組，接辞と訳語の組およびそれらを利用して抽出した単位を利用した辞書未登録語の訳語を推定する手法を提案する．なお，本論文では対象とする辞書未登録語の種類を派生語と複合語とし，英単語の辞書未登録語に対する日本語の訳語を推定する手法について考察する．更に，本手法をもとに実験システムを作成し，そのシステムに対して行った実験結果について述べる．この実験では四つの異なる分野の英文から実験データを抽出し，この実験データに対して平均63.7%の有効推定率を得ることができ，本手法の有効性を確認した．

キーワード　帰納的学習，訳語，推定，辞書，未登録語

1. まえがき

機械翻訳システムは，母国語以外の言語により情報の交換を行う際に有用な道具であり，さまざまな機械翻訳手法に関する研究が行われている．しかし，まだ今後引き続き考察が必要な課題が残されており，その中で辞書未登録語の処理は重要な問題の一つと考えられる．

日本語と英語の間での機械翻訳における辞書未登録語処理に関する研究の一つに，片仮名で記述された単語を英語のアルファベット表記に変換する処理に関する研究がある．例えば，Knightらの研究[1]は固有名詞や専門用語等の片仮名で表記された日本語の文字列をアルファベットで表記された英語の文字列へ字訳する手法を提案している．この研究では，人間により字訳された結果と比較し，その有効性を確認している．松尾らの研究[2]では実際の機械翻訳システムにおける利用を前提とした手法を提案している．これらの研究で扱われている片仮名で記述された単語は，辞書未登録語の一部分を占めている．

そして，機械翻訳システムの翻訳精度向上のためには辞書の整備が必要であるという観点から，対訳コーパスを利用した辞書自動作成手法あるいは対訳表現の自動抽出手法に関する研究[3]～[6]がある．フランス語と英語の間ではMelamedらの研究[3]がある．また，英語と日本語の間においてもいくつかの研究が行われてきた．山本らの研究[4]は既存の機械翻訳辞書および対訳コーパスを利用した専門用語辞書の自動作成手法を提案した．カバー率および処理時間において自動作成された辞書の方が人手により作成した辞書よりも勝っていたことによりこの手法の有効性が示されている．しかし，山本らの研究[4]では訳語生成に既存の辞書を利用しているために，生成される訳語は利用している辞書の精度および質に依存している．また，熊野らの研究[5]および北村らの研究[6]では，対訳

[†] 北海学園大学大学院工学研究科電子情報工学専攻，札幌市
Department of Electronics and Information Engineering, Graduate School of Engineering, Hokkai-Gakuen University, Minami 26, Nishi 11, Chuo-ku, Sapporo-shi, 064-0926 Japan
[††] 北海道大学工学部電子情報工学専攻，札幌市
Division of Electronics and Information Engineering, Faculty of Engineering, Hokkaido University, Kita 13, Nishi 8, Kita-ku, Sapporo-shi, 060-8628 Japan

コーパスをもとにして機械翻訳辞書の作成や対訳情報の抽出等を行っているために，生成される訳語は対訳コーパスにおける訳文に出現した訳語を組み合わせて生成可能なものに限定される．また，生成される訳語の精度向上のためには良質な大量の対訳コーパスが必要になるという問題がある．

そこで我々は，訳語推定に利用する単位を，既存の辞書中の見出し語とその訳語の組，接辞とその訳語の組，および帰納的学習を用いて獲得される原言語と目的言語の文字列の組とし，「要素合成原理」[7]に基づいて，それらの単位を利用して訳語を生成する手法を提案する．訳語を生成するという観点で考えると，本手法では，推定される訳語は利用している既存の辞書の訳語の精度や質および利用する訳語の精度や質にも強く依存しないという点で従来の手法に比べて優れている．つまり，帰納的学習を用いることにより，特定の分野に依存しない一般的な単語だけでなく，専門用語等の分野に依存した単語に対する訳語推定が可能である．

本論文では，対象とする辞書未登録語の種類を派生語と複合語として，英語の辞書未登録語に対する日本語の訳語を推定する手法について考察する．訳語推定に利用する単位を単語とその訳語から帰納的学習により抽出する手法およびそれらの単位を利用した辞書未登録語の訳語を推定する手法を提案し，更に，これらの手法をもとに作成した実験システムに対して行った評価実験の結果およびそれについての考察について述べる．

2. 基本的な考え方

2.1 帰納的学習について

自然言語処理分野における従来の多くの研究では，ある問題の解決に必要であると考えられる知識あるいは規則をあらかじめ用意し，その与えられた知識あるいは規則のみを利用して問題を解決することを目指している．しかし，与えられた知識や規則の例外となる問題への対処，与えられた知識や規則の中に存在しない知識が必要となった場合の処理等，これまで進められてきた研究手法では解決が困難である問題が多数存在している．そこで，我々は，これらの問題を克服するために人間が有する学習の仕組みの実現と自然言語処理分野における応用を目指して研究[8],[9]を進めている．そして，この目的のもとに，対象とする問題を機械翻訳手法における辞書未登録語の処理として研究[10],[11]を行ってきた．本研究において，帰納的学習とは具体的な例から何らかの規則あるいは知識を発見し獲得する過程であると考えている．

2.2 単語片と単語片対

本論文では「単語あるいはその訳語の字面の共通部分と差異部分の抽出の結果から得られる文字の並び」を単語片（Piece of Word: PW）と呼んでいる．そして，この単語片は辞書未登録語の訳語推定に利用する単位である．また，「単語と訳語の二つの異なる組から抽出される原言語の単語片と目的言語の単語片の対のこと」を単語片対（Pair of Pieces of Word: PPW）と呼んでいる．

本研究では，単語とその訳語から抽出された単語片対を利用して辞書未登録の訳語を推定している．このようにした理由は，辞書未登録語の訳語は獲得した文字列を利用して推定が可能であると考えられるからである．これは，単語の中のより小さい単位の文字の並びを手掛りにしてその単語の訳語を考えるという要素合成原理[7]に基づいている．

この考え方では，図1に示すようにWord 3の訳語Target Word 3は，Word 1とTarget Word 1の組あるいはWord 2とTarget Word 2の組の中に存在する文字列を利用して推定する．

例えば，図2にあるように英単語「aircraft」と「airway」の間から，共通部分として「**air**」，差異部分として「way」，「craft」が抽出される．文字列「**air**」

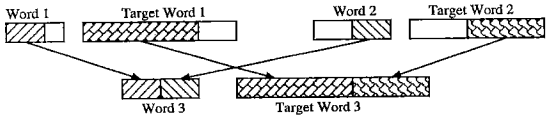


図1 他の単語とその訳語の中の文字列を利用した訳語推定

Fig. 1 An illustration of prediction of target word with strings extracted from pairs of words and target words.

Word 1: aircraft

Word 2: airway

⇓

PW 1: air @1

PW 2: craft

PW 3: way

図2 英語の単語片の例

Fig. 2 Examples of English PW's.

String 1: 航空機
String 2: 航空路
⇓
PW 1: 航空 @1
PW 2: 機
PW 3: 路

図3 日本語の単語片の例
Fig. 3 Examples of Japanese PW's.

の後ろに「craft」あるいは「way」が接続されることにより二つの単語「**air**craft」と「**air**way」の間の違いを生み出している．このように，共通部分として抽出された文字列は単語を生成する際に元となる文字列となる．そこで，抽出元の単語の差異部分を変数「@1」で置換して単語片を得る．この変数は別の単語片との組合せの際に接続位置となる．また，差異部分から抽出された文字列はそのまま単語片として抽出される．その結果「airway」と「aircraft」の間から三つの単語片「**air** @1」「way」「craft」が抽出される．更に，単語片「**air** @1」の変数の位置に「fleet」や「freight」等を接続することにより単語「**air**fleet」や「**air**freight」等が生成される．

また，図3にあるように日本語の文字列においても，英語の場合と同様のことが見られる．つまり，「**航空**」の後ろに「機」あるいは「路」が接続することにより「**航空**機」と「**航空**路」の間の違いを生み出している．字面に対する共通部分と差異部分を抽出し，抽出元の訳語において差異部分を変数「@1」と置換した結果，「**航空**機」と「**航空**路」の間から「**航空** @1」，「機」と「路」の三つの単語片を得る．更に，単語片「**航空** @1」の変数の位置に「艦隊」や「貨物」等が接続することにより，「**航空**艦隊」や「**航空**貨物」等が生成される．

そして，図4にあるように英単語とその訳語の組に対する英語と日本語の字面に対する共通部分の抽出の結果から文字列の組「air, 航空」が得られる．単語片の例で示したように共通部分として抽出された文字列は他の文字列を生成する際の元となっている．そのために，単語片と同様に，単語片対「**air** @1, **航空** @1」を得る．また，差異部分から抽出された文字列の組はそのまま単語片対「craft, 機」と「way, 路」として抽出される．

更に，図5にあるように単語片対「air @1, 航空 @1」と「mail, 郵便」を利用すると，新たな単語「airmail」

Word 1: aircraft
Word 1 for Translation: 航空機
Word 2: airway
Word 2 for Translation: 航空路
⇓
PPW 1: air @1 航空 @1
PPW 2: craft 機
PPW 3: way 路

図4 単語片対の例
Fig. 4 Examples of PPW's.

Target for prediction : 「airmail」
PPW 1: 「air @1, 航空 @1」
PPW 2: 「mail, 郵便」
⇓
Prediction Result: 「航空 郵便」
Correct Word for Translation: 「航空郵便」

図5 訳語推定の例
Fig. 5 An example of a prediction of a target word.

の訳語を「航空郵便」と推定することが可能となる．

2.3 推定する訳語

機械翻訳システムにとって必要とされる訳語は，その翻訳対象の文あるいは文章にとって最適な訳語である．これまでの機械翻訳手法の研究において，用例およびシソーラス等の知識を利用して複数の翻訳例の中から最適なものを選択する手法の研究[12]がある．しかし，この手法の研究では英語のシソーラスと日本語のシソーラスのバランスの問題等が指摘されている．更に，訳語推定対象である辞書未登録語はシソーラスにも未登録である場合がある．このために，訳語選択を行うためにシソーラスを利用する場合は，シソーラスの獲得手法あるいは既存のシソーラスの拡張手法の検討等の新たな問題が存在する．また，これ以外の訳語選択手法を取る場合には，その手法で利用する知識等に関する検討が必要になる．

このような理由から，最適な訳語を選択する手法については，解決しなければならない今後の課題と考え，本手法では，辞書未登録語の最適な訳語になり得る候補を推定する問題について考える．

3. 処理過程

3.1 概　　要

本手法をもとに作成したシステムの概要を図6に

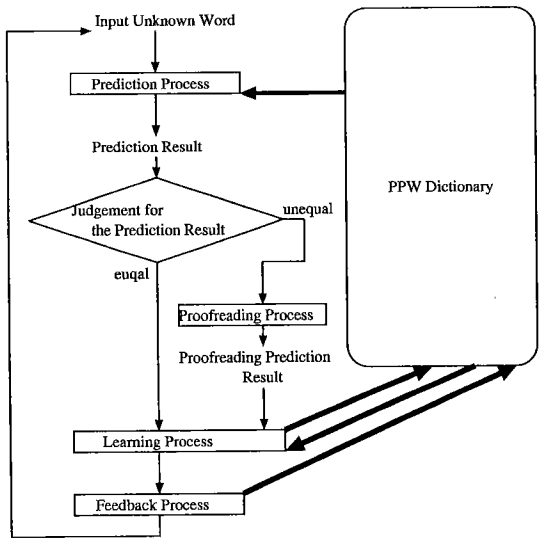


図6　システムの構成
Fig. 6　Outline of system based on our method.

示す．

辞書未登録語が入力されると最初に訳語推定部において訳語の推定を行う．ここでは，システムが既に獲得している単語片対辞書中に存在する単語片対を利用して訳語の推定を行う．次に，推定結果に対する正誤判定を行う．正しい訳語は人手により用意し，それを基準にして正誤判定を行う．もし，推定結果が正しい場合には，そのまま次の学習処理を行う．もし，推定結果が誤っていた場合には，正しい訳語を与える．次に，辞書未登録語とその正しい訳語の組を単語片対として単語片対辞書に追加する．そして，学習部においてこの単語片対と既に獲得されている単語片対の間から新しい単語片対を獲得する．最後に，訳語推定結果の正誤判定に基づいた訳語推定に利用した単語片対に対する処理をフィードバック部で施す．この処理により，正しい結果を推定した処理に利用された単語片対には今後の訳語推定における単語片対選択の際に優先順位が上がるような処理を行う．また，誤った結果を推定した処理に利用された単語片対には単語片対選択の際に優先順位が下がるような処理を行う．このフィードバック部では，同じ誤りを起きにくくすることによりそれ以降のシステムの訳語推定能力を改善する．

3.2　訳語推定部

既に獲得されている単語片対辞書に存在する単語片対を利用して辞書未登録語の訳語を推定する．訳語推定は以下のようにする．

「訳語推定手順：最初に，辞書未登録語の字面に対する左側からの最長一致によって利用可能な単語片対を検索する．次に，検索された単語片対の日本語の単語片を組み合わせ，訳語を生成する．そして，検索された英語の単語片を組み合わせて辞書未登録語のつづりが再現された場合，その日本語側の文字列が推定結果となり推定を完了する．」

字面による検索の結果，複数の単語片対の組合せが存在した場合は，推定に利用している以下の数値を順に参照して推定結果における優先順位を決定する．

（1）　単語片対の数
（2）　各単語片対の出現度数の平均
（3）　各単語片対の正推定度数の平均
（4）　各単語片対の誤推定度数の平均
（5）　日本語の単語片の接続の正接続度数の平均
（6）　日本語の単語片の接続の誤接続度数の平均

ここで，ある単語片対が正しい推定に利用された回数をその単語片対の「正推定度数」と呼び，誤った推定に利用された回数をその単語片対の「誤推定度数」と呼ぶ．また，ある日本語の単語片同士の接続が正しい訳語推定に利用された回数を「正接続度数」と呼び，誤った推定に利用された回数を「誤接続度数」と呼ぶ．

（1）の数値については小さい数値をもつ推定結果を優先する．これは，推定結果においてより長い文字列の組合せの方が正しいというヒューリスティックスに基づいている．（2）の数値は大きい数値をもつ推定結果を優先する．これは，訳語の推定において過去の推定により多く利用されたものの方がより確からしいというヒューリスティックスに基づいている．（3）と（5）の数値は大きな数値をもつ推定結果を優先し，（4）と（6）は小さい数値をもつ推定結果を優先する．これは，過去の推定において正しい推定に利用されたものほど確からしく，誤った推定に利用されたものほど確からしくないというヒューリスティックスに基づいている．この（1）から（6）までの数値を参照して推定結果における優先順位を付ける．

優先順位の決定が有効な例として，推定対象単語とその訳語「testing, テストしている」がある．単語片対辞書中には推定に利用可能な単語片対として，「test @1, テスト @1」，「ing, している」，「in @1, @1 で」，「g, グラム」等が存在する．このような場合，単語片対を組み合わせて英単語「testing」の訳語を推定した結

果として「test ing, テスト している」,「test in g, テスト グラム で」が可能である．この場合では，上述した優先順位の決定のための数値を参照することにより最初の組合せの方が利用されている単語片対の数が少ないためにもう一方よりも優先順位は高くなる．そして，この場合では優先順位の高いものが正しい訳語と一致している．

3.3 学 習 部

学習部では，帰納的学習により，2組の単語と訳語の対から単語とその訳語の字面の共通部分と差異部分を抽出した文字の並びを単語片とし，更に単語から抽出した単語片と訳語から抽出した単語片の組を単語片対として獲得している．しかし，字面だけからの共通部分と差異部分の抽出では英語の単語片と日本語の単語片の間の意味の対応が誤った単語片対を多く抽出してしまう[10]．そこで，誤った対応関係をもった単語片対の抽出を減らすために英語の単語片の抽出および単語片対の抽出に対して抽出条件を設けた．

英語はアルファベットと数種類の記号によって記述されており，日本語と比較すると出現している文字の種類が非常に少なく，漢字のような表意文字がない．そのために，1文字が意味を表す語となるのはまれである．そこで，英語の単語片抽出条件は「共通部分の文字数は2文字以上」とした．

また，単語片対を抽出する二つの条件を以下のように設定した．

条件1：抽出元の片方の組に共通部分が1箇所だけであり，もう一方の組には共通部分と差異部分が1箇所ずつ存在する．

この条件1を満たす単語片対の抽出例を図7に示す．この例では，抽出元の片方に共通部分となる英日の文字の並び「**gentleman, 紳士**」が存在し，もう一方には共通部分「**gentleman, 紳士**」と差異部分「ly, 的な」が存在する．更に，共通部分から抽出された文字列には変数「@1」を付加して，単語片対「**gentleman** @1, **紳士** @1」と「ly, 的な」を抽出する．

条件2：抽出元となる双方の組に共通部分が1箇所と差異部分がそれぞれ1箇所存在する．

条件2を満たす単語片対の抽出例を図8に示す．この例では抽出元の双方に共通部分「**meter, 計**」が存在し，差異部分がそれぞれ「thermo, 温度」「volt, 電

Word 1: gentleman
Word 1 for Translation: 紳士
Word 2: gentlemanly
Word 2 for Translation: 紳士的な
⇓
PPW 1: gentleman @1 紳士 @1
PPW 2: ly 的な

図7 条件1による単語片対の抽出例
Fig. 7 An example of a PPW extraction to which is applied Condition (1).

Word 1: thermometer
Word 1 for Tarnslation: 温度計
Word 2: voltmeter
Word 2 for Translation: 電圧計
⇓
PPW1: @1 meter @1 計
PPW2: thermo 温度
PPW3: volt 電圧

図8 条件2による単語片対の抽出例
Fig. 8 An example of a PPW extraction to which is applied Condition (2).

圧」として存在する．これらの文字列も，共通部分として抽出された文字の並びには変数「@1」を付加して，単語片対「@1 **meter**, @1 **計**」を獲得し，差異部分から抽出された文字の並びはそのまま「thermo, 温度」「volt, 電圧」を単語片対として抽出する．

本来は帰納的学習により意味的な対応関係の付け方までも学習するべきであると考えられるが，現段階ではそのような学習の仕組みは実現できていない．本研究において意味的な対応関係の付け方は，これまでの我々の研究[10]における実験結果の考察により条件1と2を決定した．これらの対応関係の付け方の獲得手法については，今後の課題として研究を行う予定である．

ここで設定した単語片対の抽出条件のために，1回の処理では，抽出可能な単語片対をすべて抽出できない英単語とその日本語の訳語の組が存在している．例えば，「unselfishly, 利己的でなく」である．英単語「unselfishly」は「un」「selfish」「ly」の三つの文字列に分解され，それぞれ単語片となる．日本語の訳語「利己的でなく」は「利己的」「で」「なく」の三つの文字列に分解されそれぞれ単語片となる．そして，抽出

表1 Susanne Corpusにおける実験データとなる辞書未登録語数
Table 1 A table of number of unknown words which are experimental data in Susanne Corpus.

ジャンル名	全出現単語数	出現単語の異なり語数	辞書未登録語の異なり語数	実験データの異なり語数
Press Reportage	39,243	4,425	1,119	179
Belles Letters, Biography, Memories	39,062	4,986	845	292
Learned Writing	37,880	3,851	739	369
Adventure and Western Fiction	40,399	3,896	580	202

された単語片が単語片対を構成すると考えられる．本手法では，1回の処理でこれらすべての単語片対を抽出することはできないが，抽出処理を繰り返すことにより同様の単語片対を抽出することが可能になる．これにより，上述の抽出条件を設定しても有効な単語片対の獲得は可能であると考えられる．

3.4 フィードバック部

フィードバック部では訳語推定に利用された単語片対がもつ以下の数値を操作する．

（1） 単語片対の出現度数
（2） 推定結果が正しい場合
- 単語片対の正推定度数
- 単語片対の日本語の単語片間の正接続度数

（3） 推定結果が誤っている場合
- 単語片対の誤推定度数
- 単語片対の日本語の単語片間の誤接続度数

フィードバック部では，推定に利用した単語片対の出現度数に1加算する．そして，推定結果が正しいものであった場合には，単語片対の正推定度数および日本語の単語片間の正接続度数にそれぞれ1加算する．また，推定結果が誤ったものであった場合には，単語片対の誤推定度数および日本語の単語片間の誤接続度数にそれぞれ1加算する．この処理により訳語推定の際に同じ誤りを起きにくくし，システムの訳語推定能力の改善を図っている．

4. 評価実験

4.1 辞書未登録語

本論文において，辞書未登録語とは電子化された辞書[13]に見出し語として登録されていない英単語と定義した．この辞書[13]には英単語の見出し語49,336語が登録されており，一般的な英文を読むことを想定し作成されている．

そして，辞書未登録語を抽出するデータとしてはSusanne Corpus[14]とした．このコーパスは，「Press Reportage」，「Belles Letters, Biography, Memories」，「Learned Writing」，「Adventure and Western Fiction」の四つのジャンルから構成されている．各ジャンルの全出現単語数，出現単語の異なり語数，辞書未登録語の異なり語数および実験対象データとなる派生語あるいは複合語である辞書未登録語の異なり語数は表1に示すとおりである．

4.2 単語片対辞書の初期状態

辞書[13]の見出し語に対し，ある語が複数の訳語をもつ場合にその英単語と訳語とを1組とし，102,156組の英単語と訳語の組を抽出した．この辞書の見出し語の英単語と訳語の組は，複合語等の他の単語の一部を構成することが可能であるため，単語片対と見ることが可能である．

次に，文献[15]を参照し，同一の接辞（接頭辞と接尾辞）をもつ英単語とその訳語の組を用意し，それらの単語から人手により接辞とそれに対応する日本語の文字列の組を抽出した．その数は351組であり，接頭辞に関するものが69組であり，接尾辞に関するものが282組であった．これらの組は英語と日本語の文字列の組であり，英単語およびその訳語から抽出しているために，単語片対とみなすことができる．同一の接頭辞をもつ英単語とその訳語の組から抽出された単語片対の例を図9に示す．また，同一の接尾辞をもつ英単語とその訳語の組から抽出された単語片対の例を図10に示す．

本評価実験では，辞書[13]から抽出した単語片対102,156組と接辞をもとにして抽出した単語片対351組の合計102,507組の単語片対は，システムの単語片対辞書に初期単語片対として実験開始前に与えた．これらの単語片対は，本システムの単語片対抽出手法で獲得可能な単語片対である．しかし，これまでの我々の研究[10]から全く単語片対辞書に単語片対が存在しない状態から開始した学習において，有効な単語片対が大量に辞書に蓄えられた状態になるためには，膨大な量の学習が必要なことが明らかになっている．そこで，これらの単語片対は初期状態の単語片対辞書に与

Word 1: **ultramodern**
Word 1 for Translation: **超現代的な**
Word 2: **ultrashort**
Word 2 for Translation: **超短波の**
⇓
PPW 1: **ultra @1　超 @1**
PPW 2: **modern　現代的な**
PPW 3: **short　短波の**

図 9　同一の接頭辞をもつ単語片対の抽出例
Fig. 9　An example of PPW extractions extracted from pairs of words and their target words which have the same prefix.

Word 1: **endless**
Word 1 for Translation: **終りのない**
Word 2: **worthless**
Word 2 for Translation: **価値のない**
⇓
PPW 1: **@1 less　@1 のない**
PPW 2: **end　終り**
PPW 3: **worth　価値**

図 10　同一の接尾辞をもつ単語片対の抽出例
Fig. 10　An example of PPW extractions extracted from pairs of words and their target words which have the same postfix.

えた状態で実験を行った．

4.3 推定結果の評価基準

辞書未登録語の正しい訳語は辞書[16]に記載されている訳語とした．辞書[16]に複数の訳語が記載されている場合には，そのすべてを辞書未登録語の正しい訳語とした．そして，この正しい訳語をもとにして，「正しい訳語と一致している推定結果あるいは正しい訳語と比較して1単語片だけが他の同じ意味を表す単語片と置き換わっている推定結果」を(1)，「正しい訳語と比較して語基の部分までは一致している推定結果」を(2)，そして「(1)と(2)に分類できない推定結果」を(3)と分類した．例えば(2)に分類される推定結果は，図11のように推定結果の語尾が誤っている結果等である．この(2)に分類される推定結果は，比較的簡単な処理を施すことで正しい訳語と一致する推定結果とすることが可能である．そのために，我々は(1)と(2)に分類される推定結果を有効な推定結果とみなすことにした．

また，全推定対象単語に占める有効な推定結果の割合を有効推定率によって示す．この有効推定率は以下の式によって計算される．

Unregistered Word :「rightfully」
PPW 1:「@1 ly,@1 に」
PPW 2:「right, 正当な」
⇓
Prediction Result:「正当な に」
Correct Word for Translation:「正当に」

図 11　(2)に分類される推定結果の例
Fig. 11　An example of an experimental result in Group (2).

$$\text{有効推定率}\,(\%) = \frac{(\text{(1)の個数}) + (\text{(2)の個数})}{(\text{全推定対象単語数})} \times 100.0$$

4.4 実験方法

上述したSusanne Corpusから抽出した派生語あるいは複合語である辞書未登録語を実験データとした．また，上述した辞書[13]から抽出した単語片対および同一の接辞をもつ単語から抽出した単語片対102,507組を与えた単語片対辞書を初期状態として実験を開始した．実験はSusanne Corpusを構成している各ジャンルごとに行った．実験の手順としては，辞書未登録語の入力，訳語推定部における辞書未登録語の訳語推定処理，推定結果に対する正誤判定と結果が誤っていた場合の校正処理，学習部における単語片対を獲得する学習処理，フィードバック部における推定に利用した単語片対に対するフィードバック処理を順次繰り返した．

4.5 実験結果

表2に実験結果を上述した基準に基づき評価した結果を示す．

この結果から各分野においてそれぞれ63.1%，63.0%，62.3%，66.3%の有効推定率を得ている．従来から提案されている機械翻訳手法では，辞書未登録語の処理は語い規則等を用いて訳語推定を行っているが，十分な結果を得るには至っていない．しかし，本手法により辞書未登録である派生語および複合語において平均63.7%の有効推定率を得ることができた．このことから，本手法が辞書未登録である派生語および複合語において有効であることを確認した．

4.6 考　察

4.6.1 正しい訳語と一致する推定結果について

実験結果において，「正しい訳語と一致する推定結

表2 実験結果
Table 2 A table of experimental results.

ジャンル名	(1) の個数	(2) の個数	率（%）	(3) の個数	率（%）	実験データの異なり語数
Press Reportage	26	87	63.1	66	36.9	179
Belles Letters, Biography, Memories	41	143	63.0	108	37.0	292
Learned Writing	50	180	62.3	139	37.7	369
Adventure and Western Fiction	20	114	66.3	68	33.7	202

表3 正しい訳語と一致する推定結果に対する単語片対に基づく分類
Table 3 A table of classification of experimental results in Group (1).

ジャンル名	(1-a) の個数	割合（%）	(1-b) の個数	割合（%）	(1-c) の個数	割合（%）	総数
Press Reportage	20	76.9	5	19.2	1	3.9	26
Belles Letters, Biography, Memories	27	65.9	9	22.0	5	12.1	41
Learned Writing	21	42.0	16	32.0	13	26.0	50
Adventure and Western Fiction	14	70.0	4	20.0	2	10.0	20

Unregistered Word: redevelopment
PPW 1: re @1, 再 @1
PPW 2: re @1, 再び @1
PPW 3: development, 開発
PPW 4: development, 発達
PPW 5: development, 産物
PPW 6: development, 進展
etc.
⇓
Prediction Result 1 再 発達
Prediction Result 2 再 開発
Prediction Result 3 再 産物
Prediction Result 4 再 進展
Prediction Result 5 再び 開発
etc.
Correct Word for Translation: 再開発

図12 (1-a) に分類される推定結果の例
Fig. 12 An example of an experimental result in Group (1-a).

Unregistered Word: thermodynamic
PPW 1: thermo @1, 熱 @1
PPW 2: thermo @1, 熱電 @1
PPW 3: dynamic, 動力の
PPW 4: dynamic, 動的な
PPW 5: dynamic, 力学の
etc.
⇓
Prediction Result 1: 熱 動力の
Prediction Result 2: 熱 動的な
Prediction Result 3: 熱 力学の
Prediction Result 4: 熱電 動力の
Prediction Result 5: 熱電 活動的な
Prediction Result 6: 熱電 力学の
etc.
Correct Word for Translation: 熱力学の

図13 (1-b) に分類される推定結果の例
Fig. 13 An example of an experimetal result in Group (1-b).

果」に分類される推定結果をその推定結果を構成している単語片対をもとにして分類し，考察を行う．ここでは「正しい訳語と一致する推定結果」に分類される推定結果を，「初期状態で単語片対辞書に与えられた単語片対のみで構成されているもの」を (1-a) として，「初期状態で与えられた単語片対とシステムにより獲得された単語片対の組合せにより構成されているもの」を (1-b) として，「システムにより獲得された単語片対のみにより構成されたもの」を (1-c) として，3種類に分類した．表3は，この単語片対に基づく分類の各分類での個数を示す．

図12に，(1-a) に分類される推定結果の例を示す．

次に，図13に (1-b) に分類される推定結果の例を示す．この中で利用された単語片対「thermo @1, 熱 @1」は，「thermocouple, 熱電対」と「thermodynamic-equilibrium, 熱平衡」の間の共通部分として抽出された単語片対であった．そして，「dynamic, 力学の」は初期状態の単語片対辞書に登録されていた単語片対であった．

また，図14に (1-c) に分類される推定結果の例を示す．この中で利用された単語片対「right @1, 右 @1」は，「right-hander, 右ききの人」と「right, 右」の間

Unregistered Word: right-field
PPW 1: right @1, 右 @1
PPW 2: right @1, 右ききの @1
PPW 2: right @1, 右きき @1
PPW 2: right, 正しい
PPW 3: -field, 翼
PPW 4: @1 - @2, @ 1 @ 2
PPW 5: field, 野原
etc.
⇓
Prediction Result 1: 右 翼
Prediction Result 2: 右ききの 翼
Prediction Result 3: 右きき 翼
Prediction Result 4: 正しい 野原
etc.
Correct Word for Translation: 右翼

図 14 (1-c) に分類される推定結果の例
Fig. 14 An example of an experimental result in Group (1-c).

の共通部分として抽出された単語片対であった．そして，「-field, 翼」は「left-field, 左翼」と「left, 左」の間の差異部分として抽出された単語片対であった．

表 3 において，他のジャンルと比較して「Learned Writing」のジャンルはシステムが獲得した単語片対が正しい推定結果を構成している割合が高くなっている．このジャンルにおける正しい推定結果には，「alkaline, アルカリ性の」や「electromagnetic, 電磁石の」等の分野に依存した専門用語が 50 個中 21 個（42.0%）存在していた．また，単語片対を抽出するもととなる辞書未登録語には専門用語が 369 個中 132 個（35.8%）存在していた．それらの単語とその訳語の組における字面の並びは類似しており訳語推定にとって有効な単語片対の獲得が可能であったと考えられる．このことから，分野に依存した単語とその訳語，例えばその分野における専門用語とその訳語等に対して，推定に有効な単語片対の獲得が行われ，本手法の有効性は大きくなると考えられる．

また，他のジャンルと比較して「Press Reportage」のジャンルはシステムが獲得した単語片対を利用した推定が正しい結果となったものの割合が低くなっている．このジャンルの文章で扱われている話題は多岐にわたっている．例えば，野球，政治や裁判等の話題である．これらの話題が異なる文章に出現している単語とその訳語の組の間の字面の並びには類似性は少ない．そのために，他のジャンルに比べてシステムによって獲得された推定に有効な単語片対の数が少ないと考えられる．しかし，初期状態で与えられた単語片対を利用して推定を行っているので，全体の有効推定率は他のジャンルと変わらない有効性を示している．これらのことから，本手法では，帰納的学習により獲得された単語片対と与えられた単語片対の双方を利用した訳語推定を行うことにより，単語片対の獲得が行える場合においても，単語片対の獲得があまり行えない場合においても，訳語推定結果はほぼ一定の有効性を示すことが確認された．

図 13 と図 14 において推定された訳語はそれぞれの英単語が存在していた英文の文脈にふさわしい訳語であった．これらの推定に利用された単語片対は，推定対象となる英単語の存在している英文中の単語とその文脈に合った訳語の組から抽出されている．ところで，実際に機械翻訳システムにおいて推定された訳語を利用する場合には文脈に合ったものが必要となる．そこで，単語片対の抽出対象の限定等，文脈にふさわしい訳語を推定する手法に対する検討が今後必要である．

4.6.2 正しい訳語と語基まで一致する推定結果について

次に，「正しい訳語と比較して語基の部分までは一致している推定結果」に分類された推定結果に対する考察を行う．「正しい訳語と比較して語基の部分までは一致している推定結果」に分類される推定結果が正しい訳語と一致することができなかった原因に基づいて，「英語の単語片に単語片の組合せのために必要な変数が不足しているために，正しい訳語とは一致しない推定結果」を (2-a) として，「訳語生成に必要な単語片対が辞書中に存在しないために，正しい訳語とは一致しない推定結果」を (2-b) として，そして「日本語の単語片の組合せが正しい日本語とはなっていないために，正しい訳語とは一致しない推定結果」を (2-c) として分類した．各分類に分類される個数はそれぞれ表 4 のようになった．

(2-a) に分類される推定結果は，例えば，「committeewoman, 女性委員」の訳語推定である．この推定において，「committee, 委員」と「woman, 女性」は単語片対辞書中には存在する．しかし，双方の単語片対ともに変数をもたないために単語片対の組合せができず，訳語が生成できない．上の例では，「committee @1, @1 委員」等の単語片対が獲得されていれば正し

表4　正しい訳語と部分一致している推定結果に対する正しい訳語と一致しない原因に基づく分類
Table 4　A table of classification of experimental results in Group (2).

ジャンル名	(2-a) の個数	割合（%）	(2-b) の個数	割合（%）	(2-c) の個数	割合（%）	総数
Press Reportage	13	14.9	44	50.6	30	34.5	87
Belles Letters, Biography, Memories	13	9.1	57	39.9	73	51.0	143
Learned Writing	12	6.7	76	42.2	92	51.1	180
Adventure and Western Fiction	8	7.0	38	33.3	68	59.7	114

表5　評価基準において (1) と (2) に分類できない推定結果に対する推定に失敗した原因に基づく分類
Table 5　A table of classification of experimental results in Group (3).

ジャンル名	(3-a) の個数	割合（%）	(3-b) の個数	割合（%）	(3-c) の個数	割合（%）	総数
Press Reportage	39	59.1	26	39.4	1	1.5	66
Belles Letters, Biography, Memories	62	57.4	36	33.3	10	9.3	108
Learned Writing	91	65.4	40	28.8	8	5.8	139
Adventure and Western Fiction	35	51.4	32	47.1	1	1.5	68

い訳語と一致する推定結果を生成できる．

(2-b) に分類される推定結果は，例えば，「semicircular, 半円形の」の訳語推定結果である．この推定において，「circular, 円形の」は単語片対辞書中に存在しているが，それ以外の部分に対応する単語片対が存在しない．そのために，正しい訳語が推定できない．

(2-c) に分類される推定結果は，例えば，上述した図 11 のように訳語の語尾が誤っている場合である．

「Press Reportage」では，他のジャンルと比較して (2-a) と (2-b) に分類されるものの割合が高くなっていた．この理由は，前節で述べたようにこのジャンルで扱われている話題が豊富であるため，単語片対の抽出元である単語とその訳語の組の間の字面の並びに類似性が少ないためであると考えられる．

また，「Press Reportage」以外のジャンルでは (2-c) に分類される割合が高かった．この理由は，この訳語推定手法の仕組みにあると考えられる．本手法は，単語とその訳語の字面のみを利用して単語片対の抽出と訳語推定を行っている．このために，アルゴリズムが単純であるにもかかわらず多様な訳語を推定することが可能であるという利点がある．その一方で，文法的に誤っている訳語を推定してしまう場合がある．また，(2-c) に分類される結果の多くは活用語の語尾の誤り等単純な誤りであった．(2-c) に分類される結果において活用語の語尾の誤り等単純な誤りである推定結果は，「Belles Letters, Biography, Memories」では 68.5%，「Learned Writing」では 68.5%，「Adventure and Western Fiction」では 46.5%を占めていた．

(2-a) と (2-b) に属する推定結果が正しい訳語と一致する推定結果となるためには，より多くの単語片対が必要である．そのために，例えばより多くの単語とその訳語の組を用意し単語片対の獲得を行うことや単語片抽出手法の改良等の検討が必要である．また，(2-c) に分類される推定結果については，推定された訳語が翻訳対象となる文において適切な接続がなされているか等の文法的な知識を利用して判断しなくてはならない．この問題は，機械翻訳手法の研究における文の生成等にかかわる問題であり，今後の課題であると考えられる．

4.6.3　誤った推定結果について

次に「評価基準において (1) と (2) に分類できない推定結果」に分類された推定結果について考察を行う．実験において誤った訳語を推定した原因に基づいて，「訳語推定に必要となる単語片対が不足しているため，推定に失敗した推定結果」を (3-a) として，「推定対象となる複合語が語基の訳語を組み合わせても複合語全体の訳語とはならないため，推定に失敗した推定結果」を (3-b) として，そして「対象となる単語のつづりが標準的なつづりと異なるため，単語片対が足りずに推定に失敗した推定結果」を (3-c) と分類した．また，表 5 に推定結果における推定の失敗原因に基づく各分類の個数を示す．

全ジャンルにおいて，(3-a) に分類されるものの割合が最も高くなっている．本手法では単語とその訳語から単語片対を抽出している．単語片対の抽出には，抽出元である単語とその訳語で各々の字面の並びが類似した組が複数存在する必要がある．そのために，推定に必要な単語片対の獲得ができずに，誤った訳語を推定したと考えられる．(3-a) に分類される訳語推定の失

表6 「帰納的学習」なしの実験システムにおける実験結果
Table 6 A table of experimental results on the system without inductive learning.

分野名	分類a	分類b	率（%）	分類c	率（%）	実験データの異なり語数
Press Reportage	20	65	47.5	94	52.5	179
Belles Letters, Biography, Memories	27	104	44.8	161	55.2	292
Learned Writing	21	106	33.3	242	66.7	369
Adventure and Western Fiction	14	81	47.0	107	53.0	202

敗を減らすためには，より多くの学習データを用意し単語片対の抽出を行うこと等が考えられる．

(3-b)に分類される例として，英単語「strong-room」がある．この単語「strong-room」の正しい訳語は「金庫室」であるが，語基としての「strong」と「room」の訳語を単純に組み合わせただけではこの正しい訳語は得られない．そのために，本手法による訳語推定に失敗する．本手法によりこのような単語の訳語を推定することは大変困難である．そこで，このような単語に対しては人手により訳語をあらかじめ与えておくしかないと考えられる．

また，(3-c)に分類される例として，英単語「colour」がある．「color」というつづりが一般的であり，このつづりで見出し語として辞書に登録されている．そのためにこの英単語「colour」は「color」という単語が辞書に登録されているにもかかわらず，未登録語であると判断され，しかも訳語の推定に失敗している．このような原因による推定失敗を防ぐには，単語のつづりの異表記に関する規則を用意し，辞書未登録語の抽出の際に単語ごとに辞書未登録語であるのか判定することが必要であると考えられる．

5. 帰納的学習に対する評価

本手法における帰納的学習の有効性を確認するために，帰納的学習に関する処理（学習処理，校正処理，フィードバック処理）を行わないシステムにおいて訳語推定実験を行い，その結果と先の評価実験の結果を比較した．本実験では，先の実験と同様の実験データに対して訳語推定を行った．その結果を表6に示す．表6では，各分野において有効推定率はそれぞれ，47.5%，44.8%，33.3%，47.0%であった．また，表2から先の実験における各分野の有効推定率はそれぞれ，63.1%，63.0%，62.3%，66.3%であった．

この中で「Learned Writing」のジャンルでは，帰納的学習を行わないシステムにおける実験と帰納的学習を行ったシステムにおける実験の有効推定率の差は29.0ポイントであった．これより，学習処理により獲得された単語片対が大きく訳語推定に貢献していることがわかる．このジャンルでは，上述したように化学における専門用語とその訳語が多く出現していた．また，正しい訳語と一致した推定結果とはならないが，単語片対の抽出元となった辞書未登録語とその訳語の中にも多くの専門用語と訳語の組が存在した．この分野では，化学に関する英文が多く扱われており，対象としている単語と訳語の字面も類似している．このことから，分野を限定することにより対象とする単語とその訳語の字面は類似しているためにより多くの有効な単語片対が帰納的学習により獲得されていることが確認された．

「Learned Writing」以外のジャンルにおいても，帰納的学習を行わないシステムにおける実験と行ったシステムにおける実験での有効推定率の差は，「Press Reportage」で15.6ポイント，「Belles Letters, Biography, Memories」で18.2ポイント，「Adventure and Western Fiction」で19.3ポイントであり，これらのジャンルでは「Learned Writing」よりも単語片対が利用されている割合が低いにもかかわらず，「初期状態で与えられた単位」が訳語推定に利用されているので全体の有効推定率は極端に低くはなっていない．このことから，「初期状態で与えられた単語片対」と「獲得された単語片対」の双方が訳語推定にとって有効に利用されていると言える．

6. 優先順位決定方法に対する評価

先の評価実験における「正しい訳語と一致した推定結果」に分類されたものの中で，**3.2**で述べた優先順位に基づき，優先順位が1位のもの，優先順位が2位から10位のもの，それ以外のものとして分類した．この分類の結果を表7に示す．

その結果，「Press Reportage」では優先順位が10位以内であったものの割合は88.5%であり，四つのジャンルの中で最も高かった．本手法では，「初期状態で与えられた単語片対」と「獲得された単語片対」とを区別せずに優先順位を決定している．しかし，単語片

表7　正しい訳語と一致する推定結果における優先順位に基づく分類
Table 7　A table of classification of experimental results in Group (1) by priority sequence.

分野名	1位の結果数	割合（%）	2位から10位の結果数	割合（%）	それ以外の結果数	割合（%）	合計
Press Reportage	13	50.0	10	38.5	3	11.5	26
Belles Letters, Biography, Memories	5	12.2	14	34.1	22	53.7	41
Learned Writing	4	8.0	23	46.0	23	46.0	50
Adventure and Western Fiction	4	20.0	5	25.0	11	55.0	20

対の学習があまり進んでいない段階では，「初期状態で与えられた単語片対」の訳語推定処理での出現度数は「システムによって獲得された単語片対」に比べて高くなっている．そのため，「初期状態で与えられた単語片対」が利用された推定結果の優先順位が，利用されない推定結果よりも高くなり，優先順位の決定に偏りが生じている．そのために表7のような結果になったと推察される．

本手法を実用的に利用するには，機械翻訳システムへの組込みが考えられる．しかし，そのためには優先順位1位のものが正しい訳語と一致する割合がより高くなる必要がある．そこで「初期状態で与えられた単語片対」と「獲得される単語片対」との間での公平な優先順位の決定方法の検討を今後の課題とし，研究を進めていく予定である．

7. むすび

本論文では，帰納的学習を利用して英単語とその訳語の字面から単語片および単語片対を抽出する手法と既存の辞書の見出し語とその訳語の組，接辞とその訳語の組およびシステムが抽出した単語片対を利用した辞書未登録語の訳語推定手法を提案した．そして，対象とする辞書未登録語の種類を派生語と複合語として，本手法をもとに作成した実験システムに対して行った評価実験の結果について述べた．辞書未登録語を抽出した各分野ごとの評価実験において，単語片対抽出手法とその単語片対を利用した辞書未登録語の訳語推定手法の有効性を確認した．また，推定結果についての考察を行い，いくつかの問題点を明らかにした．

上述した実験結果に対する考察で述べたように，本手法を機械翻訳において利用する際には，推定される訳語の質の向上と文脈に適した訳語の選択という解決すべき二つの問題が存在する．本論文では，英単語が多義語であった場合はそのすべての訳語との組をそれぞれ単語片対の学習対象としている．これにより，獲得される単語片対の汎用性は高まっているが，推定される訳語の質を低下させていると考えられる．そこで推定される訳語の質の向上を図る方法として，英単語が多義語である場合であっても，単語片対を学習する英単語の訳語をその文脈に適した訳語だけに限定する方法が考えられる．更に，機械翻訳システムにおいて必要とされる文脈に適した訳語を本手法をもとにして推定する手法について検討する必要がある．また，推定結果に対する優先順位の決定方法についての検討も必要である．今後は，これらの問題点の解決を目指して研究を進めていく予定である．

本論文では，実験データを派生語および複合語として評価実験を行い，その結果について述べたが，これは本手法が有効である辞書未登録語の種類が派生語および複合語のみに限定されることを意味するわけではない．本手法では，品詞等をもとにした文法規則や語い規則は利用しておらず，原言語と目的言語の文字列の組から構成する規則を帰納的学習により獲得し，与えられたものと獲得されたものを利用して訳語推定を行っている．それ故，本手法は語の種類に依存することなくその有効性を示すことが可能であると我々は考えている．このことを確認するために，派生語および複合語以外の種類の辞書未登録語に対する本手法の有効性についての評価実験を今後行う予定である．

文　献

[1] K. Knight and J. Graehl, "Machine transliteration," in Proceedings of 35th Annual Meeting of ACL and 8th Conference of the European Chapter of ACL, pp.128–135, Madrid, Spain, 7–12 July 1997.

[2] 松尾義博，小林正裕，白井　諭，"カタカナ表記述語の日英機械翻訳，" 情処学第55回全大(2)，pp.66–67, 24–26 Sept. 1994.

[3] I. Dan Melamed, "A word-to-word model of translation equivalence," in Proceedings of 35th Annual Meeting of ACL and 8th Conference of the European Chapter of ACL, pp.490–497, Madrid, Spain, 7–12 July 1997.

[4] 山本由紀雄，坂本　仁，"対訳コーパスを用いた専門用語対訳辞書の作成，" 情処学自然言語処理研究報告，NL94-12, pp.85–92, 19 March 1993.

[5] 熊野　明，平川秀樹，"対訳文書からの機械翻訳専門用語辞書作成，" 情処学論，vol.35, no.11, pp.2283–2290, 1994.

[6] 北村美穂子，松本裕治，"対訳コーパスを利用した対訳表

現の自動抽出," 情処学論, vol.38, no.4, pp.727-736, April 1997.
[7] 長尾 真編, "自然言語処理," 岩波講座ソフトウェア科学15, 岩波書店, 東京, 1996.
[8] 荒木健治, 高橋祐治, 桃内佳雄, 栃内香次, "帰納的学習を用いたべた書き文のかな漢字変換," 信学論 (D-II), vol.J79-D-II, no.3, pp.391-402, March 1996.
[9] 越前谷博, 荒木健治, 桃内佳雄, 栃内香次, "遺伝的アルゴリズムを用いた実例からの帰納的学習による機械翻訳手法," 情処学論, vol.37, no.8, pp.1565-1579, Aug. 1996.
[10] 笹岡久行, 荒木健治, 桃内佳雄, 栃内香次, "帰納的学習による単語片抽出を用いた未登録語の訳語推定," 1996信学ソ大, D-53, Sept. 1996.
[11] 笹岡久行, 荒木健治, 桃内佳雄, 栃内香次, "語基および接辞の接続情報を用いた辞書未登録語の訳語推定手法," 信学技報, NLC96-64, March 1997.
[12] 佐藤理史, "MBT2:実例に基づく翻訳における複数翻訳例の組み合わせ利用," 人工知能誌, vol.6, no.6, pp.861-871, June 1991.
[13] 久保正治, "英和・和英電策辞典 *gene*," 技術評論社, 東京, 1995.
[14] G. Sampson, "ENGLISH FOR THE COMPUTER," Oxford University Press, Oxford, 1995.
[15] 前田健三, "強くなる英単語," 有精堂, 東京, 1994.
[16] 小稲義男, 竹林 滋, 田桐大澄, 安藤貞雄, 小西友七, 寺澤芳雄, 山川喜久男, 吉川道夫, "新英和大辞典," 研究社, 東京, 1980.

(平成9年6月23日受付, 10年1月7日再受付)



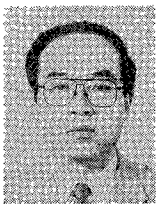
笹岡 久行 (学生員)

平7北海学園大・工・電子情報卒. 平9同大大学院修士課程了. 現在, 同大大学院博士課程に在学中. 情報処理学会, 言語処理学会各会員.



荒木 健治 (正員)

昭57北大・工・電子卒. 昭63同大大学院博士課程了. 工博. 同年, 北海学園大学工学部電子情報工学科助手. 平1同講師. 平3同助教授. 平10同教授. 自然言語の機械学習と機械翻訳に関する研究に従事. 情報処理学会, 日本認知科学会, 人工知能学会, 言語処理学会, IEEE, ACL, AAAI各会員.



桃内 佳雄 (正員)

昭40北大・工・精密卒. 昭42同大大学院修士課程了. 同年 (株) 日立製作所入社. 昭47北大大学院博士課程単位取得退学. 昭48北大大学院情報工学専攻助手, 昭59講師, 昭61助教授. 昭63北海学園大学工学部電子情報工学科教授. 自然言語の理解と生成の研究に従事. 工博. 情報処理学会, 日本認知科学会, 計量国語学会, 言語処理学会各会員.



栃内 香次 (正員)

昭37北大・工・電気卒. 昭39同大大学院工学研究科電気工学専攻修士課程了. 現在, 北大・工・電子情報工学専攻教授. 主として音声情報処理, 自然言語処理の研究に従事. 工博. 情報処理学会, 日本音響学会各会員.