34 多段階類似性判定手法におけるしきい値の最適化

工藤晃一* 荒木健治 桃内佳雄 栃内香次
(北海学園大学)† (北海道大学)‡

1 はじめに

現在、様々な機械翻訳システムが考案され、実用化されているが翻訳の精度及び品質が十分とは言えない。そこで我々は主な手法である解析型ではなく、学習型の機械翻訳システムの精度の向上を目指すために、遺伝的アルゴリズムを用いた実例からの帰納的学習による機械翻訳手法 (GA-ILMT) の開発、研究を行なっている [1]。GA-ILMT の有効性は既に確認されているが、翻訳精度に問題が残されている。GA-ILMT では、既存の翻訳例を用いて遺伝的アルゴリズムの処理過程の一つである交叉を用いて多様な翻訳例を生成する。しかし、生成される翻訳ルールには大量の誤った翻訳例が含まれるため、これらの翻訳例から獲得される翻訳ルールにも大量の誤りが生じる。これが原因となり辞書中に誤った翻訳ルールが大量に存在するため、正翻訳結果の生成を妨げ GA-ILMT の翻訳精度に影響を及ぼすのである。

そこで、我々は、GA-ILMT に多段階類似性判定手法を適用し、類似性の判定を用いた翻訳例の交叉によってこの問題の解決を試みた。本稿では、類似性の判定のしきい値を変化させ、翻訳率を最大にする最適なしきい値について調査した評価実験の結果と最適なしきい値を用いた類似性の判定の有効性ついて述べる。

2 GA-ILMT について

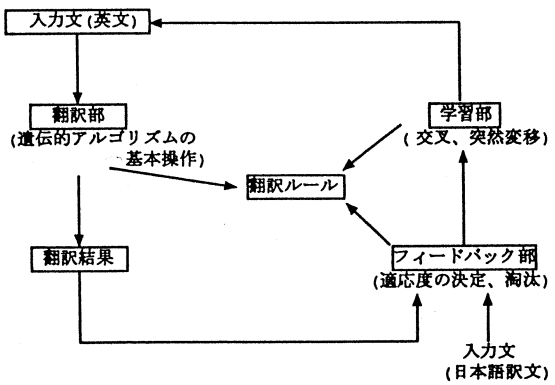


Fig. 1 GA-ILMT の処理過程

GA-ILMT の基本的な処理過程を Fig.1 に示す。() 内は、各処理部の遺伝的アルゴリズムの適用過程を示している。また、英文とその日本語訳文を組とした翻訳例を染色体に対応させる。翻訳例を構成する単語は遺伝子に対応させる。その対応を Fig.2 に示す。

*kudou@ai.eli.hokkai-s-u.ac.jp
†札幌市中央区南２６条西１１丁目北海学園大学大学工学部
‡札幌市北区北１３条西８丁目北海道大学工学部

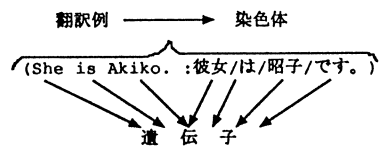


Fig. 2 染色体と遺伝子

また、英日機械翻訳を対象として GA-ILMT に基づくシステムを作成した。まず、原文として、英文を入力すると、翻訳部において、獲得されている翻訳ルールに対する遺伝的アルゴリズムの基本操作を用いて翻訳結果を生成する。次いで、フィードバック部において、ユーザーが与えた正しい日本語訳文を用い、翻訳部で用いられた翻訳ルールに対する適応度の決定と淘汰を行う。学習部において、与えらた翻訳例 (英文とその日本語訳文) に対して、多段階交叉位置決定手法 [2] を用いて交叉位置を決定し一点交叉を行い多様な新翻訳例を生成し、与えられた翻訳例及び生成された新翻訳例を用いて翻訳ルールを抽出する。多段階類似性判定手法は、翻訳例の類似度を計算し、翻訳例の交叉時に類似性の判定を行う。

3 多段階類似性判定手法について

3.1 概要

多段階類似性判定手法は、対象となる２つの文の単語の対応関係の個数及び対応関係の種類から類似度を決定し、２つの文の類似性を判定する手法である。類似度の計算の処理部では、原文同士の対応関係と訳文同士の対応関係を決定し、次いで原文同士の類似度と訳文同士の類似度をそれぞれ計算する。そして、翻訳例の交叉を行うときにこの類似度を用いて類似性の判定を行い、原文と訳文の類似度がしきい値以上であるときに交叉を実行する。

3.2 類似度の計算方法

類似度の計算では次のような対応関係を使用する。

(1) 出現位置が同じで字面が一致する単語の対応関係。
(2) 出現位置が異なり字面が一致する単語の対応関係。
(3) • 原文では、原形同じ単語の対応関係。
  • 訳文では、読みあるいは表記が一致する単語の対応関係。
(4) 同一の単語の訳語として存在する単語の対応関係。

(5) 上位概念が一致する単語の対応関係。
(6) 決定済みの対応関係に挟まれている一語の対応関係。
(7) 品詞の一致する単語の対応関係。

上位の段階で決定される対応関係は下位の段階では除外する。また、この処理部では (1) 式を用いて文同士の類似度を計算を行なう。類似度は決定された対応関係の各段階における個数で計算される。類似度は、原文と訳文のそれぞれについて計算される。

$$alpha = \frac{100.0}{\text{2つの翻訳例の原文又は訳文の単語の合計}}$$

$$\text{類似度} = alpha\times(2.0\times N_1 + 1.8\times N_2 + 1.6\times N_3 + 1.0\times N_4 + 0.8.\times N_5 + 0.4\times N_6 + 0.2\times N_7 - 0.5\times N_8) \quad (1)$$

N_n:n 段階における対応関係の数
N_8:対応関係がなかった単語数

4 評価実験

4.1 実験方法

実験には、中学校 1 年生用教科書ガイド・ワンワールド [3] に掲載されている英文と訳文の 797 組を使用した。実験では最初の 303 文を学習させ、残りの 494 文を学習させながら翻訳を行なった。また、類似度のしきい値を 25 点、40 点、50 点、55 点、60 点、70 点として実験を行い翻訳率の変化を調査する。

Table 1 評価実験の翻訳率の総計

しきい値	正翻訳（文）	誤翻訳（文）	正翻訳率%
25 点	162	332	32.8
40 点	180	314	36.4
50 点	186	308	37.7
55 点	189	305	38.2
60 点	186	308	37.7
70 点	185	309	37.4

(全翻訳文数 494 個)

4.2 実験結果

類似度の制限が 25,40,50,55,60,70 点の翻訳率がそれぞれ、32.8%,36.4%,37.7%,38.2%,37.7%,37.4%となった。Table.1 に実験結果を示す。

4.3 考察

類似性の判定のしきい値の変化による翻訳率の変化に注目するとしきい値が 55 点の時に翻訳率が最大になることが確認できる。55 点未満では類似性の低い翻訳例同士が交叉されることになるため、誤った翻訳例が 55 点の場合よりも多く生成され辞書中の翻訳ルールの精度が下がる。したがって、このときの翻訳率が 55 点より低くなると考えられる。また、しきい値を 55 点より増加させた場合では、翻訳例の生成の精度は向上するが正誤を含めた生成される翻訳例の数そのものが減少する。したがって、正しい翻訳結果を生成するために必要な辞書中の翻訳ルールが減少するため、翻訳率が 55 点のときよりも低くなる。しきい値が 55 点の場合では翻訳ルールの減少と翻訳結果の生成に必要な翻訳ルールの獲得とのバランスがとれているため翻訳率が最大になったと考えられる。ただし、今回の実験ではしきい値が 55 点のときに翻訳率が最大となったが、入力文の分野や構文が全体的に変化した場合、翻訳率を最大にするしきい値は変化すると考えられる。したがって、翻訳率を最大にするしきい値を自動的に決定するシステムが今後の課題となる。

5 おわりに

評価実験により多段階交叉位置決定手法を適用した GA-ILMT おいて類似性の判定のしきい値の変化により翻訳率が変化することが確認された。また、今回の評価実験に使用した入力文の翻訳において、類似性の判定の最適なしきい値は 55 点であることを確認した。翻訳率を最大にする類似性の判定の最適なしきい値を用いることにより本システムの性能を最大限に引き出すことが可能である。今後は類似性の判定におけるしきい値を自動的に決定するシステムについて研究を行う予定である。

謝辞

本研究の一部は文部省科学研究補助金（萌芽的研究第 9878070 号）の補助により行なわれた。

参考文献

[1] 越前谷博, 荒木健治, 桃内佳雄, 栃内香次：遺伝的アルゴリズムを用いた実例からの帰納的学習による機械翻訳手法における遺伝的アルゴリズムの適用とその有効性, 情報処理学会論文誌, Vol.2,No.8,pp.1565-1579 (1996).

[2] K.Kudo,.K.Araki.,Y.Mmouchi.,K.Tochinai.:Multi-Stage Decision Method for Production of New Translation Examples, Proceedings of the IASTED International Conference Artificial Intelligence and Soft Computing, pp.125-128 (1997).

[3] 教科書ガイド教育出版ワンワールド, 日本教材, 東京 (1991).