330 多段階交叉位置決定手法における交叉位置の制約の有効性について

工藤晃一 荒木健治 桃内佳雄 栃内香次
北学園大工 北大工

1 はじめに

近年，様々な機械翻訳手法が開発され，利用されている．我々は，言語獲得能力を計算機に与えることを目指し，学習型機械翻訳手法の研究を続けている．そして，帰納的学習能力を持った学習型機械翻訳手法に対して，遺伝的アルゴリズムを適用し，その有効性を確認した[1]．この学習型機械翻訳手法を遺伝的アルゴリズムを用いた実例からの帰納的学習による機械翻訳手法と呼び，本稿ではこの手法をGA-ILMTと表記する．

我々は，GA-ILMTの性能向上のため，多段階交叉位置決定手法[2]を提案した．本手法は，交叉対象となる２つの翻訳例の単語の対応関係を様々な知識を使って決め，類似度を計算し，交叉位置を決定する手法である．本手法により，多様な交叉位置の決定が可能となり，そして，類似度を用いて交叉を制約し，翻訳に最適な交叉を行うことが可能となった．更に，本手法では，原文と訳文の対応関係による交叉位置の制約を用いることにより，交叉位置の候補に対する確実な交叉位置の決定を可能にする．しかし，この原文と訳文の対応関係による交叉位置の制約を適用すると，交叉位置の数が減少するため，翻訳例の多様性が減少する．原文と訳文の対応関係による制約を適用しない時，生成される翻訳例の多様性が増加し，この制約がある時に翻訳不能であった入力文が翻訳可能になる場合もある．一方，翻訳ルールの増大による辞書の肥大化や，無効な翻訳ルールの増加による誤翻訳結果の生成数の増加も考えられる．

本稿では，類似度が制限されている環境で，交叉位置への制約の効果を確認するために行った評価実験より，交叉位置の制約の有効性について述べる．

2 GA-ILMT

GA-ILMTの基本的な処理過程を図１に示す．()内は，各処理部の遺伝的アルゴリズムの適用過程を示している．また，英日機械翻訳を対象としてGA-ILMTに基づくシステムを作成した．まず，原文を入力すると，翻訳部において，翻訳ルールに対する遺伝的アルゴリズムの基本操作を用いて翻訳結果を生成する．次いで，フィードバック部において，与えられた正しい訳文を用い，翻訳部で用いられた翻訳ルールへの適応度の決定と淘汰を行う．学習部では，与えらた翻訳例（英文とその日本語訳文）に対して，多段階交叉位置決定手法を用いて，翻訳例の類似度を計算し，類似性の判定と交叉位置の決定を行う．次いで，一点交叉を行って多様な新翻訳例を生成し，与えられた翻訳例及び生成された新翻訳例

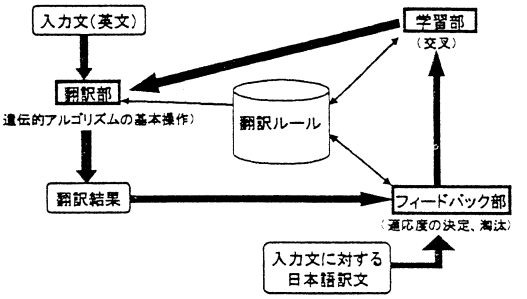


図１ GA-ILMTの処理過程

を用いて翻訳ルールを抽出する．

3 多段階交叉位置決定手法

3.1 処理概要

本手法は，対象となる２つの翻訳例の単語の対応関係を決定し，そして，その個数及び対応関係の種類から類似度を計算し，更に対応関係から交叉位置となる単語を決定する手法である．本手法の処理では，２つの翻訳例における原文同士及び訳文同士の対応関係を決定し，次いで原文同士の類似度と訳文同士の類似度をそれぞれ計算する．類似度がしきい値未満の時は，その翻訳例を処理対象から除外し，交叉を行わない．しきい値以上の時は，処理を続行し，対応関係から交叉位置の候補を決定する．原文と訳文の対応関係による交叉位置の制約を適用しない時は，全ての交叉位置の候補を交叉位置として，全ての組み合わせで交叉を行う．原文と訳文の対応関係による交叉位置の制約を適用する時は，原文と訳文の対応関係を決定し，この対応関係を持つ交叉位置の候補のみを交叉位置として交叉を行う．

3.2 原文同士及び訳文同士の対応関係の決定

原文同士及び訳文同士の対応関係の決定では，次のような対応関係を決定する．

(1) 出現位置が同じで字面が一致する単語の対応関係．
(2) 出現位置が異なり字面が一致する単語の対応関係．
(3) • 原文では，原形が一致する単語の対応関係．
    • 訳文では，読みあるいは表記が一致する単語の対応関係．
(4) 同一の単語の訳語として存在する単語の対応関係．
(5) 上位概念が一致する単語の対応関係．
(6) 決定済みの対応関係に挟まれている単語の対応関係．
(7) 品詞の一致する単語の対応関係．

表 1 評価実験の翻訳率の総計

原文と訳文の対応関係による制約	正翻訳（文）	誤翻訳（文）	正翻訳率%	総翻訳ルール数(個)
無	297	416	41.7	31,691
有	342	371	48.0	10,949

(全翻訳文数 713 個)

上位の段階で決定される対応関係は下位の段階では除外する．また，(1) 式を用いて翻訳例同士の類似度の計算をする．類似度は，対応関係の各段階の個数で計算され，そして，原文と訳文のそれぞれについて計算される．

$$\text{類似度} = \alpha\times(2.0\times N_1 + 1.8\times N_2 + 1.6\times N_3 + 1.0\times N_4 + 0.8.\times N_5 + 0.4\times N_6 + 0.2\times N_7 - 0.5\times N_8) \quad (1)$$

$$\alpha = \frac{100.0}{\text{2つの翻訳例の原文又は訳文の単語の合計}}$$

N_n:n 段階における対応関係の数 (n=1,2,3,...,7)
N_8:対応関係がなかった単語数

3.3 原文と訳文の対応関係の決定

原文と訳文の対応関係の決定では，英和辞書を使用して訳文の単語を検索し，次いで，対応する原文の単語を探し，対応関係を決定する．

4 評価実験

4.1 実験方法

実験には，中学校 1 年生用教科書ガイド・ワンワールド [3] に掲載されている英文と日本語訳文の 713 組を使用した．また，類似度のしきい値を予備実験 [4] より得られた 55 点として実験を行い，原文と訳文の対応関係による制約の有無における翻訳率を調査する．

4.2 実験結果

実験結果を表 1 に示す．原文と訳文の対応関係による制約がない場合の翻訳率は，41.7%であり，この制約がある場合の翻訳率は，48.0%となった．

5 考察

表 1 で示されるように原文と訳文の対応関係による制約がない時に獲得される翻訳ルール数は，制約がある時と比較すると 20,742 個増加している．この結果は，原文と訳文の対応関係による制約がない手法の方が，翻訳例の生成が多く行われ，そして，獲得される翻訳ルールが増加していることを示している．しかし，同時に生成される翻訳例の増加により，無効な翻訳ルールが増加することが考えられる．このため，原文と訳文の対応関係による制約がない時の翻訳では，無効な翻訳ルールの増加により，誤翻訳結果が多数生成され，正しい翻訳結果が翻訳候補の上位に入ることができない．そして，その翻訳は，誤った翻訳になると考えられる．このような原因により，実験結果のように原文と訳文の対応関係による制約を加えた手法の方が翻訳率は高い．しかし，原文と訳文の対応関係による制約がない時に翻訳可能となる場合も存在する．これは，制約により生成できなかった翻訳例が生成可能となるため，多様な翻訳ルールが獲得され，今まで翻訳できなかった入力文を翻訳することが可能になるからである．このようなことから，制約がない場合では，翻訳ルールの多様性が増加していることが確認できる．しかし，翻訳率は，原文と訳文の対応関係による交叉位置の制約の方が高いため，この制約が翻訳率の向上に必要であると考えられる．

6 おわりに

交叉位置の制約がない時の多様性の増加は，交叉位置を制約した場合に翻訳不可能であった入力文を翻訳可能にする．しかし，無効な翻訳ルールの増加による影響が大きく，翻訳率を下げるため，翻訳率の向上という点から考えると交叉位置の制約のほうが有効である．今後は，従来の一点交叉ではなく，二点交叉における多段階交叉位置決定手法の有効性について考察する予定である．

謝辞

なお，本研究の一部は文部省科学研究費 (No.09878070, No.10680367) 及び北海学園大学ハイテク・リサーチ・センター研究費による補助のもとに行われた．

参考文献

[1] 越前谷博, 荒木健治, 桃内佳雄, 栃内香次：遺伝的アルゴリズムを用いた実例からの帰納的学習による機械翻訳手法における遺伝的アルゴリズムの適用とその有効性, 情報処理学会論文誌, Vol.2,No.8,pp.1565-1579 (1996).

[2] K.Kudo,K.Araki,Y.Mmouchi,K.Tochinai:Multi-Stage Decision Method for Production of New Translation Examples, Proceedings of the IASTED International Conference Artificial Intelligence and Soft Computing, pp.125-128 (1997).

[3] 教科書ガイド教育出版ワンワールド, 日本教材, 東京 (1991).

[4] 工藤晃一, 荒木健治, 桃内佳雄, 栃内香次：多段階類似性判定手法におけるしきい値の最適化, 情報処理北海道シンポジウム '98 講演論文集, pp.67-68 (1998).