331 文字情報縮退方式を用いた帰納的学習による べた書き文のかな漢字変換手法の変換精度

松原雅文† 荒木健治† 桃内佳雄† 栃内香次‡
北学園大工† 北大工‡

1 はじめに

本手法は文字情報縮退方式 [1] で入力された数字べた書き文を漢字かな混じり文に変換するものである．文字情報縮退方式において，５０音のかな文字は0～9，*，#の１２個のキーそれぞれに複数対応している．そのため，入力に用いられるキーは１２個だけでよく，少数のキーしか装備していない小型の携帯端末などへの応用が考えられる．

本手法では，かな文字１文字の入力を１ストロークで行うことができ，軽快な入力が可能であり，入力ミスを最小限に抑えることができる．また，システムが帰納的学習により語を自動的に獲得するので初期辞書の作成は必要なく，使用者個人に合わせた辞書が自動的に生成される [2]．さらに，隣接文字情報と語の読みの文字数を学習することにより変換精度の向上を目指している．隣接文字情報は n-gram 統計 [3][4] により獲得され，これにより先行，後続文字列とのつながりを考慮した変換が可能となっている．語の読みの文字数は，入力数字べた書き文中の数字列の位置推測に利用され，より多くの語が獲得される．

本稿では本手法の概要及びその変換精度を確認するために行った評価実験結果について述べる．

2 概要

本手法の入力はすべて読みに対して行われる．そのため，ひらがな，カタカナ，ローマ字といった文字種を意識することなく入力を行うことが可能である．入力に用いる数字とかなの対応関係を表１に示す．

入力された数字べた書き文は，変換処理で，語情報辞書に登録されている語と隣接文字情報により漢字かな混じり文に変換される．変換結果に誤りがある場合，校正処理を行う．学習処理では校正済みの変換結果と数字べた書き文との比較から，語の表記と読みを多段階に抽出し語情報辞書に登録する．同時に数字べた書き文，校正済みの変換結果の隣接文字情報を抽出し，隣接文字情報辞書に登録する．フィードバック処理において，登録，正変換，誤変換された語はその情報を語情報辞書に持ち，隣接文字情報と一緒に次回からの変換に役立てられる．このように，変換処理，学習処理，フィードバック処理を繰り返し，使用者に合わせた辞書が生成され，次第に変換精度が向上していく．

表１ 数字とかなの対応関係

1:あいうえおー	2:かきくけこ	3:さしすせそ
4:たちつてと	5:なにぬねの	6:はひふへほ
7:まみむめも	8:やゆよゃゅょ	9:らりるれろ
*:（半）濁音	0:わをん	#:句読点

3 処理過程

本手法における処理過程は，変換処理，校正処理，学習処理，フィードバック処理の順である．これを図１に示す．

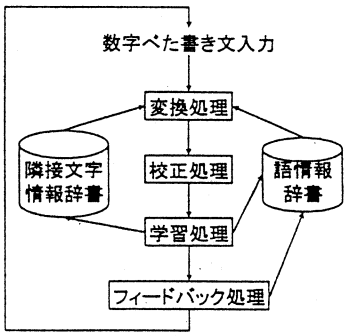


図１ 処理過程

3.1 変換処理

入力された数字べた書き文を漢字かな混じり文に変換する過程である．数字べた書き文に対して，階層化された語情報辞書に登録されている語を上位層より当てはめて変換を行う．変換候補は尤度評価関数により評価され，優先度を決定して最適な語を適用する．

3.2 校正処理

変換処理において変換結果に誤りがある場合，校正処理が行われる．人手により変換結果を訂正する過程である．

3.3 学習処理

語を獲得し，語情報辞書に登録する過程である．数字べた書き文と校正済みの変換結果との共通，差異部分を多段階に抽出することにより語の表記と読みを獲得する．この際，双方向解析を行うが，獲得できない語が存在した場合，位置推測処理により推測した位置

を基準として，同様に語を獲得する．またここで数字べた書き文と校正済み変換結果に含まれる全文字列のn-gram統計を抽出し，隣接文字情報辞書に登録する．

3.4 フィードバック処理

語を獲得する際に，その語の情報を一緒に獲得する過程である．獲得する情報は，正変換率(CR)，誤変換率(ER)である．また隣接文字情報辞書から対象となる語の先行，後続の隣接文字列存在確率(NR)を抽出する．これらを尤度評価関数に適用し，変換時に利用する．尤度評価関数(CEF)は次の通りである．

$$CEF = \alpha \times NR + \beta \times CR - \gamma \times ER$$

α, β, γ: 尤度評価係数

4 評価実験

4.1 実験方法

本手法の評価実験を行った．入力データとして，UNIXのオンラインマニュアルよりftpの項11,000文字とsedの項5,000文字の合わせて16,000文字を使用した．辞書は空の状態からftpの項に続けてsedの項の実験を行った．尤度評価係数α，β，γは予備実験により最適な値を求め，それぞれ１０，１，５とした．

4.2 評価方法

実験の評価は入力文字単位で行った．これは，誤って変換された語の中に，正しく変換された文字が含まれる可能性があるからである．正変換率，誤変換率，未変換率の定義は次の通りである．

$$\text{正変換率}(\%) = \frac{\text{正変換文字数}}{\text{入力文字数}}$$

$$\text{誤変換率}(\%) = \frac{\text{誤変換文字数}}{\text{入力文字数}}$$

$$\text{未変換率}(\%) = \frac{\text{未変換文字数}}{\text{入力文字数}}$$

4.3 実験結果

結果を図2に示す．初期正変換率24%から最大で80%までの向上が見られた．また，平均正変換率は前半のftpの項が59%，後半のsedの項が63%，全体で60%であった．

5 考察

前半のftpの項において，入力データの量に伴い正変換率は上昇し，最大で80%となった．これはシステムが学習により，対象に適応した結果である．すなわち対象の，語とそれに付随する情報を学習しているのが確認できる．次に後半のsedの項に移った直後，正変換率は55%に低下している．これは対象が変わり，

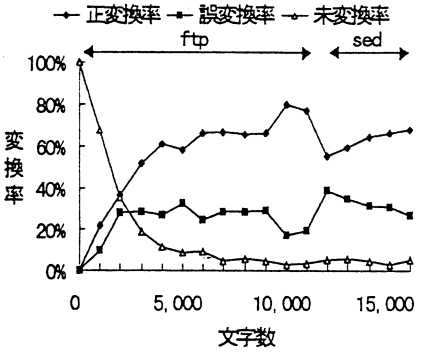


図2 変換率の推移

文中に出現する語がそれまでと異なったために，誤変換が多く行われたのが原因である．しかし，対象が変わっても，システムの適応能力により正変換率は徐々に上昇し，最終的に68%となった．

このようにかなよりも曖昧性の高い文字情報縮退方式の入力であっても，システムの学習能力により，次第に変換精度が向上するのが確認できた．

6 おわりに

本稿では，文字情報縮退方式の入力におけるかな漢字変換の精度について述べた．母音情報が縮退しているにも関わらず，帰納的学習による語の獲得に加え，それに付随する他の情報を学習することにより変換精度の向上が見られ，本手法の有効性が確認された．

今後は入力データを増やすとともに，対象が大きく変わるときの適応の度合いを調べる予定である．また，かな入力に本手法を適用した場合との変換精度の比較を行いたいと思う．

謝辞

なお，本研究の一部は文部省科学研究費(No. 09878070, No. 10680367)及び北海学園大学ハイテク・リサーチ・センター研究費による補助のもとに行われた．

参考文献

[1] 佐藤，東田，林，奥，村上：ＰＢ電話機を利用した日本語入力方式，電子情報通信学会総合大会，D-6-6(1997).

[2] 荒木，高橋，桃内，栃内：帰納的学習を用いたべた書き文のかな漢字変換，電子情報通信学会誌，Vol.J79-D-Ⅱ，No.3，pp.391-402.

[3] 長尾：自然言語処理，岩波書店(1996).

[4] 森，長尾：nグラム統計によるコーパスからの未知語抽出，情報処理学会論文誌，Vol.39，No.7，pp.2093-2100.