336　帰納的学習を用いた訳語推定手法における単語片対の抽出に対する制限

笹岡久行　荒木健治　桃内佳雄　栃内香次
北学園大工　　北大工

1. はじめに

近年、我々には母国語以外の言語を扱う機会が増えており、そのために機械翻訳に対する需要が高まりつつある。しかし、実際の機械翻訳システムには翻訳精度や翻訳結果の質等に問題がある。そこで、我々は機械翻訳システムにおける辞書未登録語の問題の解決をするため、帰納的学習を用いた訳語推定手法を提案し、４つの異なる分野から抽出した辞書未登録語での本手法の有効性を確認した [1]。しかし、この評価実験において、獲得される単位の数あるいは推定結果に対する優先順位決定方法等に問題が見出された。本研究においては、原言語と目標言語の文字列の組を単語片対と呼んでいる。訳語推定に必要となる単語片対だけを獲得するのは大変困難な問題である。従来の手法では、推定対象である単語と訳語の組と英和辞書の見出し語と訳語の組の間において単語片対の抽出を行った。今回提案する手法では、システムが単語片対を獲得する抽出元をヒューリスティクスを用いて選択するという立場で、英和辞書の見出し語と訳語の組の間からも単語片対の抽出を行う。本稿では、ヒューリスティクスによる制限を加えた上で、英和辞書の見出し語と訳語の間からも単語片対の抽出を行った訳語推定システムに対する評価実験の結果を述べる。

2. 基本的な考え方

従来の研究 [1] において、単語と文脈に適した訳語から抽出した単語片対は、訳語推定にとって有効に働いていることが考察されている。しかし、単語片対の抽出元を推定対象単語と文脈に適した訳語のみに限定すると再現率が低くなることも分かっている [2]。そこで、「２つの文字列は一致する文字列が多いほど類似している」というヒューリスティクスを基にして、英和辞書の見出し語とその訳語の組の集合から、システムが有効な単語片対を抽出する元となる文字列の組を選択する。そして、選択された文字列の組から単語片対を抽出する方法を考える。

また、正しい訳語推定処理に数多く利用された単語片対はより確からしく、逆に誤った訳語推定処理に数多く利用された単語片対は確からしくないものと見なしている [1]。しかし、この方法では獲得された多くの単位が訳語推定に使用されなかったり、使用されてもその回数が少ないために単語片対の単位の間に確からしさの差が生じ難く、その結果として訳語推定結果の優先順位決定方法が有効となっていなかったことがこれまでの評価実験において分かっている [1]。そこで、本研究では、「既出の用例を利用し，獲得した規則の確からしさを評価する」という基本的な考え方に基づいて単語片対の評価を行い、その評価を推定結果の優先順位の決定に利用する。

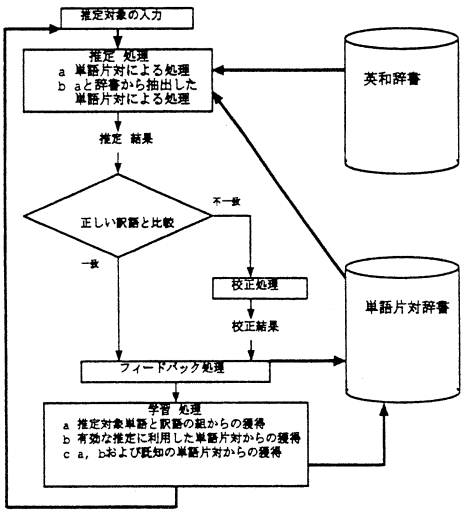


図 1: 実験システム

3. 処理過程

図 1に、実験システムの概要を示す。

システムでは、推定対象単語が入力されると獲得している単語片対を利用して訳語推定を試みる。もし、訳語推定処理が完了すれば、推定結果の正誤判定に処理を進める。また、処理が完了しない場合には、辞書の見出し語とその訳語の文字列の組から新たな単語片対を抽出し、その単位を利用して訳語推定処理を進める。また、訳語推定処理において複数の推定結果が現れた場合、各推定結果を構成している単語片対と既出の原言語と目標言語の文字列の組が部分的に一致する回数を計算し、その数値が大きいものを優先する。これにより優先順位がつけられない場合、各推定結果を構成している各単語片対の訳語推定処理における過去の利用状況を示す数値である正推定度数あるいは誤推定度数を参照し、推定結果の優先順位を決定する。その後、推定結果の正誤判定に処理を進める。もし、推定結果が正しかった場合、フィードバック処理に進み、推定結

果が誤っていた場合には、推定結果に校正処理を行い正しい推定結果とした後にフィードバック処理に進む。フィードバック処理では、推定結果を構成する各単位にその正誤判定結果に応じて、正推定度数あるいは誤推定度数を操作する。そして、推定対象となっている単語とその訳語の組、有効な訳語推定に利用した単語片対および有効な訳語推定に利用した単語片対の抽出元となった辞書の見出し語と訳語の組を単語片対辞書に追加する。そして、新たに追加された文字列の組とそれ以前に存在していた文字列の組の間から、さらに、新たな単語片対を抽出し、追加する。この処理において追加される単語片対は、既出の推定対象となった文字列とその訳語の文字列の組と部分一致するもののみとした。これは、原言語と目標言語の誤った対応を持つ単語片対の爆発的な増加を抑えるためである。また、文脈に出現した文字列のみに制限しなかったのは、その制限により訳語推定の再現率が低下するのを防ぐためである。

4. 評価実験

4.1 実験方法

本実験では、大学の工学部の講座名あるいはその講座で履修する科目に対する英語と日本語の表現100組を実験データとした。そして、単語片対を抽出するための英和辞書は "gene" [3] を利用した。評価基準は、正しい訳語と一致する推定結果が優先順位10以内に存在した場合を正推定と判定した。また、実験結果の再現率および適合率の定義式を以下に示す。

$$\text{再現率} = \frac{\text{推定を完了した個数}}{\text{推定対象単語数}} \times 100.0$$

$$\text{適合率} = \frac{\text{正推定の個数}}{\text{推定を完了した個数}} \times 100.0$$

上述したヒューリスティクスに基づいて、英和辞書から単語片対を抽出する際、推定対象単語と辞書の見出し語の間で一致する文字数が多い見出し語を優先し、単語片対を抽出した。今回の実験では、これに基づき上位500個および5000個の見出し語の間で単語片対の抽出を行った。

4.2 実験結果及び考察

表 1,2のような結果になった。両方の実験を比較すると、単語片対の抽出元となる辞書の見出し語と訳語の組の個数が増加したために、再現率に差が生じている。しかし、辞書の見出し語と訳語の組の個数が増え、推定処理に有効ではない単語片対も多く抽出されたために適合率の差を引き起こしていると考察される。

表 1: 辞書の見出し語と訳語 500 組から単語片対を抽出する場合の実験結果

推定対象単語数	再現率 (%)	適合率 (%)
20	30.0	16.7
40	20.0	75.0
60	25.0	40.0
80	50.0	50.0
100	20.0	50.0
計	29.0	44.8

表 2: 辞書の見出し語と訳語 5000 組から単語片対を抽出する場合の実験結果

推定対象単語数	再現率 (%)	適合率 (%)
20	35.0	14.3
40	20.0	75.0
60	25.0	40.0
80	50.0	30.0
100	30.0	33.3
計	32.0	34.4

5. おわりに

本稿では、ヒューリスティクスによる制限を加えた上で、英和辞書の見出し語と訳語の組の間から単語片対の抽出を行う訳語推定システムに対する評価実験の結果を述べた。本実験において、高い再現率および適合率は得られていない。そこで、実験結果に対する考察を更に進め、ヒューリスティクスによる制限に対する検討を行う予定である。

謝辞

本研究の一部は文部省科学研究費 (No. 09878070, No.10680367) および北海学園大学ハイテク・リサーチ・センター研究費による補助のもとに行われた。

参考文献

[1] Hisayuki Sasaoka, Kenji Araki, Yoshio Momouchi and Koji Tochinai, "Evaluation of Prediction Method of Target Words Using Inductive Learning", In *Proceedings of Artificial Intelligence and Soft Computing*, pp. 183 – 186, Cancun, Mexico, 1998.

[2] 笹岡久行, 荒木健治, 桃内佳雄, 栃内香次 : "帰納的学習による単語片対抽出を用いた未登録語の訳語推定", 1996 信学ソ大, D-53,Sep., 1996.

[3] 久保正治 : 英和・和英電索辞典 gene, 技術評論社,1995.