339 ユーザに動的に適応する多言語情報検索手法の提案

王忠建† 荒木健治†† 栃内香次†
†北海道大学大学院工学研究科 ††北海学園大学工学部

1 はじめに

近年、情報化社会の発展に伴い、電子化テキストデータの普及が著しく、大量の文書を必要に応じて容易かつ効率良く柔軟に検索できる文書検索技術の確立が必要である。しかし、このような大量の文書の検索に関する従来の研究 [1][2] は、検索対象が同一の言語である。そのため、最近インターネットの普及により必要となった、多言語を対象として十分な性能を発揮する検索システムはまだ開発されていない。そこで本稿では、ユーザに動的に適応する多言語情報検索手法を提案する。本手法では、ユーザに適応するために、検索語、検索類似度をフィードバックして、検索結果の精度向上を行なう。

2 処理の概要

本手法の処理過程を Fig.1 に示す。

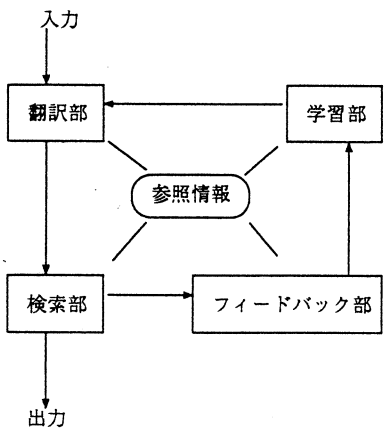


Fig. 1 処理の流れ

2.1 翻訳部

翻訳部では、入力語を日本語に翻訳して、フィードバックされた情報 (今までに検索した語がデータベースに出現する頻度情報、検索語と検索文書間の照合の検索類似度) を参照して訳語を決定し、検索類似度の閾値を参照する。フィードバックされた情報がない場合は、入力語の長さによって検索類似度の閾値を決定する。

2.2 検索部

検索部では、訳語を検索語として、フィードバックされた情報 (検索類似度) を参照してインデックスを用いた全文検索を行なう。同時に検索文字列の出現頻度を計算する。ここでインデックスはあらかじめデータベースに作成しておくものとする。

2.3 フィードバック部

フィードバック部では、正しい検索結果を選択して、検索正解率、検索質問をデータベースに、出現頻度を翻訳部にフィードバックする。検索正解率の計算は式 (1) になる [1]。

$$\text{検索正解率} = \frac{\text{検索された文書中の該当文書数}}{\text{検索された文書数}} \times 100\% \quad (1)$$

2.4 学習部

フィードバック部からの情報を用いて、動的に検索類似度を調節して検索過程を繰り返し、ユーザに適応するために最適な検索類似度と出現頻度を学習させる。これらを用いて検索結果を絞り、検索の精度を向上させる。

3 おわりに

本稿では、多言語テキストの情報を検索するという立場から、ユーザに動的に適応する多言語の情報検索手法を提案した。多言語を対象とした情報検索手法は大きな需要があると考えられる。今後は、本手法の有効性を確認するために性能評価実験を行なう予定である。

謝辞

本研究の一部は文部省科学研究費補助金 (課題番号 10680367) により行なわれた。

参考文献

[1] 長尾 真：自然言語処理、 岩波書店 (1996.4)
[2] 河瀬剛, 佐藤理史. 超並列計算機を用いた全文検索の高速化. 情報処理学会第 48 回全国大会論文集, 4E-03,1994.3.