340 決定木学習アルゴリズムを用いた多義語の訳語選択手法に対する性能評価

水野秀紀† 荒木健治†† 栃内香次†
†北海道大学大学院工学研究科 ††北海学園大学工学部

1 はじめに

機械翻訳システムの多義語の訳語選択に関して、近年様々な研究が行なわれている [1]。そして、その多くは格情報を用いている。しかし、格情報を用いるためには構文解析ツールを用いる必要があり、その結果には誤りが含まれる。そこで我々は、訳語選択を行ないたい語の周辺の語の格情報以外の情報を基に、事例から決定木学習アルゴリズム [2] を用いて決定木を構築し、それを基に多義語の訳語選択を行なう手法を提案した [3]。本稿では、本手法の性能評価について述べる。

2 システムの概要

本システムは、Fig. 1のように学習部、多義性判定部、フィードバック部から構成される。

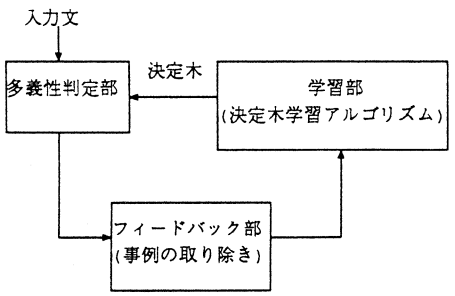


Fig. 1 システムの構成

2.1 学習部

本システムの学習部では、決定木学習アルゴリズム C4.5[2] を用いて訓練事例集合から決定木を作成する。但し、多義語の訳語選択を行なう語を含む文を構成する1単語を1事例とし、それぞれの事例がその事例の情報を表す属性と、訳語選択を行なう語の意味を表すクラスを持つ。

2.2 多義性判定部

多義性判定部では、学習部で作られた決定木を基に入力文の各単語を分類していく。その際、訓練事例に存在しない単語に関しては、シソーラスから同義語・上位語・下位語を抽出し、抽出した語で分類を行なう。そして、式 (1) の値が最も大きいクラスを最適解として選択する。

$$Y_i = \sum_{j=1}^{N} w_j X_{ij} \qquad (1)$$

X_{ij}は分類により求まったそれぞれの語のクラスiの確信度を表し、w_jはそれぞれの語のシソーラス上の距離に応じた重み係数を表す。また、Nはシステムに入力される単語数を表す。

2.3 フィードバック部

フィードバック部では、事例を適応的に構築するために事例の取り除き処理を行なう。取り除きの方法は、クラスの異なる同じ単語があった場合にその単語同士の距離 (多義語の訳語選択を行なう語からの文上の距離) の差を計算し、その逆数をその単語の取り除き指数に加えていく。そして、取り除き指数がある閾値を越えたらその単語は事例から取り除かれる。このことにより、クラスの異なる属性の同じ事例が取り除かれ、決定木の精度が向上すると考えられる。

3 評価実験

3.1 実験

実験は多義語の訳語選択を行なう語を take として、最初に事例の初期状態を空にしてからプログラム言語のマニュアル [4][5] 内の take を含む英文 107 文を入力文として上述したシステムを用いて行なった。

実験の結果、正解率は、属性値のグループ化を行なわなかった場合が 63.9% となり、行なった場合が 69.1% となった。

3.2 考察

実験結果より、属性値のグループ化を行なった方がより高い正解率が得られることが分かった。また、誤りの原因を分析すると sparseness によるものがほとんどであった。

4 おわりに

本稿では、格情報以外の情報を基に決定木アルゴリズムを用いて多義語の訳語選択を行なう手法に対しての性能評価について述べ、本手法が有効である可能性を示すことができた。今後は、3.2節で示した sparseness の問題を解決するために改良を加えていく予定である。

謝辞

本研究の一部は文部省科学研究費補助金 (課題番号 10680367) により行なわれた。

参考文献

[1] 藤井 敦, 乾 健太郎, 徳永 健伸, 田中 穂積: 動詞多義性解消における格要素の貢献度について, 情報処理学会研究報告, 96-NL-111, pp.55-62 (1996-1).

[2] Quinlan, J.R.: *C4.5: Programs for Machine Learning*, Morgan Kaufmann (1993).

[3] 水野 秀紀, 荒木 健治, 宮永 喜一, 栃内 香次: 決定木学習アルゴリズムを用いた多義語の訳語選択手法, 情報処理学会第 56 回全国大会講演論文集 (2), 6Q-9, pp.283-284 (1998-3).

[4] Brian W. Kernighan and Dennis M. Ritchie: The C programming language. Second Edition, Prentice-Hall (1988).

[5] Alfred V. Aho, Brian W. Kernighan and Peter J. Weinberger: The AWK programming language, Addison-Wesley Pub. Co. (1988).