帰納的学習による数字漢字変換手法の性能評価

松原雅文*・荒木健治**・桃内佳雄*・栃内香次**

Performance Evaluation for Number-Kanji Translation Method Using Inductive Learning

Masafumi MATSUHARA*, Kenji ARAKI**, Yoshio MOMOUCHI* and Koji TOCHINAI**

本手法は，文字情報縮退方式で入力された数字列を漢字かな混じり文に変換するものである。文字情報縮退方式において，0～9，*，#の12個それぞれの文字には複数のかなが割り当てられており，読みがな1文字の入力を1ストロークで行うことが出来る。さらに入力された数字列と校正済みの変換結果から帰納的学習により語を獲得するので，辞書が空の状態からでも対象分野に適応した辞書が自動生成される。文脈に適合した語が獲得されるので汎用性を失うことはない。母音情報縮退により失われた情報を，帰納的学習による適応能力に加え，隣接文字情報と位置推測処理により回復している。

1．はじめに

近年，携帯端末は小型，高性能，低価格化が進んでおり，その普及率が急速に伸びている。携帯性を重視して，ポケットに入るほど小型の端末もあり，中には，インターネットへのアクセスを意識し，携帯電話と一体となっているものもある［1］。電子メールの利用者数の増大もあり，このような小型の携帯端末から日本語を入力する機会が増え，また，迅速に入力したいというような要望も強まっている。しかし，このような端末はその大きさに制約があるため，日本語入力に一般的に用いられているローマ字入力を実現できるほどの多数のキー数を確保す

＊北海学園大学大学院工学研究科電子情報工学専攻
＊＊北海道大学大学院工学研究科電子情報工学専攻
＊ Division of Electronics and Information Engineering, Graduate School of Engineering, Hokkai-Gakuen University
＊＊ Division of Electronics and Information Engineering, Graduate School of Engineering, Hokkaidou University

ることができない。入力に用いられるキーは，0から9までの数字に＊，#を合わせた12個のキーであることが多い。これらのキーによる入力方式の中には，携帯電話でのデータの入力に見られる「文字循環指定方式」があるが，1文字の入力に複数回の手数を必要とし，迅速な入力は困難となっている。このようなことから，小型の携帯端末に搭載可能な少数のキーのみを用いて，日本語の入力を迅速に行える手法が望まれる。

そこで我々は「帰納的学習による数字漢字変換手法」[2] [3]を提案している。0～9，＊，#の12個のキーに50音のかな文字を表1のように対応させ，あ行を1，か行を2，...のように「文字情報縮退方式」[4]で数字列として入力し，その数字列を漢字かな混じり文に変換する手法である。かなの文字列を入力し，漢字かな混じり文に変換する「かな漢字変換」に対し，入力が数字列である本手法の変換を「数字漢字変換」と呼ぶ。

表1：数字とかなの対応関係

1：あいうえおー	2：かきくけこ	3：さしすせそ
4：たちつてとっ	5：なにぬねの	6：はひふへほ
7：まみむめも	8：やゆよゃゅょ	9：らりるれろ
＊：（半）濁点	0：わをん	#：句読点

文字情報縮退方式を用いることにより，1文字の入力を1ストロークで行うことができるので入力回数が少なくてすみ，迅速な入力が可能である。また，システムが帰納的学習により語を自動的に獲得するので，初期辞書の設定は必要なく，対象に合わせた辞書が自動生成される[5] [6]。文脈に依存した語を獲得することができるので，動的に対象に適応することができ，汎用性は失われない。実行例を図1に示す。

文字情報縮退方式による入力は，かなの母音情報が縮退した数字列である。そのため数字漢字変換の際に，この失われた情報をいかにして復元するかが重要となる。これに対し，本手法においては，隣接文字列情報と位置推測処理を利用することとした[2] [3]。位置推測処理により，語の獲得時に，情報縮退により発生する曖昧さを極力解消している。隣接文字列情報はn-gram統計[7] [8]により抽出されるが，これにより変換時に語単体の尤度のみならず，隣接する文字列とのつながりを考慮に入れた変換が可能となっている。

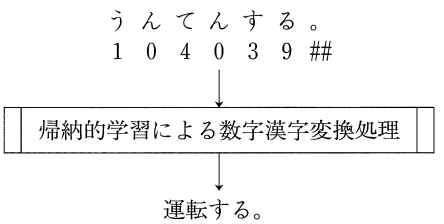


図1：実行例

本報告では，帰納的学習による数字漢字変換手法の有効性について，評価実験に基づき述べる。

2．処理概要

本手法の処理過程を図2に示す。

本手法においてユーザは12個のキーによる文字情報縮退方式を用いて，べた書きの数字列で日本語入力を行う。入力された数字列は，変換処理で語情報辞書と隣接文字列情報辞書を用いて漢字かな混じり文に変換される。変換候補が重複した場合，正変換率，誤変換率，隣接文字列情報を利用して，最適な語を決定する。変換が正しく行われなかった場合，校正処理を行う。人手により変換結果を訂正する処理である。学習処理では，校正済み変換結果と数字列との比較から，語を抽出して辞書に登録する。同時に全文字列を隣接文字列情報辞書に登録する。この情報により，隣接する文字列を考慮した変換が可能となっている。フィードバック処理では，正変換，誤変換された語はその情報を語情報辞書に持ち，次回からの変換に役立てられる。このように，変換処理，学習処理，フィードバック処理を繰り返し，変換精度が向上するのと同時に，ユーザに合わせた辞書が生成されていく。

以上のようなシステムにより，評価実験を行った。

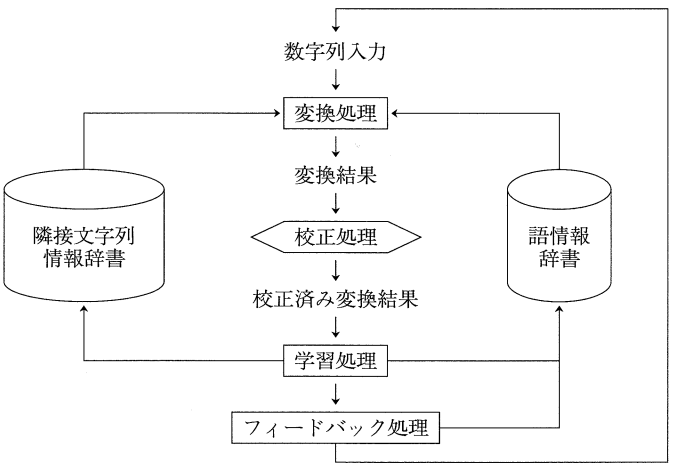


図2：処理過程

3．評価実験

対象への適応能力を調べるために，UNIXのオンラインマニュアルを入力データとして実験を行った。使用した項目は，ftp,mail,cc,csh,ld,ed,dbxで，合計100,000文字である。実験データを表2に示す。このデータは，それぞれのコマンドの項目において使用される語に多少の違

いはあるものの出現する語は限られており，限られた対象と言える。出現する文字種は950種類であり，1文字あたりのエントロピーは，8.0[bit]であった。実験は辞書が空の状態から順に行っており，1文単位で変換し，1,000文字単位で評価を行った。

実験の評価に用いた正変換率，誤変換率，未変換率を式(1)，(2)，(3)に示す。

$$\text{正変換率}=\frac{\text{正変換文字数}}{\text{入力文字数}} \quad (1)$$

$$\text{誤変換率}=\frac{\text{誤変換文字数}}{\text{入力文字数}} \quad (2)$$

$$\text{未変換率}=\frac{\text{未変換文字数}}{\text{入力文字数}} \quad (3)$$

表2：実験データ

項目名	文字数
ftp	11,000
mail	15,000
cc	8,000
csh	29,000
ld	12,000
ed	15,000
dbx	10,000
合計	100,000

尤度評価係数の最適値を決定するため，予備実験を行った。実験に用いたデータは，ftpの項目の10,000文字である。$\beta=1$，$\gamma=5$としてαの値を変化させて実験を行った。αの値に対する正変換率を表3に示す。実験結果から尤度評価係数は以下の値を用いた。

$\alpha=10$，$\beta=1$，$\gamma=5$

表3：予備実験結果

α / 文字数	正変換率						
	1	2	5	10	20	30	50
1,000	24.1%	24.1%	24.3%	24.6%	24.2%	24.2%	24.2%
2,000	38.7%	39.2%	39.5%	41.9%	45.0%	44.5%	42.8%
3,000	50.7%	50.7%	52.0%	53.3%	53.0%	52.5%	52.5%
4,000	59.8%	60.0%	61.0%	62.1%	62.1%	63.5%	61.9%
5,000	56.8%	55.5%	57.2%	58.6%	55.5%	55.0%	55.2%
6,000	70.1%	70.8%	72.0%	73.1%	72.5%	72.0%	72.1%
7,000	63.9%	63.9%	64.0%	64.0%	61.5%	61.5%	62.0%
8,000	68.8%	69.0%	69.0%	70.1%	68.9%	69.0%	69.8%
9,000	63.9%	64.5%	65.2%	66.7%	66.6%	66.6%	66.1%
10,000	74.9%	73.0%	74.9%	75.5%	71.3%	70.5%	72.1%
平均	52.0%	51.9%	52.6%	53.6%	52.8%	52.7%	52.6%

3．1　実験結果

入力文字数に対する変換率，獲得語数を表4に，変換率の推移を図3に，獲得語数の推移を図4に示す。登録語数はその時点で辞書に登録された総語数を表している。項目の変わり目において，正変換率は多少下降しているが，全体として入力文字数の増加に伴い，正変換率が徐々に上昇し最終的に80[%]付近までの上昇が確認された。全体の平均正変換率は70.2[%]で

表 4 ：入力文字に対する変換率，獲得語数

	文字数	正変換率	誤変換率	未変換率	獲得語率
(ftp)	1,000	24.6%	7.7%	67.7%	127
	2,000	41.9%	22.3%	35.8%	95
	3,000	53.3%	20.3%	26.4%	74
	4,000	62.1%	23.1%	14.8%	53
	5,000	58.6%	29.5%	11.9%	60
	6,000	73.1%	18.7%	8.2%	26
	7,000	64.0%	28.6%	7.4%	58
	8,000	70.1%	22.5%	7.4%	38
	9,000	66.7%	27.0%	6.3%	31
	10,000	75.5%	20.6%	3.9%	23
	11,000	78.2%	18.2%	3.6%	25
(mail)	12,000	64.0%	31.1%	4.9%	48
	13,000	68.7%	24.5%	6.8%	39
	14,000	63.5%	30.4%	6.1%	31
	15,000	72.3%	24.1%	3.6%	25
	16,000	76.3%	21.0%	2.7%	25
	17,000	76.3%	22.1%	1.6%	18
	18,000	81.7%	16.2%	2.1%	10
	19,000	80.0%	17.6%	2.4%	19
	20,000	75.4%	20.3%	4.3%	14
	21,000	81.5%	15.4%	3.1%	12
	22,000	73.6%	23.5%	2.9%	22
	23,000	75.2%	20.0%	4.8%	17
	24,000	72.2%	22.0%	5.8%	17
	25,000	76.5%	18.5%	5.0%	17
	26,000	74.3%	20.8%	4.9%	20
(cc)	27,000	54.2%	37.5%	8.3%	34
	28,000	57.3%	37.1%	5.6%	38
	29,000	66.2%	30.5%	3.3%	24
	30,000	62.1%	34.6%	3.3%	37
	31,000	58.7%	37.8%	3.5%	36
	32,000	66.0%	28.0%	6.0%	27
	33,000	75.5%	22.8%	1.7%	14
	34,000	67.8%	31.4%	0.8%	23
(csh)	35,000	60.0%	38.7%	1.3%	36
	36,000	63.7%	33.1%	3.2%	31
	37,000	72.9%	23.8%	3.3%	23
	38,000	65.0%	32.2%	2.8%	28
	39,000	66.1%	32.8%	1.1%	27
	40,000	70.9%	27.7%	1.4%	17
	41,000	65.2%	31.9%	2.9%	16
	42,000	70.3%	27.1%	2.6%	11
	43,000	74.3%	23.2%	2.5%	23
	44,000	73.9%	25.9%	0.2%	8
	45,000	71.4%	27.5%	1.1%	15
	46,000	75.8%	23.2%	1.0%	17
	47,000	61.9%	34.7%	3.4%	30
	48,000	58.8%	37.1%	4.1%	29
	49,000	80.4%	17.9%	1.7%	21
	50,000	71.2%	27.8%	1.0%	6
	51,000	72.3%	26.4%	1.3%	19
	52,000	75.5%	23.3%	1.2%	10
	53,000	72.2%	26.3%	1.5%	22
	54,000	67.4%	28.8%	3.8%	26
	55,000	63.4%	36.0%	0.6%	11

	文字数	正変換率	誤変換率	未変換率	獲得語率
	56,000	72.7%	26.4%	0.9%	14
	57,000	69.4%	28.0%	2.6%	11
	58,000	71.8%	27.3%	0.9%	20
	59,000	63.7%	35.2%	1.1%	14
	60,000	87.4%	11.8%	0.8%	12
	61,000	59.5%	38.2%	2.3%	24
	62,000	67.3%	30.5%	2.2%	20
	63,000	67.4%	30.6%	2.0%	25
(ld)	64,000	66.2%	32.2%	1.6%	13
	65,000	66.2%	32.4%	1.4%	12
	66,000	71.8%	27.4%	0.8%	14
	67,000	72.6%	25.6%	1.8%	3
	68,000	74.8%	24.1%	1.1%	9
	69,000	76.3%	23.1%	0.6%	14
	70,000	67.9%	29.3%	2.8%	13
	71,000	74.7%	24.7%	0.6%	2
	72,000	72.5%	27.0%	0.5%	14
	73,000	74.5%	24.8%	0.7%	18
	74,000	67.1%	32.9%	0.0%	14
	75,000	74.5%	24.3%	1.2%	9
(ed)	76,000	69.9%	29.2%	0.9%	15
	77,000	67.1%	31.3%	1.6%	12
	78,000	65.8%	32.7%	1.5%	7
	79,000	67.9%	31.2%	0.9%	15
	80,000	75.8%	23.6%	0.6%	7
	81,000	66.7%	32.2%	1.1%	3
	82,000	79.3%	20.1%	0.6%	5
	83,000	70.3%	28.9%	0.8%	10
	84,000	77.1%	22.1%	0.8%	0
	85,000	79.2%	18.7%	2.1%	0
	86,000	81.6%	18.1%	0.3%	4
	87,000	76.8%	21.7%	1.5%	14
	88,000	82.3%	16.4%	1.3%	14
	89,000	73.8%	24.3%	1.9%	23
	90,000	75.7%	23.9%	0.4%	19
(dbx)	91,000	73.3%	25.2%	1.5%	12
	92,000	72.1%	27.5%	0.4%	15
	93,000	68.2%	30.8%	1.0%	4
	94,000	76.7%	20.8%	2.5%	9
	95,000	80.0%	19.4%	0.6%	15
	96,000	81.0%	17.9%	1.1%	16
	97,000	85.1%	14.9%	0.0%	11
	98,000	74.8%	24.5%	0.7%	14
	99,000	69.2%	26.9%	1.2%	25
	100,000	69.0%	30.4%	0.6%	6

	平均			登録語数
ftp	60.7%	21.7%	17.6%	610
mail	74.1%	21.8%	4.1%	334
cc	63.5%	32.5%	4.1%	233
csh	69.4%	28.7%	1.9%	566
ld	71.6%	27.3%	1.1%	135
ed	74.0%	25.0%	1.1%	148
dbx	74.9%	24.1%	1.0%	127
合 計	70.2%	26.0%	3.8%	2,153

あった。正変換率がもっとも高かったデータは項目 csh の 59,000～60,000 文字であった。

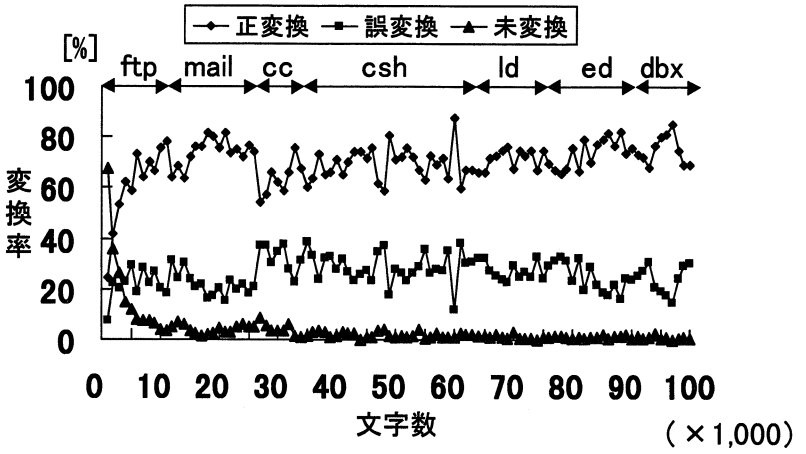


図 3 ：変換率の推移

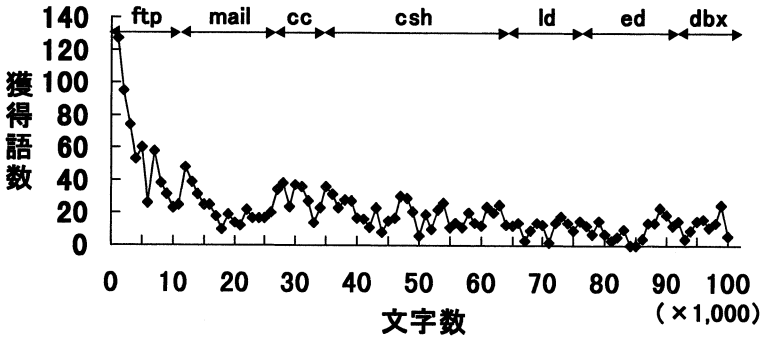


図 4 ：獲得語数の推移

3．1．1　正変換率が高かったデータ

項目 csh の 59,000～60,000 文字中のデータを示す。下線部分は誤変換を表している。

《入力数字列》

3441394196＊11#31964074073373##

296742＊14581982343190381981334371220063 2＊2514＊3##

3192＊7190414239611959344＊3##

5531385014＊2＊313＊4＊196＊11#29671904142392022 06＊814014＊341373##

319541341171561195020243981581281346＊1156＊3＊10593730##

23＊0561190187446213518 15#384982594＊19240312＊0373##

94＊192422＊16302561194＊253814＊273##

94＊192422＊1623＊0561194＊20413814373##

6119554200203373##

3193296＊45114#611952＊303＊1396＊112913＊8140213516＊1156＊094＊3##

6＊4102＊144341516＊115#1914＊6526119554206＊410021373##

6＊410521322＊44＊3251419155973##

3441394#3＊86＊2＊38198139444＊453192＊39373##

6＊906＊404＊34823＊074＊7424619730##

2704＊5314413814594＊1924959344＊3##

《変換結果》

設定されたあれば大，シェルは端末を無視します。

これはも次後にやいる予期したシェルを終了サしたサマーク関を防がこの完結機能です。

シェルがメールをチェックするファイルのリストです。

にな最初のワードがさ完結機能自動る場合，これはメールをチェックするかをきコンピュータワード指定します。

シェルのとい指定い前のファイルにを完結するようの要求した場合のブザーをなりさません。

既存のファイルを親最破壊しないように，出力のリダイレクトを制限をします。

リダイレクト記号は新規のファイルだけに使用できます。

リダイレクト記号は既存のファイルだけを通使用他します。

ファイル名置換を禁止します。

シェルスクリプトにおいて，ファイルのが存在する場合クリア時用展開しない場合の便利です。

パターンが一致していない場合の，エラーではなくファイル名置換パターンを返します。

パターンの形式ごとでしくない他エラーになります。

設定された，ジョブが終了されたただちにシェルがされします。

プロンプトをです直前もでも近他はありません。

コマンド偽一致い使用つのリダイレクトりのリストです。

《校正済み変換結果》

設定されている場合，シェルは端末を無視します。

これは間違えて入力してシェルを終了させてしまう危険を防ぐ機能です。
シェルがメールをチェックするファイルのリストです。
値の最初のワードが数字である場合，これはメールをチェックする間隔を秒単位で指定します。
シェルに対してあいまいなファイル名を完結するように要求した場合にブザーを鳴らしません。
既存のファイルを誤って破壊しないように，出力のリダイレクトを制限します。
リダイレクト記号は新規のファイルだけに使用できます。
リダイレクト記号は既存のファイルだけを対象とします。
ファイル名の置換を禁止します。
シェルスクリプトにおいて，ファイル名が存在する場合これ以上展開しない場合に便利です。
パターンが一致していない場合に，エラーではなくファイル名の置換パターンを返します。
パターンの形式が正しくないとエラーになります。
設定すると，ジョブが終了すると直ちにシェルが知らせます。
プロンプトを出す直前まで待つことはありません。
コマンドのサーチ対象となるディレクトリのリストです。

3．1．2　正変換率が低かったデータ

項目 csh の 47,000～48,000 文字中のデータを示す。下線部分は誤変換を表し，点線部分は未変換を表している。

《入力数字列》
324103＊03
3131954315272727 04＊6320124273##
25525103＊036314913＊3419#81303＊80174＊1814＊3##
2995326413＊81#2704＊55251909#2704＊03＊42139114＊312＊8552＊90312＊83955823813973##
325213181366014 36＊134＊22＊973##
3974655517563＊9475373##
36＊453252426143＊933723＊58973＊944＊3##
42＊5313195103＊03081303＊80154213＊80537373##
2＊916＊2
145631
90942641

3＊813＊0#3＊83＊0#3＊818299672＊2＊065242＊13107441947#82351242459242＊1973##
2710352＊916＊26#472425844713＊425125173##
230#2＊03＊029772＊2＊065242＊13107473##
6＊44564＊9364186＊72＊364

《変換結果》
式と演算さ
最シェルの多数中未かもコマンドは式を以下ときます。
こののこの演算さは最取る維持指定れ，要素を順有無同様です。
これらの式は通常，コマンドの中にあるわれ，コマンドを実行する上で制御の長れを制御するのに役参照されます。
式の構成要素は範囲とスペースで区切れます。
するまたはののないみには 0 ともにします。
すべての式中ときは一時らせ示数により文字列です。
次の際シェルの演算さを優先順位の的い順のします無視。
2＊ 9 えば替
1 には正
りわれた替はとい
じユーザを，3＊83＊ 0，じ要約られはみが側はのことが 13 オン間っている 47，役しない結果となりことがいれます。
替もあをしなグループきは，ため結果によって明示的の行います。
下線，群3＊ 0 から目右側へのことが 13 合目丸さ。
ビットにはでらせはとおよびみがさはと

《校正済み変換結果》
式と演算子
Cシェルの多数の組み込みコマンドは式を受け付けます。
この中の演算子はCと類似しており，優先順位も同様です。
これらの式は通常，コマンドの中に現れ，コマンドを実行する上で制御の流れを制御するのによく使用されます。
式の構成要素はホワイトスペースで区切ります。
空または値のないものは 0 とみなします。
すべての式の結果は 10 進数による文字列です。

次にCシェルの演算子を優先順位の高い順に示します。

グループ化

1の補数

論理的否定

乗算，除算，剰余これらは右側への結合性を持っているため，予期しない結果となることがあります。

組み合せのグループ化は，丸かっこによって明示的に行います。

加算，減算これも右側への結合性を持ちます。

ビットの左シフトおよび右シフト

3．2　評価実験の考察

図3，表4から分かるように，入力文字数の増加に伴い，次第に正変換率が上昇している。最大正変換率は87.4［%］であった。これは辞書が空の状態からでも本手法の学習機能により対象に適応できることを示している。3．1．1に示されるデータにおいて，1行目の「いる場合」は，変換結果では誤って「あれば大」となっている。これは，「196＊11」の変換候補として（196＊：あれば）（6＊11：場合）が「6＊」で重複し，「あれば」が優先された結果である。しかし，この誤りを学習し，同様に変換候補の重複が起こる4行目において，「場合」が優先され正しく変換されているのが分かる。その後も「場合」は正しく変換され，本手法の学習能力による適応が確認できる。

また，3．1．2に示されるデータのように，変換精度の低いデータが存在する。主な原因は，辞書に未登録の語が出現するからであり，このようなデータでは，図4，表4から分かるように獲得する語数が増大している。3．1．2のデータは，cshの文脈から外れた「式と演算子」の説明であり，「補数」や「論理」といった語が出現している。このように，新出語が多数出現すると，誤変換率が増加する。数字漢字変換においては，数字列の持つ曖昧さから未変換よりも誤変換される割合が高くなため，未変換文字数は少なくなっている。

4．おわりに

本報告では，少数のキーで迅速な日本語入力を可能にする「帰納的学習による数字漢字変換手法」の性能評価実験を行い，その結果について考察を行った。かなの情報が縮退した数字列を入力に用いるため，数字漢字変換の際に，縮退した情報をいかにして回復するかが重要となるが，帰納的学習による高い適応能力に加え，隣接文字列情報，位置推測処理を利用することにより，評価実験結果に示されるように高い変換精度を実現できることを確認した。本手法においては，動的に対象に適応することができるので，汎用性を失うことはない。最終的に80［%］

以上の正変換率が得られ，本手法の有効性が確認された。今後は，さらに多くの他の分野に対する適応能力の調査を行う予定である。

謝辞 なお，本研究の一部は文部省科学研究費(No. 09878070, No. 10680367)及び北海学園大学ハイテク・リサーチ・センター研究費による補助のもとに行われた。

参 考 文 献

[1] PCが握るモバイル活用の鍵，日経バイト5月号，日経BP社，pp. 142－165(1998).

[2] 松原雅文，荒木健治，桃内佳雄，栃内香次：文字情報縮退方式を用いた帰納的学習によるべた書き文のかな漢字変換手法，情処第57回全国大会講演論文集（2），1R-1，pp. 197－198(1998).

[3] 松原雅文，荒木健治，桃内佳雄，栃内香次：文字情報縮退方式を用いた帰納的学習によるべた書き文のかな漢字変換手法の性能評価，情処自然言語処理研究報告，98－NL-128，128－1，pp. 1－7 (1998).

[4] 佐藤亨，東田正信，林智定，奥雅博，村上仁一：PB電話機を利用した日本語入力方式，電子情報通信学会総合大会，D-6-6，pp. 102(1997).

[5] 荒木健治，高橋祐治，桃内佳雄，栃内香次：帰納的学習を用いたべた書き文のかな漢字変換，電子情報通信学会誌，Vol. J 79-D-II，No. 3，pp. 391－402(1996).

[6] Kenji Araki, Yoshio Momouchi and Koji Tochinai : Evaluation for adaptability of Kana-Kanji translation of non-segmented Japanese Kana sentences using inductive learning, In Proceedings of the PACLING-II, Australia, pp.1－7(1995)

[7] 長尾眞：自然言語処理，岩波書店(1996).

[8] 森信介，長尾眞：nグラム統計によるコーパスからの未知語抽出，情報処理学会論文誌，Vol. 39, No. 7, pp. 2093－2100(1998).