社団法人　電子情報通信学会
THE INSTITUTE OF ELECTRONICS,
INFORMATION AND COMMUNICATION ENGINEERS

信学技報
TECHNICAL REPORT OF IEICE.
SS 99-14 (1999-7)

学習に基づく自然言語処理

荒木 健治
北海道大学大学院工学研究科

〒 060-8628 札幌市北区北１３条西８丁目
E-mail : araki@media.eng.hokudai.ac.jp

あらまし

本稿では初めに自然言語処理の概要と未知語や規則の制御の問題点及びそれらの問題点を解決するために開発された学習に基づくアプローチについて述べる．さらに，学習に基づくアプローチの一つの例である帰納的学習を用いた自然言語解析手法の目的，基本原理及び応用について述べる．また，対話処理について，意味理解を行わない対話処理システムの例として ELIZA を取り上げ，その問題点と可能性について述べる．最後に，曖昧さの多い自然言語処理に対して開発された手法を曖昧さが少なく制約の多いプログラミング言語へ適用することの可能性について述べる．
キーワード　自然言語処理，学習，帰納的学習，機械翻訳，対話処理

Learning-Based Natural Language Processing

Kenji ARAKI
Graduate School of Engineering, Hokkaido University

N13-W8, Kita-ku, Sapporo 060-8628, JAPAN
E-mail : araki@media.eng.hokudai.ac.jp

Abstract

We describe the outline of Natural Language Processing, its problems and the learning-based approach in order to solve them. Moreover, we explain the purpose, the basic theory and the applications of the natural language analysis methods using the inductive learning which is the example of the learning-based approach. And we describe the problem and possibility of the system that does not understand the meanings of sentences in the dialogue processing. At the last, we describe the possibility that we apply the learning-based approach for the natural language which has a lot of ambiguity, to the programming language which has little ambiguity and a lot of constraint.
key words　natural language processing, learning, inductive learning, machine translation, dialogue processing

1 はじめに

近年インターネットの普及に代表される国際化及び高度情報化社会の進展に伴い，自然言語を取り巻く環境が劇的に変動して来ている．母国語以外の言語との遭遇の機会の増大や電子化された文書のまさに驚くべき増大は，数年前には想像することもできなかったほどである．このような状況から人間の最も重要なコミュニケーションの手段である自然言語を計算機で様々な角度から高度に利用し，人間の仕事を代行させようとする試みは緊急の課題となっている．そこで，本稿ではまず最初にこれまで行われてきた自然言語処理の概要とその問題点について述べ，次にその問題点を解決するためになぜ学習に基づくアプローチが必要となったのかについて述べる．次いで，学習に基づくアプローチの一つの例として，私がこれまで行ってきた研究について，その目的，基本原理及び応用について述べる．さらに，今後自然言語処理の研究において主要なテーマとなる対話処理について，これまでの研究の概要と今後の研究の方向について述べる．最後に，このような曖昧さの多い自然言語処理に対して開発された手法を曖昧さが少なく制約の多いプログラミング言語へ適用することの可能性について簡単に述べる．

2 自然言語処理の概要と課題

2.1 不完全情報の処理

自然言語処理の研究は，これまでいかにして曖昧さを解消して計算機上で処理するかに腐心してきたと言っても過言ではない．本来，文の持つ情報は不完全情報であるので，本来自然言語処理は不完全情報を対象として行われる必要がある．しかし，実際には自然言語処理の研究の初期の頃には，曖昧さのない状況を仮定して研究を進めることが多かった．WinogradのSHRDLU[Winograd 72]がその典型であった．SHRDLUでは，積み木の世界という非常に限られた世界を対象とし，言語理解の必要な様々な知識を厳密に与えることにより言語理解の仕組みを実現した．しかし，このSHRDLUでは言語の持つ曖昧さに対しては何の解決も行っておらず，そのような非常に限定された世界で成功しても実用的に利用できる場面が非常に少なかったためその後，実世界で大きく広がることはなかった．

曖昧さに対して計算機上のシステムが直面する問題が，何を基準として情報を削除するかである．人間の場合にも曖昧な情報に対してあらゆる可能性を保持しておくことは不可能なので，何らかの基準を用いて必要な情報だけを残しているはずである．人間の場合にはこの作業を直感的に行っていると考えられる．なぜ直感的に正しい結果だけを瞬時に把握できるのかを解明して，その仕組みを実現する必要がある．そのためには心理学的なアプローチも必要となる．特に人間の場合には，曖昧さを文脈情報を用いて解決していることが多いが，この文脈情報も自然言語処理の未解決な部分である．

次に自然言語処理の基本的な解析手法である形態素解析，構文解析，意味解析に分けてその問題点を明らかにする[1]．

2.2 形態素解析

形態素解析の目的は，文の中から品詞，活用情報，接頭・接尾語などの形態素の情報を認定することである．システムが文を処理する際の単位を決定する過程と言っても良い．特に日本語は分かち書きされないので，語の境界の認識は大きな問題である．また，この他に同音異義語の認識，未知語（辞書未登録語）の認識の問題がある．分かち書きを行う欧米語においても音声認識の場合には必ず必要となる．この形態素解析のレベルでは，広く公開されたツール[黒橋 98]も存在し，その精度も９５%以上まで上がっている．しかし，この段階は自然言語解析の最初の段階なので，この段階で誤ると後ろの処理に大きく影響する．したがって，より一層の精度の向上が必要である．

2.3 構文解析

構文解析の目的は，文の構造を明らかにし，形態素がどのような関係にあるのかを決定することにある．構文解析も近年精度は大きく向上しているが，まだまだ十分に満足の行く段階まで到達していないというのが現状である．特に，口語表現に対しては確固たる手法が確立されていない．構文解析での問題点は，構文解析の曖昧さをどのように解決するかである．例えば，「長い髪の少女の父」という表現では，髪が長いのが少女なのか父なのかこの表現だけでは決めることができない．男性より女性の方が髪が長い場合が多いという知識を用いれば，長い髪は少女に係り髪の長いのは少女の方であるということが決定できる．しかし，これは意味解析の段階での情報を用いているので，講文解析の段階では解決できないことである．この問題については，２．４節で述べる．

2.4 意味解析

意味解析の目的は，構文解析の結果より木の枝の間の意味的関係を決定することである．すなわち，何がどうしてどうなったのかを認識することである．多くの場合に

[1]そもそも自然言語の解析をこのような３つの部分に分けて議論することに問題があり，それらの処理が一体化あるいは相互に干渉し合いながら並行して処理が進んでいくというモデルの提案があるが，ここでは理解のしやすさを考えて３つに分けて説明する

は，動詞とその格パターンと構文解析結果に表現された格関係との整合性を判断して行われる．例えば，「私はごはんを食べる.」という文では，動詞「食べる」に関する格フレームを参照することにより「食べる」の対象格が「ごはん」で動作主格が「私」であることを決定する．この時に必要な知識は，「食べる」の対象格が「食べ物」であり「食べる」の動作主格が「動物」であることと「ごはん」が食べ物であり，「私」が人間すなわち動物であるという知識である．これらは，それぞれ格フレーム中およびシソーラス中に記述されている．

2.5 未知語の問題

これらの処理はいずれも予め辞書中に必要な情報が記述されていることが前提となっている．そこで，問題となるのが未知語すなわち辞書に登録されていない語の問題である．自然言語は，非常に造語能力が高いので，いくら大規模な辞書を構築しても未知語の存在を無にすることはできない．この問題に対しては，形態素解析に対しては，これまでの既知語（辞書登録語）の処理の枠組みの中でその例外として未知語の処理を扱う従来の手法と異なる未知語の処理の枠組みの中で例外として既知語の処理を行う「帰納的学習を用いた形態素解析手法 [荒木 92]」を提案し，その有効性を確認している．この手法については５．２節で述べる．構文解析，意味解析についても現在研究中であり，別の機会に報告したい．

3 規則と学習

このように従来行われてきた自然言語処理の手法は，主に規則を予め人手により与えてその規則を用いて処理を行う規則に基づく手法 [榊 93, 野村 88] である．かな漢字変換，機械翻訳などの実用化された自然言語処理システムの大半はこのような手法を用いている．規則に基づく手法の問題点は，未知語が出現した際に新たに人手により登録する作業が必要であるということである．また，使用するルールが数千の程度まで多くなってくると一つの誤解析を解消するために追加したルールによって新たに１０個の誤解析が出現してしまうという，いわゆるもぐらたたき現象が起こってしまう．

この問題を解決するために用例を用いた自然言語処理 [Watanabe 92, 古瀬 94] が最近盛んに研究されている．この手法では，人間が例を用いて問題を解決する過程を模倣し，大量の例より与えられた入力文と類似性の高い例の一部を組み合わせることにより自然言語を解析する手法であり，主に機械翻訳で多くの応用が行われている．また，用例より統計的に格情報などを獲得することにより解析を行うという手法も提案されている [宇津呂 93]．用例を用いた方法では，精度の向上は新しい実例を追加するだけで良く保守，更新が容易であるという利点がある．一方，精度の向上のためには一般に膨大な量の実例が必要であり，その処理時間も非常に大きくなるという問題点がある．

一方，これらとは別に同じ実例を利用する方法でも実例から規則を抽出し，その規則を用いて自然言語の解析を行う手法も研究されてきた [赤間 87, 佐藤 97]．この研究においては，実例より種々の段階の抽象度が異なるルールを抽出し，各ルールを段階的に適用することにより解析を行うものである．私のこれまで行ってきた「帰納的学習を用いた自然言語処理」はこの分野に分類される [荒木 92]．このような手法では，正しいルールとともに多くの誤ったルールも生成されるので，正解を与えられた際に正解よりどれだけ誤ったルールを自動的に削除できるかにその成否がかかってくる．また，一般にルールの組み合わせが膨大になるので，対象に動的にシステムを適応させてその時点で保持しているルールを制限する必要がある．これは，具象的なルールほど精度は高くなるが，一方具象的なルールほど数が多くなり適用できる場合が少なくなることに対処するためである．

4 研究の目的

以上述べてきたような自然言語処理の諸問題を解決するために，私は人間が言語を獲得し，知識を学習していくメカニズムに興味を持ち，このメカニズムを解明して工学的に実現することを最終目的として研究を進めている．このような観点に基づくシステムは，環境より情報を学習し，次第に成長することができる．したがって，本研究により，複雑で使いにくいシステムやプログラム作成の重労働といった高度情報化社会の種々の問題を解決し，人にやさしい柔軟なシステムを実現できるものと考えている．人間の幼児は，言語も知識も持たない状態から周囲の様々な環境より学習を行ない，言葉を話し，種々の知識を持つ大人に成長する．したがって，人間にはこのような生得的な能力は確かに存在する．そこで，私はこの研究の目的を「人間の言語及び知識獲得能力の工学的実現」としている．

この生得的な能力に関する研究は，いくつか存在するが，工学的に有効なシステムが完成するまでには至っていない [錦見 91] また，心理学の立場からの研究も多数行われているが [Clark 77]，これらの研究は，どのようにして子供が言語を獲得するのかを解明するという点では大きな意義があるが，そのような機構をどのようにして工学的に実現するかという問題は，当然ながら対象としていない．

5 帰納的学習を用いた自然言語処理

私は「人間の言語及び知識獲得能力の工学的実現」の研究を行う際に，対象データを段階的に高度化しながらその対象に耐え得る手法を提案するという手順で研究を進めている．具体的には，漢字かな混じり文という一種類の記号列，べた書き文とその漢字かな混じり文という記述体系が同じだが表層表現が異なる二種類の記号列，原文とその訳文といった意味的には非常に近いが記述体系が全く異なる二種類の記号列という三つの段階を対象とし，それぞれの段階に対して「帰納的学習による形態素解析手法 [荒木 92]」，「帰納的学習によるかな漢字変換手法 [荒木 96]」，「遺伝的アルゴリズムを用いた帰納的学習による機械翻訳手法 [越前谷 96]」を提案し，さらに実験によりその有効性を確認している．

5.1 帰納的学習の基本的考え方

本研究を進める上で生得的な能力を「二つの事物が同じか異なるかを判断する能力」と仮定して手法を開発し，実験を行った．したがって，この能力から 2 種類の記号列の対応関係を獲得できなくては研究の目的に合致しない．ところで，人間は対応関係を有する二種類の記号列に対してどのような方法を用いてその対応関係を決定しているのであろうか．表 1 に未知文字列からの対応関係抽出の例を示す．

表 1: 未知文字列からの対応関係抽出の例（1）

入力 1	$\alpha\,\theta\,\sigma\,\psi\,\delta\,\lambda\,\vartheta$	
入力 2	$\Xi\,\Sigma\,\psi\,\delta\,\Upsilon\,\Phi\,\Theta$	
セグメント 1	$\alpha\,\theta\,\sigma$	$\Xi\,\Sigma$
セグメント 2	$\psi\,\delta$	$\psi\,\delta$
セグメント 3	$\lambda\,\vartheta$	$\Upsilon\,\Phi\,\Theta$

表 1 の入力 1，入力 2 のような対応関係を有する二つの未知文字列を見た場合に人間は，まず二つの文字列に共通な部分を検出する．表 1 の例では，下線部 ($\psi\,\delta$) に注目すると考えられる．そして，その両側の差異部分をその出現順に対応付ける．すなわち，表 1 のセグメント 1, 2, 3 のような対応関係を考える．このような抽出過程は，我々が生得的な能力として仮定している「二つの事物が同じか異なるかを判断する能力」を基本として考えることができる．しかし，二つの文字列に共通な部分は別として異なる部分は，表 1 以外に，表 2 のようなセグメントを考えることもできる．

表 2: 未知文字列からの対応関係抽出の例（2）

入力 1	$\alpha\,\theta\,\sigma\,\psi\,\delta\,\lambda\,\vartheta$	
入力 2	$\Xi\,\Sigma\,\psi\,\delta\,\Upsilon\,\Phi\,\Theta$	
セグメント 1	$\alpha\,\theta\,\sigma$	$\Upsilon\,\Phi\,\Theta$
セグメント 2	$\psi\,\delta$	$\psi\,\delta$
セグメント 3	$\lambda\,\vartheta$	$\Xi\,\Sigma$

表 2 では，対応関係が出現順ではなく出現順と逆順になっている．このような対応関係を考えることは実際に起こり得るので，ここで出現順の対応関係を取るか出現順と逆順の対応関係を取るかは，対象とする問題に依存したヒューリスティックスであると考えられる．このようなヒューリスティックスがどのようにして獲得されるのかは，非常に重要な問題であるが，ここでは，このヒューリスティックスは与えられたものとする．

表 3: セグメントからのプリミティブ抽出の例

セグメント 1	$\alpha\,\theta\,\sigma$	$\Upsilon\,\Phi\,\Theta$
セグメント 2	$\theta\,\sigma\,\gamma\,\mu$	$\Phi\,\Theta\,\Sigma$
プリミティブ 1	α	Υ
プリミティブ 2	$\theta\,\sigma$	$\Phi\,\Theta$
プリミティブ 3	$\gamma\,\mu$	Σ

さらに，このようにして抽出されたセグメントから共通部分を抽出することにより，プリミティブな単位に分解することができる．表 3 にセグメントからの共通部分の抽出によるプリミティブ抽出の例を示す．表 3 に示したように，セグメント 1，2 の対応関係にある二つの文字列の各々の共通部分 ($\theta\,\sigma$, $\Phi\,\Theta$) をプリミティブ 2 として抽出し，その両側の差異部分 (α, Υ)，($\gamma\,\mu$, Σ) をそれぞれプリミティブ 1，プリミティブ 3 として抽出する．このように，共通部分と差異部分を分離することにより三つのプリミティブを得ることができる．この三つのプリミティブを合成することにより元の二つのセグメントを得ることができるので，この三つのプリミティブがあれば，二つのセグメントは不要となる．このような抽出方法は，基本的には我々の仮定している「二つの事物が同じか異なるかを判断する能力」によって得られるものではあるが，そのほかにやはり上述したような出現順に対応関係があるというヒューリスティクスが使われている．このように実例より共通部分と差異部分を多段階に抽出することにより知識を獲得する手法は帰納的学習の一つである．

5.2 形態素解析手法

形態素解析に対しては，従来の既知語の処理を前提としてその例外として未知語を処理する手法とは全く異なる未知語の処理を前提としてその特殊な場合として未知語を処理するという枠組みを提案した．その結果，従来の自然言語処理において一番の問題であった未知語を高い精度で処理することが可能となった．この「帰納的学習による形態素解析手法 [荒木 92]」では，辞書が全く空の状態から単語そのものを帰納的学習により獲得する．すなわち，帰納的学習ではテキスト中の漢字かな混じり文より共通部分と差異部分を多段階に抽出することにより語を獲得することができる．本手法の処理過程は二つの学習過程，二つの認識過程より構成される．処理過程を図 1 に示す．

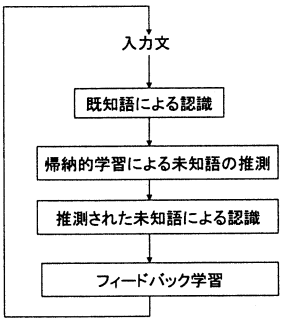


図 1: 帰納的学習を用いた形態素解析手法の処理過程

この手法では，まず文が入力されると既知語による認識が行われる．これは，既に獲得され，蓄積された語によって，入力された文字列中の語を認識する過程である．次に帰納的学習による未知語の推測を行う．これは，既知語によって認識されなかった部分より，共通パターンを 2 段階に抽出することにより行われる．この手法では，文字列中に繰り返し出現する同一文字列は語である可能性が高いという仮定に基づいている．次に推測された語を用いて未知語の認識を行う．この段階では，確実性の高いものより認識を行う．次に，認識結果に誤りが含まれている場合には，人手により認識結果中の誤りを校正し，認識結果と校正により得られた正しい認識結果を比較して正認識，誤認識の傾向を学習する．更に未登録語を辞書に登録する．このような操作により，認識の精度を向上させる．この過程をフィードバック学習と呼ぶ．したがって，この手法では帰納的学習による未知語の推測過程およびフィードバック学習の過程が語の獲得処理，既知語により認識過程と推測された未知語による認識過程が語の認識処理となる．

辞書が全く空の状態から情報処理，機械工学，応用化学，人文科学の各分野に関する論文，合計４４編，総文字数 302,703 文字を用いて評価実験を行った結果，各分野の変化点で分野の変動による多少の精度の低下が見られたが，しばらく学習すると回復し，どの分野もおおよそ９０%程度まで認識できることが示され，帰納的学習により単語の認識という段階まで言語獲得能力を工学的に実現できることが明らかになった．

5.3 かな漢字変換手法

5.3.1 概要

次に，対象を高度化して本研究を進めた．すなわち，記述体系が同じだが表層表現が異なる二種類の記号列に対する適用である．このような記号列としてべた書き文とその漢字かな混じり文を用いた．この「帰納的学習によるかな漢字変換手法 [荒木 96]」では，べた書き文とその漢字かな混じり文から帰納的学習によりかな漢字変換に必要な語の表記と読みを獲得し，次に獲得状況及び変換精度に基づく確実性の高い順に多段階に変換を行なう．本手法の処理の流れを図 2 に示す．

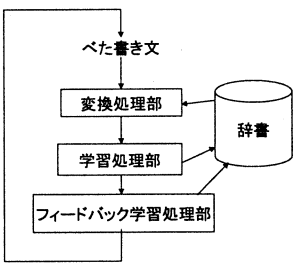


図 2: 帰納的学習によるかな漢字変換手法の処理過程

図 2 に示すように本手法は，変換処理，学習処理，フィードバック学習処理の三つの処理から構成される．べた書き文が入力されるとそれまでに学習によって獲得された語を用いて語のあてはめを行う．この際には，確実性の高い語より順に変換が行われる．確実性は，学習処理におけるその語の獲得状況及び変換に使用された際の精度によって決定される．ここで，変換結果に誤りが存在する場合には，人手によって校正が行われる．次に，学習処理を行う．学習処理は，このようにして得られた正しい漢字かな混じり文及び入力されたべた書き文を用いて行われる．学習処理は，二つの段階からなる．まず，第 1 段階では，入力されたべた書き文と校正済みの変換結果より共通部分を手掛りに語候補を得る．次に，第 2 段階ではこの語候補同士の共通部分と差異部分を抽出することにより語を獲得する．最後にフィードバック学習処理では，変換結果と校正された変換結果を比較することにより正しく変換した語の尤度を上げ，誤って変換した語の尤度を下げる．

このことにより次回からの変換精度の向上を図ることができる．

5．2節で用いた資料と同様の実験データを用いて本手法の性能評価実験を行った．実験条件も同様に辞書が全く空の状態から行っている．その結果各分野の変化点で一時的に正変換率が未知語の出現のために低下するものの学習能力によりすぐに回復し，各分野で９０％以上の精度を示した．このことは，本手法のこの応用分野における有効性を示しているものと考えられる．

5.3.2 携帯端末用日本語入力手法への応用

さらに本手法の学習能力を用いた適応性能を利用して携帯端末用の日本語入力手法を開発した．この手法を「文字情報縮退方式を用いた帰納的学習による数字漢字変換手法」と呼んでいる [松原 98]．本手法においては使用者は 12 個のキーによる文字情報縮退方式を用いて，日本語を入力する．数字とかなの対応関係を表 1 にしめす．表 1 に示すように本方式では，母音の情報が縮退している．したがって，入力される情報は通常のローマ字あるいはかなの入力より曖昧さが増大している．この増大した曖昧さを本手法ではユーザに動的に適応することにより解消する．すなわち，そのユーザが次に入力すると考えられる語の優先度を上昇させることによって解決する．帰納的学習を用いると入力された数字列と正しい変換結果よりその変換規則を動的に獲得することが可能なので，自動的に各ユーザごとにシステムを最適化することができる．

表 4: 数字とかなの対応表

1:あいうえお	2：かきくけこ	3：さしすせそ
4:たちつてと	5：なにぬねの	6：はひふへほ
7：まみむめも	8：やゆよゃゅょ	8：らりるれろ
*:（半）濁音	0：わをん	#:句読点

UNIX のオンラインマニュアル（50,000 文字）と同一著者の情報処理に関する三編の論文（72,000 文字）を用いて性能評価実験を行った．実験は辞書が空の状態から行った．その結果 UNIX オンラインマニュアルで平均 75.1 %，論文で 76.7 %の精度が得られ，本手法のこの分野における有効性が確認された．

5.4 機械翻訳手法

次に，本研究を進める第三段階として原文とその訳文といった意味的には非常に近いが記述体系が全く異なる二種類の記号列を対象とした帰納的学習手法の開発を行った．対象としたデータは翻訳例，すなわち原文とその訳文の組である．このレベルでの応用を行うには，対象としている二類の記号列の異なりが大きく，これまでの帰納的学習手法の学習能力では不十分である．そこで，遺伝的アルゴリズム [Goldberg 89] を帰納的学習に適用することにより帰納的学習手法の学習能力の強化を図った．このような手法を「遺伝的アルゴリズムを用いた帰納的学習による機械翻訳手法 [越前谷 96]」と呼ぶ．また，GA-ILMT(Machine Translation using Inductive Learning with Genetic Algorithms) と表記する．

本手法は，翻訳実例から翻訳ルールを帰納的に学習し，翻訳を行なうものである．学習型の機械翻訳手法では，一般に非常に大量の実例を必要とするという問題点を持つ．しかし，本手法では遺伝的アルゴリズムの交叉処理を応用することにより少数の実例より多くの翻訳例を自動的に生成し，多くの翻訳ルールを得ることによりこの問題を解決している．また，システム全体としても遺伝的アルゴリズムを実現しているので，使用につれてその翻訳情報をフィードバックし，誤った翻訳ルールが淘汰され最適なシステムに進化することができる．本手法の処理過程を図 3 に示す．

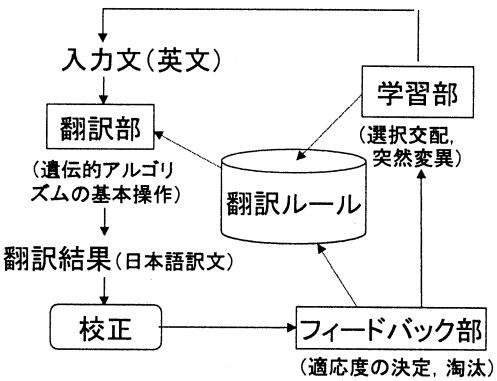


図 3: GA-ILMT の処理過程

図 3 で（ ）で示されている部分は，遺伝的アルゴリズムの適用範囲を示している．実験システムとして英日機械翻訳システムを構築した．最初に英文が入力されるとその入力された英文に対して翻訳部において，それまでに抽出された翻訳ルールへ遺伝的アルゴリズムの基本的操作を適用することにより，最適な翻訳結果を生成する．翻訳部における遺伝的アルゴリズムの適用は，遺伝的アルゴリズムの代表的なオペレータを抜粋して用いるのではなく，一連の処理手順を適用している．したがって，実験システムは遺伝的アルゴリズムの枠組みをシステム全体と翻訳部の両方に取り入れたものになっている．次にフィードバック部において，ユーザが校正することによっ

て得られた正しい日本語訳文を用い，翻訳部で使用された翻訳ルールに対する適応度の決定と淘汰を行う．そして，学習部において，与えられた英文とその日本語訳文からなる翻訳例に対し，選択交配と突然変異を行うことで多様な翻訳ルールを生成し，以後の翻訳に活用する．

このような処理を繰り返すことによりシステム自身がより多様な翻訳ルールを生成するようになる．さらに良質な訳文が与えられることにより環境に適応した良質な翻訳ルールを獲得し，より良質な翻訳を行うシステムへと進化する．

また，本手法において染色体と遺伝子は図4に示すように割り当てられている．すなわち，染色体は英文とその日本語訳文を組とした翻訳例を，そして染色体を構成している遺伝子には翻訳例を構成している単語を割り当てている．また，交叉の方法としては，1点交叉を用い，突然変異率を2％としている．中学1年生用の教科書ガイドに出現する翻訳例（1,010組，11,479文字）を用いて性能評価を行った結果，有効な翻訳率が61.9％ととなり本手法の有効性が確認された．

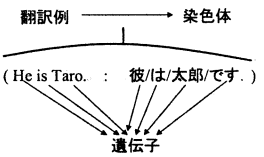


図4: 染色体と遺伝子

5.5 対話処理への応用

次の段階として現在取り組んでいる課題は対話処理への応用である．対話処理では対象とするデータとして対話例を用いるが，これは，因果関係は存在するが意味的に異なる記号列である．このようなものを処理する場合には，さらに高度な学習能力が必要となるものと考えられる．現在はこれまでの手法を応用し，どの程度の正応答率が得られるかを明らかにしている段階である．今後，さらに実験を進め，誤りを分析することにより必要な学習能力の程度を解明し，帰納的学習の枠組みで対話処理システムを実現する予定である．

5.5.1 ELIZA 的なものへの批判

そもそも計算機による対話処理については，古くから研究されており，その一つの典型的な例が精神分析医のインタビューの代行システムである ELIZA[Weizenbaum 66] である．ELIZA の対話例を図5に示す．ELIZA はデータベース中のキーワードを用いて動作しているが，入力文とキーワードを照合する際に複数のキーワードを組み合わせて最適な応答を生み出すので，文脈に依存した応答を返しているように見える．このプログラムは患者の

患者 : 男ってみんな似たようなものね．
ELIZA : どんなふうに．
患者 : いつも人の話をあれこれ盗聴しているの．
ELIZA : 具体例をあげられますか？
患者 : そうね，私のボーイフレンドがあなたをここに来させたの．
ELIZA : あなたのボーイフレンドがあなたをここにこさせた．
患者 : 彼は，私がたいてい意気消沈しているっていうの．
ELIZA : あなたが意気消沈していると聞いて残念です．
患者 : 私は手助けが必要なの，まちがいないわ．
ELIZA : もし手助けが得られれば，それはあなたにとってどんな意味がありますか？
患者 : たぶん，私の母とうまくやっていけるようになると思うわ．
ELIZA : あなたの家族について，もっと話して下さい．
患者 : 母は私を大事にしてくれるの．
ELIZA : あなたの家族の中で他にだれが大事にしてくれますか？
患者 : 私の父．
ELIZA : あなたのお父さん．
患者 : あなたは，私の父と少し似ているの．
ELIZA : どのように似ているように見えますか？
患者 : あなたは私と口げんかをしないわ．
ELIZA : なぜ，私があなたと口論しないのだと思いますか？
患者 : 私がこわいんでしょ．
ELIZA : 私があなたをこわがっていると思うと，うれしいですか？
患者 : 私の父は，だれでもこわがります．
ELIZA : あなたのお父さんについて考えて，他に何が浮かんできませんか？
患者 : ごろつき．
ELIZA : それは，あなたのボーイフレンドがあなたをここに来させたことと何か関係がありますか？

図5: ELIZA の対話例

望むものは何でも入力でき非常に頑健なシステムである．実際に，このシステムはその応答が余りにも人間らしかったために患者がシステムと応答しているのではなく，精神科医と会話していると思ったくらいであった．しかし，ELIZA は完全にアドホックな方法で応答文を作成していた．例えば，”I”を”YOU”に変換したり，「意気消沈する (depressed)」に対して「残念です (I amd sorry to hear that …)」のような応答を返す．ELIZA は全く意味を理解していないにも関わらず精神科医のインタビュー代行という仕事としては，成功を収めていた．

しかし，ELIZA 方式の対話処理システムはその後爆発的に社会に広まるということにはならなかった．これは，意味理解を全く行っていなかったために精神科医のインタビュー代行システムのような論理的な会話を行わなくても良い場面では有効であったが，例えば観光案内システムのような目的のある会話については無力であった．また，AI 研究者の科学的興味が「意味理解」の解明とその実現であったためその方向へ研究が進み，現在 ELIZA はキーワード方式の古いシステムの代表という地位に甘んじている．

5.5.2 よみがえる ELIZA

しかし，ELIZA は少なくとも非常に限られた用途であったが工学的には有効であった．実際に最近音声認識技術が実用化に近づくつれ ELIZA 方式のシステムが老人の話し相手，おもちゃとして製品化されつつある．また，ELIZA が開発された頃に比べるとハードウェアの性能が桁違いに高いので，データベースやキーワードの組み合わせを

当時にでは想像もできないくらい巨大に，複雑にすることが可能であり，このような状況の変化がELIZA的アプローチで人間が理解したと同等の応答結果を再現できる可能性があると考えている．すなわち，人間と計算機はハードウェアは異なるので理解の方法は異なっても構わないという立場である．現在，このような立場からこれまで行ってきた帰納的学習を用いた対話処理手法の研究を進めている．

6 おわりに

本稿では，これまでの自然言語処理の研究の概要を述べ，その問題点を解決するために開発された学習によるアプローチについて述べた．さらに，学習に基づく手法の一つの例として私のこれまでに行ってきた帰納的学習を用いた自然言語処理手法について，各種の応用例を基に説明した．最後に，現在取り組んでいる課題である対話処理についてその研究の立場を中心に述べた．

このように自然言語処理の研究過程を振り返ると曖昧さを持つ不完全な情報を如何にして計算機上で処理するかということを中心に研究が進められてきたものと考えられる．このような観点に立つと少なくも自然言語より曖昧さの少ないプログラミング言語にExample-basedや帰納的学習等の自然言語処理分野で開発された手法を適用することはできないのかという思いを抱いている．すなわち，Example-Based Programmingといったものや帰納的学習を用いたプログラミングといったものである．すでに，このような方向の研究は存在するかもしれないが，曖昧さが多い自然言語処理に対して開発された種々の技術をプログラミング技術に応用することは有意義なことであると考えている．今後はこのような方向での研究も進める予定である．

参考文献

[Winograd 72] Winograd, T.: Understanding Natural Language, Academic Press(1972).

[黒橋 98] 黒橋禎夫，長尾真：日本語形態素解析システム JUMAN version 3.5，京都大学大学院工学研究科 (1998).

[荒木 92] 荒木健治，栃内香次：帰納的学習による語の獲得および確実性を用いた語の認識，信学論 (D-II)，vol.J75-D-II, no.7, pp.1213-1221(1992).

[榊 93] 榊博史 ：コンピュータ翻訳技術，電子情報通信学会，東京 (1993).

[野村 88] 野村浩郷 ：自然言語処理の基礎技術，電子情報通信学会，東京 (1988).

[Watanabe 92] Watanabe, H. : A Similarity-Driven Transfer System, Porc. of COLING-92, vol.2, pp.770-776(1992).

[古瀬 94] 古瀬蔵，隅田英一郎，飯田仁：経験的知識を活用する変換主導型機械翻訳，情処学論，vol.35, no.3, pp.905-912(1994).

[宇津呂 93] 宇津呂武仁，松本裕治，長尾真：二言語対訳コーパスからの動詞の格フレーム獲得，情処学論，vol.34, no.5, pp.913-924(1994).

[赤間 87] 赤間清 ： 帰納的学習システムＬＳ／１による翻訳の学習，人工知能学会誌，vol.2, no.3, pp.341-349(1987).

[佐藤 97] 佐藤理史 ：アナロジーによる機械翻訳，共立出版，東京 (1997).

[錦見 91] 錦見美貴子，中島秀之，松原仁：一般学習機構を用いた言語獲得の計算機モデル，認知科学の発展，vol.5, pp.143-185，講談社，東京 (1991).

[Clark 77] H. H. Clark and E. V. Clark : Psychology and Language, Harcourt Brace Jovanovich(1977).

[荒木 96] 荒木健治，高橋祐治，桃内佳雄，栃内香次：帰納的学習を用いたべた書き文のかな漢字変換，信学論 (D-II)，vol.J79-D-II, no.3, pp.391-402(1996).

[越前谷 96] 越前谷博，荒木健治，桃内佳雄，栃内香次 ： 実例に基づく帰納的学習による機械翻訳手法における遺伝的アルゴリズムの適用とその有効性，情処学論，vol.37, no.8, pp.1565-1579(1996).

[松原 98] 松原雅文，荒木健治，桃内佳雄，栃内香次 ： 文字情報縮退方式を用いた帰納的学習によるべた書き文のかな漢字変換手法，情処学自然言語処理研報，vol.98(98-NL-128), pp.1-7(1998).

[Goldberg 89] Goldberg, D. E. : Genetic Algorithms in Search, Optimization, and Machine Learning, Addison-Wesley(1998).

[Weizenbaum 66] ELIZA - a computer program for the study of natural language, Communications of the Association for Computing Machinery, vol. 9, pp.36-45(1966).