社団法人　電子情報通信学会
THE INSTITUTE OF ELECTRONICS,
INFORMATION AND COMMUNICATION ENGINEERS

信学技報
TECHNICAL REPORT OF IEICE.
TL99-8 (1999-07)

平文を用いた統語規則の自動獲得

渋木 英潔　　荒木 健治　　栃内 香次

北海道大学大学院工学研究科電子情報工学専攻

〒060-8628 北海道札幌市北区北 13 条西 8 丁目
E-mail: {shib, araki, tochinai}@media.eng.hokudai.ac.jp

あらまし
我々は、これまでに帰納的学習を用いた研究を行っており、未知語の獲得を扱った研究も発表してきた。平文から、その平文に形態素解析と構文解析を行って学習に必要な情報を自動的に付与し、その結果をもとに学習することで CFG の規則を獲得することを試みた。解析に必要な知識も学習によって得るため、完全な情報が付与されるとは限らない。この解析結果から欠けている部分を補うことで実際の入力に適した規則を学習できると考える。しかし、従来の解析手法は、解析に必要な規則がすべて与えられていることを条件にしている。そのため、不十分情報を付与できる解析手法としては相応しくない。以上の背景から、我々は、単語や CFG の規則がどのような状態であっても形態素解析と構文解析を行うことができるグラフト法を提案する。

キーワード　形態素解析　構文解析　帰納的学習　文脈自由文法

Automatic Acquisition of Syntactic Rules from Non-Preprocessed Corpus

Hideyuki Shibuki　Kenji Araki　Koji Tochinai

Division of Electronics and Information Engineering,
Graduate School of Engineering, Hokkaido University

N 13-Jo, W 8-Chome, Kita-ku, Sapporo, 060-8628 Japan
E-mail: {shib, araki, tochinai}@media.eng.hokudai.ac.jp

Abstract
We have done research on Natural Language Processing using inductive learning, and have already presented some researches on acquisition of words. We attempt to acquire CFG rules from non-preprocessed sentences on the condition that morphological and syntactic analysis adds tags needed for the acquisition to the sentences. The analysis can not always add the complete information to the sentences, because rules for the analysis are also acquired. If learning completes the lacks of information, the rules can adapt themselves to actual sentences. However, the most of methods for the analysis can not add the incomplete information, because the methods can analyze sentences on the assumption that there are enough rules for analysis. We proposed Graft Method that can analyze sentences on any condition of amounts of words and CFG rules.

key words　Morphological analysis, Syntactic analysis, Inductive learning, Context-Free Grammar

1．序論

我々は、これまでに帰納的学習を用いた研究を行っており、未知語の獲得を扱った研究[1]も発表してきた。今回、これらの研究を発展させ、CFG の規則の獲得に関する研究を試みた。従来の CFG の規則の獲得を扱った研究[2][3]では、品詞タグ付きや括弧付きコーパスを用いていた。しかし、これらの情報を平文に付与するのには大きな労力が必要とされる。また、付与する方法も人によって異なっている。従って、平文コーパスから自動的に CFG 規則を獲得することが望ましい。しかし、平文のままでの学習は困難であると思われるため、自動的に平文に対して学習に必要な情報を付与することが必要である。学習に必要とするタグと括弧の情報は、形態素解析と構文解析の結果と見なすことができる。すでに獲得された知識を用いて平文に形態素解析と構文解析を行うことで、学習に必要な情報を付与できる。ただし、解析に必要な知識も学習によって得るため、入力文に対して完全に解析できるとは限らない。そのような解析結果は不完全情報である。その不完全情報を補うように学習することで、単語や CFG の規則を獲得していく手法を開発した。しかし、従来の解析手法は、解析に必要な規則がすべて与えられていることを条件にしている。そのため、不完全情報を付与するための解析手法としては相応しくない。以上の背景から、我々は、単語や CFG の規則がどのような状態であっても形態素解析と構文解析を行うことができる Graft 法を提案する。この手法は、まず、小さな部分解析木の列を作成し、その部分解析木を接ぎ合わせて徐々に部分解析木の数を減らしていくことで全体の結果を求める。これにより、完全に減らしきれない場合でも不完全情報を付与することが可能である。さらに、学習と組み合せることで使用できる単語や CFG の規則を増やし、解析の精度を上昇させることができる。

我々は、本手法と帰納的学習を実装したシステムを開発した。このシステムは、単語や CFG の規則を解析結果から獲得し、獲得された規則を用いて、システムは次の解析を行う。システムが自動的に付ける尤度と、ユーザが、全ての結果の中から、獲得するのに相応しい結果を選択する。この処理を繰り返すことで平文から統語規則を獲得する。この手法には、不足している単語や CFG の規則の部分を明らかにし、現実の文に適した規則を獲得できるという利点がある。

2節で本手法が必要とする知識の定義を述べる。3節で不完全情報からの学習について述べる。4節で本手法の詳細を述べる。5節で評価実験とその考察を述べる。6節は結論である。

2．本手法の解析に必要な知識の定義

解析に必要な知識は、全て学習によって獲得されるものとする。具体的には、統語範疇、認知単位、認知規則、統合規則の四種類である。

2.1 統語範疇

統語範疇は、本手法の解析における内部表現として定義する。統語範疇は品詞に相当するものも含んでいる。それぞれの統語範疇は、レベルと到達可能リストをもっている点が従来と異なっている。レベルにより統語範疇の間に階層構造が生まれ、階層構造の存在は、本手法の形態素解析と構文解析の負担を軽減する。到達可能リストの中には、LINGOL と同じく到達可能な統語範疇が存在している。到達可能な統語範疇の中には、その到達可能リストをもっている統語範疇自身も含まれる。LINGOL が、ある統語範疇から到達可能な全ての統語範疇を表の形式で表わしていたのに対して、本手法では、到達可能な統語範疇の中から、その統語範疇と同じか一つ上のレベルをもつ統語範疇だけに絞ってリストの形式で表現する。例えば、「名詞」が「名詞句」に到達可能であり「名詞句」が「文」に到達可能であるならば、「名詞」が「文」に到達可能であることは容易に推論できる。本手法では、部分解析木を接ぎ合せて全体を表現する。そして、部分解析木の作成には、一つ上のレベルまでの到達可能性で十分である。従って、不要な到達可能統語範疇を削除することができる。

2.2 認知規則と認知単位

認知規則は、認知単位と統語範疇を１対１で結び付ける規則として定義する。認知単位とは辞書における見出し語に相当する。認知単位は、我々が通常使う形態素や単語よりも広い範囲を含んでいる。このことは、認知単位に対する研究[4]にあるように、人間が日本語文法で定められた単位に縛られないことと、より大きな単位

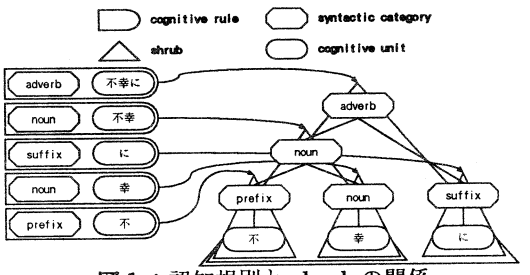


図１：認知規則と shrub の関係

で認知することで処理の効率が上がることから問題はないと思われる。最小の認知単位は文字である。その他の認知単位は、より小さい認知単位の組み合せと見なすことができる。もしも、自分より小さい認知単位とその組み合わせが判明しているならば、その文字以外の認知単位をもつ認知規則は、その組み合わせを記憶している。この組み合わせは確定した部分解析木と見なすことができる。この部分解析木を shrub と呼ぶ。図1に認知規則と shrub の関係を示す。形態素解析では認知単位に対応する shrub を当てはめていく。これは、形態素解析の段階で構文解析を一部済ますことになり、構文解析の負担を軽減することができる。

2.3 統合規則

統合規則は、二つの統語範疇を統合し、一つの統語範疇に置き換える規則として定義する。統語される二つの統語範疇をそれぞれ第一範疇、第二範疇と呼び、置き換えられた統語範疇を統合範疇と呼ぶ。統合範疇のレベルは、第一範疇と第二範疇のレベルが同じ場合には、そのレベルよりも一つ高いレベルになり、第一範疇と第二範疇のレベルが異なる場合には、高い方のレベルと同じレベルになる。第一範疇と第二範疇のレベル差は、最大で1である。統合規則を図2に示す。2.1 の到達可能性と同じく理由から、この条件で十分である。統語解析の結果は、この統合規則を用いて作成されるため、二分木での表現となる。しかし、必要があれば、4.3 で述べるように、容易に三分木以上の形式に変換することができる。

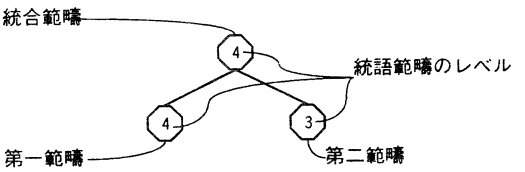


図2：統合規則

3．不完全情報からの学習

3.1 本手法の解析結果を用いた学習

本手法によって得られる不完全情報から、どのようにして新しく単語と CFG の規則を獲得するのかを、簡単な例を使って説明する。表1で表わされる CFG の規則があると仮定する。そして、次のような入力がなされたとする。

表1：CFG 規則

Verb Phrase	→	Verb	Noun Phrase	Noun	→ I
Noun Phrase	→	Article	Noun	Verb	→ read
Noun Phrase	→	Noun		Article	→ the

Input sentence: I read the book

表1であげたCFGの規則では、この入力に対する完全な解析木を作ることはできない。しかし、図3で示すような不完全情報を付与することができたならば、図4(次頁)で示すように、新しい統語範疇と認知単位"book"を獲得した後、「名詞句」と「動詞句」を新しい統語範疇でまとめる統合規則と、「名詞」と"book"を結び付ける認知規則を獲得することができる。それによって、次回の解析から、この入力文と類似した文に対して解析を行うことが可能になる。

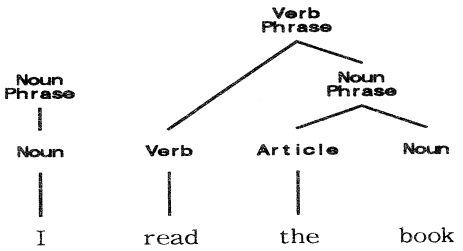


図3：解析結果

3.2 不完全情報を付与する解析における問題点

不完全情報を付与する解析における問題は、解析に必要な規則が不足していることである。認知規則の不備は、形態素解析での未知語の処理が必要となる。そして、未知語の存在は、構文解析がボトムとなる統語範疇が不明の状態でも解析できなければならないことを要求する。さらに、学習のために 3.1 の「名詞」と"book"のように対応する統語範疇を推測することも要求する。統合規則の不備は、入力文全体に対応する統語範疇をトップとして解析木が作成できない可能性があることを示し、構文解析がトップとなる統語範疇に依存せずに解析できなければならないことを要求する。さらに、学習のために 3.1 の「名詞句」と「動詞句」のように可能な限り少ない統語範疇にまとめることも要求する。CFG の規則を用いた代表的な解析手法として CKY 法[5]や Earley 法[6]があるが、これらの要求を全

て満たすことはできない。CFG規則を用いない手法として、係り受け解析手法[7][8]があるが、品詞が分かっていることと係り受け行列が用意されていなければならないことが条件のため同様である。Example-Based Method[9]は、実例が増えるほど解析の精度が上昇していくため、学習と組み合せることで解析精度を上げることができるが、実例がないときに不完全情報を付与することはできない。

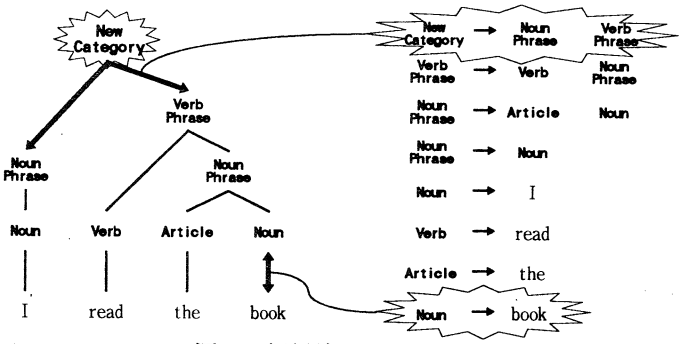


図4：解析結果からの学習

不完全情報からの学習のためには、入力文全体に対応する統語範疇に依存せず、未知語を含んでいても処理することができ、その未知語に対応する統語範疇を推測し、可能な限り少ない統語範疇にまとめることができる解析手法が必要とされる。本手法はこの条件を満たすように開発された。

4．本手法の詳細

4.1 処理の流れ

本手法は、現在の時点で作成可能な全ての結果を求め、それぞれを尤度評価して尤度の高い結果から表示する。求める結果は小さな部分解析木を接ぎ合わせた集合体で表現される。この集合体を forest、各部分解析木を wood と呼ぶ。情報を付与するまでの大まかな処理の流れは以下の通りである。形態素解析で認知規則を用いて shrub を当てはめていく。入力文全体に対応する当てはめられた shrub の列を grove と呼ぶ。この時点で grove に対して1回目の尤度評価を行う。次に構文解析で、grove を flora と呼ばれる接ぎ合わせるための層に変換する。flora は plant と呼ばれる統語範疇のポインタで構成される。統合規則を用いて flora から幾つかの wood を作成する。作成した wood の頂点を plant として新たな flora を作り、積み上げる。新たな flora が作成できなくなるまでこの作業を繰り返す。作成される forest のイメージを図5に示す。作成された forest に対して2回目の尤度評価を行う。1回目と2回目の尤度の和が最終的な尤度となり、この尤度に基づいて表示される。尤度評価を2回行うことで、形態素解析と構文解析の両方でよい結果を得られたものが残るようにしている。それぞれの詳細は、各処理を扱った次節以降で述べていく。

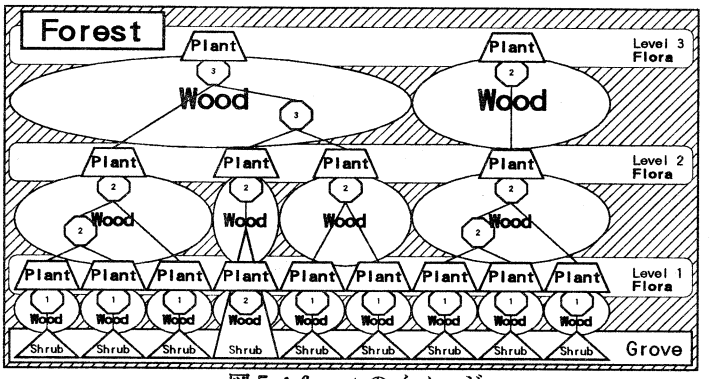


図5：forest のイメージ

4.2 形態素解析

本手法の形態素解析は、多段階分割法[10]に基づいたものである。多段階分割法は、高い確実性をもつ単語を用いて一意に決定できる部分から決定し、その後も、確実性の高い部分から順次決定していく手法である。この手法は入力文の曖昧性を減少させるのに有効である。ここで問題となる確実性の高さは、本手法において、使用する認知規則の統語範疇のレベルの高さで示される。従って、最初、基準となるレベルを現在認知規則の統語範疇がもつことのできる最高レベルに合わせ、その後徐々に下げていくことで、確実性の高い認知規則から順に対応するシラブを当てはめていくことができる。未だ shrub を当てはめられていない範囲を不定範囲と呼ぶ。基準レベルが最低レベルまで下がっても残っている不定範囲は未知語と見なされ、未知語の shrub として作成される。

本手法における形態素解析の手続きは、以下の3つの手順に要約できる。

1. 入力文全体を一つの不定範囲と見なし、基準レベルを認知規則がもつことのできる統語範疇の中で最も高いレベルに合わせる。
2. 不定範囲を認知単位を用いて shrub に確定させる。ただし、その認知単位は、現在の基準レベルと同じレベルの統語範疇をもつ認知規則のものでなくてはならない。
3. 入力文全体が shrub で当てはめられたら、形態素解析を終了する。そうでなければ、shrub の当てはめられていない範囲を不定範囲とし、基準レベルを一つ下げて手順 2 に再帰する。もしも、基準レベルが最低レベルであれば、不定範囲を一つの未知語と見なして形態素解析を終了する。

4.3 構文解析

本手法の構文解析では plant を単位として処理を行う。plant とは、入力文中のどの範囲がどの統語範疇にまとめられるかを示す要となる統語範疇へのポインタである。同じ入力であってもどのレベルで処理するかによって扱いも異なってくる。例えば「飛行機が」という言葉は、単語レベルで「飛行機」と「が」の 2 単語で構成されていると見ることができる。しかし、これが一つの文節であるということは異論のないところであり、文節と見なしてしまえば、内部がどのようになっているかを詳しく見る必要はない。この文節単位での考え方を使ったものが係り受け解析であり、係り受け解析における長所の一つである。plant と flora にはレベルがあり、そのレベルを徐々に上げていくことで、文節レベルにこだわらず、小さな単位から大きな単位での文構造へと処理を進めることができる。この plant の内部がどのように下位の plant で構成されているかを示したものが wood であり、各 wood を plant の位置で接ぎ合わせていったものが forest である。2.3 で述べた三分木以上の形式への変換とは、forest の中の plant 以外の統語範疇を無視し plant 間のつながりだけを強調することである。

形態素解析の結果はそのままでは構文解析ができないため flora に変換しなくてはならない。4.3.1 で形態素解析結果からの変換を述べる。構文解析の本体は、wood を作成することと、wood を接ぎ合わせて forest を形成することに分けられる。

wood を接ぎ合わせることは、新たな flora を作成し積み上げることで行われる。この処理は 4.3.2 で述べる。wood の作成は 4.3.3 で詳しく述べる。しかし、これからの処理を説明していく上で必要な用語をここで述べる。図 6 は wood の詳細を示したものである。wood のトップは trunk、ボトムは twig と呼ぶ。最も左に位置する twig を graft と呼び、graft を与えて wood の作成を行う。4.4.4 で構文解析のアルゴリズムをまとめる。

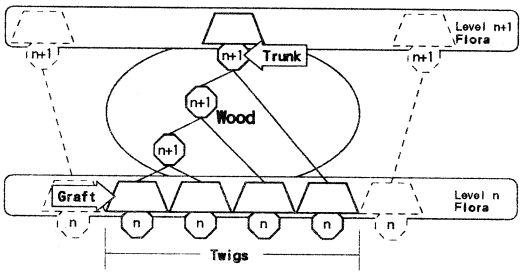


図 6 ：wood 詳細

4.3.1 形態素解析結果からの変換

grove 中の各 shrub は各 plant に 1 対 1 で変換される。まず、shrub が未知語である場合には、無条件で、その shrub は、指している統語範疇が不明な plant に変換される。そうでない場合には、その隣接する shrub によって変換される plant が異なる。隣接する shrub が未知語でなく、その統語範疇のレベルが、隣接される shrub の統語範疇のレベルよりも 2 つ以上高い場合には、その shrub は、指している統語範疇が不明な plant に変換される。これは、統合規則の第一範疇と第二範疇のレベル差が最大でも 1 であるため、2 つ以上レベル差がある plant 同士は決して統合されることがないからである。隣接する shrub がない場合、または、隣接する shrub が先の条件に当てはまらない場合には、その shrub は自分の統語範疇を指す plant に変換される。図 7 はこの 3 つのパターンを示す。

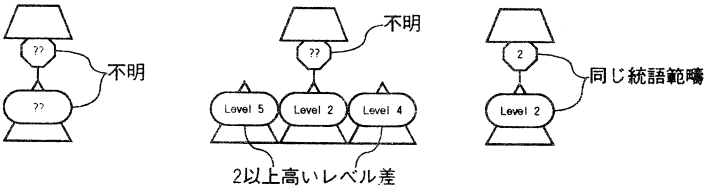


図 7 ：shrub から plant への変換

4.3.2 wood の接合

次に、wood の接合について述べる。wood の接合は flora 単位で行われる。現在の最上層に位置する flora のレベルよりも一つ高いレベルをもつ flora を作成し、その flora を最上層に積み上げる作業である。この作業は、最上層 flora よりも一つ高いレベルをもつ flora が作成されなくなるまで、処理レベルを 1 ずつ増加して続けられる。処理レベルとは積み上げようとする flora がもつレベルのことである。flora は自分よりも低いレベルをもつ plant や不明な統語範疇を指している plant を含むことができる

が、少なくとも一つは自分と同じかそれよりも高いレベルをもつ plant を含まなくてはならない。初めは、変換された最下層 flora が最上層 flora であるので、処理レベルを 2、最下層 flora の最も左に位置する plant を graft として処理をはじめる。現在の graft から対応する wood を作成する。作成された wood の最も右に位置する twig が、現在の最上層 flora の最右 plant と同一でなければ、作成された wood の最右 twig の右隣に位置する plant を新たな graft として右隣の wood を作成する。作成された wood の最右 twig が、現在の最上層 flora の最右 plant と同一になるまでこの処理を繰り返す。同一になったならば、それまでに作成された wood の trunk の列を指す plant の列を作成して、そこまでの forest を固定させる。これらの plant で新たな flora を作り、最上層に積み上げる。ただし、wood の作成が一意に決まらない場合には、その全てを求め、それぞれに対して flora を作成して処理を続ける。flora の積み上げができなくなった時点で、最上層 flora に含まれる plant 数が 1 である場合は、完全な構文解析を行うことができたこと示している。そうでない場合には、何らかの CFG 規則が欠如していることを示している。

4.3.3 wood の作成

最後に、wood の作成について述べる。wood は、graft、twig のリミット、wood の処理レベルから作られる。twig のリミットは、最初、その twig を含んでいる flora の最右 plant を指している。wood の処理レベルは 4.2.2 での処理レベルと同じレベルである。wood の作成は、未知語の統語範疇を推測するために、トップダウンに展開する必要がある。まず、graft が指す統語範疇の到達可能リストの中から、処理レベルと同じレベルをもつ到達可能範疇を全て選び出し、作成する wood の trunk とする。graft の指す統語範疇が不明である場合には、処理レベルと同じレベルをもつ全ての統語範疇を trunk とする。trunk が graft の指す統語範疇と同一であるか、あるいは、少なくとも一度展開しているという条件付きで graft の指す統語範疇が不明である場合に作成された wood は正しいと見なす。正しいと見なされた wood は与えられた graft から作成できる wood の一つとなる。graft の指す統語範疇が不明である場合、後で、その統語範疇は wood から推測されて学習が行われる。つまり、この統語範疇を、未知語の shrub から変換された plant が指していた場合、その未知語に対応する統語範疇を判明させることができる。作成された wood が正しいと見なされたかどうかに関わらず、現在の trunk から統合規則を使って twig をトップダウンに展開していく。正しい wood が作成された時点で処理を中断しないのは、左再帰規則を用いて別候補を作成できる可能性があるからである。この時に問題となるのは左再帰規則による無限ループであるが、本手法では、Earley 法のようなクロージャを作ることなしに無限ループを回避する。本手法では、wood 作成処理の終了は twig のリミットが graft を指した時に行われる。twig のリミットは展開が行われるたびに graft に近づいていく。twig となる flora に含まれている plant 数が有限である以上、展開も有限のものとなる。この単純な機構によって無限ループを回避しながら wood の展開を行う。展開に使用される統合規則は、以下の三つの条件を満たさなくてはならない。統合範疇が現在の trunk と同一であること、第一範疇が現在の graft の指す統語範疇の到達可能リストの中に含まれていること、第二範疇が現在の graft の右隣から現在の twig のリミットまでの範囲にある plant が指す統語範疇の到達可能リストの中に含まれていることである。ただし、第二、第三の条件で用いる到達可能性をもつべき統語範疇が不明である場合には、その条件を満たしていると見なす。第三の条件により、展開する前にその twig の範囲を確定することができる。第一範疇を仮の trunk、第二範疇に関する条件で用いた plant の左隣の plant を仮の twig のリミットと見なして、仮の wood を同様にして展開する。この仮 wood を first wood (FW) と呼ぶ。FW が正しければ、第二範疇を仮の trunk、第二範疇に関する条件で用いた plant を仮の graft と見なして仮の wood を展開する。この仮 wood は second wood (SW)と呼ぶ。SW も正しく、かつ、FW の最右 twig が SW の最左 twig と隣接していれば、先の統合規則を用いて FW と SW を統合して最終的な wood を作成する。正しい FW、SW の候補が複数あり、隣接の条件を満たしていれば、それぞれを組み合せて複数の最終的な wood を作成する。

4.3.4 構文解析のアルゴリズム

本手法における構文解析の手続きは、以下の 6 つの手順に要約できる。

1. grove から最下層 flora に変換し、処理レベルを 2 に合わせる。通常、shrub のルートと同じ統語範疇を指す plant に変換する。ただし、隣接する shrub の統語範疇より 2 レベル以上低い場合は、不明な統語範疇を指す plant に変換する。
2. 手順 3 に従って、処理レベルを 1 ずつ増加させながら、現在の最上層 flora よりも 1 つ高いレベルをもつ flora を作成し積み上げる。flora が作成できなくなった時点で構文解析の処理を終える。

3. 手順4—6に従って、最上層floraから、woodの最右twigが最上層floraの最右plantになるまでwoodを作成する。woodを作成するgraftは、最初は最上層floraの最左plantであり、次からは作成されたwoodの最右twigの右隣のplantである。graftの指す統語範疇の到達可能リストの中からtrunkを予想する。graftの指す統語範疇が不明な場合は全ての統語範疇がtrunkとする。ただし、trunkのレベルは処理レベルと同じレベルでなくてはならない。
4. trunkとgraftの指す統語範疇が同一であるか、一度展開した後でgraftの統語範疇が不明である場合にそのwoodは正しいとされる。twigのリミットがgraftを指すまで、統合規則を用いて展開し、FWとSWを作成する。ただし、その統合規則は、統合範疇が現在のtrunkと同一であること、第一範疇が現在のgraftの指す統語範疇の到達可能リストの中にあること、第二範疇が現在のgraftの右隣のplantからtwigのリミットまでのplantの指す到達可能リストの中にあることの条件を満たさなくてはならない。この条件は、到達可能リストをもつべき統語範疇が不明である場合には満たされているものとする。
5. FWとSWが共に正しく、FWの最右twigがSWの最左twigに隣接している場合、統合規則を用いて最終的なwoodを作成する。

4.4 尤度評価

作成されたgroveは、評価式(1)に従って、自動的に尤度評価される。

$$PDG = \Sigma(LS \times NCS) / NS \qquad (1)$$

PDGはgroveの尤度、LSはgrove中の各shrubの認知規則がもつ統語範疇のレベル、NCSはgrove中の各shrubの範囲に対応する文字数、NSはgrove中に含まれるshrubの総数である。もしも、shrubが未知語の場合には、LSは0である。この式は、入力文をできるだけ少ないshrubに分割し、そのshrubができるだけ多くの文字を高いレベルをもつ統語範疇でまとめている場合に、PDGが高くなるようにしている。システムは、PDGに従ってgroveをソートし、上位10位までのgroveを構文解析に送る。10位よりも下のgroveは、確実性の低いshrubで構成されていることが多いためforestを作成しても無駄であると判断した。

作成されたforestは、最上層floraのplantから、評価式(2)に従って、自動的に尤度評価される。

$$PDF = \Sigma(LP \times NCP) / NP \qquad (2)$$

PDFはforestの尤度、LPは最上層flora中の各plantが指す統語範疇のレベル、NCPは最上層flora中の各plantの範囲に対応する文字数、NPは最上層flora中に含まれるplantの総数である。もしも、plantが指す統語範疇が不明な場合には、LPは0である。この式も、groveをできるだけ少ないplantに統括し、そのplantができるだけ多くの文字を高いレベルをもつ統語範疇でまとめている場合に、PDFが高くなるようにしている。最終的に、システムは、PDFとPDGの和に従ってforestをソートし、上位20位までのforestを表示する。もしも、20よりも多くforestが作成された場合、その入力文を解析するには単語やCFGの規則があまりに不足していることを示している。そのような状態では、効率よく学習することが難しいため、入力文は無視される。この20という値は、ユーザが選択可能な候補数と判断したからである。

5．評価実験

5.1 実験手順と結果

本手法と不完全情報からの学習を実装したシステムを作成しその評価実験を行った。実験は2通り行い、実験1はクローズデータに対するもので、実験2はオープンデータに対するものである。実験1は「外国人のための日本語学習用テキスト」の中から860文をかな漢字交じりのまま抜き出し、同じ順序で30回繰り返して入力した。実験2は実験1と同じデータを一回だけ入力した後、「科学の絵本」(数字は入力文数、340)、小学1－3年の「国語・上」(それぞれ、132,300,256)、中学1年の「国語」(64)、中学「公民」(1508)をこの順で入力していった。今回の実験では、ユーザが関与することなく、全てを尤度評価に委ねて行っている。評価の基準は解析成功率と正解率の2つである。解析成功は、尤度評価1位のforestの最上層floraのplant数が1であるものである。正解は、解析が成功したforestを

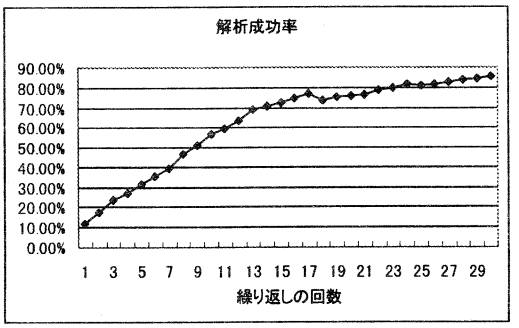
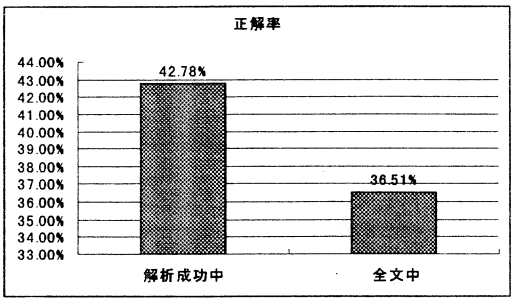


図8：実験1の解析成功率

我々が調べ、文節レベル以上の範囲に間違いがなかったものを正解とした。実験1の解析成功率と正解率を図8と図9にそれぞれ示す。実験2に関しては解析成功率だけを調べ、図 10 に示している。

5.2 考察

図8から、本手法と不完全情報からの学習を用いて平文から入力文を1つの統語範疇にまとめる CFG 規則の獲得が可能であることが確認される。しかし、図9にあるように正解率になると50%を下回っている。これは、学習のための結果を選択するのに尤度評価だけに頼っていることと、似たような表現を繰り返して入力しているために、人間から見て不自然な規則であっても、その入力を処理するのには不都合がなかったことが原因と考えられる。しかし、多様な表現で入力される実験2の結果(図 10)では、逆に類似した文が少なすぎるため、一つにまとめる CFG 規則が獲得できなかった。延べ入力文数の違い(実験1:25800,実験2:3460)もあるだろうが、オープンデータに対する有効性は確認できなかった。また、実験1にしても学習自体の効率は決してよいとはいえず、これらの問題の改善が必要とされる。だが、本手法の付与した不完全情報は我々が意図した通りのものであった。



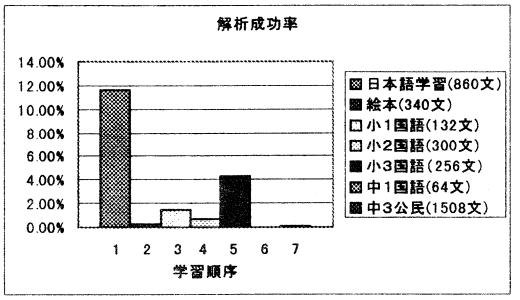


図9：実験1の正解率
図10：実験2の解析成功率

6．結論

我々は、不完全情報を付与できる形態素解析と統語解析の手法として Graft 法を提案した。本手法は、不十分な単語や CFG の規則であっても解析することができる。本手法の形態素解析は、高い確実性をもつ部分から shrub を当てはめていく。これにより、形態素解析と同時に低いレベルでの構文解析を済まし構文解析の負担を軽減している。構文解析では、トップダウンに wood を展開し、wood を flora 単位で積み上げていく。これにより、入力文全体に対応する統語範疇に依存せず、未知語を含んでいても処理することができ、その未知語に対応する統語範疇を推測し、可能な限り少ない統語範疇にまとめることができる。我々は、今後、この不完全情報から単語や CFG の規則を最大限引き出す学習の手法を開発する。

参考文献

[1] 荒木健治, 栃内香次：”帰納的学習による語の獲得および確実性を用いた語の認識”, 通信学論, J75-D-II, 7, pp.1213-1221(1992).

[2] 森信介, 長尾真：“統計によるタグ付きコーパスからの統語規則の獲得”, 自然言語処理, 110-12, pp.79-86(1995).

[3] 白井清昭, 徳永健伸, 田中穂積：“括弧付きコーパスからの日本語確率文脈自由文法の自動抽出”, 自然言語処理, 4, 1, pp.125-146(1997).

[4] 横田和章, 亀田弘之, 藤崎博也：“日本語の文法および未知の認知単位の自動獲得のための一方法”, 自然言語処理, 3, 4, pp.115-128(1996).

[5] M.A.Harrison, “Introduction to Formal Language Theory”, Addison Wesley(1978).

[6] J.Earley, “An Efficient Context-Free Parsing Algorithm”, Comm. of ACM, 13, 2, pp.97-102(1970).

[7] 春野 雅彦, 白井 諭, 大山 芳史, “決定木を用いた日本語係受け解析”, 情処学論, 39, 12, pp.3177-3186(1998).

[8] 白井 諭, 池原 悟, 横尾 昭男, 木村 淳子, “階層的認識構造に着目した日本語従属節間の係り受け解析の方法とその精度”, 情処学論, 36, 10, pp.2353-2361(1995).

[9] Mosleh Hmoud Al-Adhaileh, Tang Enya Kong, “A FLEXIBLE EXAMPLE-BASED PARSER BASED ON THE SSTC”, Proc. of COLING-ACL'98, pp.687-693(1998).

[10] 荒木健治, 栃内香次, 永田邦一：“多段階分割法によるべた書き日本語文のかな漢字変換”, 情処学論, 28, 4, pp.412-421(1987).