14 ユーザに動的に適応する多言語検索手法の評価

王忠建* 荒木健治 栃内香次
(北大工)†

1 はじめに

インターネットの普及に伴い、電子化された種々の異なる膨大な言語文書が急増しており、しかし、大量の文書の検索に関する従来の研究 [1][2] は、検索対象が同一の言語である。一方、多言語を対象として十分な性能を発揮する検索技術はまだ開発されていない。多言語検索には、入力言語と検索対象言語が異なっており、その訳語に多義性があるため、検索結果は誤りを多く含んでいる可能性がある。また、ユーザの必要とする検索結果は人によって異なると考えられる。キーワード検索には検索の漏れを防ぐため、シソーラスを使用する。そのため不要な情報を含んだり、検索結果が膨大になるなどの問題を生じる。いかにして検索結果を絞り、ユーザに適応した検索結果を得るのかが重要な課題と考えられる。そこで本稿では、ユーザに適応するために、同義語の検索と類似検索を行ない、次にフィードバックされた検索結果を形態素解析し、検索対象文内の情報を利用する。また、本手法は検索結果から統計的情報を用いて、同じ内容であっても同義語の存在など多様な表現に対応するための検索、逆に、同一の単語でも異なる意味を持つ語のための検索結果の制約などの方法を用いてユーザに動的に適応する。

2 処理の概要

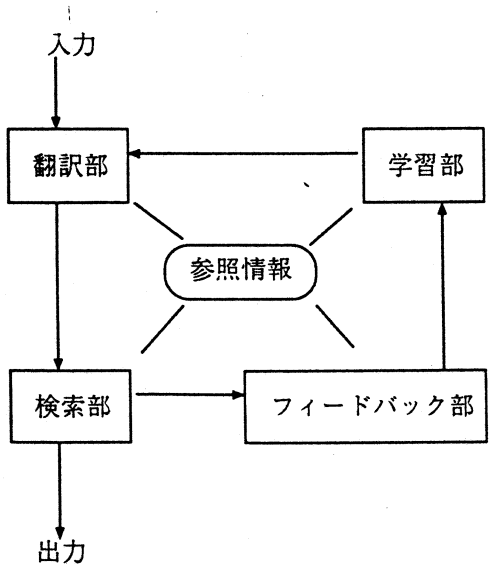


Fig. 1 処理の流れ

2.1 翻訳部

翻訳部では、入力語の英語キーワードを日本語に翻訳し、シソーラス [3] を用いて、同義語を求めて、検索語とする。更に、検索の漏れを軽減するため、類似検索を利用する。

2.2 検索部

検索部では、訳語とその同義語を検索語として、学習で獲得した参照情報 (正解と誤りのそれぞれの共通単語情報) を参照して全文検索を行なう。

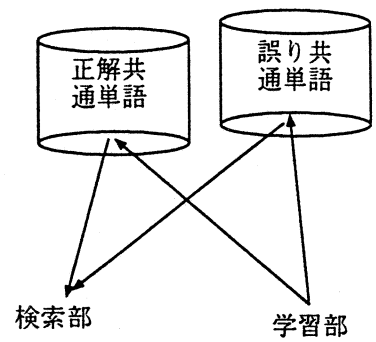


Fig. 2 参照情報

2.3 フィードバック部

フィードバック部では、ユーザは検索結果からランダムに選択したそれぞれ同じ数の正解と誤りを、学習部にフィードバックし、システムに学習させる。そして、検索する時、学習で獲得した統計的情報を利用して、検索結果の状況によってフィードバックするかどうかが決定される。フィードバックする場合、ユーザが正解と誤りを判断し、学習部へフィードバックする。

2.4 学習部

ここで、ユーザに適応する性能を高めるために、統計的手法を用いている。フィードバックされた正解と誤りの検索結果を形態素解析し、それぞれの共通単語の出現頻度を計算し、ユーザに適応した検索情報を統計的に抽出する。そして、検索を繰り返し、この適応情報を利用して絞った検索結果を見ながら、正解と誤りを人手で判断する。次に、この情報をフィードバックし、適合率, 式 (2) を用いて自動的に適合率を計算する。ゆう度, 式 (1) の中の重み係数を調節し、ある閾値を満足する適合率の検索結果の中、最も数が多い検索結果を出力する。

*wzj@media.eng.hokudai.ac.jp
†札幌市北区北 13 条西 8 丁目北海道大学工学部

$$\text{ゆう度値}\,(V) = \alpha\frac{\sum(CH)}{\sum(S)} - \beta\frac{\sum(EH)}{\sum(S)} \qquad (1)$$

式 (1) において、αとβは重み係数、$\sum(S)$ は一つ検索対象文中の単語の数である。また、正解と誤りのそれぞれの共通単語は検索対象文の長さに依存しないように $\sum(S)$ を用いて尤度式を正規化する。$\sum(CH)$、$\sum(EH)$ は検索対象文の中での正解と誤り単語の出現頻度の和を表す。

3 評価実験

3.1 実験

実験のデータはインターネットから入力された英語キーワードのすべての訳語を用いて情報検索ツール goo により検索された日本語文書 3010 文を用いた。英単語を検索語とした全文検索結果を絞るためにゆう度式を利用した。ゆう度式で、重み係数αの値とゆう度の閾値は予め与える。そして、適合率によってシステムが自動的にβを調節し、ユーザに適応した検索結果を求める。表1,2,3はフィードバックする前とフィードバックした後の適応した検索結果を示す。ここで検索結果を評価するのは適合率の式 (2) と再現率の式 (3) を用いている。

$$\text{適合率} = \frac{\text{正検索結果数}}{\text{全検索結果数}} \times 100\% \qquad (2)$$

$$\text{再現率} = \frac{\text{正検索結果数}}{\text{全正検索結果数}} \times 100\% \qquad (3)$$

Table 1 フィードバック前の検索結果

検索質問	検索結果	正解	誤り	適合率%
language	66	44	22	63.6
law	139	22	117	18.6
program	145	46	99	31.7
basis	72	7	65	9.7
平均				30.85

Table 2 一回目フィードバック後の検索結果

検索質問	検索結果	正解/誤り	適合率/再現率%
language	53	44/9	83.0/100.0
law	30	22/8	73.3/100.0
program	59	43/16	72.8/93.5
basis	15	7 / 8	46.6 / 100.0
平均			68.93 / 96.37

Table 3 二回目フィードバック後の検索結果

検索質問	検索結果	正解/誤り	適合率/再現率%
language	54	44/10	81.4/100.0
law	28	21/7	75.0/95.4
program	52	41/11	78.8/89.1
basis	9	7 / 2	77.7 / 100.0
平均			78.22 / 96.13

3.2 実験の考察

実験結果の表から見るとフィードバック後の適合率と再現率がかなり良いことが分かる。検索結果のフィードバックによってユーザごとに訳語の多義性を解消し、ユーザに適応した検索結果を得ることができた。更に共通単語を用い検索結果を絞ることが有効であることを証明した。

4 まとめ

本稿では、多言語テキストの情報を検索するという立場から、統計的情報を用い、ユーザに動的に適応する多言語の情報検索手法を提案した。多言語を対象とした情報検索手法は大きな需要があると考えられる。入力語と検索対象文、或いは出力語は異なる言語のため、訳語の多義性や検索の漏れ、検索結果が膨大になるなどの問題がある。これを解決するために、共通単語を利用して、検索結果を絞り、多義性を解消してユーザに適応した検索結果が得られた。小規模な実験であるが、提案した方法の有効性を示すことができた。今後は、実験の規模を拡大し、評価する予定である。

謝辞

本研究の一部は文部省科学研究費補助金 (課題番号 10680367) により行なわれた。また、以下のツールを使用させていただきました. 開発者の皆様に感謝致します。

京都大学工学部 長尾研究室, 奈良先端科学技術大学院大学 松本研究室:日本語形態素解析システム JUMAN

参考文献

[1] 長尾 真：自然言語処理, 岩波書店 (1996.4)

[2] 河瀬剛, 佐藤理史： 超並列計算機を用いた全文検索の高速化, 情報処理学会第 48 回全国大会論文集, 4E-03,1994.3. たべた書き文のかな漢字変換, 電子情報通信学会論文誌 D-II Vol.J79-D-II No.3 pp.391-402 1996.3

[3] 国立国語研究所：分類語彙表, 秀英出版社