241　帰納的学習を用いた平文からの語彙と文脈自由文法規則の自動獲得

渋木英潔　荒木健治　栃内香次
北海道大学大学院工学研究科

1　はじめに

自然言語を処理する一手法として，規則に基づいて解析する方法がある．この規則を人手により与えることは莫大な労力が必要とされる．また，学習を伴わずに作成された規則は静的なものとなり，現実の入力文のようにさまざまな言語現象に対応することができない．この問題を解決するために，平文から帰納的学習を用いて語彙と文脈自由文法規則を獲得することにより，対象に動的に適応する手法を開発した．

2　背景

文脈自由文法規則を獲得する従来研究には [1, 2, 3] などがある．[1, 2] は品詞タグや構文情報が付与されたコーパスを使用している．品詞や構文情報を付与するには多大な労力が必要であり，付与するスタイルにも個人差がある．そのため，入力は品詞及び構文情報などの字面以外の情報を持たない平文とし，品詞をはじめとする統語範疇は，帰納的学習により平文からシステムが自動的に獲得するものとした．平文からの獲得を扱った研究として [3] がある．[3] は既に存在する語彙や文脈自由文法規則の不足を補うことを目的としており，本手法のようにすべて空の状態から獲得することを対象としていない．仮に，空でない状態を初期状態とすると，事前に与えるべき規則はどのようなものであるべきなのかという問題が起こる．我々は，この問題を避けるため，規則の初期状態を空とした．

3　概要

まず，入力された平文に対し，それまでに獲得された語彙及び文脈自由文法規則を用いて，形態素解析と構文解析を行う．解析結果は解析木で表現される．本手法の解析の目的は，入力文が非文かどうかを判断するものではない．入力文には，意味的な非文（内容を伝えることの出来ない文）はないと仮定する．そのため，どのような入力に対しても必ず何らかの解析結果を導き出すことができる．形態素解析では，入力文に確実性の高い語彙から順次当てはめていく．当てはめることのできなかった部分は一つの未知語と見なして処理を進める．構文解析では，ボトムを推測しながら小さな部分解析木を作成し，その部分解析木をより大きな部分解析木にまとめる方法をとっている．これによって，語彙や文脈自由文法の規則の量的な不足に関わらず，解析結果を導き出すことが可能となる．

導き出された解析結果が不完全である場合，解析に必要な規則が欠如していると判断する．不完全な解析結果とは，解析木の頂点の数が 1 でない場合，解析木の品詞に相当するノードと語彙とが結びついていない場合のどちらかである．前者の場合，「隣接する二つのノードは一つのノードにまとめることができる」というヒューリスティックに従って，解析木の頂点のノードをまとめる文脈自由文法の規則を獲得する．後者の場合，「同じ位置に対応するノードと語彙は結びつく」というヒューリスティックに従って，対応するノードと語彙を結び付ける．

品詞を初めとする統語範疇は番号で識別され，必要に応じて任意に獲得することができる．獲得された統語範疇は，「周囲の環境が同一である統語範疇は同一である」というヒューリスティックに従って同一化される．このようにして，自動的に品詞体系を構築していく．

4　評価実験

本手法を実装したシステムを作成し，評価実験を行った．評価基準として，解析成功率と正解率の二つを設けた．解析の成功は，一つの解析木で表現された場合とした．解析の正解は，成功した解析結果の中で，文節以上の単位において係り受け関係に誤りがないものとした．使用したコーパスは外国人用の日本語学習テキスト [4] である．このコーパスを 30 回繰り返して入力した結果，解析成功率が 85.3%，正解率が 42.8%となった．繰り返して入力する理由は，幼児初期の言語獲得が，よく知った文脈で，よく知った大人の言葉の使い方にふれる経験と密接に関係している [5] ことから繰り返しが有効と判断したためである．解析成功率の値は，本手法の有効性を示すものと考えられる．しかし，正解率が 50%を下回っている．これは，同じコーパスを繰り返して入力したため，同じ表現が何度も出現し，人間から見て不自然であっても，その表現専用に特化した規則が獲得されたことが原因と考えられる．

5　むすび

平文に対して形態素解析と構文解析を行い，その結果に帰納的学習を用いることで，語彙と文脈自由文法規則を自動的に獲得できることを確認した．

謝辞　本研究の一部は，文部省科学研究費補助金（No.10680367）により行われた．

参考文献

[1] 森信介，長尾真，“統計によるタグ付きコーパスからの統語規則の獲得，” 信学技報，NLC110-12, pp.79-86(1995).

[2] 白井清昭，徳永健伸，田中穂積，“括弧付きコーパスからの日本語確率文脈自由文法の自動抽出，” 自然言語処理，4, 1, pp.125-146(1997).

[3] M. Kiyono, J. Tsujii, “Hypothesis Selection in Grammar Acquisition,” Proc. of the 15th COLING, 2, pp.837-841(1994).

[4] 片桐ユズル，はじめてのにほんご，大修館書店 (1990).

[5] ジョージ・バターワース，マーガレット・ハリス，発達心理学の基本を学ぶ，村井潤一監訳，小山正，神土陽子，松下共訳，ミネルヴァ書房 (1997).