242 帰納的学習を用いた単語分割手法の中国語への適用

王 忠建 荒木健治 栃内香次
北海道大学大学院工学研究科

1 はじめに

日本語を計算機で扱う場合、まず単語に分けなければならない問題がある。我々は帰納的学習を用いた日本語の形態素解析手法を提案し、その有効性を確認した[1]。本手法は文法的知識を用いていないので、どのような言語にも適用できる手法である。中国語[2]も日本語と同様にべた書きで単語間の区切りのない言語である。そこで、本稿では本手法の汎用性を確認するために、本手法を中国語へ適用し、その有効性を確認した実験の結果を報告する。中国語の単語分割に関する研究[3]は、大別すると2つの流れがある。一つは機械分割法（規則に基づく）であり、もう1つは知能分割法である。これらの方法は予め単語辞書を準備する必要がある。しかし、すべての単語と各種規則を予め辞書に登録することは不可能である。その問題点を解決するために、帰納的学習による単語分割手法を開発した。本手法では予め単語辞書、規則辞書の構築の必要がなく、単語辞書は空から学習を繰り返すに従って自動的に獲得されるので次第に単語分割精度が高くなる。

2 処理の概要

処理の流れを図1に示す。

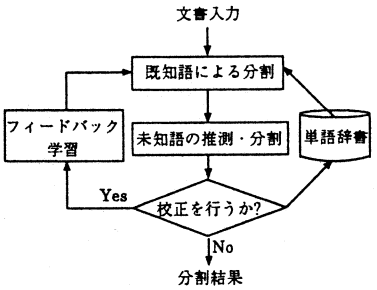


図1:処理の流れ

2.1 既知語による分割

それまでに獲得した単語を用いて文を単語単位に分割する。分割候補が重複する場合、尤度及び誤分割率、正分割率、長さ、分割の位置などの順に情報を用いて正しい候補を決定する[1]。

2.2 未知語の推測

辞書に登録されていない単語は帰納的学習を用いて推測する。文の中に共通に出現する文字列は共通パターンとして抽出する。その抽出した共通パターンに基づく単語の確実性の高いものより辞書に登録し、単語分割を行う。

2.3 フィードバック学習

ユーザは分割結果に誤りがある場合校正を行う。校正済みの結果をシステムにフィードバックして、システムが自動的に正しい単語及び使用した単語の出現頻度、分割の正分割率、誤分割率などを辞書に登録する。

3 評価実験

3.1 実験

実験データはInternet上で引用した新聞記事の96文（3,100単語）を用いた。辞書は空から始める。システムが自動的に分割を行って、文字列の共通パターンを抽出し、単語として登録する。修正した結果をシステムにフィードバックして学習させる。表1の結果は平均4回繰り返した結果である。

3.2 結果及び考察

フィードバック前の結果はシステムが自動的に処理した結果である。この結果を見ると辞書は空からシステムが自動的に未知語の推測できることが分かった。推測できなかった部分はフィードバックでユーザが分割結果を校正して、システムにフィードバックする。フィードバック後の結果はシステムが処理を繰返し行い学習した後の分割結果である。結果の評価は下の三つの式を用いた。

正分割率＝（正分割数／総単語数）x100%
誤分割率＝（誤分割数／総単語数）x100%
未分割率＝（未分割数／総単語数）x100%

表1: 単語分割実験結果

フィードバック前		
正分割率[%]	誤分割率[%]	未分割率[%]
62.0	15.6	22.2
フィードバック後		
正分割率[%]	誤分割率[%]	未分割率[%]
90.3	9.4	0.4

4 まとめ

本稿では帰納的学習を用いた文を単語に分割する手法を中国語へ適用し、その汎用性を確認する実験を行った。小規模な実験により本手法は中国語へ適用できることが分かった。今後、実験の規模を拡大し、品詞情報を付与することを研究する予定である。

謝辞

本研究の一部は文部省科学研究費補助金（課題番号10680367）により行なわれた。

参考文献

[1] 荒木健治、栃内香次、帰納的学習による語の獲得および確実性を用いた語の認識、電子情報通信学会論文誌 D-II Vol.J75-D-II No7 pp.1213-1221 1992年7月

[2] 望月十八吉、中国語と日本語、光生館(1974).

[3] 呉勝遠、一種漢語分詞方法、計算機研究与発展、Vol.33 No.4 pp.306-311 Apr.1996