243　構文解析例からの帰納的学習を用いた構文解析規則の獲得

正富 欣之　荒木 健治　栃内 香次
北大工

1　はじめに

自然言語の文内容は何らかの構造を持ったものであるが、それが発話あるいは表記されると1次元の単語の並びに変換される。したがって、文内容の構造を理解するために、構造を復元する処理が必要となる。自然言語処理において、構造を復元する処理である構文解析は重要な役割を果たすものである。

本稿では、構文解析規則の獲得の研究について述べる。解析規則を用いて構文解析を行なう場合、抽象的文法規則は対象に依存するような言語現象への対処が困難である。また、用例から得られた具体的な規則ではその量が膨大である。そこで、自動的に解析規則を獲得することによりさまざまな抽象度の解析規則を獲得し、それらを用いて最適な抽象度の解析規則を適用することにより精度を向上させる。したがって、上記のことを実現するために本手法では構文解析例（単語列と構文解析結果の組）から帰納的学習を用いることにより構文解析規則を獲得する。本手法の利点としては、規則を人手により与えていないので、会話文などの非文法的な文や省略の多い文にも柔軟に対応できることが考えられる。また、一般的には難しい対象に依存した文の解析もシステムが動的に適応することにより解決できることが多い。これは、このような限定された対象にのみ有効な規則を学習により自動的に生成することができるからである。さらには、構文解析例から学習できるので、適応能力が高く、さまざまな文章に対応できる。

2　概要

入力された単語列は構文解析規則により構文解析が行なわれ結果が得られる。この単語列は帰納的学習による単語の認識 [1] によって得られる。構文解析結果に誤りが含まれる場合には校正処理を行なう。校正処理部で使用する構文解析結果は日本語構文解析システム KNP [2] の結果である。ただし、KNP の結果に誤りが含まれていたり、解析不能であった場合は人手により校正する。学習処理部では、得られた校正済み構文解析結果（品詞情報付）と単語列の組を用いて帰納的学習を行ない、構文解析規則を獲得する。さらに、誤った結果を生成した場合、正解と誤りの差分より誤りの原因となったルールを推定することによりフィードバック処理を行なう。以上のような処理を繰り返すことにより、質の高い構文解析規則辞書が得られ、構文解析結果の精度が向上する。

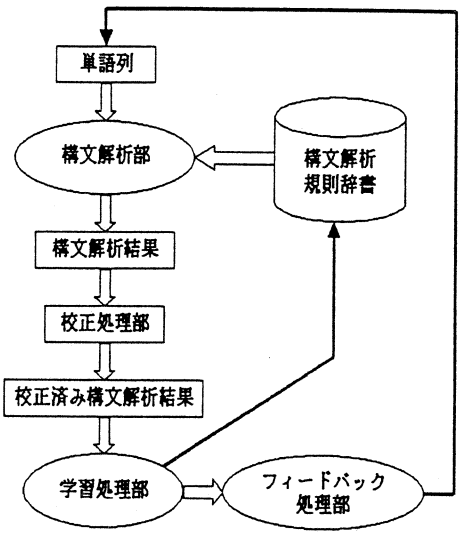


Fig. 1　処理過程

3　処理過程

本手法の処理の流れを Fig. 1 に示す。Fig. 1 のように本手法は、構文解析、校正処理、学習処理、フィードバック処理の順に行なわれる。

3.1　学習処理

学習処理では、単語列と校正済み構文解析結果を用いて構文解析規則を獲得する。単語列と校正済み構文解析結果の共通部分と差異部分から構文解析規則を獲得する。この操作を獲得された規則について新たに新しい規則が抽出されなくなるまで再帰的に繰り返す [3]。係受け関係については、単語間の複数の関係がすべて同一の場合のみ共通部分であるとし、それ以外は差異部分とする。係受け関係の差異部分から獲得される構文解析規則は係受けの語の組にして記憶する。構文解析規則は、係受け関係の共通部分が 50 %以上で、かつ字面上の一致が 50 %以上の場合に獲得される。

帰納的学習を用いた構文解析規則の獲得例を Table 1 に示す。1 と 2 の入力文と校正済み構文解析結果の組を比較すると、係受け関係はすべて一致しているので、「私」と「彼」の部分が差異部分となる。これより、

Table 1 構文解析規則の獲得例

1	入力文：私 は これ まで 多く の 試み を 行って きた。 校正済み構文解析結果： [(私 n は p)#4 (これ d まで p)#3 (多く n の p)#1 $1(試み n を p)#1 $1$3$4(行って v きた s)。]
2	入力文：彼 は これ まで 多く の 試み を 行って きた。 校正済み構文解析結果： [(彼 n は p)#4 (これ d まで p)#3 (多く n の p)#1 $1(試み n を p)#1 $1$3$4(行って v きた s)。]
3	入力文：私 は いま まで 多く の 業績 を 残して きた。 校正済み構文解析結果： [(私 n は p)#4 (いま d まで p)#3 (多く n の p)#1 $1(業績 n を p)#1 $1$3$4(残して v きた s)。]

1,2 より帰納的学習により獲得された構文解析規則
<@1 は これ まで 多く の 試み を 行って きた。:
[(@1 は p)#4 (これ d まで p)#3 (多く n の p)#1 $1(試み n を p)#1 $1$3$4(行って v きた s)。] >
<私：私 n > <彼：彼 n >

1,3 より帰納的学習により獲得された構文解析規則
<私 は @2 まで 多く の @3 を @4 きた。:
[(私 n は p)#4 (@2 まで p)#3 (多く n の p)#1 $1(@3 を p)#1 $1$3$4(@4 きた s)。] >
<彼：彼 n > <これ：これ d > <いま：いま n > <試み：試み n > <業績：業績 n >
<残して：残して v > <行なって：行なって v >

2,3 より帰納的学習により獲得された構文解析規則
<@1 は @2 まで 多く の @3 を @4 きた。:
[(@1 は p)#4 (@2 まで p)#3 (多く n の p)#1 $1(@3 を p)#1 $1$3$4(@4 きた s)。] >
<私：私 n > <彼：彼 n > <これ：これ d > <いま：いま n > <試み：試み n > <業績：業績 n >
<残して：残して v > <行なって：行なって v >

[]：文,()：文節,#?：文節番号,$?：係先番号,n：名詞,p：助詞,d 指示詞,v：動詞,s：接尾辞

獲得される構文解析規則は Table 1 の「私」と「彼」の部分が変数なったものが獲得される。同様に、1 と 3、2 と 3 の入力文と校正済み構文解析結果の組からも差異部分が変数となる構文解析規則が獲得される。

3.2 フィードバック処理

以下に、フィードバック処理での手順を示す。

1. 単語列および校正済み構文解析結果の共通部分と差異部分を決定する。
2. 共通部分を正解析、差異部分を誤解析とする。
3. 正しく解析した構文解析規則の正変換度数を 1 増加させる。
4. 誤って解析した構文解析規則の誤変換度数を 1 増加させる。

3.3 構文解析

入力された単語列を構文解析する処理である。単語列に対して、最大一致する構文解析規則を順に適用し結果を得る。複数の構文解析規則が適用可能な場合については、以下の順で規則を適用する。

1. 最長一致する構文解析規則で字面が最も多いもの。
2. 最も少ない構文解析規則で構成されているもの。
3. 構成している構文解析規則の正解析率の平均が最高のもの。
4. 構成している構文解析規則の正解析度数の和が最高のもの。
5. 構成している構文解析規則の誤解析度数の和が最低のもの。

4 おわりに

本稿では、単語列と構文解析結果の組から帰納的学習を用いることで、構文解析規則を獲得し、その規則を用いて構文解析を行なう手法について述べた。今後は本手法の有効性を確認するための実験を行ない、考察する予定である。

謝辞

なお、本研究の一部は科学研究費補助金（課題番号 10680367）により行なわれた。

参考文献

[1] 荒木健治, 栃内香次：帰納的学習による語の獲得および確実性を用いた語の認識, 電子通信学会論文誌 D-II, Vol.J75, No.7, pp.1213-1221, 1992.

[2] 黒橋禎夫：日本語構文解析システム KNP version 2.0 b6 使用説明書, 京都大学大学院情報学研究科, 1998.

[3] 荒木健治, 高橋祐治, 桃内佳雄, 栃内香次：帰納的学習を用いたべた書き文のかな漢字変換, 電子通信学会論文誌 D-II, Vol.J79, No.3, pp.391-402, 1996.