社団法人　電子情報通信学会
THE INSTITUTE OF ELECTRONICS,
INFORMATION AND COMMUNICATION ENGINEERS

信学技報
TECHNICAL REPORT OF IEICE.
TL2000-44, NLC2000-79(2001-03)

# 帰納的学習を用いた単語分割手法の多言語に対しての汎用性の評価

王 忠建　荒木 健治　栃内 香次
北海道大学大学院工学研究科
〒060-8623 札幌市北区北 13 条西 8 丁目
E-mail:{wzj,araki,tochinai}@media.eng.hokudai.ac.jp

あらまし　我々は特定の言語に依存しない単語分割手法の開発を目指し，帰納的学習を用いた単語分割手法を提案している．本手法においては文書中に重複して出現する文字列の共通部分および差異部分を再帰的に抽出し，単語として確実性の高いものから順に用いて文を単語に分割する．よって本手法では辞書，分割ルールなどを予め用意する必要がなく，入力文中の未知語を推測して辞書を自動的に生成し，更に分割結果を校正した情報を用いることにより文書を単語に分割する能力が向上する．実験により本手法は日本語，中国語に対しての有効性を既にそれぞれ確認された．本稿では，同一アルゴリズムを用いて異なる言語の実験結果により本手法の多言語への汎用性の確認を行う．

キーワード　多言語，単語分割，帰納的学習，汎用性

# Evaluation of Generality for Multi-language of Word Segmentation Method Using Inductive Learning

Zhongjian Wang　Kenji Araki　Koji Tochinai
Graduate School of　Engineering, Hokkaido University
N13－W8, Kita-ku, Sapporo 060--8628 Japan
E-mail: {wzj, araki, tochinai}@media.eng.hokudai.ac.jp

Abstract　We have proposed a method that segments a text into words by using inductive learning, and confirmed the performance to Japanese and Chinese word segmentation by experiments respectively. The method uses only the surface information of characters, so that it is independent on any specific language and a general method. In this paper, we do experiments of Japanese text and Chinese text with same algorithm simultaneously to demonstrate the generality of the method. The results of experiment show that the method is possible to be used to word segmentation of general non-segmented language.

key words　multi-language, word segmentation, inductive learning, generality

## 1. はじめに

機械翻訳，情報検索，及び音声認識などは全て単語を基本的な単位として行われる．そこで，日本語，中国語，タイ語などのように単語分かち書きをしない言語の自然言語処理において単語分割は欠かすことができない処理過程である，このように単語分かち書きをしない言語を計算機で扱うために，それぞれの言語における単語分割方法が開発されている．その手法は，大別して統計的な手法[1][2]，規則に基づく手法[3][4]と規則辞書と統計情報を融合する手法[5][6]があげられる．

統計的な手法では漢字の隣接情報を利用して単語の境界を決定している．しかし，一般にスパースネスの問題を解決するべく高精度な統計モデルを使用するために，大規模なデータが必要である．

規則に基づく手法は予め単語辞書及び曖昧分割を処理する規則を用意する．規則に基づく手法の正解率は辞書の大きさと規則の量に依存する．また，規則の抽出，整理及び更新には膨大な労力がかかる．

規則辞書と統計的な情報を融合する手法では規則辞書に基づいて統計的な情報で規則が適用可能かどうかを判断して，最適分割パスを決定している．また，規則に基づく手法，規則辞書と統計的な情報を融合する手法は予め単語辞書，タグ付きコーパスなどの用意が必要である．しかし，すべての単語と各種規則を登録するのは不可能であり，大規模なタグ付きコーパスの作成にも多くの労力が必要となる．

さらに，情報技術，インターネットの発展に伴い，様々な言語情報が膨大に存在するので，複数の言語を処理できる技術の開発が必要となった．我々はこの要求に応じて多言語の単語分割処理を目指して帰納的学習アルゴリズムを提案した[7][8]．本手法では予め単語辞書，規則辞書，タグ付きコーパスなどを準備する必要は一切ない．更に，表層レベルの字面情報のみから単語分割が行えるので言語に依存せず多言語に対応できるという利点がある．本手法は字面情報を利用し，文書に頻繁に出現する文字列を再帰的に二段階に共通部分，差異部分を抽出する．異なる抽出状況により抽出された共通部分，差異部分を単語としての確実性の高い順に獲得する．以下本論文では文字列より抽出されたすべての共通部分，及び差異部分を WS(Word segment)と呼ぶ．WS は抽出状況により S1，S2，S3 に分類して辞書に登録する．そして，WS を用いて文を単語に分割する．ユーザが分割結果の誤りを校正する．この校正過程で単語として確認された WS は CW(Correct word)と呼ぶ．分割結果と校正済みの分割結果を比較することにより，登録された CW，WS の正分割度数，誤分割度数，未分割度数などの情報を更新する．

共通部分と差異部分を再帰的に抽出するとは入力文を更に細かく分割できなくなるまで繰り返して共通部分と差異部分を抽出し，抽出された共通部分から更に共通部分及び差異部分を抽出するということである．なお，本論文で帰納的学習とは文書中に重複して出現する文字列を再帰的に抽出する過程である．

本文には日本語の実験に EDR コーパス [1] からの文書，中国語の実験に Sinica コーパス [2] からの文書を用いた．

日本語の文字は漢字，仮名で書かれて時制などの形態変化があり，文法上の関係を表す語，いわゆる，助詞などが存在する．日本語の特徴をまとめるヒュ—リスティクスを利用してある程度の単語を認識することができる．一方、中国語では漢字を羅列するだけで，単語と単語との切れ目を示さない．また，漢字の大部分が表意文字であり，一つの漢字が一つの音節を持ち，一つの概念を持つことが多い．単語は一つあるいは複数の漢字で構成される．中国語は単語の形式が変化せず，主として単語の位置で文法上の関係を表す．複合語に含まれる各単語は基礎的文法にしたがって成立し，修飾と被修飾部分の組み合わせによって単語となる．文脈によって単語の切れ目と品詞の分類が異なる[9]．日本語も中国語も単語を構成する同じ漢字が他の単語に出現し，更に一つの単語として存在し得る．このような特徴によって，単語分割では複数の分割可能性を持つ曖昧分割が生じやすい．

このような異なる特徴を持つ 2 言語に対して我々は同一アルゴリズムを用いて単語分割実験を行った．それらの実験結果より本アルゴリズムが固有の言語に依存せず、多言語に対して汎用性を有することを

---

[1] Sinica Corpus, http://rocling.iis.sinica.edu.tw//ROCLING/index_c.htm

[2] http://www.iijnet.or.jp/edr/

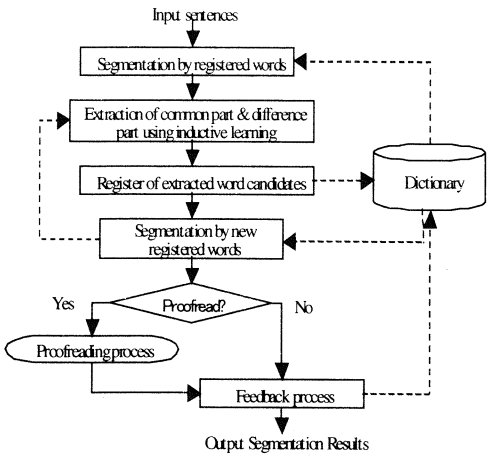



図 1: 処理の流れ

確認することができた.

## 2. 概要

図 1 に本手法の流れを示す. まず, 文を入力して, すでに辞書に登録されている CW, WS を用いて文書を単語に分割する. ここで分割されなかった部分文字列について帰納的学習を用いて未知語を推測する. 未知語の推測は文書中に複数回出現する文字列を再帰的に抽出することにより行われる. 抽出過程は文書から重複して出現する文字列を再帰的に抽出する過程と抽出された文字列から更に共通部分, 差異部分を抽出する過程の二段階で行われる. 抽出された文字列すなわち WS を単語としての確実性の高い順に分類する. 抽出された WS は抽出状況によって単語としての優先順位が決定され, 辞書に登録される. そして, 推測された WS で分割を行う. この抽出, 分割の過程は分割できる部分が分割を終わるまで繰り返す. ユーザは分割結果の正誤を判断し, 分割結果の誤りを校正する. システムは分割結果と校正により得られた正しい結果を比較することにより, 辞書に登録されている CW と WS の正分割度数, 誤分割度数及び頻度の情報を更新する. 更に, 校正で得られた正しい分割結果を用いて正しい単語を CW として辞書に登録する. このような処理を繰り返すことによって, システムは更新された辞書を用いて新しい入力文を分割し, 更に正分割率が徐々に上昇していく.

## 3. 処理過程

### 3.1. 獲得された語による分割

それまでに辞書に獲得された CW, WS を用いて文を単語に分割する. CW は校正処理により単語として確認されたものである. CW で分割されなかった部分文字列は文字列の抽出により獲得された WS を用いて分割を行う. WS は抽出された共通部分 S1, 再抽出された共通部分 S2, 残りの差異部分 S3 で構成され, 単語としての確実性の高い順は S2, S1, S3 である(3.2 参照). そして, S2, S1, S3 の順で分割を行う. 処理手順を以下に示す.

1. 辞書中に既に登録され, かつ単語として確認された CW と入力文中の部分文字列をマッチングすることにより単語分割を行う. ただし, マッチングされた分割候補が複数個存在する場合, 正しい分割候補はゆう度評価関数の値の大きい順に決定し, 分割を行う.
2. 同じゆう度評価関数の値の分割候補が複数個存在する場合, 誤分割度数の小さいものを選択する. 更に, 同じ誤分割度数の分割候補が複数個存在する場合, 正分割度数の高いものを選択し, 以下, 順に出現頻度の高いもの, 文字数の多いもの, 分割位置が一番前のものの順に決定し, 分割を行う.
3. CW の単語がない場合, WS を S2, S1, S3 の順に用いて分割を行う. また, 重複が存在する場合, ゆう度評価関数の値, 及び (2) の手順にしたがって正しい分割候補を決定して分割を行う.

以下にゆう度評価関数 LEF(Likely Evaluation Function)を示す.

$$LEF = FR + \alpha \cdot CS - \beta \cdot ES + \gamma \cdot LE \quad (1)$$

FR(Frequency of appearance), CS(Frequency of correct segmentation), ES(Frequency of erroneous segmentation), LE(Length of CW or WS)は登録された CW あるいは WS の正分割度数, 誤分割度数, 出現頻度, 単語の文字数である. α, β, γは係数である. このゆう度評価関数は出現頻度が高く, 正分割度数が高く, 誤分割度数が低く, 更に文字数の多い CW, WS を優先的に用いることを表している.

### 3.2. 未知語の推測

獲得された CW で分割されなかった部分文字列に

ついては帰納的学習を用いて未知語の推測を行う．文中に複数回現れる文字列は単語として確実性が高いと考えられるので，これらの文字列から再帰的に共通部分と差異部分を抽出することにより未知語を推測する(未知語とは今まで辞書に登録されない語を指す)．また文字列の抽出は再帰的に二段階すなわち共通部分の抽出と高次共通部分の抽出を行い，かつ抽出される状況により単語とする確実性の高い順に三つのクラス S2，S1，S3 に分類される．図2に分かち書きをしない文書の一般の例を示す．この図2の例を用いて次に未知語の推測方法を述べる．

αβχδκφεφγοπμτγβπαβχδοπμτγβ
ηφεφγτγβαζθ。

図2 分かち書きをしない文の例

### 1. 共通部分の抽出

文頭から1文字ずつ用いて2文字以上の共通部分を取り出す．取り出された共通部分の文字列はαβχδ，βχδ，χδ，φεφγ，εφγ，φγ，οπμτγβ，πμτγβ，μτγβ，τγβ，γβである．

それら抽出された共通部分を長い順に用いて文の分割を試みる．文を分割できたものを対象として更に共通部分と差異部分の抽出を行う．この段階で抽出される文字列を S1(Segment one)と呼ぶ．抽出条件以下に示す．二文字以上の文字列が文書中に重複して出現する場合，S1 として抽出する 図1の文書において，抽出された S1 としての単語候補は“αβχδ”，“φεφγ”，及び“οπμτγβ”である．

また，抽出された S1 に含まれ，かつ他の S1 のどこにも含まれていない出現位置が少なくとも一つある文字列も S1 として抽出される．例えば，“τγβ”は抽出され，S1 とする．

### 2. 高次共通部分の抽出

抽出された共通部分に他の共通部分が含まれる場合には，更に共通部分と差異部分を抽出する．これは，一つの共通部分が複数の単語によって構成される可能性があるからである．このような再帰的な共通部分，差異部分の抽出により，単語としてより確実性の高いものを抽出することができる．この S1 からの共通部分の再抽出は高次共通部分の抽出という．高次共通部分は単語として最も確実性が高いと考えられる．高次共通部分の抽出条件を以下に示す．

①．共通部分 S2 の抽出と残りの差異部分 S3 の処理：

抽出された S1 同士の共通部分が存在する，あるいは，S1 に別の S1 が含まれていて，更に別の S1 に含まれない出現位置が少なくとも一つ存在する場合，この S1 の共通部分を抽出して，S2(Segment two)という．残りの差異部分は S3(Segment three)という．例えば，“τγβ(S1)”は“οπμτγβ(S1)”に含まれ，“οπμτγβ”から“τγβ”を抽出できる．“τγβ”を抽出して S2 に所属させ，残りの差異部分“οπμ”は S3 に所属させる．

②．一文字単語の処理

一文字が分割済みの単語で囲まれている場合，この一文字を単語として抽出する．抽出された一文字の単語は S2 に所属させる．図2おいて，“π”は“οπμτγβπαβχδ”において“οπμτγβ”と“αβχδ”で囲まれており，両側は分割済みのため，“π”を抽出して S2 に所属させる．

抽出した共通部分，差異部分を WS といい，単語として確実性の高い順に辞書に登録する．このようにして抽出された WS は，単語としての確実性の高い順に S2，S1，S3 である．校正処理で確認された正しい単語である CW に所属しているもの，及び帰納的学習で抽出された WS を S1，S2，S3 に分類したものを辞書に登録する．登録する際には同時に CW，WS の正分割度数 CS，誤分割度数 ES，頻度 FR，文字数 LE 及びその分類 LC(S2，S1，S3)も登録する．

### 3.3. 推測された語による分割

既に登録された CW を用いて分割されなかった部分に対して，推測された WS を用いて単語として確からしさの高い順に分割が行われる．ここで推測された WS を S2，S1，S3 の順に用いて分割を行う．具体的な処理過程を以下に示す．

- S2，S1，S3 の順で WS を用いて文を単語に分割する．
- 分割候補が複数個存在する場合，ゆう度評価関数の値が大きいものを優先的に用いて分割する．

● ゆう度評価関数の値が同じ分割候補が複数個ある場合の処理は3.1節の2と同様である．

### 3.4. フィードバック処理

必要があれば，ユーザが分割結果の誤りを校正する．次に，システムは分割結果と校正された正しい分割結果を比較することにより，辞書に登録されている正分割度数，誤分割度数，頻度及び分類を更新する．正分割の場合，分割に用いた CW あるいは WS の正分割度数を増加させる．誤った分割の場合，分割に用いた CW あるいは WS の誤分割度数を増加させる．CW, WS のゆう度を更新する方法は以下のとおりである．

1. 正分割結果のゆう度の更新:

正分割の場合，正分割に用いた CW，WS の頻度と正分割度数を増加させる．更に，正分割に用いた WS の分類を CW とする．

2. 誤分割結果のゆう度の更新:

①. 誤分割に用いた CW, WS の誤分割度数を 1 増加させる．更に以下の処理を行う．

②. 正しい単語が辞書にない場合，正しい単語の頻度 FR を 1 にして，CW として辞書に登録する．

③. 正しい単語あるいは WS が辞書にある場合，システムはその単語あるいは WS の頻度 FR を 1 増加する．更に WS の所属を CW とする．

3. 未分割結果の処理

分割されなかった部分文字列に対して校正済み分割結果より正しい単語を辞書に登録する．登録された単語の頻度を 1 にして，分類を CW にする．

## 4. 評価実験

本手法の多言語への汎用性及び異なる分野文書への適応性を確認するために，三分野の中国語文書と日本語文書への評価実験を行った．実験結果を評価するために，式(2)，(3)，(4)に示す正分割率，誤分割率，未分割率を用いた．本論文では正分割数とは分割結果において人間によって与えられた分割結果と完全に一致する数である．未分割数とは未分割文字列を，正しく分割した際に用いられる単語数である．誤分割数とは総単語数から正分割数と未分割数を除いた数である．

$$\text{正分割率} = \frac{\text{正分割数}}{\text{総単語数}} \times 100\ [\%] \qquad (2)$$

$$\text{誤分割率} = \frac{\text{誤分割数}}{\text{総単語数}} \times 100\ [\%] \qquad (3)$$

$$\text{未分割率} = \frac{\text{未分割数}}{\text{総単語数}} \times 100\ [\%] \qquad (4)$$

### 4.1. 予備実験によるゆう度評価関数の係数の決定

まず，ゆう度評価関数の係数の最適値を決定するために予備実験を行った．250 文の中国語の経済学の文書（約 7,000 単語）を用いて，欲張り法[10]でゆう度関数の係数を変化させ最大の正分割率が得られる最適な係数値を求めた．まず $\alpha, \beta$ に初期値を与え，$\gamma$ を変化させ，正分割率が最大となる $\gamma$ の値を求める．次に $\beta$ の値を変化させ正分割率が最大となる $\beta$ の値を求める．そして，$\alpha$ を変化させ正分割率が最大となる $\alpha$ の値を求める．このような操作を繰り返して正分割率が安定している時が最適な係数の値とした．実験により最適な係数は $\alpha=1, \beta=70$, 及び $\gamma=50$ であった．

### 4.2. 実験データ

Sinica コーパスから建築学 145,727 単語，経済学 113,000 単語と電子工程学 116,110 単語の文書のデータを用いた．建築学には建築美学，建築評論及び建築新聞などの文書がある．経済学には経済システム，経済政策及び経済理論などの文書がある．電子工程学には電子工学，通信工程及び器械工程，核工業などの文書がある．合わせて 374,837 単語の文書をデータとして分野ごとに対しての適合性の評価実験を行った．

EDR コーパスから 389,230 単語の文書を用いて各言語ごとに対しての汎用性についての評価実験を行った．

### 4.3. 実験手順

実験は辞書が空の状態から始め，中国語の三つ分野の文書を一分野づつ，一つの分野の文書に対して約 100 単語の段落を一段落づつ入力して実験を行っ

表1．日本語と中国語の分割実験結果

| 言　語 | 中国語文書(総単語数：374,837) | | | | 日本語文書 |
|---|---|---|---|---|---|
| 分　野 | Architecture | Economics | Engineering | Average | |
| 単　語　数 | 145,727 | 113,000 | 116,110 | | 269,858 |
| 正分割率[%] | 89.3 | 91.2 | 91.9 | 90.6 | 87.5 |
| 誤分割率[%] | 10.1 | 8.4 | 8.1 | 9.0 | 12.3 |
| 未分割率[%] | 0.6 | 0.4 | 0.0 | 0.4 | 0.2 |

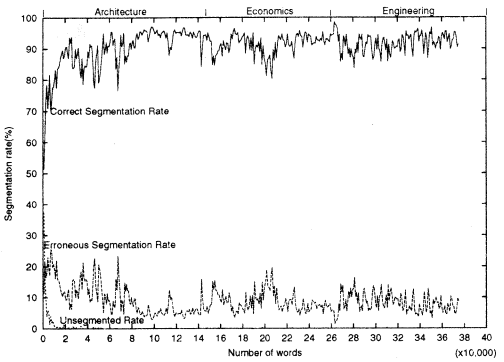



図2．Sinicaから三分野文書の分割率の推移

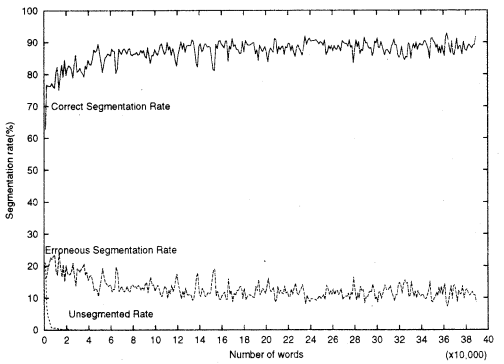



図3．EDRからの日本語文書の分割率の推移

た．システムは帰納的学習を用いてWSを抽出することにより未知語を推測し，辞書が自動的に生成される．フィードバック処理ではユーザが分割結果の誤りを校正し，システムが分割結果と校正済み分割結果とを比較することにより，辞書に登録されたCW，WSの情報を更新する．日本語文書の実験は同様に約100単語の段落で入力して行った．

### 4.4. 実験結果と考察

実験結果を表1と図2、図3に示す．図2，図3には中国語文書と日本語文書それぞれの正分割率，誤分割率と未分割率の推移を表している．表1は日本語の平均分割率と中国語の3分野のデータを順番に入力した場合，それぞれの分野の平均分割率と全体結果の平均分割率を示している．

#### 1. 分野ごとに適応性

表1に示されるように中国語3分野の文書それぞれの平均正分割率は89.3%，91.2%と91.9%で，総平均正分割率は90.6%となった．上記の374,837単語の文書中には人名，地名などの固有名詞，専門用語などが含まれているが，それに対して特別な処理を行わなくても帰納的学習を用いて未知語を推測できることが確認された．

最初は辞書が空なので未知語を推測しながら分割を行い，未知語が推測され登録される単語数が増加するにつれて正分割率が向上している．約23,000単語が処理されたとき，正分割率が約95%になったが，その後辞書に登録されたCW，WSが増加するのに伴い，曖昧分割が原因で誤分割率が大きくなっている．しかし，約80,000単語が処理されたとき，フィードバックの効果により登録されたCW，WSの正分割度数，誤分割度数などが更新され，誤分割率が低下し，正分割率が上昇している．

分野が変化したとき，正分割率は一時的に低下している．これは専門用語などの未知語が出現したことが原因であるが，帰納的学習で未知語を推測し，

獲得することにより正分割率は再び上昇している．また，局所的に変化する個所が見られ，そこの正分割率が低下しているが，これは分野内での細かい変化のために未知語が出現したことが原因と考えられる．例えば，建築学には建築美学，建築評論及び建築新聞などの文書があるため，新しい用語が出現し，正分割率に影響を与える．

## 2. 言語ごとに汎用性

図3に日本語文書の単語分割の正分割率，誤分割率，未分割率の推移を表している．EDRコーパスのテキスト文書は分野ごとにまとめられていないため，図2の分野ごとの中国語の実験結果と比べると，正分割率の大きい変化が見られなかったが，これは異なる分野の文書が混在しているため専門用語などが徐々に発生し，用語の大きな変化がないことが原因と考えられ，処理された単語数が増加するに従って正分割率が徐々に上昇していることを示している，実験の終わりごろ，正分割率はほぼ90%に達したが平均総正分割率は87.5%であった．

同一アルゴリズムで異なる言語を用いた実験結果によると本手法は言語ごとに適応すること，即ち，汎用性を持つことが分かった．

## 3. 誤りの原因と校正処理について

図2，図3に示している誤分割率の推移曲線は，処理される単語数の増加に従い誤分割率が下がっていることを示している．更に，図2，図3中の未分割率の推移曲線は未知語を推測する能力を表している．実験の始めは辞書が空なので，分割は推測されたWSにより行われたため，未分割率は高かった．しかし，辞書が自動的に生成されるにしたがって未分割率が大幅に減少し，約20,000単語を処理した後，総平均未分割率は0.4%であった(図2参照)．図3から分かるように日本語単語分割において正分割率が上昇している傾向と誤分割率が減少している傾向はその有効性を示している．図4に処理された単語の数が増加するに伴う，結果の誤りを校正する回数(誤りの校正と未分割語の入力の総回数)の変化を示す．中国語に対しては辞書が空の場合の校正回数と111,000単語を処理した後の校正回数とを比較すると，98回から44回に減少している．図4で日本語の誤分割校正回数の変化が大幅に減少しているが，実験の全過程に校正回数が大きかったのは分野ごとに文書をまとめていないため，未知語の出現が続くのが原因と考えられる．よって本システムの未知語を処理する能力の有効性が確認された．

文書中の始めの1,000単語の段落と360,000単語から361,000単語の間の段落の文書を取り出して考察を行った．表2に誤分割の原因を示す．実験の始めは辞書が空なので分割候補が足りないため，既登

表2 誤分割原因の割合

| | | 0~1,000 words | 360,000~361,000 words |
|---|---|---|---|
| 割合 | 未登録語による誤り | 15.0% | 0.8% |
| | 曖昧分割による誤り | 1.5% | 6.0% |
| | コーパスの揺れによる誤り | 0.5% | 0.4% |
| 合計 | 平均誤分割率 | 17.0% | 7.2% |

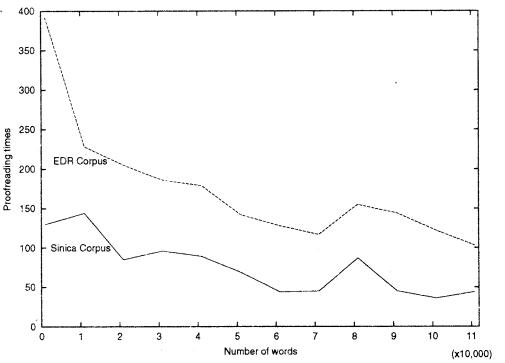



図4．校正回数の推移

・・・/可//分為//両//{大部分}//・・・
…may divide to two { large parts}…
・・・/由//三//{大//部分}//資料//組成/・・・
…by three { large parts}…
・・・/{大部分}//的//商業/・・・
…{ all most} of business…
・・・/解決//{大部分}//的//問題/・・・
…solve {all most} of problem…
・・・/最//{大//部分}/・・・
…the largest { part}…

図5. 曖昧分割の例

録のCW，WSを用いて分割が行われている．例えば：出口(export)が既に登録されているが，出口到(export to)，出口商(export businessman)と出口額

(volume of export trade)などは登録されていないため，分割結果が/出口/到・・・，/出口/商・・・と/出口/額・・・になった．これらの正しい分割結果は/出口到/，/出口商/と/出口額/である．この原因で誤分割率は表2に示したように実験の始め1,000単語で平均17%，終わりに近い1,000単語で平均7.2%であった．同様に，それぞれの誤分割中の未登録語による誤り，曖昧分割による誤り及びコーパスの揺れによる誤りの割合は未登録語による誤りが15%と0.8%，曖昧分割によるものは1.5%と6.0%，コーパスの揺れによるものは0.5%と0.4%であった．これは，実験の最初では未登録語が多いため誤分割が多数発生し，実験が進んで辞書に登録された単語が増えるに伴い，未登録語による誤りの割合が下がると同時に曖昧分割による誤りの割合が大きくなったものと考えられる．曖昧分割の例を図5に示す．図5で文字列“大部分”は文脈によって分割結果が異なる．

本手法によりほとんどの分割を正しく分割することができたが，更に完全に正しく分割するためには学習機能を増強することと未知語の抽出を細かく処理することが解決策として考えられる．

## 5. おわりに

本論文では字面情報から帰納的学習を用いて未知単語を推測することにより文を単語に分割する手法を提案した．そして，本手法を中国語の3分野の文書に対して分野ごとの適応性，及び日本語と中国語の実験結果を比較することにより，本手法の多言語への汎用性を確認する実験を行った．実験は辞書が空の状態から開始した．三つの分野の文書を用いて90.6%の平均正分割率が得られたことにより，本手法は異なる分野の文書に適用できることが確認された．更に，全く異なる言語に対しての実験結果，即ち，日本語文書の正分割率87.5%の結果から本手法は特定な言語に依存することなく複数の言語に適応できることが確認された．本手法は未知語を処理することができるという長所が辞書が空の状態から得られた実験結果より確認された．

今後は分割曖昧性の解消により分割精度を更に向上させること及び，帰納的学習を用いて品詞を付けることを計画している．

## 参考文献


[1] Sproat, R. and Shih, C., “A statistical method for finding word boundaries in Chinese text,” Computer Processing of Chinese and Oriental Languages, Vol.4, No.4, pp.336-351, 1990.

[2] 小田 裕樹，北 研二，“PPM*言語モデルを用いた日本語単語分割，”情報処理学会論文誌，Vol.41, No.3, pp. 689-700, Mar. 2000.

[3] 呉勝遠，“一種漢語分詞方法，”計算機研究与発展，Vol.33, No. 4, pp. 306-311, April 1996.

[4] Chen, K.J and S.H. Lin, “Word Identification for Mandarin Chinese Sentences, ” Proceedings of Coling 92, pp.101-107, Nantes, France, August 1992.

[5] Sproat, R., Shih, C., W.Gale and N.Chang, “A stochastic finite-state word-segmentation algorithm for Chinese,” Computational Linguistics, Vol.22, No.3, pp.377-404, 1996.

[6] 宋柔等，“基于語料庫和規則庫的人名識別法，”計算語言学研究与応用，pp.150-154, November 1993.

[7] 荒木健治，栃内香次，“帰納的学習による語の獲得および確実性を用いた語の認識，”電子情報通信学会論文誌，D-II Vol.J75-D-II, No.7, pp.1213-1221, July 1992.

[8] Zhongjian Wang, Kenji Araki and Koji Tochinai, “Word segmentation method using inductive learning for Chinese text, ” Proceedings of the IASTED International Conference, Artificial Intelligence and Soft Computing, pp.452-458,July 2000.

[9] 香坂順一，中国語の単語の話，光生館，東京，1971

[10] 浅野孝夫，今井浩，計算機とアルゴリズム，オーム社，東京，2000.