社団法人　電子情報通信学会
THE INSTITUTE OF ELECTRONICS,
INFORMATION AND COMMUNICATION ENGINEERS

信学技報
TECHNICAL REPORT OF IEICE.
TL2000-47, NLC2000-82(2001-03)

音声波形からの帰納的学習を用いた音声翻訳手法おける変換ルールの獲得

村上浩司，荒木健治，広重真人，栃内香次
北海道大学大学院工学研究科電子情報工学専攻
〒060-8628　札幌市北区北13条西8丁目
Phone & Fax: 011-706-7389
E-mail:{mura, araki, hiro, tochinai}@media.eng.hokudai.ac.jp

あらまし　従来から音声翻訳は大きく分けて音声認識部，機械翻訳部，音声合成部の3つの処理技術の統合として考えられ，またそれぞれの処理は複雑な多くの処理から構成され，音声を文字というシンボルに変換することを前提として実現を目指してきた．しかしそれぞれの処理が複雑でかつ多くの課題を抱えているため，各処理の精度を向上させてもその組み合わせとなる全体の精度を上げることは困難である．そこで我々は新しい観点から従来の音声翻訳システムでは不可欠な形態素解析や構文解析といった言語の固有の性質に依存する処理を省略し，大幅にそのシステム構造を簡素化することで処理の複雑さから起きる精度の低下を防ぎ，かつ音声を文字に変換することなく音声の特徴波形を扱うことで，言語の固有の性質に依存しない汎用的な音声翻訳を実現する手法を提案する．

キーワード　音声翻訳，帰納的学習，音声の特徴波形

Rule Acquisition for a New Speech Translation Method with Waveforms Using Inductive Learning

Koji MURAKAMI, Kenji ARAKI, Makoto HIROSHIGE, and Koji TOCHINAI
Graduate School of Engineering, Hokkaido University
Kita 13 Nishi 8, Kita-ku, Sapporo, 060-8628 JAPAN
Phone & Fax: +81-11-706-7389
E-mail:{mura, araki, hiro, tochinai}@media.eng.hokudai.ac.jp

Abstract　Conventional speech translation is a integration of the three processing techniques that contain several complicated parts. Generally, realizing the speech translation had a condition that speech had been transformed to the characteristics. However, achieving high translation performance is like combination among all processings. It is very difficult because each processing is so complicated and has many problems. Then, we propose a new speech translation method that independent on any characteristics of all languages. Our approach has some advantages that we use time-varying characteristics of speech without transform to characteristics and we would prevent declining the precision of translation by omitting some processings that were indispensable for traditional methods: morphological analysis, syntactic analysis and others.

key words　Speech translation, Inductive learning, Time-varying characteristics of speech

1 はじめに

これまで音声翻訳は，入力された原言語の発話を文字に変換する音声認識部，そこで得た発話内容の文字列を目標言語の文字列に変換する機械翻訳部，そして変換された目標言語の文字列を音声に変換する音声合成部に分割され，それらの技術の統合として研究が行われてきた．

ATR 音声翻訳通信研究所は，特に日英及び英日翻訳 [1][2] に関して最終的に，「話題の対象が限定される等の一定条件下で，異なる言語での対話を支援するツールとして利用可能である」としている [3]．

しかしどの処理も，良好な結果はまだ得られていない．たとえ各処理の精度が 90%を達成したとしても，音声認識，形態素解析，構文解析，構文変換，文生成，音声合成といった処理を経た後の最終的な精度は，53%でしかない．すなわちそれぞれの処理の精度の低下は全体の精度の低下に著しく影響を与える [2] ため，すべて処理の精度の向上のみが最終的な結果の精度を向上させるいう問題がある．その上，全体の処理の複雑さは，音声翻訳において重要な双方向の実時間の対話にも影響を与える．

そこで本論文ではそれらの複雑な数々の処理を省略し，原言語と目標言語の音声特徴の時間的変化に着目し，それらの間の対応関係を決定しその変換規則を帰納的学習を用いて学習することで音声翻訳を実現させる手法を提案する．この手法においては言語に依存した処理を省くことで，言語に依存せず汎用的に音声翻訳を可能にするだけでなく，全体の処理が他の手法に比べて少ないため，双方向の対話的な実時間の処理を可能にするものである．本研究では，新しい音声翻訳手法の提案と音声翻訳を実現するための音声処理，ルール獲得などの評価実験とその考察結果に基づき，提案する帰納的学習を用いた音声波形からの音声翻訳手法の有効性を確認する．また，本論文では原言語に日本語，目標言語に英語を用いた．

2 基本的な考え方

2.1 従来の方法

音声翻訳は，入力された原言語の音声を音節，単語などに分け認識し文字に変換する音声認識部，得

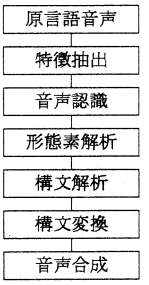


図 1: 従来の手法の処理過程

られた文字を形態素解析により品詞化し，構文解析を施すことでその構文の構造を形状化した後，目標言語の構文構造に変換する機械翻訳部，そして目標言語の構文構造のルールから訳文を得た後に，その文を出力する音声合成部という大きく 3 つの技術の統合で研究されてきた．

従来の手法の処理過程を図 1 に示す．

2.2 提案する手法

複雑な処理構造をもつ従来の音声翻訳手法に対して，本手法ではシステム全体の処理構造を簡素化する．

我々はまず，TDNN[4] とは異なったアプローチのニューラルネットワークを用いて母音認識，及び子音の音素の認識を試みたが，精度は低いものであった [5][6]．

そこで音声認識で得られる文字ではなく，音声波形そのものを扱うことを考えた．翻訳とは，両言語で意味の対応を取ることが条件であるため，文字での対応の代わりに音声の特徴波形間において対応を決定付ける．こうした音響的特徴の対応関係を決定する変換規則を学習することで処理の簡素化，及びスピードアップを図る．つまり音声翻訳システムの構造を簡素にし，精度の低下を防ぐようなシステムの構築を提案する．

機械翻訳部における形態素解析や構文解析は各言語に依存する技術であるため，多くの音声翻訳手法では，対象言語を換えることは言語翻訳部をも換える必要がある．それに比べ，我々が提案する手法では言語に依存する処理がないため，基本的に対象とする言語が替わっても音声の翻訳例があれば，同一システムをどのような言語にも利用できる．我々が着目するのは各言語の固有の性質ではなく，音声中の音響的な特徴変化であるため，い

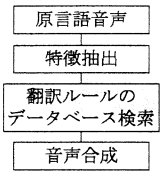


図 2: 提案する手法の処理過程

かなる言語でも翻訳の基本的能力には影響しない．

ここで．提案する手法に求められる最も重要な能力は，各言語の固有の性質に依存しない処理方法で音声翻訳を行うことである．また数々の処理を省略しシステムを構築することから，入力から出力までの即時性が実現される．そして，意味が伝わるレベルの翻訳精度の達成で音声翻訳を実現することである．

2.3 処理過程

2.3.1 処理構造

本論文で提案する手法の処理過程を図 2 に示し，処理構造を図 3 に示す．

今，両言語の音声発話の対応関係が決定しているとする．同じ言語内で実例発話の音声特徴の時間変化波形を比較し，共通部分・差異部分を抽出する．抽出された共通部分と差異部分の個数が同じ場合のみ，翻訳ルールを獲得し，翻訳ルール辞書に登録される．つまり翻訳ルールは両言語の文中での，対応する共通部や差異部の位置情報を保持している．そして帰納的学習により波形の比較からルールを獲得するだけでなく，ルール同士を比較することでも共通部分・差異部分を抽出し翻訳ルールを獲得する．翻訳する場合，翻訳したい発話の中に辞書に登録してある翻訳ルールが持つ共通部もしくは差異部と類似していれば，ルールに従って目標言語の対応している特徴変化の波形が選択される．

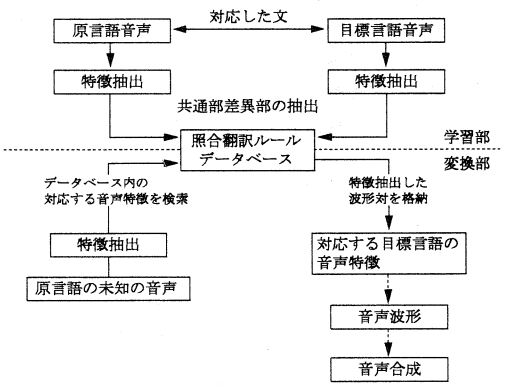


図 3: 処理構造

2.3.2 本手法の特徴

本手法では音声の特徴を文字に変換しないため単語や節，音素などの正確な境界は必ずしも重要ではない．比較する音声の音響的な共通部分と差異部分の両方に着目しその関係を利用することが大きな特徴である．これにより音声認識において重要で，かつ困難とされている音声のセグメンテーション処理が不要となる．

対象の音声に着目し声道情報を比較して共通部分及び差異部分を抽出する．このとき抽出される時間的な音声の特徴変化が，翻訳ルール中に表現される．そして帰納的学習において，それらの翻訳ルールをデータベースとして制御する．帰納的学習は，音声を比較することで得られる共通部分及び差異部分の翻訳ルールだけを保持するのではなく，帰納的学習の特徴でもあるその時点で得した翻訳ルール同士をまた比較し，さらにルールを獲得する再帰的学習を行う．この学習を繰り返し行うことで翻訳ルール数を増やし，翻訳を行う上での汎用性を高める．

3 処理手順

3.1 音声処理

3.1.1 対象音声

音声波形には様々な情報が含まれているだけでなく雑音なども含まれているため，ここでは周波数特徴の時間変化を抽出し，学習データとする．まず，本実験では，無響室において DAT を用いて 48kHz のサンプリングレートで録音し，10kHz にダウンサンプリングした．音声データは原言語，目標言語とも日本人男子大学生によって 20 文を 2 回ずつ発話し，発話データを 10 文ずつ 2 グループに分け用意した．

本手法では，時間的な音声の特徴変化ベクトルを利用する．音声を処理するにあたり，表 1 のようなパラメータを用いた．また，言語に依存しない形で音声特徴を生成するため，すべてのパラメー

表 1: 音声処理の実験条件

音声を切り出すフレームの大きさ	20msec
フレーム周期	3msec
音声窓	ハミング窓

タや適用した音声特徴はすべて言語間で共通とした．表 1に処理の条件をまとめる．

3.1.2 音声特徴

本手法においては音声の特徴波形同士を比較することで共通部分，差異部分として捉えるた必要がある．ここではAR係数から求めたパワースペクトルを用いた．

3.2 発話間における共通部分の始点探索

日本語と英語の2言語間の対応関係から，翻訳ルールを抽出するために2組の音声発話の実例を比較する．翻訳ルールを抽出するための共通部分および差異部分の始点探索について述べる．

3.2.1 ベクトル間の距離計算

声道情報の時間的変化としてベクトルに変換された音声発話の組をそれぞれの言語内で比較することで，共通部分及び差異部分を抽出する．本手法では両言語の特徴波形を同じパラメータで取り扱うことで，言語の性質に依存することなく音声特徴の変化を捉える．

音声を比較する場合，話速の差による時間軸上の伸縮を正規化しなければならない．我々は端点自由DP法[11]で得られるパスと類似した結果を得るように発話中の話速の違いの吸収を試みた．

2つの比較対象となる音声特徴ベクトルの誤差を測るために，我々は以下のような手法を用いた．比較を行う音声特徴ベクトル（以下，比較ベクトルと呼ぶ）を一定のフレームで切り出し時間軸上でシフトさせる．同時に参照されるベクトル（以下参照ベクトルと呼ぶ）も誤差計算する始点を時間的にシフトさせながら，比較ベクトルとの誤差を計算することでシフト時間毎に求めることができる．図4に概要及び計算される距離のグラフを示す．

ここで，実際の計算を考える．比較ベクトルをX_k，参照ベクトルをR_kとする．式(1)と式(2)に

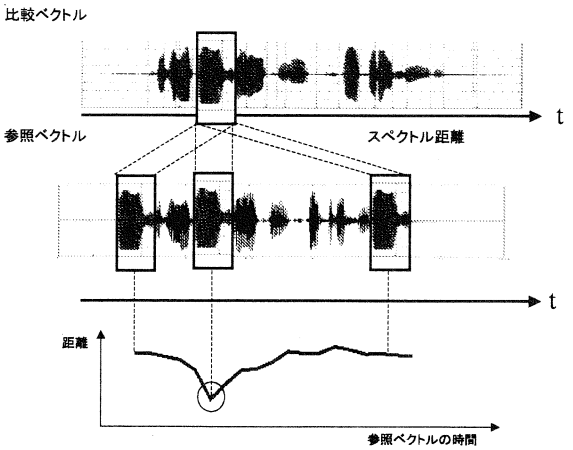


図 4: ベクトルの比較

それぞれのベクトルを示す．両ベクトル間の距離$d(k)$は，次式(3)によって与える．

$$X_k = [x_1\ x_2 \cdots x_n] \quad (1)$$

$$R_k = [r_{1,k}\ r_{2,k} \cdots r_{n,k}] \quad (2)$$

$$d(k) = \frac{1}{n}\sum_{i=0}^{n}(X_{(k)} - R_k)^2 \quad (3)$$

図4の距離グラフのように，切り出された比較ベクトルと参照ベクトルのある点からの部分との誤差が著しく小さくなれば，その部分は両ベクトルが対応している点として考え，こうした距離極小点が存在することで共通部分として扱うこととする．逆に誤差が大きければ，そうした点の存在を差異部分として考える．このときの全体の計算量は比較ベクトルのシフト総数と参照ベクトルのシフト総数との積となる．こうして最終的に得られるパスは，比較ベクトルと参照ベクトルとの全体的な誤差の比較結果となる．

3.2.2 発話間の距離

ある部分の比較ベクトルと参照ベクトル全体との間で計算された距離には，当然ながら大きなばらつきがある．この距離をそれぞれ，切り出す比較ベクトル毎にグラフにしたものを図5に示す．この図では，横軸は参照ベクトルの各フレーム周期，つまりシフト数を表し，縦軸は下に向かって比較ベクトルのシフト数となる．

この図は，同一話者，同一内容 ”これは私のおごりです ” の別発話を比べた例である．このとき各グラフ内の最小距離を持つ点が共通部分の始点になり得る．各グラフの最小距離の点を結んだ線が，DP で得られるパスに相当する．

こうして比較ベクトルと参照ベクトルとの統計的な距離を求めることができた．しかし，各グラフの最小距離を持つ点が共通部分の点であることを示さなくてはならない．そこで，最小距離を持つ点がベクトル間の共通部分の始点としてみなせるか，もしくは差異部分としてみなすかを決定するアルゴリズムを導入する．

3.3 始点の決定

図 5 のように比較ベクトルと参照ベクトルがほぼ一致する場合，グラフ内の距離は極端に短くなる．このように顕著にその距離が小さい場合，両ベクトル間の共通部分としてみなすことができる．そこで各グラフの最小距離をもつ点とそのグラフの平均距離と分散から，閾値を設けそれによって共通部分であるかを決定する．

式 (3) における誤差分布は，ガウス分布と仮定する．これは，与えられる入力パターン数が非常に大きいと仮定すれば近似的に可能であり，実際の分布とは大きく異ならない．ガウス分布は式 (4) で表される．

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} exp[\frac{-(x_{i(k)} - r_{i,k})^2}{2\sigma^2}] \qquad (4)$$

また，$\sigma = 1$ $\mu = 0$ と仮定した場合，標準正規分布として式 (5) で表される．

$$f(x) = \frac{1}{\sqrt{2\pi}} exp[\frac{-x^2}{2}] \qquad (5)$$

共通部分，差異部分の区別を決定するのが閾値 θ の役割である．グラフ全体の分布からの最小距離を持つ点への距離を表す値と考えられる．図 8 に閾値の確率分布内の位置を示す．

ここで，式 (4) の指数部と式 (5) の指数部が等しくなれば同様の分布を示すことになる．今，危険率を 4.6%とすると閾値 θ は式 (7) のように計算される．

$$(x_{i(k)} - r_{i,k})^2 = 4\sigma^2 \qquad (6)$$

$$\theta = 4\sigma^2 \qquad (7)$$

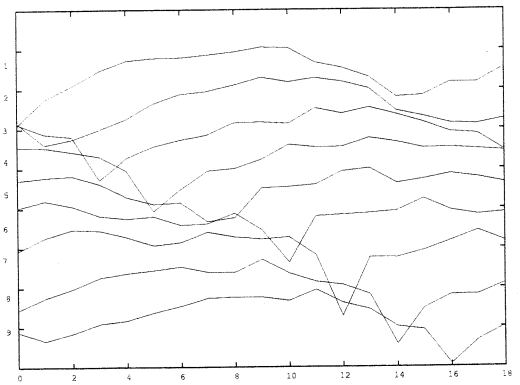


図 5: 発話間の距離 (1) ” これはわたしのおごりです ”

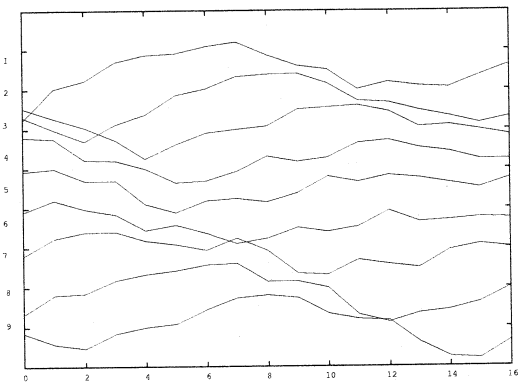


図 6: 発話間の距離 (1) ” これはわたしのおごりです ”” これはあなたにです ”

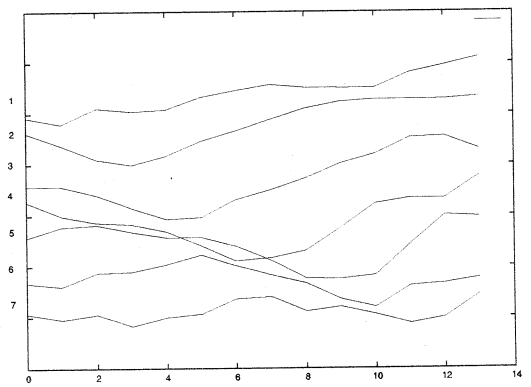


図 7: 発話間の距離 (1) ” おかんじょうをおねがいします ”” ちょうしょくはなんじですか ”

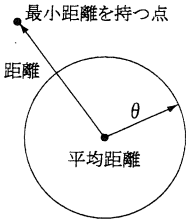


図 8: 閾値の役割

窓幅	0	100	200	300	400	500	600	700	800	900	1000	1100	1200	1300	1400	1500	1600	1700	1800
500msec	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0

図 9: 共通部分と差異部分 (1) ”これはあなたにです”

窓幅	0	100	200	300	400	500	600	700	800	900	1000	1100	1200	1300	1400	1500	1600
500msec	0	0	0	0	0	1	1	1	1	1	1	1	1	0	0	0	0

図 10: 共通部分と差異部分 (2) ”これはあなたにです”” これはあかいです”

窓幅	0	100	200	300	400	500	600	700	800	315	900	1000	1100	1200
500msec	1	1	1	1	1	1	1	1	1	1	1	1	1	1

図 11: 共通部分と差異部分 (3) ”これはあなたにです”” わたしはやきゅうをする”

よって，図 4 の距離のグラフのように顕著に下に凸な点での計算が閾値を超えた場合，その点は共通部分の一部となり得ると考え”0”と表し，差異部分となり得る点は”1”として表すこととする．

4 翻訳ルール抽出および帰納的学習

4.1 翻訳ルール抽出

このようにして決定された共通部分と差異部分の始点を，翻訳ルール抽出に用いる．翻訳ルールは対象のベクトルの共通部分および差異部分の情報からなるため，原言語と目標言語の両言語内でのそれらの部分の対応を決定させて考える．

ここでまず，3つの例の共通部分，差異部分検索の例を示す．図 9 では，全体が共通部分として計算されている．無声部分や発話の長さの影響については，音声の揺れとして扱うこととする．図 10 においては，”これは”と”です”に当たると推定される部分が共通部分として計算され，”あかい”” あなたに”に当たると推定される部分は差異部分として計算されている．

このとき，具体的な時間と音声の特徴変化との関係は把握していない．しかし本手法は音声を共通部分，差異部分という単位で扱っているため，問題はないものとする．我々は，図 10 の 2 文の比較の場合，その距離計算においては”共通部分-差異部分-共通部分”という文の関係が計算により導かれているため，正しいものとなる．図 11 では，図 9 と対照に，全体的に差異部分として計算されている．実際の発話内容からみても共通部分として計算される部分は少ない．すべて差異の場合は全文差異という結果が得られる．

ここで，最終的に得られる翻訳ルールは次のような種類をもつ．ただしこのとき翻訳ルールはあくまで両言語内の共通部分と差異部分の個数が同じときに限り獲得するが，その個数が違うときは対応関係を決定することができないため，翻訳ルールとして獲得しない．

最終的に得られる翻訳ルールの種類は以下のものである．

1. 全文一致
2. 共通部分，差異部分を持つ
3. 全文差異

そして，抽出される各翻訳ルールが保持する情報は以下のものである．

- 翻訳ルールの種類
- 音声発話のインデックス
- 各差異部分，共通部分のそれぞれの始点及び終点のセット
- 対応関係が決定している目標言語の音声発話のインデックス

4.2 帰納的学習

実例や用例に基づく学習型の翻訳手法においては，翻訳のルールを獲得するために大量のデータが必要となり高い精度の翻訳を実現させるにはあらかじめ十分な量の実例データを準備し学習させる必要がある．

我々が適用する帰納的学習の場合，そのサンプル中で最適な一般化を予め外化しておくことで，比較的少量のサンプルであっても最大限の能力を発揮できる．

我々が適用する帰納的学習の場合，準備した学習データのみから翻訳ルールを得るのではなく，獲

表 2: 翻訳ルール

	言語	抽出したルール	登録したルール
組	原言語	198	189
1	目標言語	168	88
組	原言語	122	115
2	目標言語	122	115

表 3: 適用されたルール

文	長さ	対応した部分	発話
5	413	(0-80)(140-280)	私はホッケーをする
1	468	(0-80)(140-280)	私は野球をする
6	434	(90-160)	そこでゴルフをする
10	439	(90-160)	そこで柔道をする

得した翻訳ルールの中から帰納的に学習を繰り返すことでも新たに翻訳ルールを獲得することができるため，学習用の実例データを大量に用意する必要がないという利点がある．

4.2.1 翻訳ルール獲得

まず原言語と目標言語の音声特徴から，翻訳ルールを抽出する．両言語の音声特徴は同じ意味を表す翻訳例の対である．2 種類の音声発話をそれぞれ用意し各言語とも，共通部分及び差異部分の始点検索を行う．

4.2.2 新しいルールの生成

そして，音声発話の組の比較だけでなく獲得されたルール同士でも，再帰的に翻訳ルールを獲得する．共通部分を要素に持つルール同士を比較しその中で再び共通部分が抽出されれば，比較した翻訳ルールがそれぞれに保持する共通部分よりも時間的に短い新しい共通部分が生成され，翻訳ルールの保持する情報となる．このとき，差異部分を保持するルール同士を比較しその中で共通部分が抽出されれば，その共通部分を要素とする新しい翻訳ルールが生成される．

5 性能評価実験

5.1 始点探索実験

始点探索実験では，それぞれの言語で発話文を比較し，その音声の特徴波形から，式 (7) を用いて共通部分及び差異部分の始点と終点を抽出した．

5.2 翻訳ルール獲得実験

抽出した共通部分及び差異部分の始点と終点を用いて翻訳ルールを獲得した．音声発話セット毎の両言語の抽出したルール数と，言語間で対応関係が決定している翻訳ルール数を表 2 に示す．

5.3 原文再現実験

原文の再現実験を行った．翻訳対象の原文は当然，目標言語の発話が存在していないため対応関係が決定していない．もしこの原文を翻訳ルールが持つ共通部分や差異部分を用いて文全体を置き換えることができれば，原文の意味は変化せずそれぞれの部分は対応関係が決定しているため，文全体の翻訳が可能になる．

学習データにはない”わたしはゴルフをする”という原文の再現実験を行った．まず翻訳文と各翻訳ルールを比較し，最長一致する共通部分を持つ翻訳ルールを適用した．次に翻訳文中で先のルールが適用されなかった部分をもう一度すべての翻訳ルールと比較して，最長一致する翻訳ルールを適用した．こうして翻訳ルールから作成されたいくつかの候補文の中に翻訳文が再現された．図 3 にこのとき適用されたルールを示す．

5.4 考察

翻訳ルールを適用し翻訳文を再現する際に，候補の文が数多く生成される．翻訳の自動化のためにも，的確な再現文を生成させる必要がある．

6 まとめ

言語固有の性質に依存しない手法を用いて，音声の実例データの特徴ベクトルを原言語及び目標言語において比較し，共通部分と差異部分を抽出した．そして翻訳ルールを獲得し，帰納的学習を用いて学習することで，翻訳文をルールから再現することができた．目標言語の翻訳文を翻訳ルールから求めることがこれからの課題となる．

表 4: 原文再現実験に用いた音声発話セット

グループ	番号	原言語	目標言語
1	1	私は野球をする.	I play baseball.
	2	私はサッカーをする.	I play football.
	3	私は空手をする.	I play karate.
	4	私はピアノを弾く.	I play piano.
	5	私はホッケーをする.	I play hockey.
2	6	そこでゴルフを見る.	I watch golf.
	7	そこでテレビを見る.	I watch television.
	8	そこでテニスを見る.	I watch tennis.
	9	そこで人を見る.	I watch the man.
	10	そこで柔道を見る.	I watch judo.
B	b1	私はゴルフをする.	I play golf.
	b2	私はテニスをする.	I play tennis.
	b3	私は柔道をする.	I play judo.

参考文献

[1] 森元, 田代, 竹澤, 他:"音声翻訳実験システム (ASURA) のシステム構成と評価", 情報処理学会論文誌, Vol.37,No.9,pp.1726-1733(1996)

[2] 菅谷史昭, 他:"本瀬翻訳システム (ATR-MATRIX) の評価", 信学技報 SP2000-21 (2000)

[3] 山本誠一:"コーパスベース音声翻訳技術", 電子情報通信学会誌, Vol.83, No.8, pp.604-611, (2000 年 8 月)

[4] ATR 国際電気通信基礎技術研究所編:"ニューラルネットワーク応用", オーム社 (1995)

[5] 村上浩司, 広重真人, 大槻典行, 宮永喜一, 栃内香次:"2 重構造ニューラルネットワークによる音声認識", H8 電気関係学会北海道支部連合大会公演論文集, 300, P314(1997 - 10)

[6] K.MURAKAMI, M.HIROSHIGE, Y.MIYANAGA, and K.TOCHINAI:"A Prototype System for Continuous Speech Recognition using Group Training based on Neural Network", ITC-CSCC, pp1013-1016(1997)

[7] 荒木健治, 栃内香次:"多段階共通パターン抽出法を用いた翻訳例からの帰納的学習による翻訳", 情報処理北海道シンポジウム 1991, pp.47 - 49(1991)

[8] 内山智正, 荒木健治, 宮永喜一, 栃内香次:"帰納的学習による機械翻訳手法の評価実験", 情報処理学会研究報告, NL93 - 4, pp.23 - 30(1993)

[9] 追江, 千葉:"動的計画法を利用した音声の時間正規化に基づく連続音声認識", 日音学誌, 29 − 7, pp.483 - 500(1971)

[10] Sakoe, H. and Chiba, S.:"Dynamic Programming algorithm optimization for spoken word recognition", IEEE, Trans., ASSP-26, 1, pp.43-49(1978)

[11] Silverman, H.F. and Morgan, D.P.:"The application of dynamic programming to connected speech recognition, IEEE, ASSP magazine, July, pp.6-25(1990)

A 付録: 使用した発話内容

表 4 に本実験で使用した音声データを示す. 発話データはその意味から大きく 2 つに分けた. B の項目にある音声発話は翻訳の実験に用いるための文である.