3—Q—7

HMMを用いた自由会話音声における発話速度変化の予備抽出*

◎松村 真言　広重 真人　荒木 健治　栃内 香次 (北大・工)

1　はじめに

自由会話音声における発話速度の大きな変化には、何らかの意味があると考えられる。ここで局所的話速変化の研究を行なう際、話速変化を豊富に含むサンプルデータを多く必要とするが、話速変化を豊富に含む箇所は少なく、その中で強い表現として意図的に話速を変化させていると推定できる箇所はさらに少ない。筆者らはこの意図的話速変化は頻度が少ないゆえに強い印象を与える表現手段であると考え、そのモデル化と自動抽出について検討しており [1]、自然な話速変化を含む音声を収録している。収録において筆者らは、自然な話速変化が失われないように長時間の録音をし、話者が録音環境に慣れるよう工夫している。その際、大量に録音された自由会話音声から大きな話速変化をもつ箇所の抽出が不可欠である。従来、筆者らは人間の聴取によってこの抽出作業を行なってきたが、多大な労力をともなうこと、話速のみの聴取は困難でピッチ変化やパワー変化を話速変化と感じて抽出しやすいことなど問題が多い。手法の一つとして音声認識システムによる自動音素抽出が有用と考えられるが、1) 対象とする音声は接話型ヘッドセットマイクロホンを用いて収録した雑談等の自由会話であるため、各種の環境雑音や他の話者の発話などが重畳している 2) 話者は録音セッションごとに異なる場合が多い、など高精度認識には障害がある。

そこで、本稿では始めから高精度の音素認識で音素に基づく話速を算出することは困難と考え、一般的に入手可能な音声認識ツールと学習済みパラメータセットを使用し、できるだけ少ない労力で予備的に仮の音素境界を求めて、大きな話速変化を含む可能性のある箇所を予備抽出することを考える。予備抽出された音声データは目視を含む詳細な手法で再度話速分析し、話速研究のサンプルデータとして活用する。

音素認識ツールとしては既存の HMM ツールキットである HTK を用いる。HMM パラメータは名古屋大学板倉研究室より配布されているもの [2] を用いる。本稿で扱う音声は雑音を多く含み、学習話者と認識話者が異なるため、HTK には音素の認識はせず、書き起こしテキストを与えて強制割り付けにより音素境界のみを推定する。

本稿では上記のように必ずしも良好といえない条件のもとでの使用を前提とする HMM による音素境界推定システムを作成し、その精度評価と、自由会話音声からの予備的な話速推定を行う。

2　HMMを用いた音素境界推定

本稿では、音声認識用の HMM ツール HTK を音素境界推定のみに機能限定して用いる。書き起こしテキストを用意し、HTK は書き起こしテキストで示される順番を守って学習済の音素 HMM を配列する。これは各音素 HMM の境界のみを最適に調整する「強制割付 (forced alignment)」機能に相当する。

ここでは、音素境界を求めることが目的であるため、各音素が独立である monophone モデルを採用した。さらに、学習済の HMM パラメータとして名古屋大板倉研究室の「標準的な日本語音素 HMM」[2] を利用した。

3　音素境界推定の精度評価実験

音素ラベルの付与されている ATR 日本語連続音声データベースを用いて、音素境界推定の精度を確認する実験を行った。アナウンサにより明瞭に発音された雑音等の少ないデータベース音声を用いるので、実際の一般人による自由会話音声と比べて音素境界推定システムにとって有利な条件での評価となる。

3.1　実験対象データ

ATR 日本語連続音声データベースより話者 myi の 503 文中の 20 文について音素境界推定を行なった。学習データはサンプリング周波数を 16kHz に変換して用い、特徴パラメータはメルケプストラム分析で得られた 12 次元ベクトルとその差分および二階差分、さらにパワーの差分および二階差分を含めた全 38 次元である。

*A preliminary speech rate calculation of spontaneous conversational speech by using HMM. By Makoto Matsumura, Makoto Hiroshige, Kenji Araki and Koji Tochinai (Graduate School of Engineering,Hokkaido University)

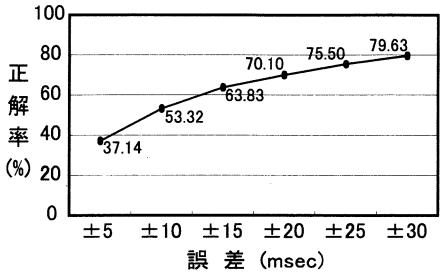


図 1: 音素境界誤差

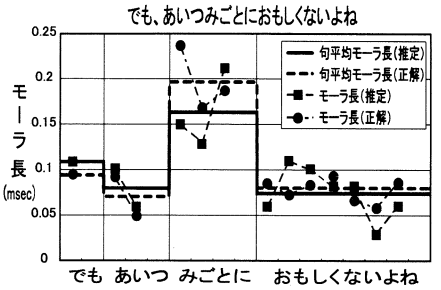


図 2: 自由会話音声の話速変化

3.2 精度評価方法

データベースの音素ラベルに記されている音素境界を正解とし、本稿のシステムで求めた音素境界との差の絶対値により評価した。この誤差値が閾値以内に存在する場合を正解とし、20 文全文にわたった正解率を計算した。本システムにおいて音素境界は 5ms ごとに出力されるので、正解として許容する誤差の閾値は 5ms ごとに ± 5ms から ± 30ms に設定し、正解率の変化を求めた。

3.3 結果および考察

結果を図 1 に示す。許容誤差が 5msec の場合正解率 37.14 %となり低い確率であるが、20msec で 70.10 %となり、7 割程度まで正解率が上昇する。

注意を集中しない場合の話速変化の知覚に関する研究 [4] において、アクセント句程度の長さの平均としての局所話速の変化を知覚する場合、閾値として約 20msec 程度の値が得られている。このことから、本研究の目的のもとでは音素境界の推定誤差の許容範囲を 20msec 程度に設定することは可能であると考えられる。また、無音から発話が立ち上がる文頭部、および発話が終了し無音に移行する文末部で大きな誤差が頻繁に観察され、文頭文末の誤差が正解率を下げている可能性も考えられる。以上の観点から、図 1 に示される結果は話速の予備抽出の目的には充分であると判断し、次章で自由会話音声に適用する。

4 自由会話音声の話速変化

上述の音素境界推定ツールを、当研究室で録音した自由会話音声 (男性話者 2 名) に適用し、音素長から求められるモーラ長に基づく話速を算出した。さらにフレーズ (句) 単位の平均話速もあわせて算出した。ここでのフレーズは、意味のわかる文節相当の長さで、人手により決定する。フレーズの平均話速は、任意に伸張する最終モーラ長を除いて求めた平均モーラ長により表す。

結果の例を図 2 に示す。図 2 において、正解モーラ長は目視および聴取によって筆者らが決定した。モーラ持続長は個々の音素境界の誤差の影響を受けてばらついているが、フレーズの平均持続長は、音声サンプルの話速変化を良好に表している。

5 まとめ

本稿では、既存の HMM ツールキットを用い、発話内容の書き起こしテキストと学習済み HMM パラメータセット用いて、音素境界を求めるツールを作成した。さらに、この音素境界推定ツールの精度評価を行ない、自由会話音声に適用し、音素長に基づく話速を算出した。今後の課題としては、文頭文末の大きな誤差への対処法が挙げられる。また、本稿の結果をもとに実際に話速変化の大きい箇所を抽出する必要があり、現在、単純しきい値による抽出や、話速の知覚を考慮した可変しきい値の適用などを検討している。

参考文献

[1] 高丸 圭一, 鈴木 貫太郎, 広重 真人, 栃内 香次, "自由会話音声における局所的話速変化分析のための話速表現の検討", 音講論,2-Q-3,pp.285-286(1999-09)

[2] 名古屋大板倉研究室,『A standard HMM set of Japanese phonemes.』 http://www.itakura.nuee.nagoya-u.ac.jp/

[3] 夏目 貴史, 桜井 淳宏, 広瀬 啓吉, "言語的な情報を利用した韻律データベース作成の自動化", 音講論,2-P-7,pp.281-282(1999-03)

[4] M.Hiroshige, K.Suzuki, K.Araki and K.Tochinai,"On Perception of Word-based Local Speech Rate in Japanese without Focusing Attention",Proc.ICSLP 2000,vol III,pp.255-258(Oct.2000)