53 帰納的学習を用いた電子メイル返信文自動生成手法の概要

植松 智* 荒木 健治 栃内 香次
(北大工)†

1 はじめに

電子メイルによる情報のやり取りが頻繁に行われている現在、その返信文の作成に多大な時間や労力が費やされることとなった。そこで、このような問題を解決する方法として、受信メイルに対する返信文の下書きを自動生成することで、ユーザの返信文作成のための時間や労力を削減するような手法が求められている。

これまでに開発されてきた対話処理のシステムの多くは、ユーザの入力に対して応答文を生成する規則が、あらかじめシステムに組み込まれている[1],[2],[3]。このため、想定されるすべてのパターンを用意しておく必要がある。さらに、大規模になればなるほど規則を人手で与えるのが困難になる。また、あらかじめ用意されたパターン以外の状況や、ユーザや内容に即した応答への適用が困難になるという問題点も挙げられる。

そこで本稿では、実例からそこに内在する生成ルールを動的に獲得していくことができる、帰納的学習[4]を用いた電子メイル返信文自動生成手法を提案する。本稿では、本手法を構築するにあたり、最も基本的なモデルについて述べる。これは、送信相手・題といったメイル特有の情報や、詳しい品詞の情報などを用いず、形態素解析により得られた形態素の字面情報と、その形態素が自立語であるか付属語であるかという情報だけを用いて、どのような生成ルールがどれだけ獲得できるかについて実験を行うことにする。本稿では実験を通じて本手法の概要を表し、その結果から様々な情報の利用の仕方などについて考察を行う。

2 処理過程

本手法では、二つのルール獲得処理を平行して行う。なお、全てのルールは正適用回数・誤適用回数という値を持つ。また本手法では受信メイル内の1文ごとに対して1個のルールのみを用いることとする。

まず、受信メイルを Juman を用いて形態素に分割し、二つのルール獲得処理によって獲得された生成ルールとの比較を行う。ここで適用できる生成ルールが存在した場合には優先度に基づき生成ルールを出力する。また出力された生成ルールと、入力された受信メイルと対になっている送信メイルとを比較して、削除・修正が必要な場合にはその適用されたルールの誤適用回数を増やし、そのまま残して使える場合にはそのルールの正適用回数を増やすというフィードバック処理を行う。さらに、入力された受信メイルとその受信メイルと対になっている送信メイルの組を用いて、共通部分抽出処理・入出力変換処理の両手法を用いて生成ルールの獲得を行う。各処理の詳細については以下に示す。

2.1 共通部分抽出処理

過去に入力され、メイル対データに保存された全ての受信メイル・送信メイルの組と、現在入力された受信メイル・送信メイルの組を、それぞれ受信側同士・送信側同士形態素単位での比較を行う。ここで、助詞や助動詞といった付属語はそれだけで意味を持たないものなので、付属語のみの一致をルールとして獲得することをさける必要がある。そこで、ルールを獲得する場合は必ず自立語を含んだ部分文字列の組をルールとして獲得するものとする。また、入力された受信メイル・送信メイルの組はメイル対データとして保存する。共通部分ルールの具体例を表1に示す。

2.2 入出力変換処理

入力された受信メイルと、その受信メイルと対になっている送信メイルの組を形態素単位で比較し、両方に自立語を含んだ部分文字列が存在した時、その一致部分を変数化して残りの部分を変換部分として持つ入出力変換ルールを獲得する。また、あらたに獲得された入出力変換ルールは、過去に獲得された入出力変換ルールと変換部分同士を比較して、両方に自立語を含んだ部分文字列があった場合、これを部分変換ルールとして獲得するものとする。入出力変換ルールの具体例を表2に示す。

3 ルールの優先度

受信メイルの一文に対し、複数の生成ルールが適用可能だった場合の優先度について以下に示す。

*uematsu@media.eng.hokudai.ac.jp
†札幌市北区北13条西8丁目北海道大学工学部

3.1 各処理の優先度

まず、共通部分ルールの中で適用できるルールの存在を調べる。適用できるルールが存在しなかった場合は、次に入出力変換ルールの中で適用できるルールが存在するかを調べる。さらに適用できるルールが存在しなかった場合には、部分変換ルールの中に適用できるルールが存在するかを調べる。

3.2 各処理のルールの優先度

3．1で示した各処理のルールの中で、さらに複数のルールが適用可能である時には以下の手順で適用するルールを一つに絞る。まず、各ルールが保持している値、正適用回数・誤適用回数を用いて、正適用回数−誤適用回数を計算し一番大きな値を選ぶ。これで適用できるルールが一つに絞られない場合には、さらに各ルールの中で受信側の形態素が一番多いものを選ぶ。これでも一つに絞られない場合には、ルールの登録が早いものを優先して出力することにする。

表1 共通部分ルールの獲得例

（受信 現在） /もともと:1/札幌:1/の:2/方:1/です:2/か:2/？:2/ （受信 過去） /まつ:1/は:2/もともと:1/札幌:1/の:2/人:1/？:2/ （受信 一致部分） _/もともと:1/札幌:1/の:2/_
（送信 現在） /僕:1/は:2/本州:1/出身:1/で:2/、:2/大学:1/入学:1/を:2/機:1/に:2/札幌:1/に:2/き:1/ました:2/。:2/ （送信 過去） /あと:1/、:2/僕:1/は:2/本州:1/の:2/人間:1/で:2/、:2/大学:1/入学:1/から:2/札幌:1/に:2/すんで:1/ます:2/。:2/ （送信 一致部分） _/僕:1/は:2/_/本州:1/_/大学:1/入学:1/_/札幌:1/に:2/_
（共通部分ルール） （受信） _/もともと:1/札幌:1/の:2/_ （送信） _/僕:1/は:2/_/本州:1/_/大学:1/入学:1/_/札幌:1/に:2/_ 正適用回数__回 ； 誤適用回数__回 ；
補足 スラッシュは形態素の区切りを表し、形態素の後ろの数字は自立語（1）付属語（2）を表している。 アンダーバーは、その部分が差異部分であったことを表す。

表2 入出力変換ルールの獲得例

（受信 現在） /スポーツ:1/何:1/か:2/やって:1/る:2/の:2/？:2/ （送信 現在） /スポーツ:1/は:2/結構:1/好き:1/。:2/
（入出力変換ルール） （受信） /@0/何:1/か:2/やって:1/る:2/の:2/？:2/ （送信） /@0/は:2/結構:1/好き:1/。:2/ 正適用回数__回 ； 誤適用回数__回 ；
補足 スラッシュは形態素の区切りを表し、形態素の後ろの数字は自立語（1）付属語（2）を表している。 また@0は変数部を表している。

4 実験

実験に用いるデータは、自分が使っている Microsoft 社の Outlook Express に蓄えられているメイルの中から、受信・送信がしっかりと対になっているものを任意に２５組選択した。ここで、実験によって獲得されたルールの個数、および実験中にルールが適用された回数を表３に示した。また、各処理におけるメイルの入力数に対するルール獲得数の推移を図１に、各処理により獲得されたルールの再現率・適合率を図２に示した。

再現率・適合率はそれぞれ以下の式（１）式（２）で求めることとする。

$$\text{再現率} = \frac{\text{ルールが適用された回数}}{\text{入力されたメイルの個数}} \quad (1)$$

$$\text{適合率} = \frac{\text{ルールが正適用された回数}}{\text{ルールが適用された回数}} \quad (2)$$

表３ 各ルールの実験結果

	獲得されたルール数	ルールが正適用された回数	ルールが誤適用された回数
共通部分ルール	２６個	４回	４回
入出力変換ルール	４４個	０回	０回
部分変換ルール	４個	０回	１回

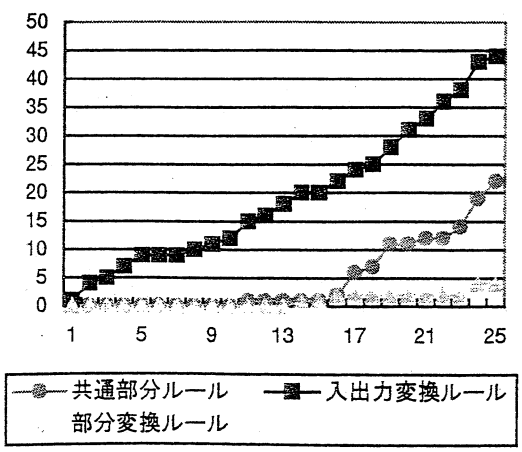


図１ 各手法におけるルール獲得数の推移

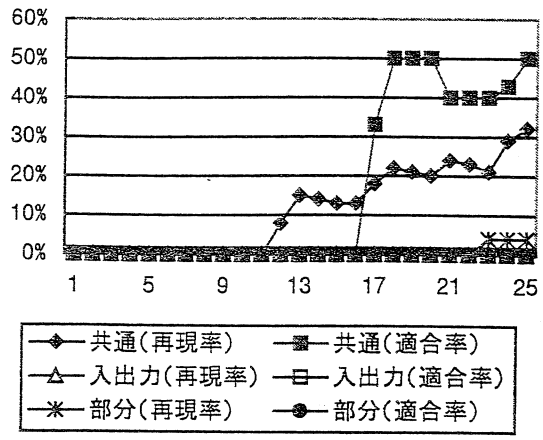


図２ 各ルールの再現率・適合率

5 考察

5.1 共通部分抽出処理

今回はルール獲得の際の条件が、区切られた形態素の字面の一致および自立語・付属語の一致としたため、長い部分文字列をルールとして獲得することができなかった。また、文と文の比較を網羅的に行ったため、関連の無い共通部分ルールも獲得してしまい、適用されたルールの内５０％が誤適用されてしまった。誤適用の例は表４に示した。

5.2 入出力変換処理

受信・送信メイル間で一致する部分文字列が少なかったために、適用できる入出力変換ルールを獲得することができなかった。また部分変換ルールは、共通部分処理と同じようなルールが獲得されたので、その必要性を再検討することにする。

6 おわりに

本稿で紹介した手法は、文の対応関係を網羅的に行ったため、誤ったルールの獲得やルールの誤適用が起こった。実験の最終的な結果、ルールの誤適用は全体で約５６％となってしまった。そこで、メイルの処理を文ごとに考えるのではなくて、メイル中の複数の文をひとつのまとまりとして処理することの必要性を検討し、その手法の構築を考察していく。

今後の予定としては、詳細な品詞情報の利用およびルール同士の組み合わせ、さらに題名や送信相手といった情報の利用を予定している。またデータ数が少ないため、手法の有効性を正確に評価できてはいないので、今後より多くのデータを用いて追加実験を行う予定である。

表４　ルール誤適用の例

（受信 現在） /普段:1/、:2/何:1/やって:1/ます:2/か:2/？:2/ /バイト:1/と:2/か:2/して:1/ます:2/か:2/？:2/
（共通部分ルール） （受信） /何:1/ （送信） /する:1/ 正適用回数__回 ； 誤適用回数__回 ；
（送信 現在） /ここ:1/最近:1/は:2/、:2/継続:1/的な:2/バイト:1/は:2/して:1/ない:2/なあ:2/。:2/ /普段:1/は:2/、:2/昼間:1/は:2/だいたい/大学:1/に:2/行って:1/る:2/。:2/
受信メイルと共通部分ルールの受信側との比較を形態素単位で行った結果、“何”という一致する文字列が受信メイル側にあるので共通部分ルールの送信側“する”を応答文の下書きとして出力する。ここで出力された文字列と、受信メイルと対になっている送信メイルとを形態素単位で比較を行う。その結果、出された下書きと送信メイルの間で一致する文字列が無いので、誤適用されたと判断してこのルールの誤適用回数を１増やす。
補足 スラッシュは形態素の区切りを表し、形態素の後ろの数字は自立語（１）付属語（２）を表している。

参考文献

[1] 人工知能学会(編):人工知能ハンドブック,オーム社 (1990).

[2] Weizenbaun,J. : ELIZA – A Computer Program for the Study of Natural Language Communication Between Man And Machine ,Communications of the Association for Computing Machinery,vol9,No1,pp.36-45(1966).

[3] 石崎俊 : 自然言語処理,昭晃堂 (1995).

[4] 荒木健治 : 帰納的学習を用いた自然言語処理の有効性について,信学技報, TL99-41, pp.33-40 (2000).