54 情報抽出のための帰納的学習を用いた重要文決定手法

塚原卓人* 荒木健治 栃内香次
(北大工)†

1 はじめに

現在、計算機の普及に伴い、計算機を用いて文書を扱う機会が増えている。そこで、本稿では大量の文書を読む際の膨大な時間と労力を軽減し、迅速な処理の手助けとなる手法を提案する。

このような手法として、従来から情報抽出や自動要約[1][2]が存在する。情報抽出は文書の中からTable 1のようなユーザが用意したフレームのスロットに当てはまる内容を抜き出すものである。この方法は、ユーザの扱う文書が常に同じパターンで表現されている場合や、ユーザの要求する情報が常に同じ場合には有効だが、様々な内容の文書に対して汎用的とは言えない。

Table 1 フレーム形式の例

スロット	スロット値
日時	2月19日午後4：30
場所	7階小会議室

自動要約では文書中の各文の重要度を計算し、重要度の高い文をそのまま残すという方法が用いられている。この場合、重要な文をそのまま残しただけという表示方法が問題である。

そこで、これら二つの手法の長所を組み合わせることによってこの問題を解決することが考えられる。はじめに自動要約の方法で重要文を決定し、次いでその文の内容に合ったフレームを作成し、フレーム形式で表示するという手法が考えられる。

本稿では、その前半部分である重要文の決定手法を提案する。本手法では帰納的学習[3]を用いることで、ユーザがどのような文を重要と判断したかを学習し、重要文を決定する。以下では本システムの処理過程を示すとともにそれを用いた実験の結果から本システムの有効性について考察する。

2 概要

まず入力文書中の各文の状態を、数値を用いた状態パラメータで表す。次に各文の状態パラメータと過去に扱った文の状態パラメータを用いたルールとを比較し各文の重要度を計算して重要文を決定する。校正処理部では、決定された重要文に対し、ユーザが正誤の判断をし、校正処理を行う。校正された結果から、ルール獲得部で帰納的学習により新たにルールを獲得することによって、ユーザが重要だと判断する文のパラメータの傾向を学習する。これによって、重要文決定の精度が向上していく。

3 処理過程

3.1 状態パラメータ決定部

重要文の決定は、入力文書中の各文の状態によって判断する。そこでまず、入力文書中の各文の状態を数値で表す。これを状態パラメータと呼ぶ。状態パラメータは、人間が重要文を決定するときの判断材料として考えられる要素を用いる。これをTable 2に示す。

Table 2 状態パラメータの内容

パラメータ[0]：文の位置
1：一文目 2：前半部分 3：中間部分 4：後半部分
パラメータ[1]：段落
1：第一段落 2：最終段落 3：その他の段落
4：段落分けなし
パラメータ[2]：段落中の位置
1：一文目 2：前半部分 3：中間部分 4：後半部分
パラメータ[3]：前文との接続関係
1：順接 2：逆接 3：添加 4：言い換え 5：例示
6：理由 7：対比 8：転換 9：その他
パラメータ[4]：箇条書き
1：箇条書きされている文 0：箇条書きでない通常の文
パラメータ[5]：日時表現の有無
1：日時の表現がある 0：日時の表現がない
パラメータ[6]：文のタイプ
1：推量 2：依頼 0：その他

Table 2に示した7つの要素がどのような状態かを与えられた数値で表し、その数値を並べた7桁の数列を状

*tukahara@media.eng.hokudai.ac.jp
†札幌市北区北13条西8丁目北海道大学工学部

態パラメータとする。実験に用いた文書[4]をTable 3に示して、状態パラメータの説明をする。

Table 3　例文

２００２年W杯のインターネットによる入場券申し込みが、受け付け開始１時間前になって急きょ延期された。１５日午前０時（日本時間）から受け付けが開始される予定だったが、１４日午後１１時前に国際サッカー連盟（ＦＩＦＡ）が一方的に受け付け延期を発表した。原因は「技術的な問題」としているが、昨年１０月に続く延期に批判が噴出しそうだ。なお、国内の郵送による申し込みは予定通りきょう１５日、用紙配付・受け付けがスタートする。 突然の「受け付け延期」は、開始１時間前に発表された。ＦＩＦＡが公式ホームページで、「最終チェックの段階で技術的な問題が発生した」と延期を発表。 ： ： ：

Table 3の一文目「２００２年W杯の･･･」という文の状態パラメータは「１１１９０１０」となる。一番目の「1」は、その文が一文目であることを示している。以下同様に７つの要素の数値を並べる。

3.2 重要文決定部

重要文決定部では、各文の状態パラメータと重要文決定ルールとを比較し、重要文の決定を行う。重要文決定ルールとは、過去にユーザがどのような文を重要と判断したかを表すもので、過去にユーザが扱った文の状態パラメータとそれを重要度決定ルールとして用いた回数のセットで表される。重要文決定ルールとは、二種類あり、過去にユーザが重要と判断した文の状態パラメータからなる正ルールと、重要でないと判断した文の状態パラメータからなる誤ルールがある。重要文決定ルールはTable 4のような形で存在する。

Table 4　ルール

状態パラメータ	使用回数
１１１２００１	4
１０１００１０	2
１ｘ１ｘ０ｘｘ	9
２３１１１０１	1
ｘｘ１ｘｘ０１	7
ｘｘ１ｘｘｘｘ	１８
：	：

Table 4のようにルールは、状態パラメータとその状態パラメータの使用回数のセットで表される。また、「１ｘ１ｘ０ｘｘ」のようなｘを含む状態パラメータは、ルール獲得部で新たに得られるルールで、状態パラメータ同士の共通部分を残し、一致しない部分をｘと表したものである。入力文の状態パラメータがｘ以外の数字の部分とすべて一致した場合にこの状態パラメータが重要度の計算に用いられる。このようなルールを作ることで、重要文決定ルールの汎用性が高くなる。

入力文書中の各文の状態パラメータと重要文決定ルールを比較し、次の計算を行う。

$$\text{重要度} = \frac{\text{一致した正ルールの使用回数}}{\text{一致した重要文決定ルールの使用回数の和}} \quad (1)$$

式（1）により、文の状態パラメータが正ルールと多く一致すれば重要度は1に近づき、誤ルールとの一致が多ければ重要度は0に近づく。また、頻度の高いルールほど重要度に与える影響が大きくなり、正ルールと誤ルールの両方に存在するものは重要度の決定に与える影響が小さくなる。

重要度の高い文をどの程度の割合で残すかを要約率とし、次のように定義する。

$$\text{要約率（％）} = \frac{\text{重要と判断できる文の数}}{\text{全文数}} \times １００$$

今回は全文書とも仮に要約率５０％となるように実験を行った。

3.3 校正処理部

重要文を決定した結果の校正処理をユーザが行う。今回の実験ではここでも要約率が５０％となるようにユーザ校正を行った。

3.4 ルール獲得部

ここでは、校正された結果から新たにルールを獲得する。入力文書中でユーザが重要と判断した各文の状態パラメータを新たに正ルールとして加える。さらに、新たに加わったルールと既存のルールとの共通部分を正ルールとして獲得する。また、重要度の計算に使用したルールの使用回数に1を加える。この処理によって、重要度の決定に使用される頻度の高いルールの影響が大きくなる。

また、誤ルールについても同様の処理を行う。

4 実験

4.1 実験方法

実験は、実際に 27 文書[4]を用いて行った。重要度決定ルールは空の状態にしてから始め,各文書の重要度決定の正解率を求めた。正解率は次のように求める。

$$\text{正解率}(\%) = \frac{\text{正認識文数}}{\text{全文数}} \times 100 \quad (2)$$

正認識文とは、重要かどうかの判断がユーザと同じであった文と定義する。

4.2 実験結果

実験の流れを、具体例をあげて示す。実際に実験に用いた入力文書の例を Table 5 に、その文書の重要文決定の結果とユーザの校正した結果を Table 6 に示す。重要文の決定は重要な文を 0、重要でない文を 1 で表している。

Table 5 入力文書

Ｊリーグ神戸とともに高知・春野で春季キャンプを張る西武が１７日に超豪華紅白戦を行うことが１４日、分かった。松坂大輔投手（２０）を先発させるほか、西口、石井、豊田の先発４本柱をすべて登板させる、公式戦では不可能な投手リレーで春野のファンを喜ばせる。

１７日にはキャンプ施設内の陸上競技場でＪリーグ「神戸―広島」のプレシーズンマッチも行われる。松坂とカズ（三浦知良＝神戸）が「激突」することにもなり、高知県営春野総合運動公園では対応に追われている。同運動公園は近隣の臨時駐車場を借りるなど４０００台分のスペースを確保。さらに高知駅から臨時バスを２２便増発させるなどファンの受け入れに万全の態勢を敷いてきた。

だが野球、サッカーとも満員となれば対応しきれない。西武の今キャンプ観客動員数は初の紅白戦が実施された１１日の２万人が最高。１７日の紅白戦で２万人以上のファンが訪れることは必至。Ｊリーグ、プレシーズンマッチが行われる陸上競技場は最高２万５０００人収容可能だが、プレシーズンマッチのチケットを今回だけ特例の６０００枚に限定発売。同運動公園の関係者は「できる限りの対策を講じてきたが、限界があります」と話した。

当日同運動公園はガードマン１９人、職員２８人、高知南警察署の１８人で対応にあたる。だが２大スターの競演での混乱ぶりは想像できない。【山内崇章】

Table 6 重要文決定の結果

文	状態パラメータ	重要文決定	校正後
Ｊリーグ神戸とともに高知・春野で春季キャンプを張る西武が１７日に超豪華紅白戦を行う…	１１１９０１０	0	0
松坂大輔投手（２０）を先発させるほか、西口、石井、豊田の先発４本柱をすべて登板させ…	２１４９０００	0	0
１７日にはキャンプ施設内の陸上競技場でＪリーグ「神戸―広島」のプレシーズンマッチも…	２３１９０１０	0	0
松坂とカズ（三浦知良＝神戸）が「激突」することにもなり、高知県営春野総合運動公園で…	２３３９０００	0	0
同運動公園は近隣の臨時駐車場を借りるなど４０００台分のスペースを確保。	３３４９０００	0	0
さらに高知駅から臨時バスを２２便増発させるなどファンの受け入れに万全の態勢を敷いて…	３３４３０００	0	0
だが野球、サッカーとも満員となれば対応しきれない。	３３１２０００	1	1
西武の今キャンプ観客動員数は初の紅白戦が実施された１１日の２万人が最高。	３３２９０１０	0	1
１７日の紅白戦で２万人以上のファンが訪れることは必至。	３３３９０１０	1	1
Ｊリーグ、プレシーズンマッチが行われる陸上競技場は最高２万５０００人収容可能だが、…	４３４９０００	1	1
同運動公園の関係者は「できる限りの対策を講じてきたが、限界があります」と話した。	４３４９０００	0	1
当日同運動公園はガードマン１９人、職員２８人、高知南警察署の１８人で対応にあたる。	４２１９０１０	1	0
だが２大スターの競演での混乱ぶりは想像できない。	４２３２０００	1	1
【山内崇章】	４２４９０００	1	1

Table 6 の校正結果より、全１４文中で正認識文は１１文あり、ユーザが校正した文は３文であった。

式（2）より、この文書の重要文決定の正解率は７８．６（%）となる。

重要文決定の正解率を Fig.1 に、重要文決定ルールの獲得の様子を Fig. 2 にそれぞれ示した。

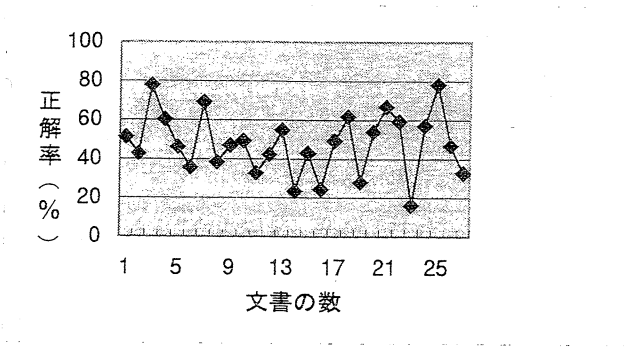


Fig.1 正解率

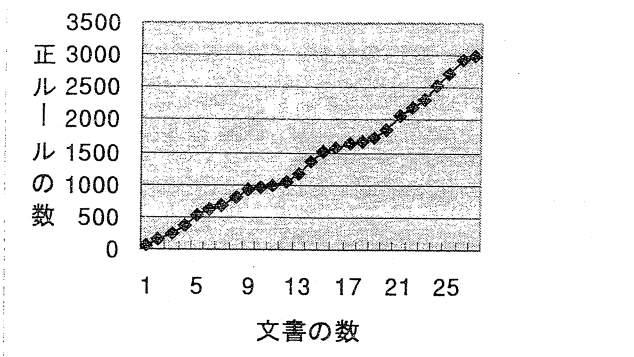


Fig.2 正ルールの獲得状況

4.3 考察

Fig.1 より、正解率は右上がりにはなっておらず、不安定な結果を残した。正解率の平均は、４８．３８（%）となった。一方 Fig.2 より獲得したルールの数は実験を重ねるごとに増えていた。また、実験を重ねるごとにルールの使用回数にも差が出ていた。これらはユーザの重要文決定の傾向を学習していることを示している。ここで、重要文決定ルールの学習の結果が、正解率にうまく反映されなかった原因について考察する。

最も大きな原因として、文の状態パラメータの内容が考えられる。実際にユーザが重要文を選ぶ際に、本稿で示した七つのパラメータ以外にも判断材料を用いている可能性は否めない。例えば、名詞や動詞の特徴や決まった表現パターンなど、考えられる要素を加え、状態パラメータをより実際の判断材料に近づけることで、正解率の向上が期待できる。

その他の原因として、評価方法も考えられる。今回の正解率は、入力文書中の文の数が少ない場合、重要文決定を一つ誤ったときの影響が大きくなってしまうため、不安定な結果が出たのではないかと考えられる。より正当な評価方法が必要である。

また、要約率を 50%と決めたことも原因の一つと考えられる。今回の実験では、入力文書によって文の数が大きく異なった。実験に使った文書のうち文の数が最小のものは六文、最大のものでは四十文もあった。実験を通じて、文の数が少ないほど要点が絞ってあり、文の数が多いほど重要ではない文の数が多いという傾向が見られた。文書の長さや内容によって、要約率も変化する必要があり、その傾向を学習する必要性も感じた。

5 おわりに

本稿では入力文書中の各文の状態パラメータと過去のユーザの判断から帰納的学習を用いて、ユーザの重要と判断する文の傾向をルールとして獲得する手法を提案した。これにより、ユーザが重要と判断する文の状態パラメータをルールとすることに成功した。しかし、状態パラメータの内容が不十分であったため、学習結果が正解率の向上にうまく反映されなかった。

今後は状態パラメータの内容を改善し、実際に人が重要文を選ぶときの判断材料にできるだけ近くなるように工夫する必要がある。また、要約率や評価方法などの問題点も改善していく予定である。

参考文献

[1] Hideo Watanabe：A method for abstracting newspaper articles by using surface clues.Producings of the 16th International Conference on Computational Linguistics,Vol.2,pp.974-979（1996）

[2] 山本和英・増山繁・内藤昭三：文章内構造を複合的に利用した論説文要約システム GREEN，自然言語処理，２（１），pp. 39－55（1995）

[3] 荒木健治：帰納的学習を用いた自然言語処理の有効性について，信学技法，TL99－41，pp. 33－40（2000）

[4] http://www.nikkansports.com

[5] 宮地裕・北原保雄・渡辺実・山口佳紀・川端善明・市川孝・尾崎知光・古田東朔・興津敬一郎：“日本語６　文法Ｉ”岩波書店（1976）

[6] 大野晋・竹内美智子・山口明穂・北原美紗子・西田直敏・安田章・田中章夫：“日本語７　文法Ⅱ”岩波書店（1977）