1—P—15

局所的話速低下を検出する動的変化閾値のパラメータに関する検討*

◎高丸 圭一　広重 真人　荒木 健治　栃内 香次（北大・工）

1　はじめに

自由会話音声では、話者は強調等を表現するために意図的に発話速度を変化させることがある。話速の局所的変化は聞き手の注意をひくための話者による表現の一つであり、発話中の話速の局所的変化箇所を捉えることは音声情報処理において有用であると考えられる。筆者らは種々の要因による変化が重畳されている自由会話音声のモーラ持続長変化の概形から話者の意図的制御に起因する局所的話速変化箇所を捉えることを検討している[1-2]。本稿では、自由会話音声試料に対し、既に提案した局所的話速低下箇所を捉える閾値[2]によって検出される箇所と聞き手が知覚する局所的話速低下箇所との関係について調査し、閾値のパラメータに関する検討を行う。

2　局所的話速低下箇所を検出する閾値

2.1　概要

聞き手によって「際立った話速の低下箇所」として知覚される箇所は、強調等を表現するために話者によってモーラ持続長が意図的に伸長制御された箇所である可能性がある。これは話者が発する聞き手に注意を促す信号の一つであると考えることができる。本研究では、聞き手によって知覚されるモーラ持続長の局所的伸長の閾値の存在を仮定する。話者が平均的にある持続長を保って発話を進めている際に、その持続長に比べてモーラ持続長が長くなると、聞き手は局所的伸長(話速低下)を知覚する。このとき、それまで話者が保っていたモーラ持続長が基準となり、次に発されたモーラがその長さを越えたため局所的伸長を知覚する。また、持続長が長いモーラが続く箇所では、聞き手はその遅さに慣れていき、判断の基準値が上がるため、その直後では伸長の判断は鈍感になる。このように、聞き手の伸長知覚の閾値は現在のモーラ以前のモーラの持続長によって、動的に変化すると仮定し、モーラ持続長の局所的伸長箇所を捉えるために可変閾値(以下VTと記す)を導入する。

2.2　可変閾値VTを表す関数

モーラ持続長がその時点でのVTに比べて短いとき、そのモーラ持続長を知覚の基準とするために、VTはそのモーラ持続長に近づくように減少する。一方、モーラ持続長がその時点でのVTに比べて長いとき、VTは増加する。ただし、聞き手は個々のモーラ持続長を逐一知覚して、その閾値を1モーラごとに大きく変化させることは困難であると考えられるため、VTは緩やかに変化する必要がある。VTが緩やかにモーラ持続長変化に追従して変化することにより、話者の意図的制御に起因しないモーラに含まれる音素の特徴によるモーラ持続長の変化を検出することは抑制されると考えられる。VTのふるまいを表現する式を以下に示す。AMD^nは発話中のn番目のモーラの持続長にMDAF[2]を適用した値(AMD)を表し、V^n_{init} はn番目のモーラ始端でのVTの値(n-1番目のモーラ終端でのVTの値に等しい)である。

$AMD^n > V^n_{init}$ のとき:

$$V_{temp}(t) = V^n_{init} + A_u\left\{1-\exp\left(-\frac{t}{\tau}\right)\right\}$$

$$V^n(t) = \begin{cases} V_{temp}(t) & (V_{temp}(t) < AMD^n) \quad (1a) \\ AMD^n & (V_{temp}(t) \geq AMD^n) \quad (1b) \end{cases}$$

$AMD^n \leq V^n_{init}$ のとき:

$$V^n(t) = V^n_{init} + A_d\left(AMD^n - V^n_{init}\right)\left\{1-\exp\left(-\frac{t}{\tau}\right)\right\} \quad (2)$$

A_uはVTの上昇の大きさを決定する係数である。A_dはVTの下降の度合いを決める係数であり、$0 < A_d \leqq 1$とする。τは変化の緩やかさを決める係数である。

3　VTの自由会話音声への適用

3.1　パラメータの設定

VTにはA_u、A_d、τ および V^1_{init} の4つのパラメータを設定する必要がある。V^1_{init} は1番目のモーラ始端、すなわち発話開始時のVTの初期値である。初期値 V^1_{init} の違いは発話の前半部分での伸長箇所検出に影響を与えるが、VTは発話中の各モーラでその持続長に近づくように変化するため、発話の中盤から後半での伸長箇所検出に与える影響は少ないと考えられる。本稿では V^1_{init} =100[msec]に設定する。VTの変化の緩やかさを表すパラメータ τ は[2]に従い、以下のように設定する。

$$\tau = \begin{cases} 400 & \text{first time that } V^n_{init} > AMD^n \\ 200 & \text{otherwise} \end{cases}$$

A_uとA_dはそれぞれVTの上昇、下降の量を決めるパラメータである。A_uとA_dの大きさは聞き手の話速変化への注意の度合いによって変化すると仮定し、本稿では、表1に示す3種類の設定を考える。param.1は[2]に従った設定である。この設定により、VTは $AMD^n > V^n_{init}$ のとき、1単語程度の長さ(400～500[msec])で、人間の単語単位での持続長伸長の閾値[3]である26[msec]程度上昇し、$AMD^n \leq V^n_{init}$ のとき、VTはAMDに近づくように下降する。param.2はA_uを大きくすることにより、伸長箇所でVTが大きく上昇し、A_dを小さくすることにより、VTが下降しにくくなる。VTによって検出される箇所は、大きく局所的に伸長している箇所のみとなり、聞き手が話速変化に注意を払っておらず、大きく局所的に伸長された箇所のみを知覚する状態を表現した設定と言える。param.3はA_uを小さくすることにより、AMDが大きいモーラでもVTは大きく上昇しない。また、AMDが小さいモーラではそのAMDを知覚の基準にするべく、VTは下降する。従ってこの設定は、聞き手が局所的伸長に注意を払い、AMDの変化を逐一知覚しようとしている状況を表現しているといえる。

表1: パラメータの設定

	A_u	A_d
param.1	26	1.0
param.2	75	0.3
param.3	13	1.0

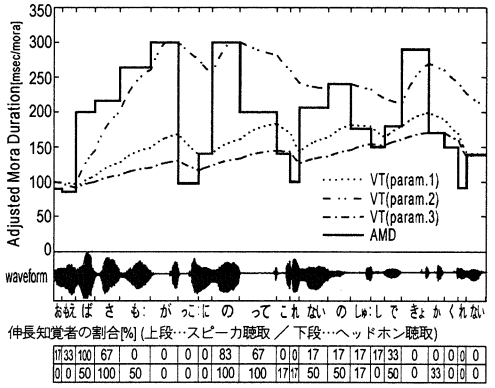
* "A Study on Parameters of a Variable Threshold to Detect Local Speech Rate Decelerations in Spontaneous Conversational Speech", by Keiichi TAKAMARU, Makoto HIROSHIGE, Kenji ARAKI and Koji TOCHINAI (Graduate School of Engineering, Hokkaido University)

3.2 自由会話音声への適用

3.1節で設定した3種類のパラメータを用いたVTを10文の自由会話音声試料に適用した。その一例を図1に示す。param.2でのVTは大きく伸長した箇所のみを検出し、param.1、param.3の順に検出箇所が多くなり、かつ各検出箇所でのAMDがVTを越える部分の面積が大きくなっていることが分かる。各モーラにおけるAMDがVTを越えた部分の面積値は聞き手が知覚する伸長の度合いに対応すると考えられる。

4 聴取実験

聞き手が知覚する局所的伸長箇所を確認するために、3.2節で用いた10文について3種類の聴取実験を行った。被験者は男子大学生6名である。実験1では、被験者に「くつろいだ状況」で音声を聞くように教示した上で、各音声を1回ずつスピーカから提示し、局所所的伸長箇所を指摘させた。実験2、3では、ヘッドホンから音声を聴取させ、文節末の伸長の有無と文節末以外での局所的話速低下箇所をそれぞれ精細に聴取させた。実験2、3では被験者自身の操作により、何度でも聞き直すことを許可した。図1の下部にスピーカ聴取(実験1)、ヘッドホン聴取(実験2、3)それぞれの伸長を知覚した被験者の割合を示す。「おもえばさ」の後半「ばさ」の部分や、「のって」「ないの」などを伸長箇所として知覚した被験者の比率が高いことが分かる。聞き手が伸長を知覚する箇所が一致していれば、伸長知覚者の割合は0[%]に近い値と100[%]に分かれると考えられるが、本実験では、伸長を知覚する箇所が被験者間で一致していない場合が多く観察された。また、スピーカ聴取の結果に比べ、ヘッドホン聴取の結果の方が局所的話速低下を指摘された箇所は多かった。しかしながら、本実験の範囲内では、スピーカ聴取とヘッドホン聴取の結果に大きな違いは見ら



17	33	100	67	0	0	0	0	83	67	0	0	17	17	17	17	33	0	0	0	0
0	0	50	100	50	0	0	0	100	100	17	17	50	50	17	0	50	0	33	0	0

図1: 自由会話音声へのVTの適用例

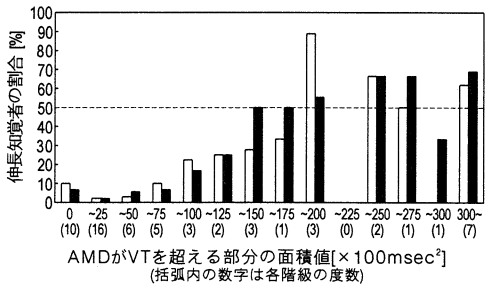


図2: AMDがVTを越える面積別の伸長知覚者の割合

表2: 伸長知覚者の割合Nが50%を越える面積S

(単位: msec²)

	スピーカ聴取	ヘッドホン聴取
param.1	8,000	7,000
param.2	3,000	1,000
param.3	11,000	11,000

れなかった。これは「局所的話速低下箇所を聴取」することが教示されているため、どちらの場合も被験者の話速変化への注意の度合いが強かったためと考えられる。

5 検出箇所と聞き手の知覚との比較

発話中で話者の意図的な伸長制御は意味内容を保持し得る区間に対して行われると考えられる。多くの被験者が一致して伸長を知覚している箇所において、AMDがVTを越える部分の面積値が大きいことが望ましい。そこで、文節相当の区間(以下「文節」と呼ぶ)をひとまとまりとして、文節末モーラを除いた文節内でAMDがVTを越える部分の面積の和Sと、文節内に1箇所でも話速低下箇所があると知覚した被験者の割合Nを比較する。図2にparam.1を用いた場合の試料中の全文節のSを2500[msec²]ごとに分類したNの平均値を示す。Sが小さい箇所では伸長を知覚する被験者数は少なく、Sが増加するとともに、Nは右上がりに増加し、50[%]を越える値となることが分かる。他のパラメータにおいても、同様の傾向が確認された。

この結果より、Sがある値以上の箇所が、聞き手が一致して局所的話速低下と知覚する箇所である可能性がある。そこで1000[msec²]刻みで、Sがその値以上である文節のNの平均値を調査した。Sがその値以上であるNの平均値が50[%]を越える最小の値(以下$S_{N_ave\geqq50}$と記す)を表2に示す。param.1およびparam.3では$S_{N_ave\geqq50}$は7000～11000[msec²]であった。これはparam.1を用いた$S_{N_ave\geqq50}$が10000[msec²]付近であった先行報告[2]と一致する結果である。これらのパラメータによる検出でSが正の値をとるにもかかわらず、Nの平均値が50[%]以下であった箇所は、人間による聴取においても、聞き手の話速変化への注意の程度等の要因によって局所的話速低下箇所であるか否かの判断が分かれる箇所であると考えられる。param.2では、$S_{N_ave\geqq50}$は1000～3000[msec²]であった。param.2は多くの人が一致して話速低下を知覚すると考えられる大きな変化箇所を捉えるように設定したパラメータであり、妥当な結果が得られたといえる。

6 まとめ

本稿では、局所的話速低下箇所を検出する閾値VTのパラメータに関する検討を行った。VTのパラメータを3種類設定し、10文の音声試料に適用した。聴取実験を行い聞き手が知覚する局所的話速低下箇所を確認した。AMDがVTを越える部分の面積値と聞き手が局所的話速低下を知覚する箇所との関係を確認し、設定した各パラメータが、目的どおりの適切な検出を行うことができることを確認した。より多くの自由会話音声に対してVTを適用し、パラメータを調整するとともに、検出される局所的話速低下箇所の妥当性を確認する必要がある。

参考文献

[1] K.Takamaru *et.al.*: "A Proposal of the Model to Extract Japanese Voluntary Speech Rate Control", Proc. ICSLP2000, Vol.III pp.654-657 (2000-10)

[2] 高丸他: "発話速度概形近似モデルにおける話速変化近似関数の検討", 音講論,3-Q-6,pp.353-354 (2001-3)

[3] M.Hiroshige *et.al.*: "On Perception of Word-based Local Speech Rate in Japanese without Focusing Attention",Proc.ICSLP2000, Vol.III pp.255-258 (2000-10)