1—P—16

音声対話データベースからの局所発話速度変化箇所の予備抽出*

◎松村 真言　広重 真人　荒木 健治　栃内 香次 (北大・工)

1　はじめに

自由会話音声において、話者が意図的に発話速度を大きく変化させている箇所は少ないが、それゆえに強い表現手段の一つであると考えられる。よって筆者らはこの意図的話速変化のモデル化と自動抽出について検討している [1]。話速研究には話速変化を豊富に含む音声サンプルが多数必要であるが、大きな話速変化箇所を豊富に含む箇所は少なく、従来のように人間の聴取によって、会話音声の膨大な録音の中からこれらのサンプルを抽出することは非常に労力がかかる。そこで、本研究では一般的に入手可能な HMM 音声認識ツールを利用し、あらかじめ書き起こしテキストを与えて「強制割付 (forced alignment)」により音素 HMM の境界のみを割り付けることにより、比較的少ない労力で予備的に仮の音素境界のみを算出して、大きな話速変化を含む可能性のある箇所を予備抽出することを試みる。このようにして予備抽出された音声データは事後にさらに目視を含む詳細な手法で再度話速分析することにより、話速研究のサンプルデータとして活用する。

先の報告 [2] では、音素境界推定の精度評価実験および当研究室で録音した自由会話音声に対しての話速算出実験を行った。本稿では、局所的発話速度変化箇所を多く含むサンプルを実際に数多く収集するため、音声対話データベース中の音声に対して発話速度の予備抽出を行ない、求められた仮の発話速度より大きな話速変化が含まれていると考えられる箇所を推定する。

HMM 音声認識ツールおよび学習済 HMM パラメータセットとして、前稿 [2] と同じく HTK および名古屋大学板倉研究室より配布されているパラメータセット [3] を用いた。また、本稿では新たに RWCP 音声対話データベースの対話音声に対して話速の仮推定を行い、さらに話速の知覚を考慮した可変閾値 [4] を用いて発話速度の変化箇所抽出を行なう。

*A preliminary calculation of speech rate variation from spoken dialogue corpus. By Makoto Matsumura, Makoto Hiroshige, Kenji Araki and Koji Tochinai (Graduate School of Engineering,Hokkaido University)

2　データベース音声における音素境界推定

データベース中の対話音声に対して、HTK と学習済 HMM パラメータセット、およびデータベースに収録された書き起こしテキストを用いておおまかな音素境界を定める。今回実験に用いた音声は、顧客が海外旅行を計画し、旅行代理店のカウンターに来店している状況を想定した男性 2 話者の対話音声で、業者側の話者は旅行代理店に勤務している者である。音声の収録は主にスタンドマイク 2 台を用いて行なわれたため相手話者の音声の重畳などがあり、またパンフレットをめくる音などの雑音も含まれている [5]。

データベース中で定義されている「発声単位」を 1 サンプルとして、音素境界推定・話速算出を行なう。書き起こしテキストは対話音声データベース中の「ローマ字記述」を用い、「,」で記述されている言語的および音響的区切りには、HMM において「sp」(ショートポーズ) モデルを充てた。開始時刻および終了時刻が 10msec 単位で与えられているため、文頭部および文末部の無音区間はないものとして、silent モデルは充てないこととした。以上の条件のもと、連続した約 7 分の対話音声データに対して音素の強制割付を行なった。ここで、サンプル数は 2 話者合計 390 の発声単位、サンプルあたりの平均モーラ数は約 7.2 モーラであった。

3　話速変化箇所の推定

3.1　話速変化箇所の推定

音素の強制割付を行なったサンプルに対して、音素をモーラにまとめてモーラ単位での話速を求め、話速変化の大きな箇所があるかを推定する。推定に際し、話速の知覚を考慮した可変閾値 [4] を導入する。この可変閾値は聞き手の注意レベルに相当し、持続長の長いモーラが連続したときにはその遅さに慣れていき、遅い箇所の直後では伸長の判断に鈍感になる話者の知覚の性質を仮定している。モーラ持続長がこの動的閾値を大きく超えた場合に、局所的伸長として知覚されると考える。どの程度閾値を超えているかをモーラ持続長曲線と可変閾値曲線とで囲まれる領域の面積（以下「閾値超過面積」と記

表 1: 全モーラに対する閾値超過面積毎の度数分布

総モーラ数（全 390 サンプル中）	2813
面積 100000($msec^2$) 以上	105
面積 100000～50000($msec^2$)	108
面積 50000～20000($msec^2$)	204
面積 20000～10000($msec^2$)	159
面積 10000～2500($msec^2$)	363
面積 2500～1($msec^2$)	415
面積 0	1459

表 2: サンプルのスコア毎の分布

10 モーラ以上の総サンプル数	102
スコア 50000($msec^2$) 以上	32
スコア 20000～50000($msec^2$)	30
スコア 5000～20000($msec^2$)	28
スコア 5000 未満 ($msec^2$)	12

す）で表し、この面積が大きい箇所に知覚可能な局所的伸長が含まれているものとみなす。また、話者の意図的話速コントロールは主に伸長に含まれるとする本研究の立場から、短縮しているモーラ、すなわちモーラ持続長が注意レベルよりも下回るモーラに関しては検出対象外として閾値超過面積は 0 とした。すべてのモーラについて閾値超過面積を算出し、面積ごとに当該するモーラの度数を算出した。度数分布を表 1 に示す。

ここで、全てのサンプルにおいて、閾値超過面積がサンプル内で最大となるモーラの閾値超過面積をそのサンプルのスコアとして出力する。ただし、サンプルの最終モーラは文末に相当すると考えられ、大きなフレーズ末伸長がたびたび観測されたため、閾値超過面積が最大となるモーラがサンプルの最終モーラに相当する場合、閾値超過面積の次点をそのサンプルのスコアとした。また、モーラ数の少ない短すぎるサンプルに関しては、話速変化研究対象として望ましいサンプルである可能性が低いと考えられるため、サンプルのモーラ数が 9 モーラ以下の 288 サンプルを除外し、残りの 102 サンプルに対してスコアを求め、話速変化箇所の推定を行なった。

3.2 結果および考察

スコアごとの当該サンプルの度数分布を表 2 に、モーラ持続長と可変閾値曲線の例を図 1 に示す。このサンプルは、スコア値が約 221,748 のサンプルである。スコアの大きなサンプルの閾値超過面積が最大のモーラを調べたところ、多くは sp の直前のモーラであった。この sp 直前のモーラは、任意に伸長するフレーズ最終モーラに該当するため、必ずしも意図的伸長に該当するとはいえない。よって、

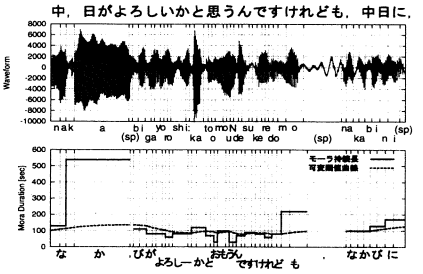


図 1: モーラ持続長と可変閾値曲線の例

フレーズ末モーラを除いた場合でのスコアも求める必要があると考えられる。

また、単一モーラ毎に求めたスコアの値では音素セグメンテーションの誤差の影響を大きく受けるため、フレーズに区切り、各フレーズ内のそれぞれのモーラでのモーラ持続長曲線と可変閾値曲線とで囲まれる領域の面積の総和をもとにフレーズ単位でのスコアを求めることも検討する必要がある。

4 まとめ

本稿では、HMM を用いた発話速度変化の予備抽出手法を、対話音声データベースに対して適用し、粗い音素セグメンテーションを行っておおまかな話速を求め、局所的話速変化が生じていると考えられるサンプルを予備抽出した。この局所話速変化箇所の推定には話者の知覚の性質を考慮した可変閾値を用い、伸長の度合いを閾値超過面積として表した。

今後は、モーラ単位で求めたスコアの妥当性を考慮するとともに、フレーズ単位でのスコアを求め、これらから局所的話速変化を含むサンプルの抽出をさらに検討する予定である。

参考文献

[1] 高丸 圭一, 鈴木 貫太郎, 広重 真人, 栃内 香次, "自由会話音声における局所的話速変化分析のための話速表現の検討", 音講論,2-Q-3,pp.285-286(1999-09)

[2] 松村 真言, 広重 真人, 荒木 健治, 栃内 香次, "HMM を用いた自由会話音声における発話速度変化の予備抽出", 音講論,3-Q-7,pp.355-356(2001-03)

[3] 名古屋大学板倉研究室,『A standard HMM set of Japanese phonemes.』 http://www.itakura.nuee.nagoya-u.ac.jp/

[4] 高丸 圭一, 広重 真人, 荒木 健治, 栃内 香次, "発話速度概形近似モデルにおける話速変化近似関数の検討", 音講論,3-Q-6,pp.353-354(2001-03)

[5] 『RWCP 音声対話データベース』, http://www.rwcp.or.jp/people/toyoura/rwcdb/speech/index.html