118　局所的話速低下を検出する閾値VTのパラメータによる検出箇所の違いについて

高丸 圭一　広重 真人　荒木 健治　栃内 香次
北海道大学大学院工学研究科

1　はじめに

話速の局所的な変化は話者による聞き手の注意を引く表現の一つである。筆者らは種々の要因による変化が重畳されている自由会話音声のモーラ持続長変化の概形から話者が意図的制御と考えられる局所的話速変化箇所を検出する可変閾値VTを先に提案した[1]。本稿では、VTのパラメータについて検討し、検出箇所と聞き手が知覚する局所的話速低下箇所との関係について考察する。

2　局所的話速低下箇所を検出する閾値VT

2.1　概要

本研究では、聞き手によるモーラ持続長の局所的伸長の知覚における閾値の存在を仮定する。持続長が長いモーラが続く箇所では、聞き手はその遅さに慣れていき、判断の基準値が上がるため、その直後では伸長の判断は鈍感になる。このように、聞き手の伸長知覚の閾値は現在のモーラ以前のモーラの持続長によって、動的に変化すると考えられる。聞き手は閾値を1モーラごとに大きく変化させることは困難であると考えられるため、VTは緩やかに変化させることにする。

VTのふるまいを表現する式を以下に示す。AMD^nは発話中のn番目のモーラの持続長にMDAF[1]を適用した値(AMD)を表し、V^n_{init}はn番目のモーラ始端でのVTの値(n-1番目のモーラ終端でのVTの値に等しい)である。

$AMD^n > V^n_{init}$のとき:

$$V_{temp}(t) = V^n_{init} + A_u\left\{1-\exp\left(-\frac{t}{\tau}\right)\right\}$$

$$V^n(t) = \begin{cases} V_{temp}(t) & (V_{temp}(t) < AMD^n) \quad (1a) \\ AMD^n & (V_{temp}(t) \geqq AMD^n) \quad (1b) \end{cases}$$

$AMD^n \leqq V^n_{init}$のとき:

$$V^n(t) = V^n_{init} + A_d\left(AMD^n - V^n_{init}\right)\left\{1-\exp\left(-\frac{t}{\tau}\right)\right\} \quad (2)$$

A_uはVTの上昇の大きさを決定する係数である。A_dはVTの下降の度合いを決める係数であり、$0 < A_d \leqq 1$とする。τは変化の緩やかさを決める係数である。

2.2　パラメータの設定

A_uとA_dの大きさは聞き手の話速変化への注意の度合いによって変化すると仮定し、本稿では、表1に示す3種類の設定を考える。param.1は[1]に従った設定である。この設定により、VTは1単語程度の長さで、人間の単語単位での持続長伸長の閾値[2]である26[msec]程度上昇する。param.2ではA_uを大きくすることにより、伸長箇所でVTが大きく上昇し、A_dを小さくすることにより、VTが下降しにくくなる。VTによって検出される箇所は、大きく局所的に伸長している箇所のみとなり、聞き手が話速変化に注意を払っておらず、大きく局所的に伸長された箇所のみを知覚する状態を表現した設定といえる。param.3はA_uを小さくすることにより、AMDが大きいモーラでもVTは大きく上昇しない。また、AMDが小さいモーラではそのAMDを知覚の基準にするべく、VTは下降する。従ってこの設定は、聞き手が局所的伸長に注意を払い、AMDの変化を逐一知覚しようとしている状況を表現している。VTの変化の緩やかさを表すパラメータτは[1]に従う。

表1: パラメータの設定

	A_u	A_d
param.1	26	1.0
param.2	75	0.3
param.3	13	1.0

3　聴取実験

聞き手が知覚する局所的伸長箇所を確認するために、自由会話音声10文について聴取実験を行った。被験者は男子大学生6名である。図1に各パラメータを用いたVTを自由会話音声に適用した例と、スピーカ聴取、ヘッドホン聴取それぞれで話速低下を知覚した被験者の割合を示す。「おもえばさ」の後半「ばさ」の部分や、「のって」「ないの」などを伸長箇所として知覚した被験者の比率が高いことが分かる。

4　VTによる検出箇所と聞き手の知覚との比較

文節相当の区間(以下「文節」と呼ぶ)をひとまとまりとして、文節末モーラを除いた文節内でAMDがVTを越える部分の面積の和Sと、文節内に1箇所でも話速低下箇所があると知覚した被験者の割合Nについて、1000[msec²]刻みで、Sがその値以上である文節のNの平均値を調査した。Sがその値以上であるNの平均値が50[%]を越える最小の値(以下$S_{N_ave \geqq 50}$と記す)はparam.1およびparam.3では$S_{N_ave \geqq 50}$は7000～11000[msec²]であった。これはparam.1を用いた$S_{N_ave \geqq 50}$が10000[msec²]付近であったとする先行報告[1]と一致する結果である。これらのパラメータによる検出でSが正の値をとるにもかかわらず、Nの平均値が50[%]以下であった箇所は、人間による聴取においても、聞き手の話速変化への注意の程度等の要因によって局所的話速低下箇所であるか否かの判断が分かれる箇所であると考えられる。param.2では、$S_{N_ave \geqq 50}$は1000～3000[msec²]であった。param.2は多くの人が一致して話速低下を知覚すると考えられる大きな変化箇所を捉えるように設定したパラメータであり、妥当な結果が得られたといえる。

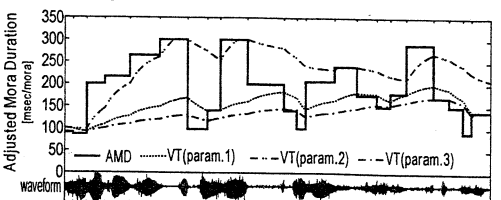
5　むすび

VTのパラメータを3種類設定し自由会話音声試料に適用した。AMDがVTを越える部分の面積値と聞き手が局所的話速低下を知覚する箇所との関係を確認し、設定した各パラメータが、目的どおりの適切な検出を行うことができることを確認した。より多くの自由会話音声に対してVTを適用し、パラメータを調整するとともに、検出される局所的話速低下箇所の妥当性を確認する必要がある。

参考文献

[1] Takamaru *et al.*: "Detecting Japanese Local Speech Rate Deceleration in Spontaneous Conversational Speech", Proc. Eurospeech 2001, Vol.2, pp.935-938 (2001-9)

[2] Hiroshige *et.al.*: "On Perception of Word-based Local Speech Rate in Japanese without Focusing Attention",Proc.ICSLP2000, Vol.III pp.255-258 (2000-10)



伸長知覚者の割合[%] (上段…スピーカ聴取 ／ 下段…ヘッドホン聴取)

17	33	100	67	0	0	0	0	83	67	0	0	17	17	17	33	0	0	0	0
0	0	50	100	50	0	0	0	100	100	17	17	50	50	17	0	0	33	0	0

図1 各パラメータによるVTの適用例